MBA EM

DATA SCIENCE

Árvores, Redes e Ensemble Models II – III

Prof.ª Dra. Valquíria Alencar

Natan Manoel Mendonça 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonça 334.876.988-50

MBA USP ESALQ

Agenda

01. **Conceitos Fundamentais**
O que são modelos de ensemble e por que combinar modelos?

02. **Técnicas de Ensemble**
Voting, averaging, bagging, boosting e stacking

03. **Random Forest**
Algoritmo para redução de variância

04. **Aplicação Prática**
Treinamento de modelo com Random Forest

05. **XGBoost**
Biblioteca para treinar ensembles de árvores com foco em performance

06. **Aplicação Prática**
Treinamento de modelo com XGBoost

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

01

Por que combinar modelos?

Do modelo único ao poder do ensemble

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O QUE DISCUTIMOS NA AULA ANTERIOR

Limitações de uma árvore individual

Overfitting

A árvore pode crescer demais e começar a **"decorar" os dados de treinamento**, em vez de aprender padrões gerais.

Sensibilidade a pequenas mudanças

Pequenas **alterações** no conjunto de treinamento podem gerar uma **árvore completamente diferente**.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

DE ONDE VÊM OS ERROS DE UM MODELO?

Trade-off viés-variância



Alto viés = previsões consistentes, mas fora do alvo

Alta variância = previsões espalhadas e inconsistentes

- **Modelos de alto viés** normalmente são muito **simplistas para capturar os padrões** verdadeiros dos dados. Eles ajustam mal o conjunto de treinamento, levando a uma baixa precisão de treinamento e teste.

- **Modelos de alta variância** são **excessivamente flexíveis** e se ajustam muito de perto aos dados de treinamento, incluindo o ruído. Eles **ajustam demais o conjunto de treinamento** e não conseguem generalizar para dados não vistos, levando ao overfitting e a **previsões com variabilidade** alta.

Natan Manoel Mendonca 394.876.668-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

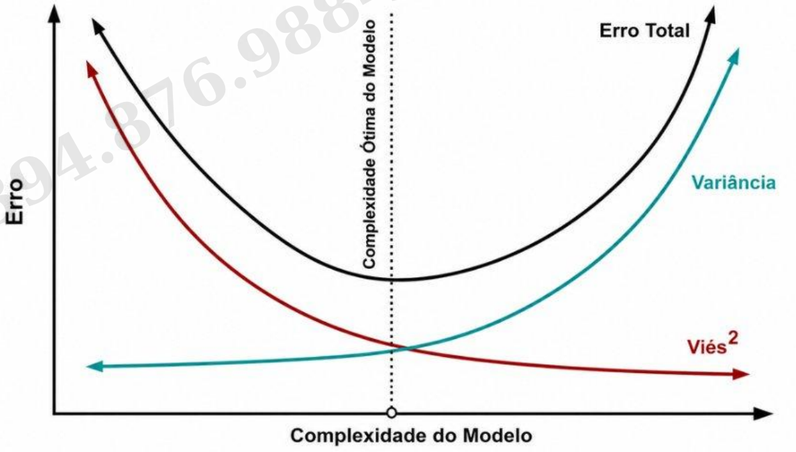
O QUE BUSCAMOS

Um equilíbrio entre viés e variância

Reduzir o viés tende a **aumentar a variância** — e vice-versa. Não dá para zerar os dois.

Buscamos o ponto de **equilíbrio** : nem simples demais, nem flexível demais.

Os ensembles nos ajudam a chegar **mais perto desse equilíbrio** do que um modelo isolado.



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como podemos melhorar isso?

Natan Manoel Mendonça 359.976.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Imagine que você precisa tomar uma decisão difícil. Em vez de pedir a opinião de uma só pessoa, você consulta várias. A decisão final é a **opinião da maioria**.

Esse é o princípio do ensemble: **combinar vários modelos fracos para criar um modelo forte.**

Natan Manoel Mendonca 394.870.088-50

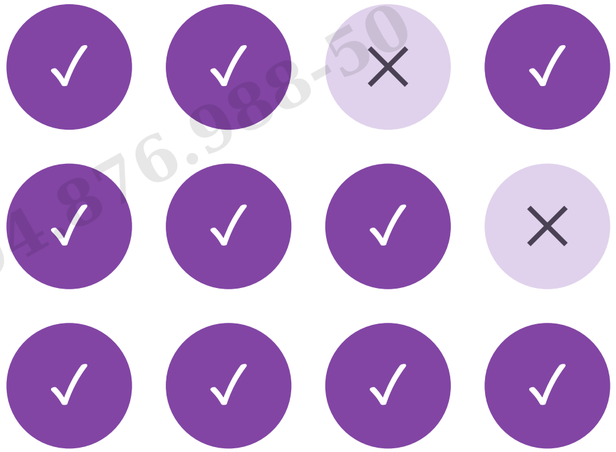
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

ANALOGIA

O júri

Um único jurado pode ter vieses ou cometer erros.

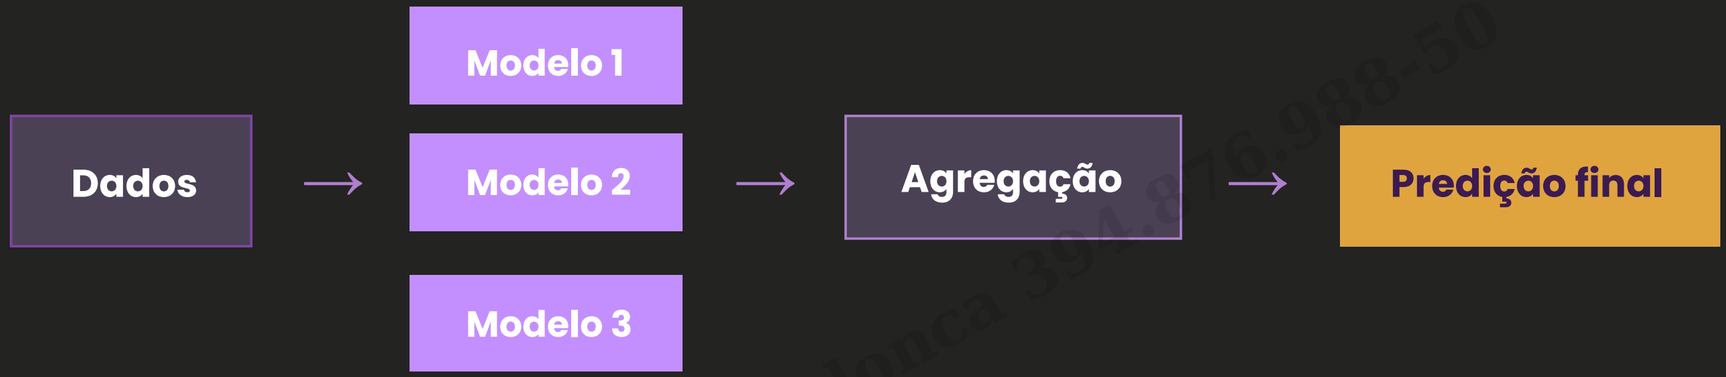
Quando 12 jurados votam, os erros individuais tendem a diminuir. O veredito coletivo é **mais confiável** do que a opinião de qualquer pessoa sozinha.



Veredito: 10 × 2

Natan Manoel Mendonca 394.376.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Combinar múltiplos modelos para obter uma predição mais **robusta** e **precisa**

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

DEFINIÇÃO

O que é ensemble?

Ensemble treina **múltiplos modelos** e **combina suas predições** em uma única saída.

Modelos diferentes erram em pontos diferentes — ao fazer a média ou votação entre vários modelos, **os erros individuais tendem a se cancelar**.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

02

Técnicas de ensemble

Explorando voting/averaging, bagging, boosting e stacking

Natan Manoel Mendonça:394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Estratégias de ensemble learning

Voting / Averaging

É a forma mais simples de ensemble. Vários modelos são treinados de forma **independente** e suas previsões são combinadas. Em classificação, usa-se a **votação** ; em regressão, a **média** das previsões.

Bagging

Treina vários modelos do **mesmo tipo** usando **diferentes amostras** do conjunto de treinamento. A combinação das previsões **reduz a variabilidade** e melhora a generalização.

Boosting

Treina modelos de forma **sequencial** , em que cada novo modelo busca **corrigir os erros** dos anteriores. Essa estratégia aumenta gradualmente o desempenho do modelo final.

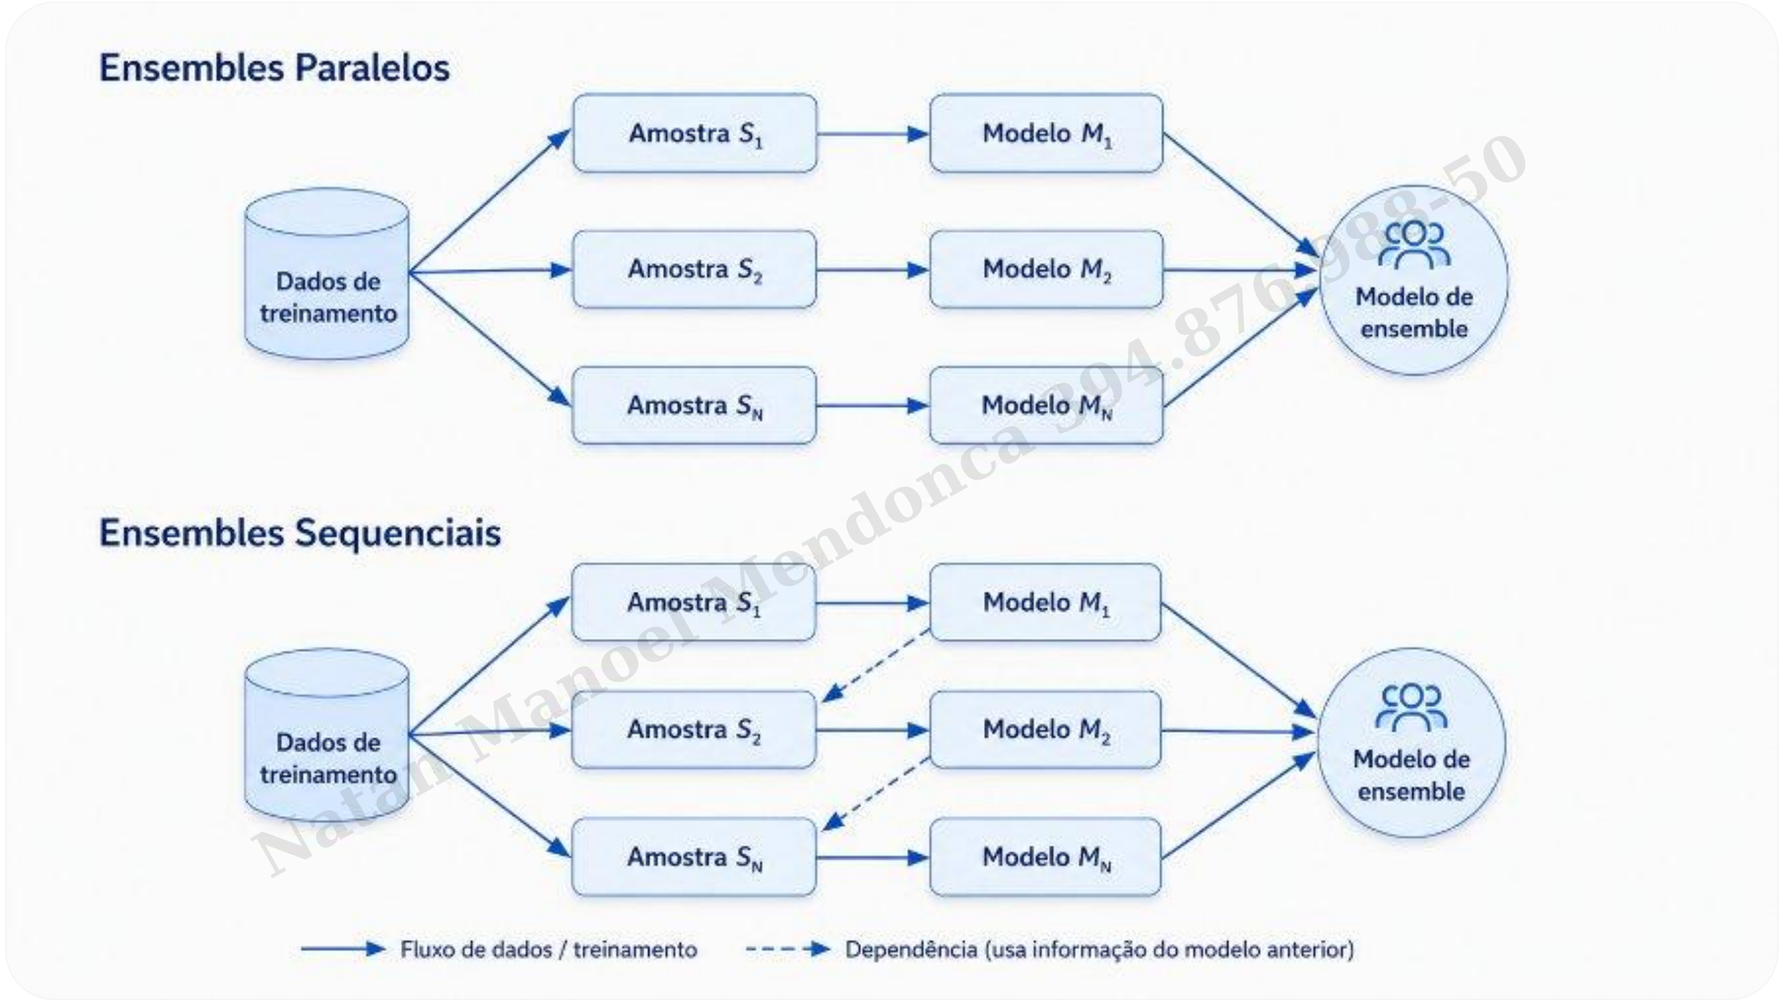
Stacking

Combina diferentes modelos usando um **meta-modelo** , que aprende a melhor forma de **integrar as previsões** dos modelos base para obter uma resposta final mais precisa.

Natan Manoel Mendonca 395.527.288-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tipos de ensembles



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

03

Voting e averaging

A forma mais simples de combinar modelos

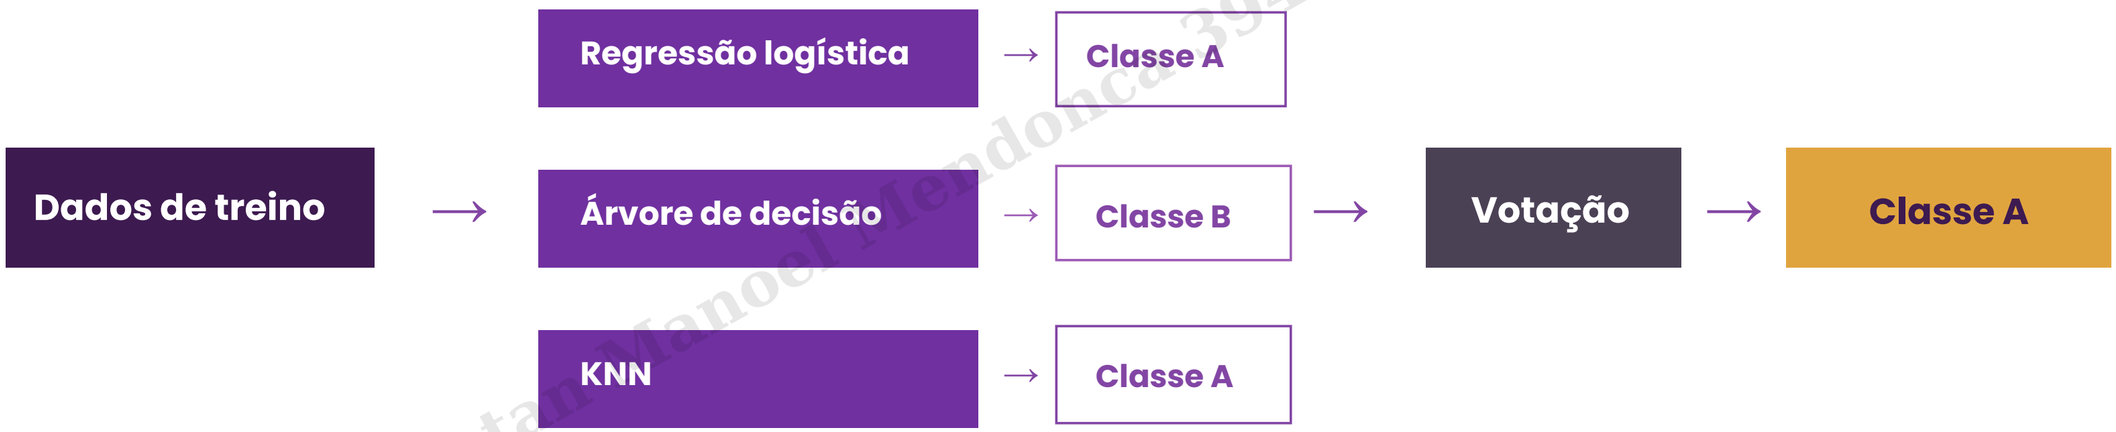
Natan Manoel Menegatica 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

CLASSIFICAÇÃO · VOTAÇÃO

Do voto individual à decisão final

Cada modelo vota em uma **classe** — a mais votada vence.



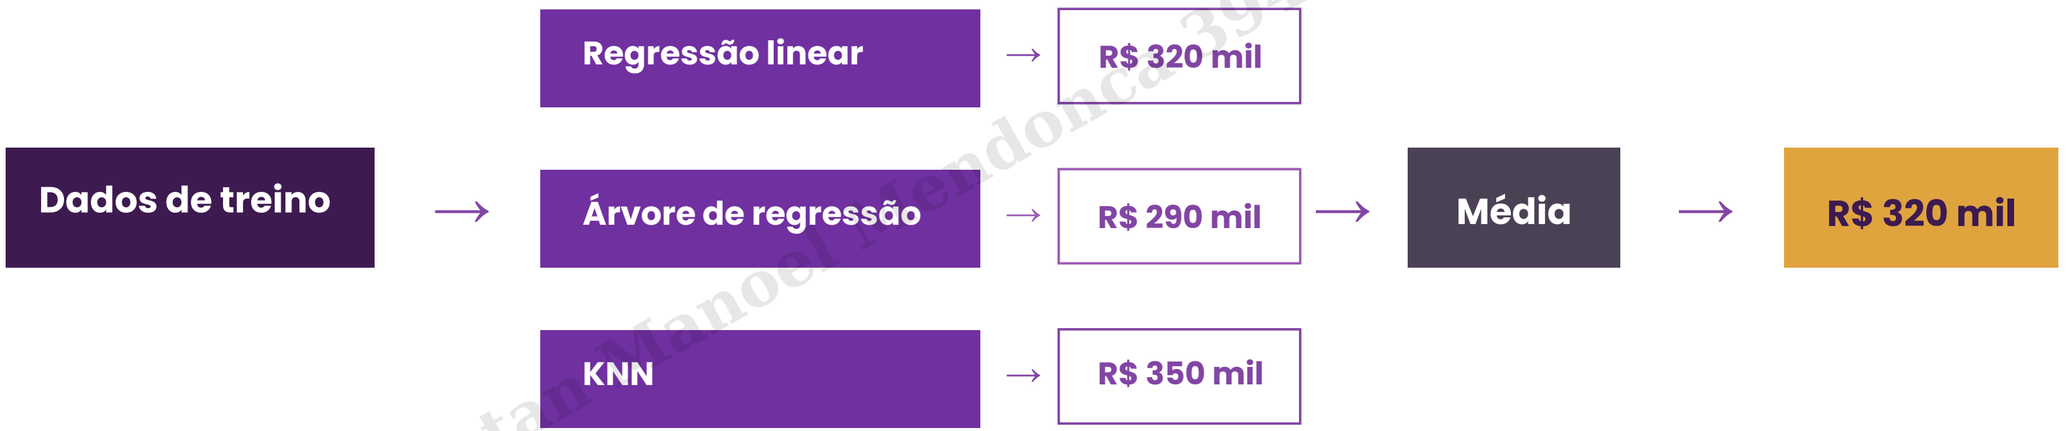
Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

REGRESSÃO · MÉDIA

Da previsão individual à média final

Cada modelo prevê um **número** — a saída é a média das previsões.



Natan Manoel Fendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Hard voting, soft voting e averaging

CLASSIFICAÇÃO

Hard voting

Cada modelo vota em uma classe; a mais votada vence.

Modelo A: Doença
Modelo B: Saudável
Modelo C: Doença
Resultado: Doença (2×1)

CLASSIFICAÇÃO

Soft voting

Faz a média das **probabilidades** de cada modelo. Mais preciso quando os modelos são bem calibrados.

P(Doença): 0,9 · 0,4 · 0,7
Média: 0,67 → Doença

REGRESSÃO

Averaging

A previsão final é a das previsões numéricas.

Modelo A: R$ 320 mil
Modelo B: R$ 290 mil
Modelo C: R$ 350 mil
Média: R$ 320 mil

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

04

Bagging

Reduzindo variância com amostragem

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Bagging: Bootstrap Aggregating

1

Bootstrap

Cria N amostras aleatórias **com reposição** a partir dos dados originais.

→

2

Treinar

Treina um modelo **independente** em cada amostra bootstrap — em paralelo.

→

3

Agregar

Combina previsões por **votação** (classificação) ou **média** (regressão).

Nadia Manoel Mendonca 394.876.988-50

O que é bootstrap? Amostragem **com reposição**: cada amostra tem o mesmo tamanho dos dados originais, mas ~63% dos registros são únicos e o restante se repete — gerando diversidade entre os modelos.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO A PASSO · 1 DE 2

Amostragem com reposição



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO A PASSO · 2 DE 2

Dentro e fora da amostra: o conceito OOB



entram na amostra bootstrap **treinam o modelo**

ficam de fora **out-of-bag (OOB)**

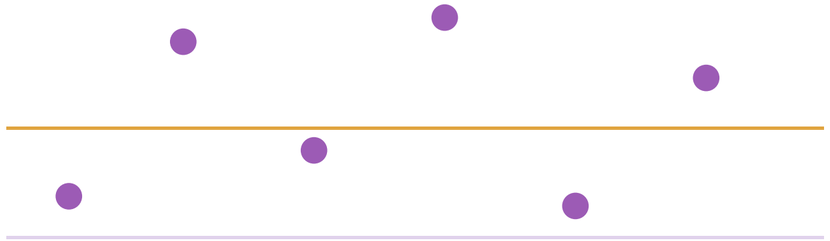
Validação gratuita

As amostras OOB nunca foram vistas pelo modelo — servem como **conjunto de teste embutido**, sem separar dados de validação.

Natan Manoel Mendonca 394.876.988-50

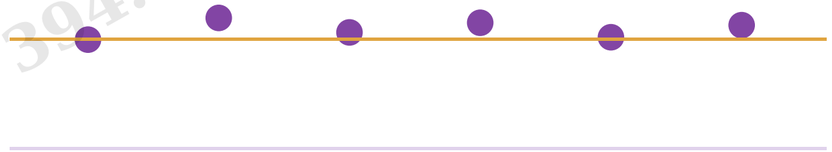
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Agregação reduz variância



Árvores individuais

Previsões espalhadas em torno do valor real



Média do ensemble

Desvios se compensam — previsão estável

Natan Manoel Mendonca 394.876.988-50

O bagging mantém o viés de cada modelo, mas **reduz drasticamente a variância** do conjunto.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

05

Boosting

Aprendizado sequencial e correção de erros

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO A PASSO · 1 DE 2

Um modelo simples e seus erros

Modelo 1

árvore rasa (weak learner)



acertos e **erros** nos dados de treino

Os erros ganham **mais peso** e viram a prioridade do próximo modelo.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PASSO A PASSO · 2 DE 2

Cada modelo corrige o anterior

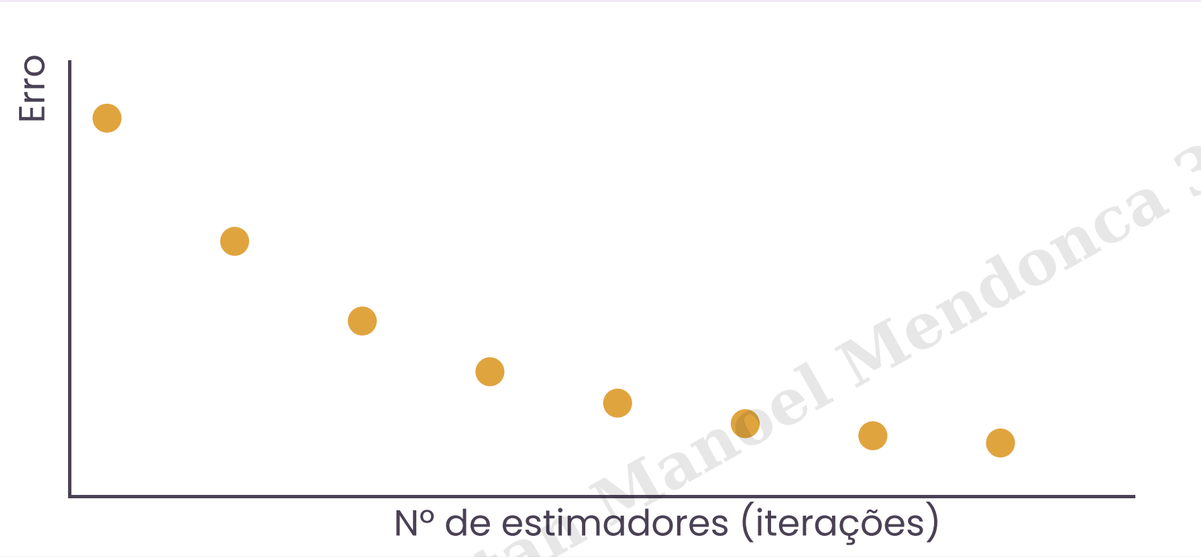


A previsão final é a **soma ponderada** de todos os modelos da sequência.

Nadan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como o erro vai diminuindo?



Queda rápida no início

Cada estimador ataca o resíduo do anterior — sobra cada vez menos para corrigir.

Depois, estabiliza

Com muitos estimadores, o ganho diminui — e o modelo pode passar a decorar ruído.

Freios do boosting

Learning rate e **early stopping** param o processo no ponto certo.

Natan Manoel Mendonca 394.876.088-50

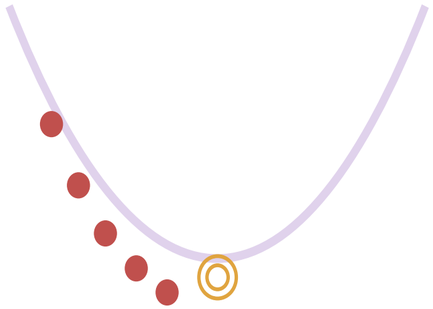
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Learning rate: descendo a duna até o vale

De olhos vendados na duna, você sente a inclinação do chão — o **gradiente** dá a **direção** do passo; o **learning rate** dá o **tamanho** do passo. No boosting, **cada passo é uma nova árvore** — o learning rate controla o quanto ela contribui.

Nós enxergamos o vale todo; quem desce sente apenas a inclinação sob os pés.

Passos minúsculos



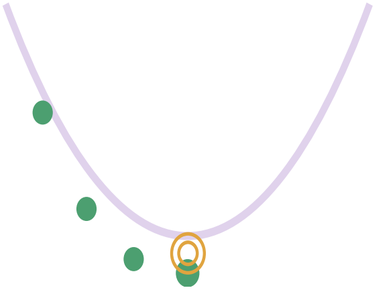
Seguro, mas **leva mais tempo** para chegar ao ponto mais baixo — **aprendizado lento e caro**.

Passos gigantescos



Atravessa o fundo e para do outro lado — fica **oscilando** de um lado para o outro, sem descansar no ponto mais baixo.

Passos equilibrados



Desce com boa velocidade e **chega ao ponto mais baixo** sem ultrapassá-lo. É o que buscamos.

Repare nos passos minúsculos: perto do topo o gradiente é grande e você anda bastante; perto do fundo o terreno fica plano, o gradiente diminui e os passos **encurtam sozinhos**. O tamanho real da passada = **learning rate** (fixo) × **inclinação** naquele ponto.

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Três gerações de boosting

AdaBoost 1995	Repondera as observações: **erros ganham mais peso** na próxima rodada.
Gradient Boosting 2001	Cada novo modelo ajusta diretamente o **resíduo** (gradiente da função de perda).
XGBoost 2014	Gradient boosting **otimizado**: regularização + engenharia de alto desempenho.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

06

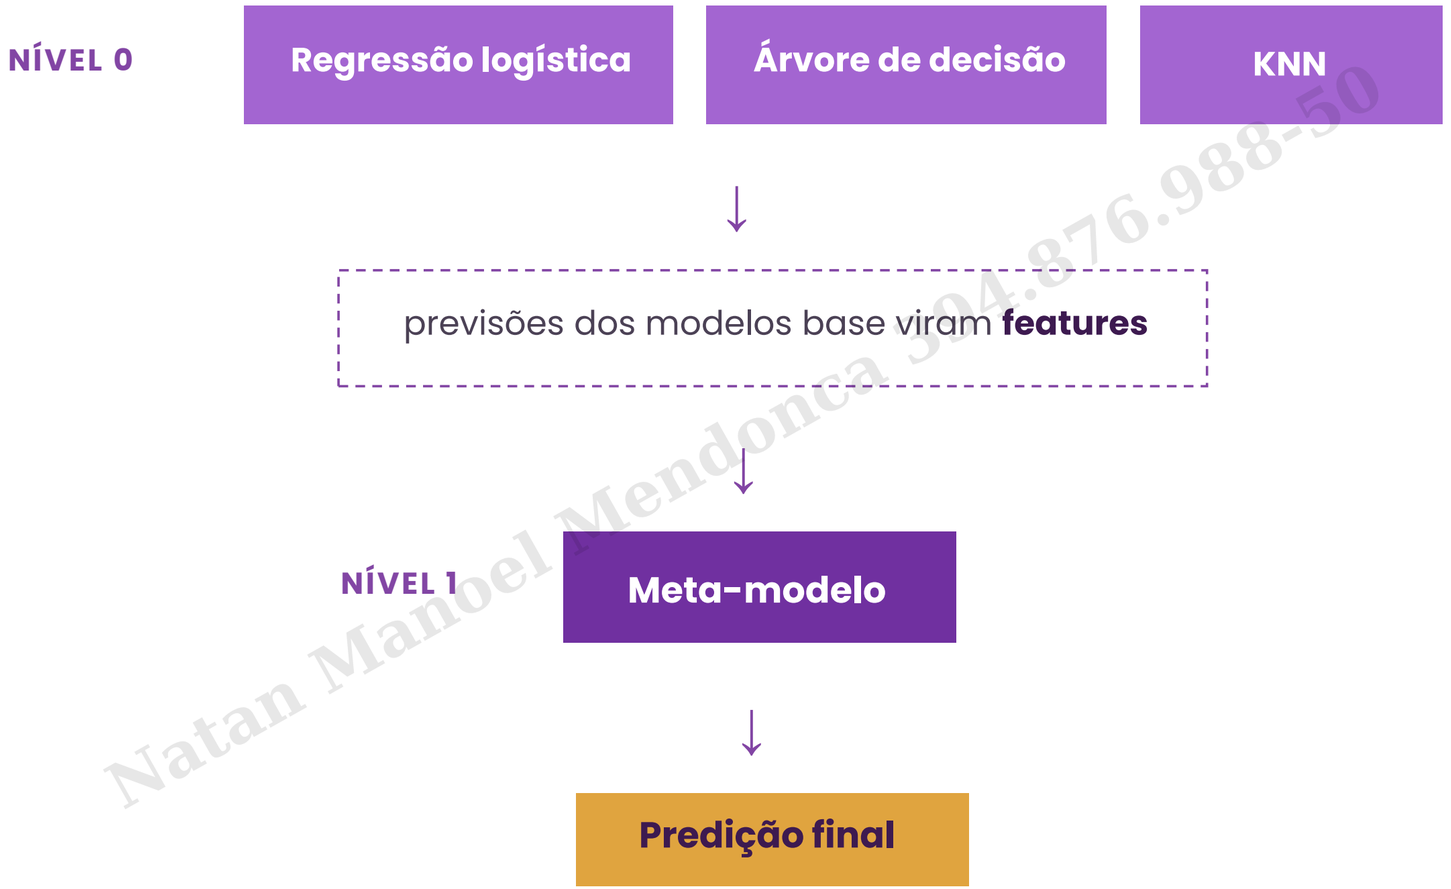
Stacking

Meta-aprendizado: modelos que aprendem a combinar modelos

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Dois níveis de modelos



Natan Manoel Mendonca 304.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Meta-modelo sem vazamento de dados

O risco

Se o meta-modelo treina com previsões feitas **sobre os dados de treino dos modelos base** , recebe previsões otimistas demais.

Vazamento de dados → ensemble superestimado

A solução: out-of-fold

Validação cruzada: cada previsão que alimenta o meta-modelo vem de um **fold que o modelo base não viu** no treino.



Natan Manoel Mendonca 394.876.088-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

07

Random Forest

Conhecendo o algoritmo

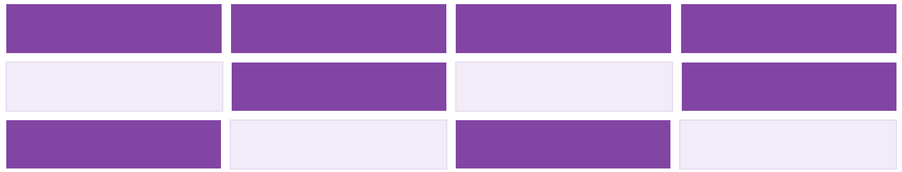
Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A dupla aleatoriedade do Random Forest

1 · LINHAS

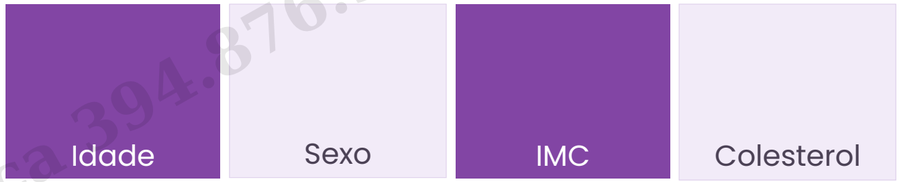
Bootstrap de observações



Cada árvore treina em uma **amostra bootstrap** diferente das linhas.

2 · COLUNAS

Subconjunto de variáveis por split



Em cada divisão, só um **subconjunto aleatório de features** é candidato ao split.

Natan Manoel Mendonca 394.876.988-50

Duas camadas de aleatoriedade → árvores **descorrelacionadas** → ensemble mais eficaz.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Bagging tradicional × Random Forest

Bagging tradicional

- Bootstrap apenas das **linhas**
- Cada split considera **todas as variáveis**
- Variáveis fortes dominam → árvores **correlacionadas**

Random Forest

- Bootstrap das linhas **+ sorteio de variáveis por split**
- Árvores exploram **caminhos diferentes**
- Árvores **descorrelacionadas** → maior redução de variância

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

BAGGING + ALEATORIEDADE NA SELEÇÃO DE VARIÁVEIS

Como funciona o Random Forest

1. Cria N amostras **bootstrap** dos dados
2. Em cada divisão, considera apenas um **subconjunto aleatório de variáveis**
3. Treina uma **árvore completa** (profunda) em cada amostra
4. **Agrega** as previsões de todas as árvores

Inovação-chave

O sorteio de variáveis em cada divisão **descorrelaciona as árvores**.

Árvores mais diversas produzem um ensemble mais eficaz na **redução de variância**.

Natan Manoel Mendonca 304.876.088-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

AJUSTE DE HIPERPARÂMETROS

Hiperparâmetros do Random Forest

`n_estimators`

Define o **número de árvores** que formarão a floresta. Mais árvores geralmente deixam a previsão mais estável, mas aumentam o tempo de treinamento e gasto computacional.

`max_features`

Define **quantas variáveis** serão consideradas como candidatas em **cada divisão da árvore** . Valores muito altos tornam as árvores mais parecidas; valores menores aumentam a variedade do conjunto.

`max_depth`

Define o **número máximo de níveis** de cada árvore. Árvores muito profundas podem memorizar os dados de treinamento. Árvores mais rasas são mais simples, mas podem deixar de capturar padrões importantes.

`min_samples_split`

Define o **número mínimo de observações** que um nó precisa ter para poder ser dividido. Valores maiores dificultam novas divisões e geram árvores mais simples. Valores menores permitem árvores mais detalhadas.

`min_samples_leaf`

Define o **número mínimo de observações** que uma folha final deve conter. Valores maiores produzem previsões mais gerais e estáveis. Valores muito pequenos podem gerar regras específicas demais.

`bootstrap`

Define se cada árvore será treinada com uma amostra aleatória dos dados, selecionada **com reposição** . Quando True , cada árvore recebe uma amostra diferente, aumentando a diversidade da floresta e caracterizando o mecanismo de bagging.

Vinai Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

>>

Da teoria ao código

Será que um ensemble com Random Forest consegue superar o resultado de uma árvore individual?

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

08

XGBoost

Conhecendo a biblioteca eXtreme Gradient Boosting

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A BIBLIOTECA

O que é o XGBoost



Biblioteca **otimizada e distribuída** de gradient boosting — eficiente e flexível.

Trata **valores faltantes** nativamente e **dispensa a dummização** de variáveis categóricas.

Traz **regularização L1 e L2** embutida, controlando a complexidade das árvores e protegendo contra overfitting.

Escala para **grandes volumes de dados** em ambientes distribuídos (Ex: Hadoop).

Natan Manoel Medeiros 294.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A ideia central do XGBoost

Gradient boosting

com árvores como base

+

Regularização L1/L2

árvores sob controle

+

Engenharia

paralelização · cache · sparsity

=

Boosting rápido e regularizado

Natan Manoel Menezes 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Regularização L1/L2

objetivo = **erro nos dados** + **penalidade pela complexidade**

Cada folha tem um **peso (w)**, que indica o quanto ela influencia a previsão final. A **regularização** funciona como um "freio", penalizando pesos muito altos. Assim, o modelo evita previsões exageradas sem evidência suficiente nos dados.

Regularização L1 `reg_alpha`

- Ajuda o modelo a se tornar mais simples ao **penalizar a soma** dos valores absolutos dos **pesos das folhas** das árvores.
- Algumas contribuições podem ser reduzidas até zero, fazendo com que o modelo **ignore padrões fracos, ruidosos ou pouco relevantes** .
- Assim, a L1 funciona como um **mecanismo de seleção e simplificação** , ajudando a **reduzir o overfitting**.

Regularização L2 `reg_lambda`

- **Penaliza pesos muito grandes** nas folhas das árvores, **reduzindo a influência excessiva** de qualquer parte específica do modelo.
- Diferente da L1, ela normalmente não zera contribuições, mas **suaviza os valores** , tornando o modelo mais estável e menos sensível a variações ou padrões extremos nos dados de treino.
- É uma das formas mais comuns de **controlar a complexidade** do modelo, pois **evita** que as árvores façam **correções exageradas** a cada etapa do boosting.

Jatan Manoel Mendonça 294.876.[illegible]-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Hiperparâmetros do XGBoost

`n_estimators`

Número **máximo de árvores** construídas **em sequência** . Mais árvores permitem mais correções, mas aumentam o custo computacional

`learning_rate`

Controla o **peso** da **contribuição de cada nova árvore** para a previsão final. Um valor alto faz mudanças grandes; um valor baixo faz ajustes menores e mais cuidadosos.

`max_depth`

Define o **número máximo de níveis** de cada árvore. Árvores muito profundas podem memorizar os dados de treinamento. Árvores mais rasas são mais simples, mas podem deixar de capturar padrões importantes.

`min_child_weight`

Define a **quantidade mínima de informação** que deve existir em um **nó filho** para que uma divisão seja aceita. Valores maiores tornam o modelo mais conservador, criando árvores mais simples.

`subsample`

Define a **fração das observações** de treinamento usada para construir cada árvore. Valores menores que 1 adicionam aleatoriedade, reduzem a dependência de casos específicos e podem ajudar a controlar o overfitting.

`colsample_bytree`

Define a **fração das variáveis disponíveis** para **construir cada árvore** . Isso aumenta a diversidade entre as árvores. Valores menores podem reduzir overfitting, mas valores muito baixos podem impedir que o modelo encontre variáveis importantes.

`reg_alpha / reg_lambda`

Regularização L1 / L2. **Controla complexidade e overfitting** . **L1:** Valores maiores favorecem modelos mais simples e podem reduzir a influência de variáveis pouco relevantes. **L2:** Valores maiores tornam as previsões mais suaves e conservadoras, ajudando a reduzir o overfitting.

Modelo sensível a tuning

Use early stopping e validação cruzada para calibrar!

Natan Manoel Mendonça 356.976.588-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

>>

Da teoria ao código

Com Random Forest, alcançamos **83%** de recall e **96%** de acurácia.

Será que o XGBoost consegue superar esse resultado?

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

APLICAÇÃO PRÁTICA

XGBoost em Python

```python
from xgboost import XGBClassifier
xgb = XGBClassifier(
    n_estimators=300,
    learning_rate=0.1,
    max_depth=6,
    early_stopping_rounds=20)
xgb.fit(X_train, y_train,
        eval_set=[(X_val, y_val)])
y_pred = xgb.predict(X_test)
```

Interface familiar

Mesmo fit / predict do scikit-learn.

Early stopping

Para de adicionar árvores quando a validação para de melhorar.

Mesmas métricas

Acurácia, matriz de confusão, ROC (Classificação) MSE, RMSE, MAE (Regressão)

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Decision Tree × Random Forest × XGBoost

CRITÉRIO	Decision Tree	Random Forest	XGBoost
Tipo	Modelo único	Ensemble bagging	Ensemble boosting
Treinamento	Construção recursiva da árvore, escolhendo o melhor split em cada nó	Paralelo	Sequencial, cada árvore corrige erros anteriores
Viés / variância	Baixo viés, alta variância	Reduz variância	Reduz principalmente viés; pode controlar variância com regularização
Overfitting	Alto risco	Menor risco que uma árvore única	Pode sofrer overfitting sem regularização/tuning
Interpretabilidade	Alta	Média/baixa, explicável por feature importance	Média/baixa, explicável por feature importance
Velocidade de treino	Rápida	Média a alta, mas paralelizável	Média; otimizada, mas sequencial **Pode ser rápido na prática, mas depende bastante do volume de dados e dos hiperparâmetros.*
Sensível a hiperparâmetros	Pouco	Média	Muito

Natan Manoel Mendonca 394.876.088-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Do simples ao máximo desempenho

COMECE SIMPLES

Decision Tree

baseline e explicabilidade

→

GENERALIZE

Random Forest

robustez sem muito tuning

→

MAXIMIZE

XGBoost

alta performance

Natan Manoel Menolotto 394.876.[illegible]50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sugestões de Leituras/Referências

Livro-base

- GÉRON, A. *Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow.* 2. ed. Rio de Janeiro: Alta Books, 2021.

Documentação técnica

- SCIKIT-LEARN. *Ensemble methods.* Disponível em: https://scikit-learn.org/stable/modules/ensemble.html
  Referência oficial com a descrição dos estimadores usados nos notebooks: VotingClassifier, BaggingClassifier, RandomForestClassifier, GradientBoostingClassifier e StackingClassifier.

- XGBOOST DEVELOPERS. *XGBoost Documentation.* Disponível em: https://xgboost.readthedocs.io/en/stable/.
  Documentação oficial do XGBoost.

Leitura complementar

- CHEN, T.; GUESTRIN, C. *XGBoost: A Scalable Tree Boosting System.* In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, p. 785-794.
  Disponível em: https://arxiv.org/abs/1603.02754. Artigo original do XGBoost. Leitura recomendada para entender as escolhas de projeto que tornaram o algoritmo padrão em competições e aplicações industriais.

Nadia Raquel Mendonca 357.076.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigada!

Prof.ª Dra. Valquíria Alencar | linkedin.com/in/valquiria-alencar

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ