MBA EM

DATA SCIENCE

Coleta de Dados: Crawlers e Web Scraping

Prof. Guilherme Lima

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ

X

Minhas redes

guilhermelimadev

LinkedIn guilherme-lima-developer

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Web Scraping

Extraindo informações de forma automatizada

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Quando não há API ou acesso direto aos dados



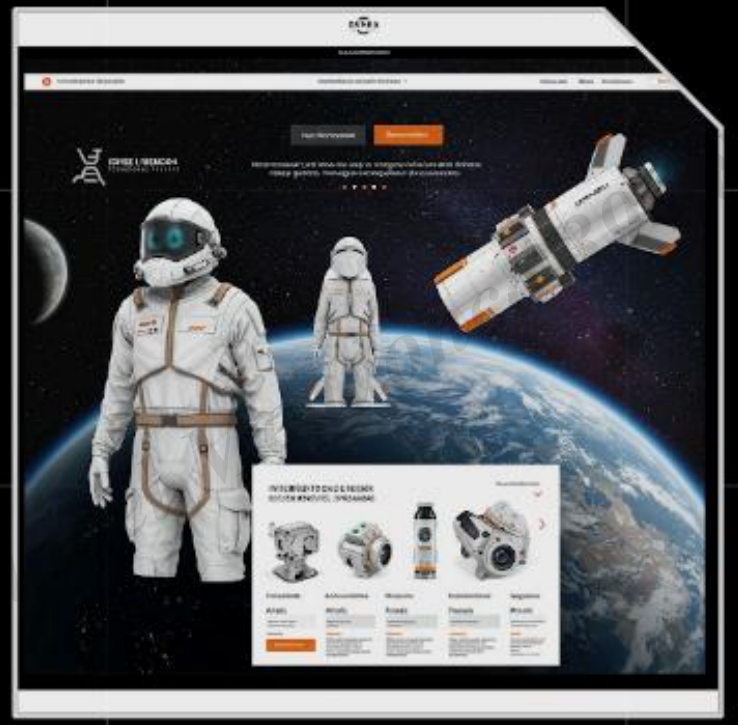
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

01 | Como o Scraping funciona?

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como o Scrapy FUNCIONA







CÓDIGO → SITE → HTML

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Como o Scrapy FUNCIONA



CÓDIGO → SITE → HTML



Extrai os dados

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Web Scraping ≠ Hacking



Scraping

É legal, desde que seja ético e público



Hacking

1. Quebrar a segurança
2. Invadir um sistema
3. Explorar vulnerabilidades
4. Acesso não autorizado

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A INTERNET

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Natan Manoel Mendonca 394.876.988-

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Qual o navegador que você usa?

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Você acessa a internet com quais dispositivos?

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98











Natan Manoel Mendonca 394.876.980 50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sabe o que é mais curioso?

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Curiosamente, **não há uma autoridade central com poder legal** que controle e organize toda a internet.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ao contrário do que muitos imaginam

Diversas organizações, que surgiram de maneira espontânea e colaborativa ao longo dos anos, são responsáveis por administrar diferentes aspectos da rede.

- IETF
- W3C
- ICANN
- ISOC
- ARIN

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Natan Manoel Mendonca 394.876.988-

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

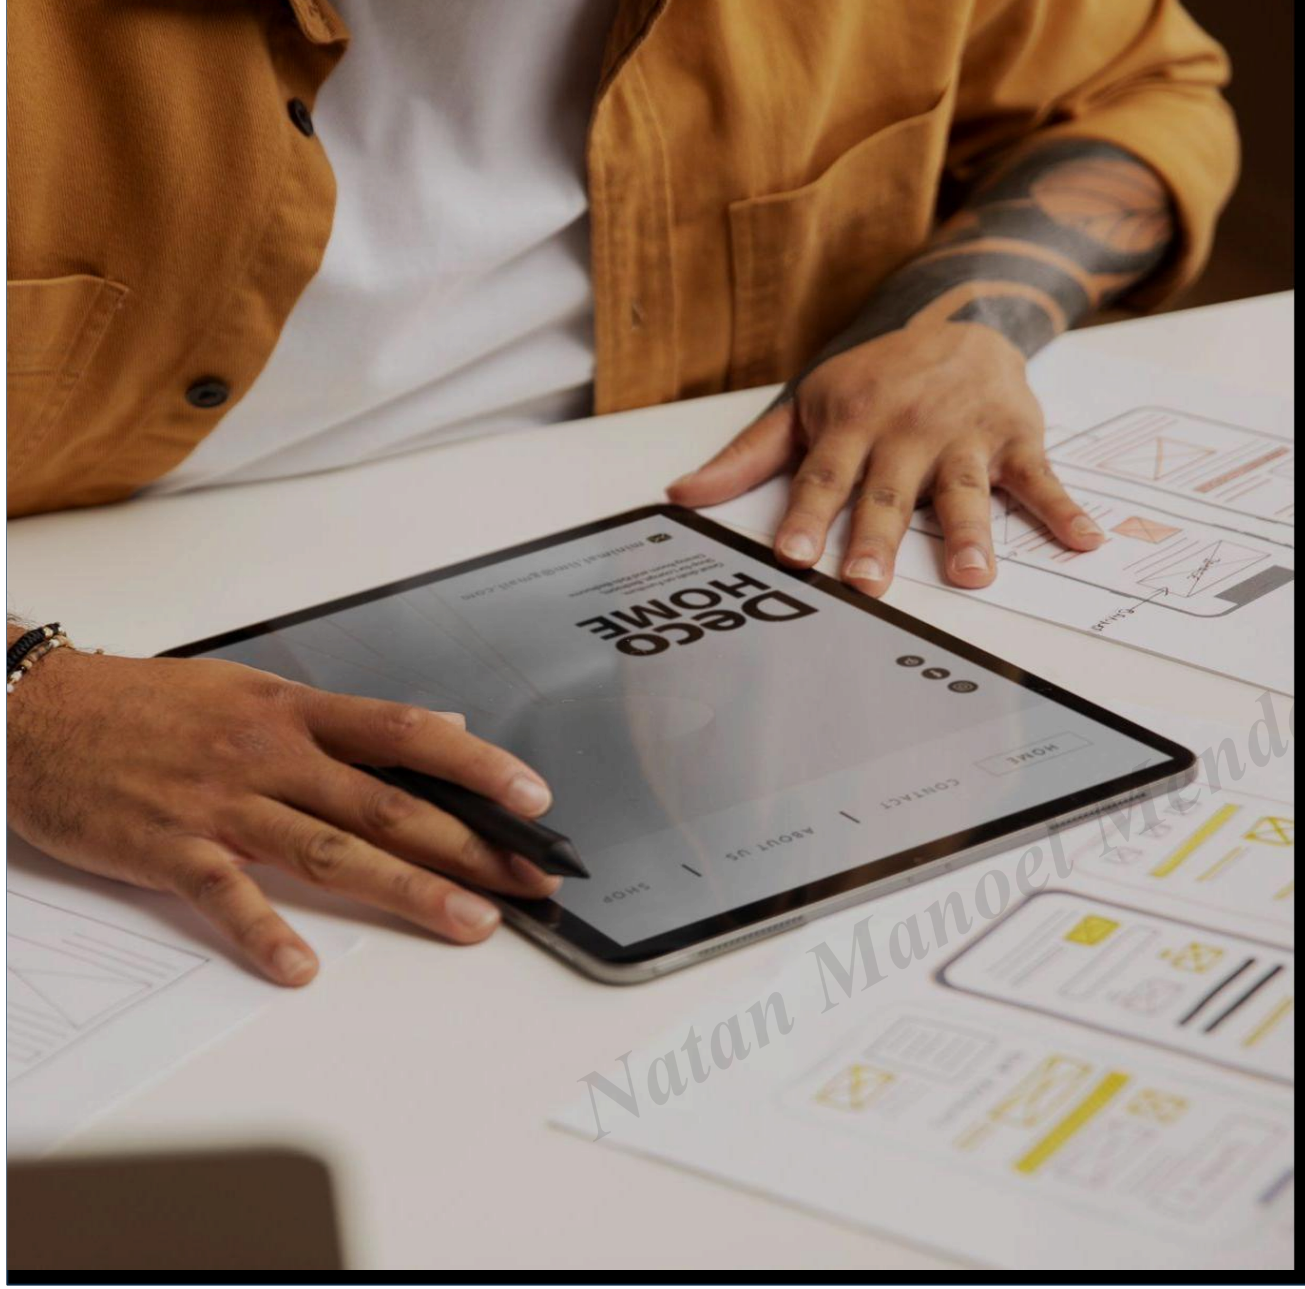
O que aconteceria,
se alguém não seguir aos padrões publicados por essas organizações?

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ignorar os padrões definidos por essas organizações pode resultar em problemas — suas criações podem simplesmente não funcionar corretamente na internet.



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Web scraping, na prática, é quando seu programa assume o papel de um navegador, acessando e interpretando sites automaticamente.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

MAIS SOBRE A INTERNET

REDE

Fundamentos da Conectividade

HTML

A Arquitetura das Páginas Web

CSS

Estilizando a Experiência Visual

JAVASCRIPT

Tornando a Web Dinâmica

CLIENTE

O Ponto de Acesso do Usuário

SERVIDOR

O Fornecedor de Conteúdo

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SOBRE A INTERNET



HTML

A Arquitetura das Páginas Web





CLIENTE

O Ponto de Acesso do Usuário

SERVIDOR

O Fornecedor de Conteúdo

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

HTML

Linguagem usada para estruturar e organizar o conteúdo de páginas na web.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ferramentas de Desenvolvedor (DevTools)



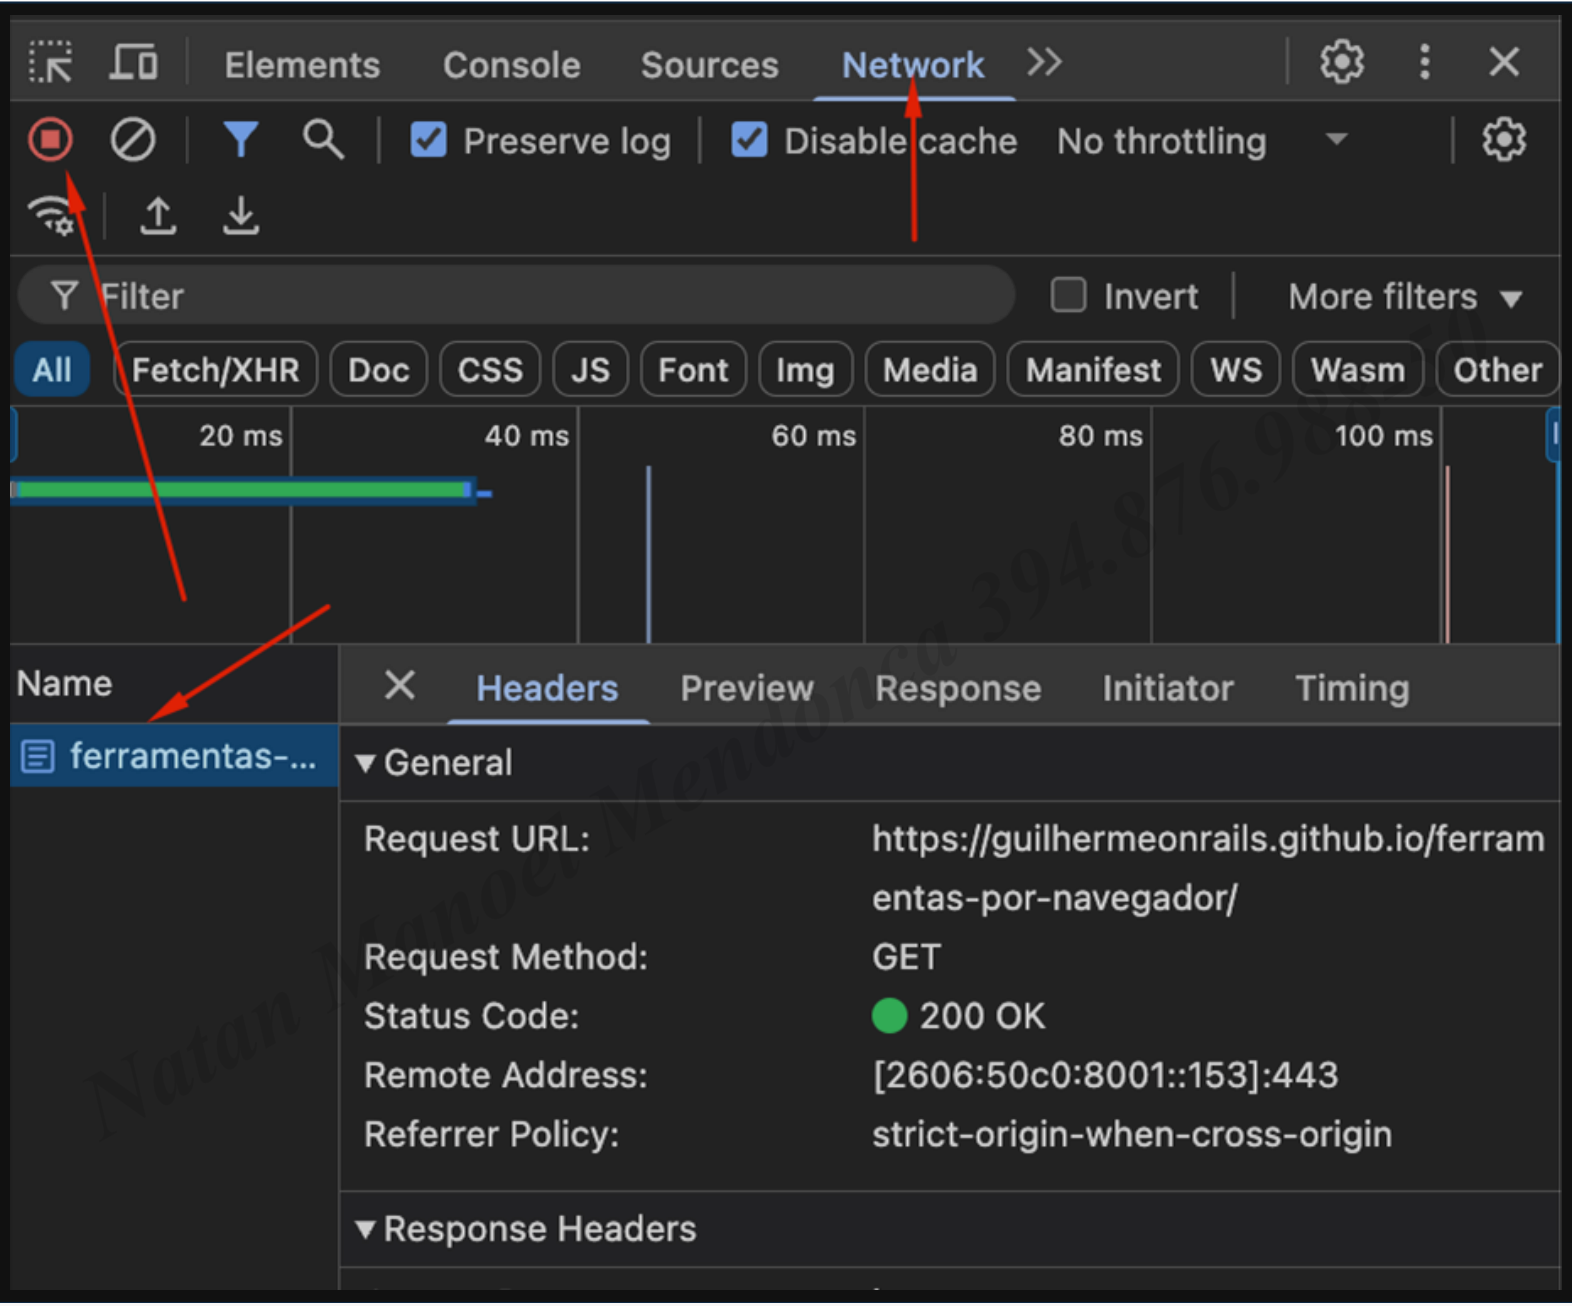
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ferramentas de Desenvolvedor (DevTools)

São um conjunto de recursos embutidos nos navegadores modernos que permitem inspecionar, editar e depurar páginas da web em tempo real.

Como acessar

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Request URL:	https://guilhermeonrails.github.io/ferramentas-por-navegador/

A URL para a qual a solicitação foi enviada

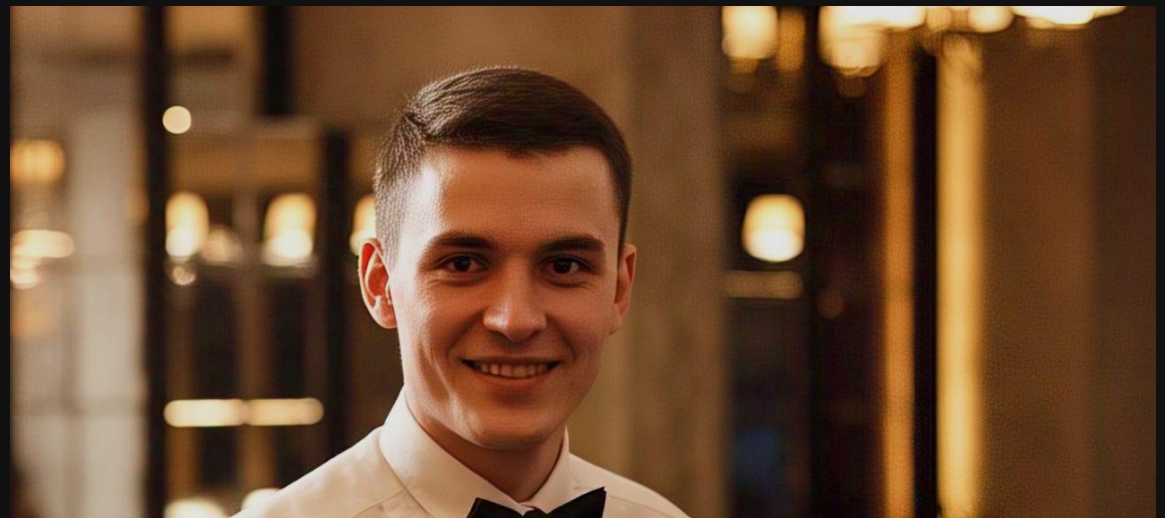
Request Method:	GET

O método HTTP usado

Status Code:	200 OK

O status da resposta

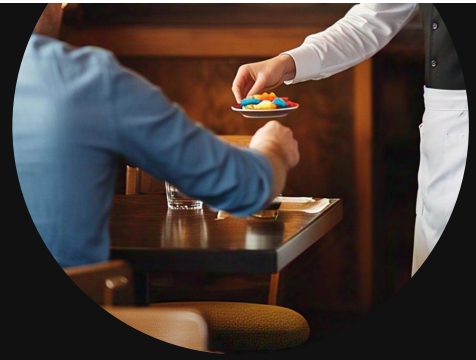
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98





REGRAS





A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Protocolo

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

HTTP

Um protocolo que define as regras para troca de informações dentro do modelo cliente-servidor na web.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



cliente-servidor

Um modelo de comunicação entre dois lados

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Resumindo

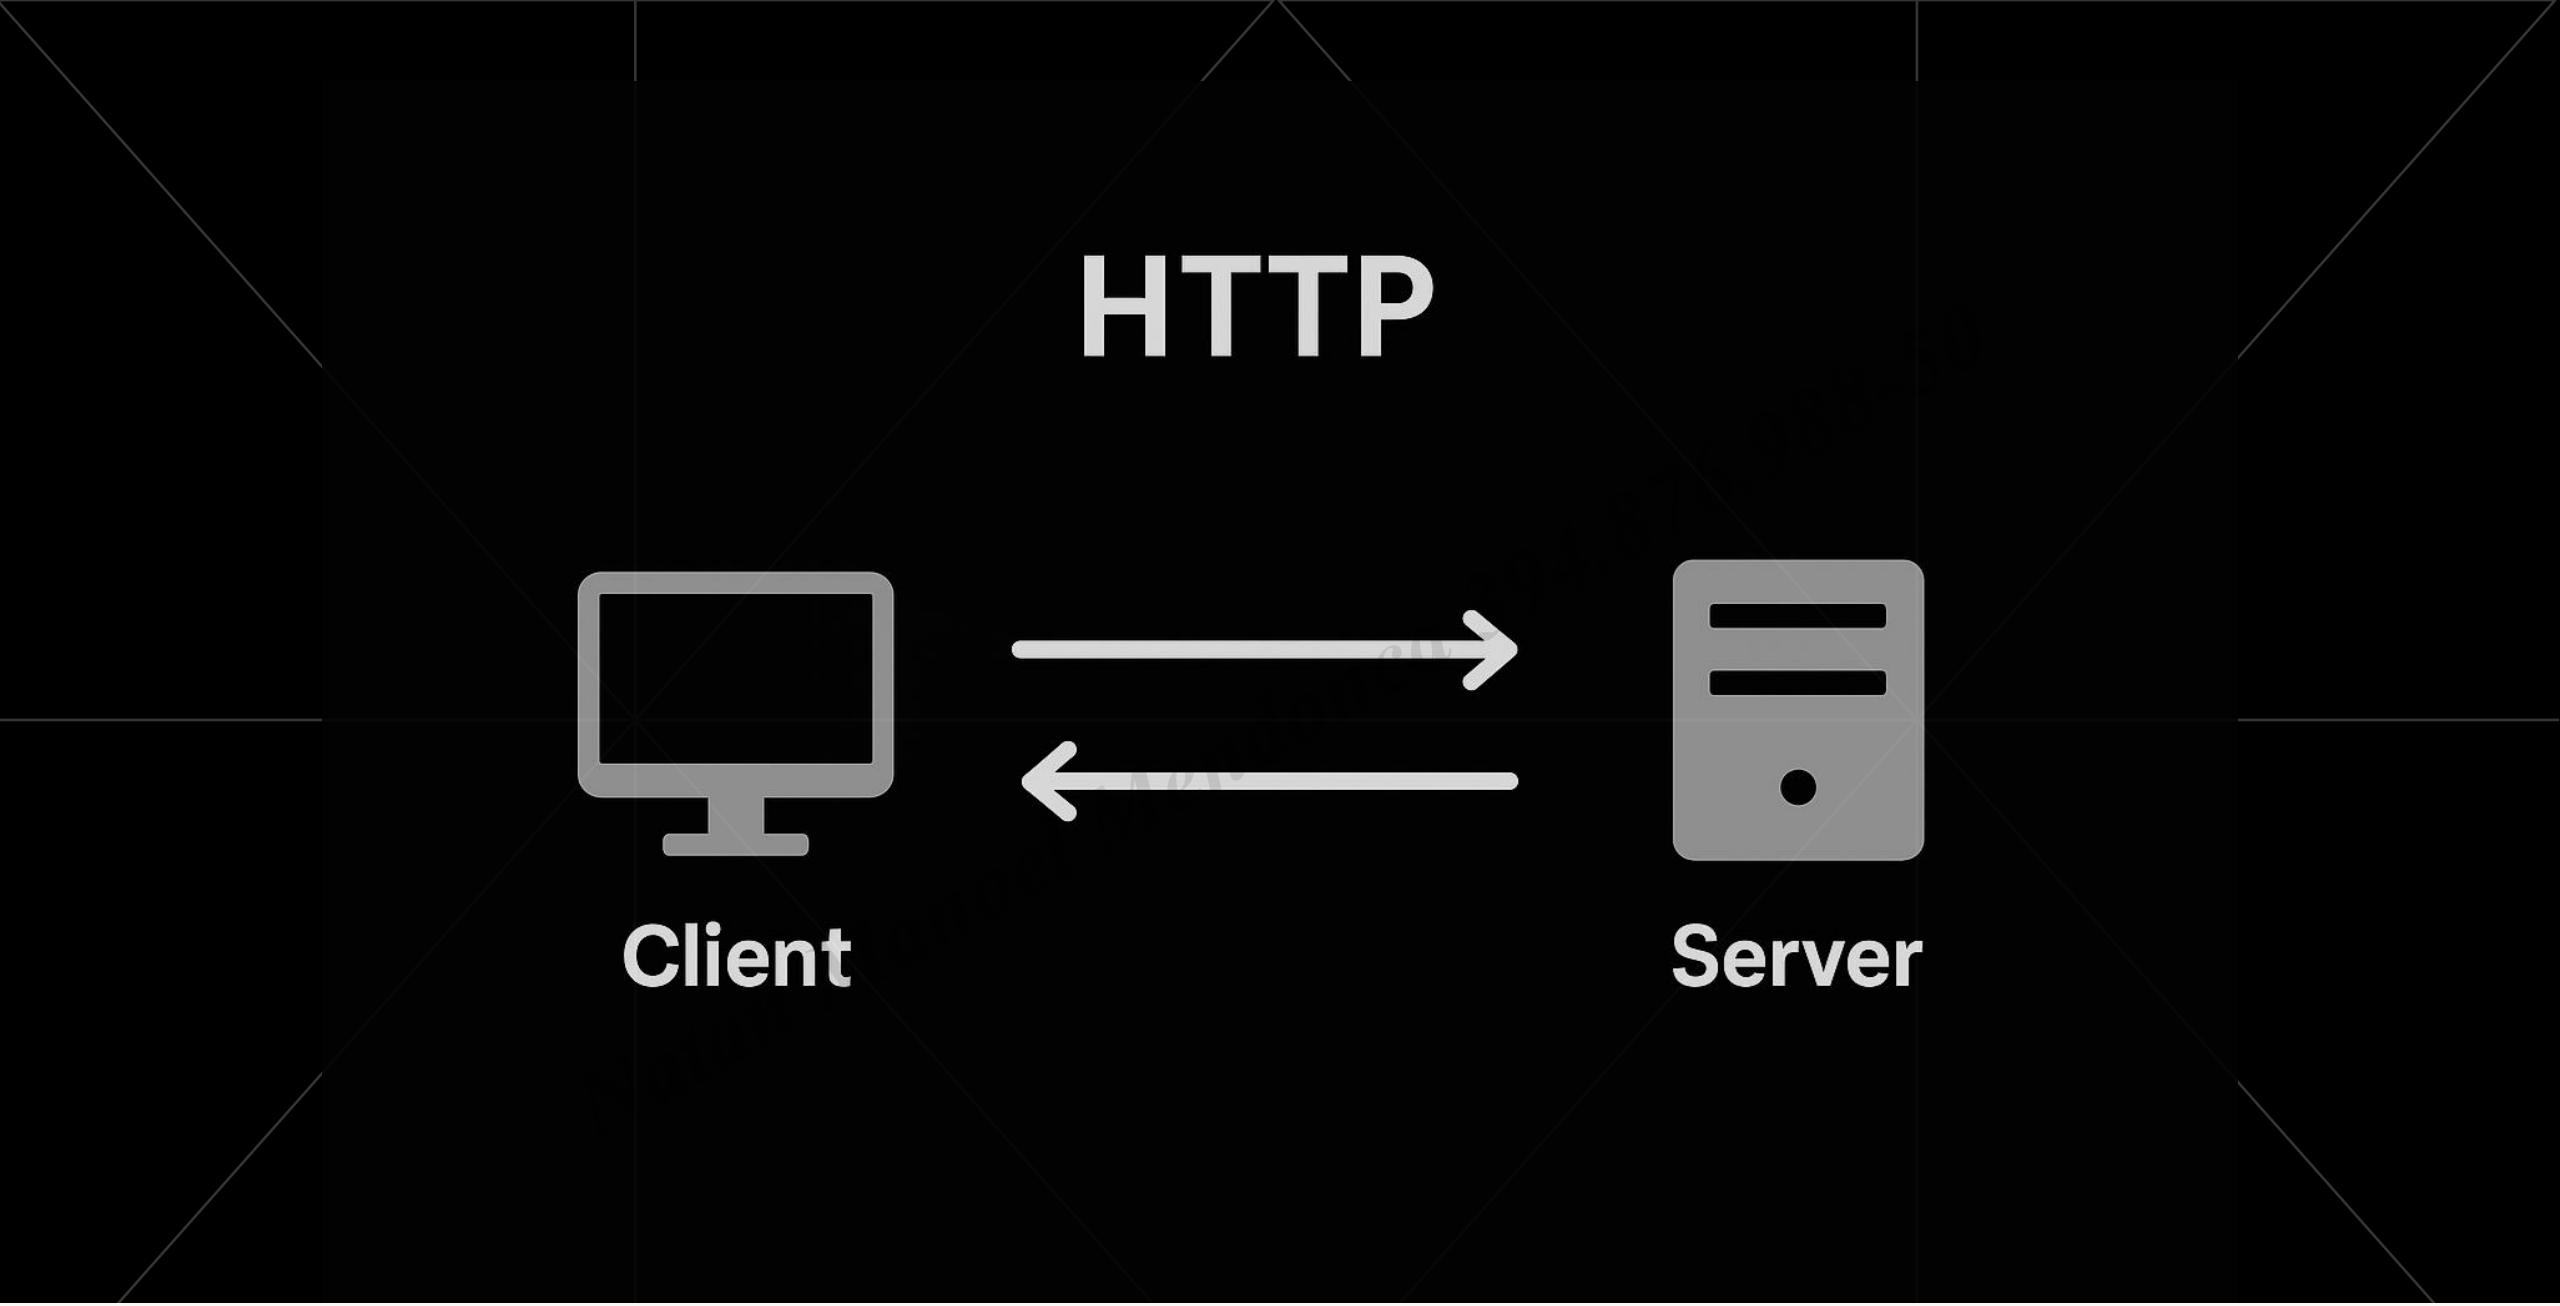
HTTP

Como elas se comunicam

Cliente-servidor

Como as partes se organizam.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SOBRE A INTERNET

REDE

Fundamentos da Conectividade

HTML

A Arquitetura das Páginas Web

CSS

Estilizando a Experiência Visual

JAVASCRIPT

Tornando a Web Dinâmica

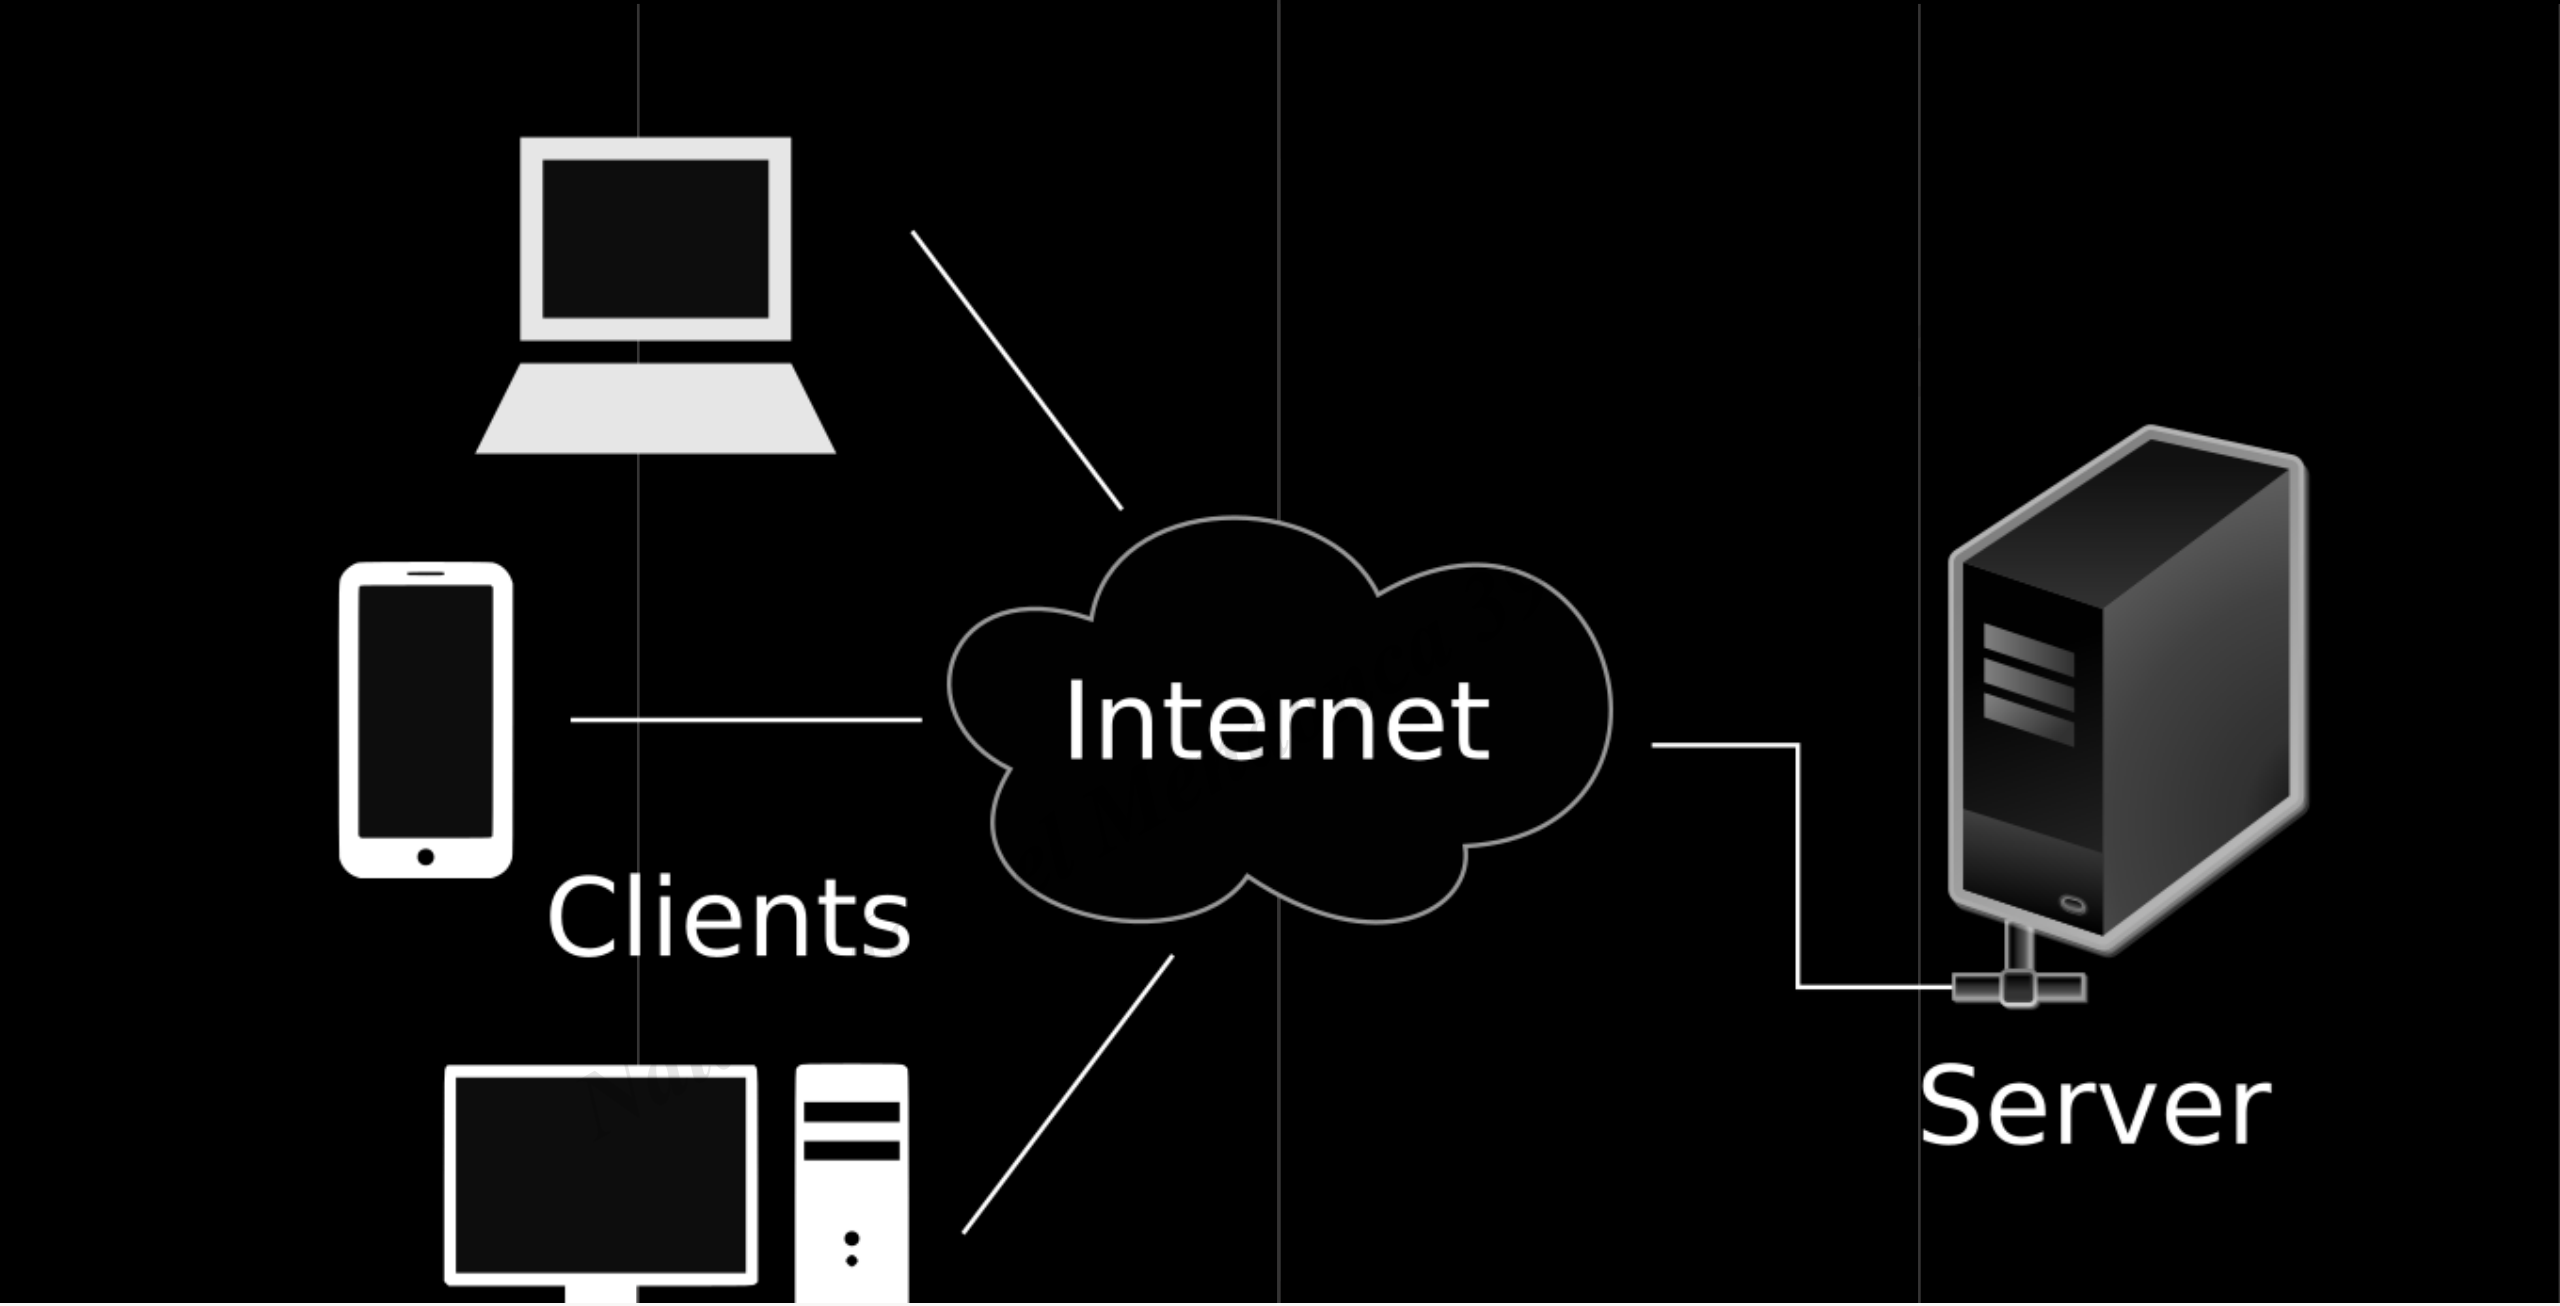
CLIENTE

O Ponto de Acesso do Usuário

SERVIDOR

O Fornecedor de Conteúdo

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

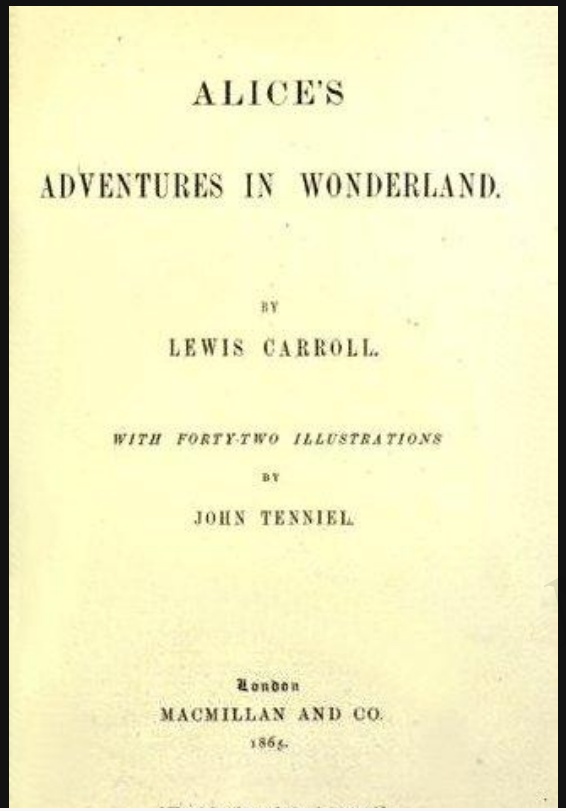
BeautifulSoup



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Homenagem a um poema

Lewis Carroll


ALICE'S

ADVENTURES IN WONDERLAND.

BY

LEWIS CARROLL.

WITH FORTY-TWO ILLUSTRATIONS

BY

JOHN TENNIEL.

London

MACMILLAN AND CO.

1865.





A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

BeautifulSoup

Uma biblioteca do Python usada para analisar e extrair informações de arquivos HTML de forma simples.

- **Ler páginas da web** e extrair títulos, links, tabelas, etc.;

- Transformar o **HTML em objetos Python navegáveis,** facilitando buscas por tags, classes, IDs e conteúdos.



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

WEB e um quarto bagunçado

A web é desorganizada e imprevisível.

Um scraper pode falhar por **um simples erro de estrutura**.

Por isso, mais do que culpar o site, é essencial prever exceções e tornar seu código resistente a imprevistos.



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Natan Manoel Mendonca 39 876.988

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Que tipo de erro, Poderia acontecer neste código?

```
1 from bs4 import BeautifulSoup
2 import pandas as pd
3
4 url = "https://br.investing.com/currencies/"
5 response = requests.get(url)
```

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Permissões e Ações Legais



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

LGPD não menciona explicitamente o termo scraping



De acordo com o artigo 7º, §3º da LGPD, o tratamento de dados pessoais cujo acesso é público deve considerar a finalidade, a boa-fé e o interesse público que justificaram sua disponibilização.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Uma história do mundo real

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

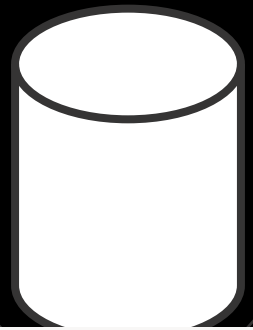
2010











Pete Warden

Toda historia aqui

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Nomes

Localizações

Amigos

Interesses

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

PARE COM ESSA ATIVIDADE!





Pete Warden

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Big data? Posso pagar, dar um jeito.

Advogados?

Calma aí...

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Três critérios precisam ser atendidos

Consentimento

Termos de Serviço de muitos sites proíbem especificamente o uso de scrapers.

Problemas físicos

Scrapers derrubarem um site ou limitarem sua capacidade de atender outros usuários

Intencionalidade

A real intenção do código, o que ele faz

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Scraping na prática

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sugestões de Leituras/Referências

Mitchell, R. 2024. Web Scraping with Python (3ª ed.). Editora Novatec
O livro-referência do tema. Cobre exatamente a progressão da aula: requests, BeautifulSoup, navegação por árvore HTML, formulários/login e Selenium para conteúdo dinâmico. Inclui um capítulo forte sobre ética e legalidade do scraping.

Automate the Boring Stuff with Python (2ª ed.) — Al Sweigart
Ideal para o público iniciante da aula. Tem capítulos práticos sobre requisições web, parsing de HTML e automação de navegador, com leitura leve. (Disponível gratuitamente online em automatetheboringstuff.com.)

Gourley, D.; Totty, B.; Sayer, M.; Aggarwal, A.; Reddy, S. 2002. O'Reilly Media
Aprofunda o que a aula só tangencia: o protocolo HTTP por baixo do requests.get() — status codes, headers (como o HEAD do seu código), cookies, sessões e cache. Entender HTTP é o que separa quem "usa requests" de quem "domina coleta web".

Natan Manoel Medeiros 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Prof. Guilherme Lima | https://www.linkedin.com/in/guilherme-lima-developer/

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ