MBA EM
DATA SCIENCE

Aula extra: Desenvolvimento de APIs e Integração Prática de LLMs I-II

Helder Prado Santos

Natan Manoel Mendonca - 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonça - 394.876.988-50

MBA USP ESALQ

Ciclo de Vida: Do Protótipo ao Produto

Fase 1: Prototipação

Testes isolados em notebooks, validação de prompts e experimentação inicial sem preocupação com escala.

Abismo de Integração

Desafios de concorrência, padronização de formatos, latência de rede e gerenciamento de dependências.

Fase 3: Operação

Disponibilização via API resiliente, monitoramento de métricas, auditoria e governança em produção.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O Conceito de Serviço de IA

Atualização Independente

Troca de modelos de linguagem e prompts sem exigir alterações nos sistemas que consomem o serviço.

Poliglotismo Tecnológico

Uso de Python para IA e processamento pesado, enquanto outras aplicações podem utilizar TypeScript, Java ou outras tecnologias.

Escalabilidade Direcionada

Dimensionamento dos recursos do serviço conforme a demanda por processamento e inferência.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Os Três Pilares: API, LLM e RAG

API (A Ponte)

Interface padronizada para comunicação segura entre sistemas, clientes e microsserviços.

LLM (O Cérebro)

Capacidade avançada de raciocínio, síntese de contexto e geração de linguagem natural.

RAG (A Memória)

Mecanismo de busca semântica para ancorar as respostas aos documentos privados da organização.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Anatomia de uma API (Application Programming Interface)

O Contrato da Interface

Isola a complexidade interna. Define rigorosamente quais dados de entrada são exigidos e qual formato de resposta será retornado.

Reutilização Corporativa

Transforma scripts pontuais de cientistas de dados em utilitários reutilizáveis para toda a organização.



O cliente (**aplicação**) não precisa saber como a cozinha funciona ou como os pratos são preparados. Ele apenas faz um pedido seguindo o cardápio (**API**). O garçom recebe o pedido, leva a solicitação para a cozinha (**servidor**) e depois entrega o resultado ao cliente.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Arquitetura Cliente-Servidor



Cliente (Client)

Navegador, aplicativo mobile, dashboard de BI ou script Python requisitante.

1. Requisição (Request) →

← 2. Resposta (Response)



Servidor (Server)

Onde residem os recursos, a lógica de negócio e os modelos de Inteligência Artificial.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O Protocolo HTTP como Meio de Transporte

Natureza Stateless

Cada requisição é completamente isolada e deve conter todas as informações necessárias para ser processada.

Endpoints e Rotas

Endereços específicos para identificação de recursos na rede, como /predicao ou /resumo.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Métodos HTTP: Indicando a Intenção

GET

Consulta & Leitura

Utilizado exclusivamente para obtenção de dados. Não altera o estado do servidor.

POST

Processamento & Envio

Envio de dados complexos para inferência de IA, criação de registros ou buscas volumosas.

PUT / PATCH / DELETE

Gestão de Recursos

Métodos auxiliares do padrão REST para atualização total, parcial ou remoção de dados.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Anatomia de uma Requisição (Request)

URL & Endpoint

Destino exato da chamada no servidor (ex.: https://api.empresa.com/v1/analise).

Headers (Cabeçalhos)

Metadados da chamada contendo tipo de conteúdo (Content-Type) e tokens de segurança.

Query Parameters

Filtros simples passados diretamente na URL para personalização (ex.: ?formato=resumido).

Body (Payload)

Corpo da requisição com dados volumosos e estruturados enviados para análise da Inteligência Artificial.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Status Codes: A Resposta do Servidor

Natan Manoel Mendonca - 394.876.988-50

Família 2xx

Sucesso

200 OK: Requisição recebida, validada e processada com êxito.

Família 4xx

Erro do Cliente

400 Bad Request: Parâmetros inválidos ou ausentes na chamada.

Família 5xx

Erro do Servidor

500 Internal Error: Falha crítica no código, modelo ou infraestrutura.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

JSON: Linguagem de Comunicação entre Sistemas

Estrutura Chave-Valor

Formato hierárquico intuitivo baseado em objetos e listas, legível tanto para humanos quanto para máquinas.

Interoperabilidade

Fácil conversão direta para DataFrames, Dicionários Python, JSONB em SQL e objetos JavaScript.

```
// Exemplo de Payload JSON

{
  "prompt": "Resuma o contrato",
  "temperatura": 0.2,
  "documento_id": 9842
}
```


```
{
  "prompt": "Resuma o contrato",
  "temperatura": 0.2,
  "documento_id": 9842
}
```


Natan Manoel Mendonça 694.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A Nova Geração de Frameworks: FastAPI

Assincronismo Nativo

I/O não bloqueante com suporte a async/await, prevenindo gargalos durante chamadas externas a LLMs.

Servidores ASGI

Execução otimizada sobre Uvicorn para entregar alta concorrência de requisições simultâneas.

Documentação Automática

Geração automática de interfaces OpenAPI/Swagger interativas para testes rápidos.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Schemas e Tipagem: Blindando Entradas e Saídas

Validação Declarativa

Elimina checagens manuais repetitivas ao rejeitar automaticamente payloads fora do padrão antes da execução.

Contrato de Dados Estrito

Garante tipagem consistente (inteiros, strings, datas) entre sistemas cliente e o modelo de IA.

```python
# Exemplo de Schema Pydantic


class RequisicaoAnalise(BaseModel):
  texto: str
  max_tokens: int = 500
  temperatura: float = 0.1



class RequisicaoAnalise(BaseModel):
  modelo: str
  texto: str
  max_tokens: int = 500
  temperatura: float = 0.1
```

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O que é uma LLM sob a Ótica da Engenharia?

Arquitetura Transformer

Processamento baseado no mecanismo de Self-Attention para ponderar a relevância entre palavras distantes.

Função Matemática

Mapeamento estocástico que transforma uma sequência de entrada em distribuições de probabilidade.

Mudança de Paradigma

Transição de algoritmos de regras determinísticas rígidas para inteligência probabilística flexível.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Panorama de Provedores de IA Generativa

Natan Manoel Mendonca - 394.876.988-50

Proprietários

Google, OpenAI, Anthropic

Conveniência máxima, estado da arte em capacidade e ausência de gestão de infraestrutura.

Open-Weight

Llama, Mistral

Soberania total sobre dados, customização avançada e controle de custos em escala.

Aceleração em Nuvem

Groq, Together AI

Inferência ultrarrápida otimizada por hardware especializado como LPUs e GPUs dedicadas.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tokens e Janelas de Contexto (Context Window)

O que é um Token?

Fragmentos de palavras (~4 caracteres em inglês). Base para tarifação, processamento e limites operacionais.

Janela de Contexto

Capacidade máxima de tokens (Entrada + Saída) que a rede visualiza simultaneamente em uma chamada.

4K → 32K → 128K → 1M+

Tokens em Janelas de Contexto Modernas

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Parâmetros de Inferência: Temperatura e Top-P

Natan Manoel Mondonça - 394.876.988-50

Temperatura Baixa (0.0 - 0.2)

Maior determinismo e consistência. Recomendado para extração de dados, geração de JSON e RAG.

Temperatura Alta (0.7 - 1.0)

Maior variabilidade e exploração criativa. Adequado para ideação, escrita e brainstorming.

Top-P (Nucleus Sampling)

Corte cumulativo de probabilidade. Restringe a seleção aos tokens mais prováveis do universo.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Incerteza e Alucinação: O Desafio Corporativo

⚠ O que é Alucinação?

Geração de informações incorretas, imprecisas ou não sustentadas pelos dados disponíveis, apresentadas de forma plausível e convincente.

🚫 Riscos para Negócios

Respostas não verificadas podem causar falhas de conformidade, dificuldade de auditoria, decisões baseadas em informações incorretas e problemas em processos automatizados.

Natan Manoel Mondonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Boas Práticas de Segurança em APIs de IA

🔑 Gestão de API Keys

Nunca expor credenciais em código-fonte. Armazenar chaves em Variáveis de Ambiente (.env).

Isolação de Ambientes

Separação rigorosa entre chaves de Desenvolvimento, Homologação e Produção.

Limites Financeiros

Configuração de limites teto de gastos nos provedores para evitar custos imprevistos.

Natan Manoel Mondonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Saídas Estruturadas (Structured Outputs)

Constrained Decoding

A geração de tokens é restrita diretamente pela gramática do JSON Schema definido.

Integração Analítica

Converte textos não estruturados (ex.: avaliações) em tabelas relacionais sem falha de parsing.

Garantia de Formato

Garante que a resposta contenha 100% dos campos declarados, tipos corretos e sintaxe válida para ingestão automática.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Rate Limits e Governança Financeira

RPM & TPM

Requisições por Minuto e Tokens por Minuto como métricas principais de restrição de uso.

Perfil de Latência

Chamadas a LLMs levam segundos, exigindo arquiteturas assíncronas e feedbacks ao usuário.

Previsibilidade de Custos

Estimativa de consumo financeiro baseada na volumetria esperada de tokens de entrada e saída.

Natan Manoel Mondonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Por que as LLMs Falham com Dados Privados?

Knowledge Cutoff

O modelo possui conhecimento congelado até a data limite em que seu treinamento foi encerrado.

Ponto Cego Corporativo

Modelos genéricos nunca acessaram planilhas, relatórios ou manuais internos da empresa.

Custo de Retreinamento

Treinar uma LLM do zero para aprender documentos internos é inviável financeira e operacionalmente.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Embeddings: “Entendimento” da Semântica do Texto

Vetor Denso

Uma lista ordenada de centenas ou milhares de números reais gerada por um modelo neural especialista.

Dimensões Conceituais

Cada dimensão do vetor captura traços latentes do texto (assunto, tom, intenção e contexto).

```
// Representação de Vetor de Embedding
"Reembolso de viagens"
 ↓
 [-0.012, 0.284, 0.089, ..., -0.154]
```

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O Hiperespaço Vetorial

Agrupamento Semântico

Textos com ideias similares são posicionados próximos no espaço multidimensional, independentemente das palavras exatas utilizadas.

Exemplo Prático

"Dor de cabeça intensa" e "Paciente com cefaleia" possuem palavras totalmente diferentes, mas vetores quase idênticos.

Natan Manoel Mondonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Busca Léxica vs. Busca Semântica

Natan Manoel Mendonca - 394.876.988-50

Busca Léxica (Palavra-Chave)

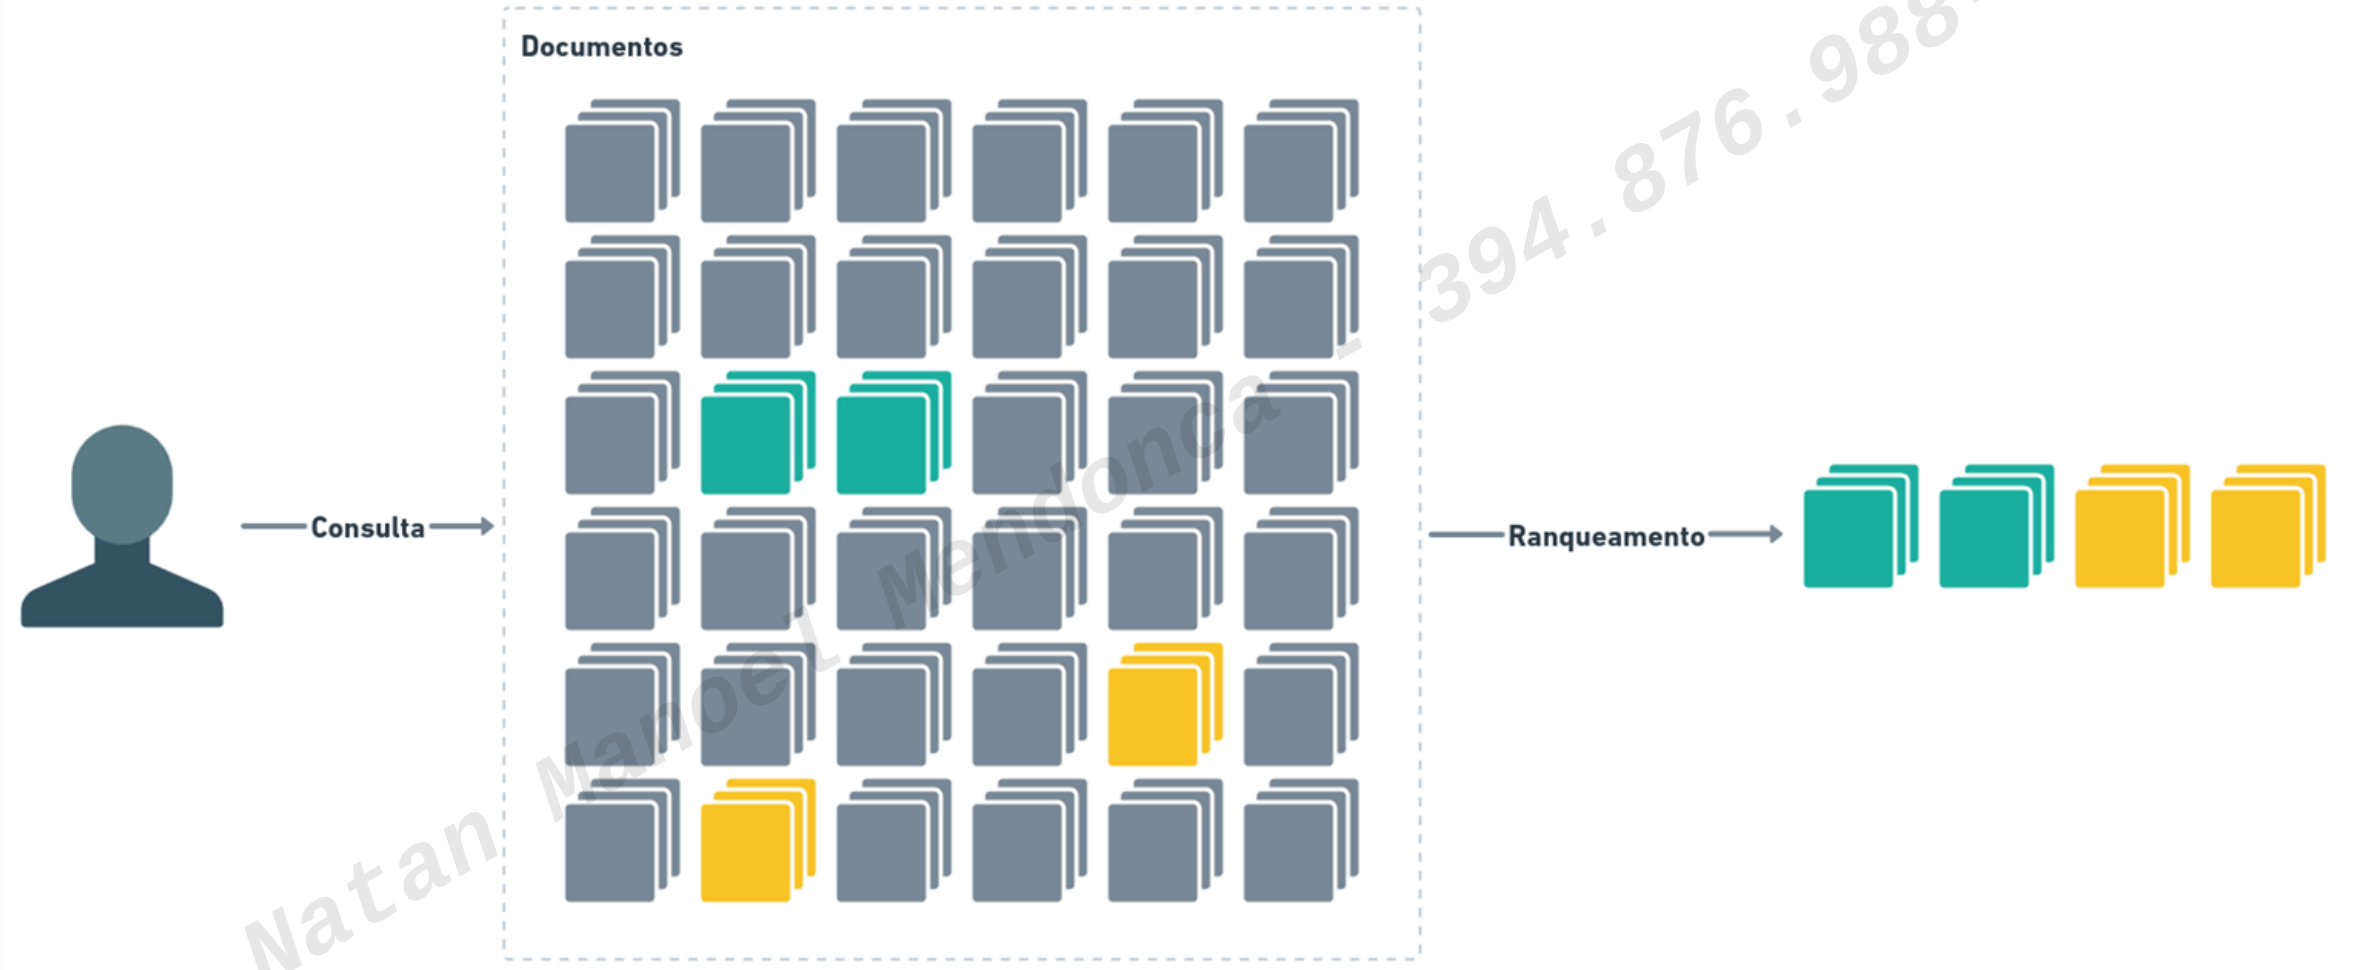
Procura correspondência exata de caracteres (ex.: BM25, SQL LIKE). Falha com sinônimos, erros de digitação e variações do termo.

Busca Semântica (Vetorial)

Procura o significado contextual. Localiza o documento correto mesmo que nenhuma palavra da busca esteja presente no texto original.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sistema de Recuperação da Informação



Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Métricas de Similaridade Vetorial

Mais Utilizada

Similaridade de Cosseno

Mede o ângulo entre dois vetores. Foca na orientação temática, ignorando o comprimento do texto.

Distância Direta

Distância Euclidiana (L2)

Mede a distância em linha reta entre dois pontos no espaço.

Alta Performance

Produto Escalar (Dot Product)

Avalia a direção e magnitude combinadas. Ideal para vetores previamente normalizados.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Bancos de Dados Vetoriais (Vector DBs)

Consulta por Vizinhos

Projetados para responder em milissegundos: "Quais são os K vetores mais parecidos com esta consulta?"

Armazenamento Híbrido

Armazena o vetor, o texto original correspondente e metadados auxiliares para filtragem.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Algoritmos de Busca Aproximada (ANN)

⚠ O Desafio k-NN Exato

Comparar a busca com 100% dos vetores da base torna-se computacionalmente inviável em bases grandes.

Índices HNSW

Grafos navegáveis que criam atalhos para encontrar vizinhos próximos em milissegundos.

Busca ANN (Approximate Nearest Neighbors)

Sacrifica uma fração mínima de precisão matemática perfeita para obter ganhos de até 100x em velocidade de resposta.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Panorama de Tecnologias Vetoriais

Natan Manoel Mendonça - 394.876.988-50

Embutidos / Locais

ChromaDB, DuckDB

Execução local ou em memória. Perfeitos para protótipos, testes e aplicações leves.

Nuvem Distribuída

Pinecone, Qdrant, Milvus

Alta escalabilidade horizontal para bilhões de registros e ambientes de missão crítica.

Extensões SQL

pgvector (PostgreSQL)

Unifica o modelo relacional tradicional a buscas por similaridade vetorial na mesma base.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O que é Retrieval-Augmented Generation (RAG)?

1. Recuperação (Retrieval)

Busca cirúrgica dos trechos mais relevantes do documento no banco vetorial.

2. Geração (Generation)

A LLM recebe a dúvida + os trechos e redige a resposta ancorada na fonte.

“O Especialista com uma Biblioteca”

Uma LLM sem RAG responde usando o conhecimento e o contexto disponíveis para ela. Com RAG, ela recebe acesso, no momento da pergunta, aos documentos relevantes de uma biblioteca corporativa antes de formular a resposta.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O Fluxo Completo do RAG em Duas Fases

Fase Offline

Ingestão & Indexação

Processamento dos documentos, divisão em pedaços (chunking), conversão em embeddings e salvamento no Vector DB.

Fase Online

Inferência & Augmentation

Recebe a pergunta do usuário, busca no banco, monta o prompt contextualizado e gera a resposta final.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Fase de Ingestão: Tratamento e Limpeza

Fontes Heterogêneas

Extração de texto de PDFs complexos, páginas web, planilhas e sistemas legados.

Remoção de Ruído

Limpeza de cabeçalhos, rodapés, caracteres especiais e elementos que poluem a busca.

Enriquecimento

Adição de metadados auxiliares (data, setor, autor) para permitir filtros precisos.

Natan Manoel Mendonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Chunking (Divisão de Textos)

Tamanho do Pedaço

Chunks muito grandes diluem a busca; chunks muito pequenos perdem o contexto da ideia.

Conceito de Overlap

Sobreposição entre chunks adjacentes para nunca quebrar frases ou conceitos ao meio.

Divisão Semântica

Quebra baseada na estrutura do documento (parágrafos, títulos e seções de Markdown).

Natan Manoel Mondonça - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A Mecânica do Retrieval (Recuperação)

Natan Manoel Mendonca - 394.876.988-50

1. Pergunta

"Qual a regra de reembolso?"

2. Embedding

Gera vetor da pergunta

3. Busca

Busca no Vector DB

4. Contexto

Retorna Top-K trechos

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Augmentation e Grounding (Ancoragem)

Regra de Ancoragem

Instrução estrita forçando a LLM a utilizar ESTRITAMENTE as informações dos contextos recuperados.

Redução de Alucinação

Se a informação não estiver presente no contexto, o modelo declara explicitamente que desconhece a resposta.

```
// Estrutura do Prompt Final (Augmented)

[INSTRUÇÃO]
Responda usando apenas o contexto fornecido abaixo.
Se a informação não estiver no contexto, informe que não
encontrou a resposta.

[CONTEXTO RECUPERADO]
- Trecho 1: ...
- Trecho 2: ...

[PERGUNTA]
{pergunta_usuario}
```

Natan Manoel Mendonça 894.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Matriz de Decisão: RAG vs. Fine-Tuning

Conhecimento Factual

RAG (Retrieval)

Ideal para dados dinâmicos que mudam com frequência, necessidade de auditoria de fonte e custo reduzido de atualização.

Estilo & Comportamento

Fine-Tuning

Ideal para ensinar um tom de voz específico, jargões técnicos estritos ou seguir formatos complexos de saída.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Resiliência e Tolerância a Falhas em IA

Exponential Backoff

Tentativas progressivas de reconexão em caso de inconsistências temporárias de rede.

Timeouts Explícitos

Limites de tempo para evitar que o cliente aguarde indefinidamente a resposta da LLM.

Estratégias Fallback

Modelos secundários ou respostas padrão amigáveis em cenários de indisponibilidade total.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A API como Hub Central de Analytics

Pipelines ETL / ELT

Engenharia de dados consumindo a API para enriquecer e classificar registros em lote.

Dashboards & BI

Ferramentas de visualização e análise disparando consultas e exibindo métricas e indicadores de negócio.

Sistemas Corporativos

Sistemas de CRM, ERP e RH consultando a base de conhecimento via HTTP.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Desenho Arquitetural da Prática de Laboratório

FastAPI (API)

Orquestrador que gerencia as rotas HTTP, validações e documentação automática.

Gemini API (Inteligência)

Provedor que fornece os embeddings numéricos e o raciocínio para geração da resposta.

ChromaDB (Banco Vetorial)

Banco vetorial local para indexação e recuperação semântica dos documentos.

Pydantic (Contrato)

Garantia de entrada e saída estruturada em padrão JSON limpo.

Natan Manoel Mendonca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sugestões de Leituras/Referências

ALAMMAR, Jay; GROOTENDORST, Maarten. Hands-on large language models: language understanding and generation. Sebastopol: O'Reilly Media, 2024.

HUYEN, Chip. Designing machine learning systems. Sebastopol: O'Reilly Media, 2022.

KLEPPMANN, Martin. Designing data-intensive applications: the big ideas behind reliable, scalable, and maintainable systems. Sebastopol: O'Reilly Media, 2017.

LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, v. 33, p. 9459–9474, 2020.

Natan Manoel Menduca - 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Helder Prado Santos | linkedin.com/in/helderprado

Natan Manoel Mendonca - 394.876.988-50