# ESTATÍSTICA I



CERTIFICAÇÃO
DE QUALIDADE

FGV

# Fundação Getulio Vargas

**Programa de Certificação de Qualidade**

Curso:

Graduação em Administração

Estatística I

Professor Elaborador:

**Paulo Sérgio de Souza Coelho**

Paulo Sérgio de Souza Coelho é doutor em Sistemas Computacionais pela Universidade Federal do Rio de Janeiro (2005), formado em Licenciatura em Matemática pela Universidade Estadual de Feira de Santana (1996), com mestrados em Engenharia de Sistemas e Computação pela Universidade Federal do Rio de Janeiro (2000) e em Administração pelo Ibmec-RJ (2003). Atualmente é Superintendente de Educação Executiva – Rio, professor adjunto na Faculdade de Ciências Econômicas da UERJ e professor convidado da FGV/EBAPE. Foi executivo no Banco Itaú com cargos de Gerente de Estratégia de Vendas (Cartão Americanas) e Gerente de Pricing e CRM (Cartão Ponto Frio). Atuou como especialista em Métodos Quantitativos na área comercial (supply chain, pricing e demanda) da Globex Utilidades (Ponto Frio). Foi Professor Adjunto das Faculdades Ibmec-RJ, atuando nos níveis de graduação, mestrado e pós-graduação lato senso (MBA). Foi professor de ensino fundamental e médio na Secretaria Estadual de Educação – RJ e em colégios particulares. Atua em pesquisa nas áreas de Administração e Economia, com base em Métodos Quantitativos, Estatística, Pesquisa Operacional e Economia Comportamental.

# Sumário


1. Comece por aqui ..... 5
   1.1. Aplicações da estatística ..... 5
   1.2. População e amostra ..... 6
   1.3. Dados ..... 8
      1.3.1. Variáveis ..... 8
   1.4. Softwares ..... 10
      1.4.1. Excel ..... 10
2. Apresentação de dados ..... 16
   2.1. Usando a tabela dinâmica do Excel ..... 16
   2.2. Dados qualitativos ..... 21
      2.2.1. Tabelas de frequência e tabelas de dupla entrada ..... 22
      2.2.2. Gráficos para dados categóricos ..... 23
   2.3. Dados quantitativos ..... 24
      2.3.1. Ordenação de dados numéricos ..... 25
      2.3.2. Gráficos para dados numéricos ..... 27
3. Estatística descritiva ..... 32
   3.1. Dados numéricos não agrupados ..... 32
      3.1.1. Médias de Posição ..... 33
      3.1.2. Formato da distribuição ..... 52
   3.2. Dados numéricos agrupados ..... 53
      3.2.1. Distribuição de frequências ..... 53
      3.2.2. Proporção ..... 55
      3.2.3. Média ..... 56
      3.2.4. Variância e desvio padrão ..... 57
   3.3. Intervalos de concentração ..... 60
      3.3.1. Lei empírica ..... 61
      3.3.2. Lei de Chebyshev ..... 62
   3.4. Detecção de Outliers ..... 63
4. Probabilidade ..... 65
   4.1. Abordagens ..... 66
   4.2. Conceitos fundamentais ..... 70
      4.2.1. Probabilidade marginal ..... 71
      4.2.2. Probabilidade condicional ..... 72

4.2.3. Eventos independentes ..... 73
4.2.4. Teorema de Byes ..... 74
4.3. Probabilidade de eventos compostos ..... 77
4.3.1. Lei de Adição ..... 77
4.3.2. Lei da multiplicação ..... 80
5. Variáveis aleatórias e distribuições de probabilidade ..... 83
5.1. Distribuição de probabilidades discreta ..... 83
5.1.1. Valor esperado de uma variável aleatória discreta ..... 84
5.1.2. Variância de desvio padrão de uma variável aleatória discreta ..... 85
5.2. Modelos teóricos de distribuição de probabilidades discretas ..... 86
5.2.1. Distribuição binomial ..... 86
5.2.2. Distribuição de Poisson ..... 89
5.2.3. Distribuição hipergeométrica ..... 90
5.3. Distribuição de probabilidade contínua ..... 92
5.4. Modelos teóricos de distribuição de probabilidades continuas ..... 95
5.4.1. Distribuição normal ..... 96
5.4.2. Distribuição uniforme ..... 101
5.5. Distribuição exponencial ..... 103
6. Anexo – Tabela de distribuição normal ..... 105
7. Bibliografia ..... 107

# 1. Comece por aqui

## 1.1. Aplicações da estatística

Um dia, eu vi escrito no jornal que certo candidato iria ganhar as eleições com 60% dos votos válidos. Em outro jornal, em outro dia, vi que havia um estudo revelando que, no Brasil, há um desperdício de 20% na construção civil. E que esse mesmo desperdício era de apenas 5% em países desenvolvidos.

Essas informações foram obtidas com o uso da estatística. Mas a estatística não é apenas o número (60% dos votos), ou números (20% no Brasil e 5% em países desenvolvidos). A estatística é mais que o número. Estatística é toda área de conhecimento que transforma dados em informações. A transformação é feita através de procedimentos de:

- coleta (pesquisa de indivíduos, consulta de relatórios e demonstrativos, extração de dados em sistemas de computador)
- organização (ordenar, separar, identificar, resumir)
- apresentação (tabelas, gráficos, vídeos)
- análise (diversos métodos)

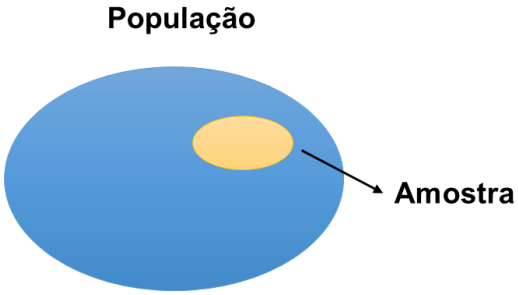
Entretanto, é muito comum ouvir falar de “estatística de vendas”, “estatística de acidentes” etc. Coloquialmente estatística pode significar apenas os números, ou o conjunto de números, sobre determinado fato.

A estatística é muito importante para o administrador. A tarefa de administrar requer controle, que só é obtido através da medição. Por exemplo, considere um processo hipotético de controle de qualidade de uma indústria de cervejas. A qualidade é definida comparando dados dos produtos que foram fabricados com limites desejados ou suportados. Por exemplo, as garrafas que deveriam ter 290ml de cerveja acabam contendo um pouco mais ou um pouco menos. Se o limite de qualidade estabelecer que até 3ml a mais ou a menos é tolerável, então uma garrafa com 289ml está dentro da especificação, enquanto uma garrafa com 295ml não está. Mas o controle não é feito garrafa por garrafa, e, sim, considerando indicadores de um lote de milhares de garrafas. A estatística é a ferramenta para ajudar nesse complexo processo de controle.

Todas as áreas da administração precisam de medição e controle. Para a área de Finanças isso é bem evidente, tendo em vista que os objetos de trabalho já são números. Mas a área de Recursos Humanos também precisa medir e controlar, por exemplo, faltas, bancos de hora e horas extras, custo dos benefícios e a relação desse custo com a folha total etc. Há, inclusive, uma área de RH que está tomando forma e sendo chamada de *People Analytics*, que reúne diversas ferramentas estatísticas para dar suporte a estratégias de RH. A área de Marketing também precisa de medição e controle. Por exemplo, o perfil do público alvo pode ser medido com base em idade e renda, as mídias são escolhidas na relação custo x benefício etc.

## 1.2. População e amostra

Esses são, provavelmente, os conceitos mais elementares da estatística. E, felizmente, são muito simples de se compreender. Em linhas bem simples, a amostra é um subconjunto da população. É importante manter em mente que a população é o conjunto de observações ou indivíduos que se deseja estudar, mas que por algum motivo não está disponível. A amostra é a parte da população que está disponível.




Por exemplo, quando se utiliza a estatística para fazer uma previsão do resultado da eleição, a população é formada por todos os eleitores. No caso da eleição para presidente no Brasil em 2018, a população de eleitores era de mais de 147 milhões de pessoas. Mas as pesquisas são geralmente são feitas com menos de 3 mil eleitores. Então a amostra é representada por 3 mil pessoas dentre os 147 milhões de pessoas que estão na população.

Os dados da população são chamados de parâmetros populacionais. Os dados equivalentes na amostra são chamados de estatísticas amostrais. Por exemplo, para

as eleições de 2018, a idade média do eleitor era de aproximadamente 43 anos (dados do TSE). Mas determinada pesquisa, com 3 mil eleitores, apontou que a idade média foi de 45 anos (pois a pesquisa, por motivos aleatórios, acabou selecionando pessoas com mais idade). Nesse caso se diz que a média de 43 anos é o parâmetro populacional, também chamado de parâmetro verdadeiro, e a média de 45 anos é a estatística amostral, também chamada de estimativa.

A razão de analisar amostras em vez de analisar a população é, em última análise, custo. Isso fica bem evidente no exemplo eleitoral. O custo de consultar os 147 milhões de eleitores é tão alto que só é feito pela máquina pública, com todos os funcionários da justiça eleitoral e ainda contando com milhares de pessoas que trabalham no processo gratuitamente (mesários de seção, consolidadores, transportadores), em instalações públicas ou fornecidas gratuitamente pela iniciativa privada (em geral escolas e universidades). O custo dessa consulta populacional é tão alto que não pode ser arcado por uma empresa privada. Por isso, empresas de pesquisa de opinião consultam apenas 3 mil pessoas, o que é financeiramente viável. A estatística é a ferramenta que permite que uma amostra tão pequena quando comparada com a população possa ser usada para dar informações que representem a população.

Além disso, algumas pesquisas requerem a destruição do objeto sob análise. No exemplo do controle de volume das garrafas de cerveja, o equipamento que faz a medição exata do líquido que está dentro da garrafa precisa acessar todo o líquido; ou seja, a garrafa já fechada e pronta para o consumo é aberta ainda na fábrica, e toda a cerveja é colocada no equipamento que fará a medição do volume. Depois dessa medição a cerveja é descartada. Então, não seria possível analisar toda a população de garrafas industrializadas, caso contrário nenhuma garrafa de cerveja chegaria às prateleiras para ser vendida.

É importante saber se os dados sob análise representam toda a população ou apenas uma amostra. O cálculo de algumas estatísticas é feito de forma diferente quando se tem uma amostra ou uma população sob análise. Mais que isso, em alguns momentos serão usadas informações amostrais para inferir parâmetros populacionais. Essas questões serão discutidas posteriormente.

## 1.3. Dados

Os dados são obtidos a partir das características ou propriedades das unidades de interesse. Assim, se há um interesse sobre a idade dos eleitores, então as unidades de interesse são os eleitores. Cada eleitor tem diversas características: idade, altura, peso, renda, endereço de residência, candidatos escolhidos etc. Entretanto, nem todas as características são importantes para a análise. Sendo a idade a única característica importante, o processo de coleta é obter as idades de todas as unidades (eleitores) do conjunto de dados, não importando se amostra ou população. Se a análise é na amostra de 3 mil eleitores, então haverá 3 mil observações de idade. Esse conjunto é chamado de variável.

- Unidade: cada um dos objetos da amostra/população sob análise.
- Variáveis: características ou propriedades sendo consideradas.

Os dados são obtidos a partir de alguma fonte, que pode ser primária ou secundária. Dados de fonte primária são os coletados especificamente para a análise através de pesquisa, observação ou experimento. Já os dados de fonte secundária foram coletados por algum motivo alheio à análise que está sendo feita, estão disponíveis em algum repositório e são distribuídos por uma organização ou indivíduo de forma comercial ou livre.

### 1.3.1. Variáveis

As variáveis são a forma principal como os dados que serão analisados estão agrupados. Um estudo que considere idade, renda e profissão começa pela separação dos dados nessas três variáveis. Cada variável será analisada separadamente e/ou conjuntamente com outras.

As variáveis podem ser quantitativas ou qualitativas. A variável profissão é qualitativa, pois as ocorrências observadas serão “professor”, “advogado”, “administrador”, entre outras. Variáveis qualitativas são também chamadas de categóricas, pois as observações estão classificadas em categorias ou classes. Essas categorias podem estabelecer uma ordem, como tamanho (P é menor que M, e M é menor que G) ou medalha olímpica (ouro > prata > bronze), por exemplo.

As variáveis quantitativas são numéricas, e, como tal, podem ser manipuladas por operações matemáticas (soma, subtração, multiplicação etc.). Idade provavelmente é uma variável numérica: 20, 23, 30 anos. A renda também pode ser uma variável numérica: 1.000, 1.600, 2.000 reais.

É importante observar que uma variável como idade pode estar disponível em forma qualitativa. Por exemplo, um questionário de pesquisa, ao perguntar a idade, dava como opções as seguintes faixas: “de 15 a 20”, “de 20 a 30” etc. Nesse caso, a variável idade será do tipo qualitativa.

Veja na Tabela 1 uma lista de exemplos de variáveis e a descrição de seu tipo, como quantitativa (ou numérica) ou qualitativa (ou categórica).

**Tabela 1.** Exemplos de variáveis e seus tipos

| VARIÁVEL | TIPO |
|---|---|
| Número de telefones por domicílio | Quantitativa/numérica |
| Duração em minutos da chamada de longa distância mais demorada do mês | Quantitativa/numérica |
| Se alguém no domicilio possui telefone celular | Qualitativa/categórica |
| Se existe, no domicílio, conexão de internet de banda larga | Qualitativa/categórica |
| Tempo gasto fazendo compras numa livraria | Quantitativa/numérica |
| Número de livros didáticos comprados | Quantitativa/numérica |
| Área de especialização do aluno | Qualitativa/categórica |
| Sexo do aluno | Qualitativa/categórica |
| Nome do provedor de internet | Qualitativa/categórica |
| Número de compras realizadas pela internet em um mês | Quantitativa/numérica |
| Loja de departamento preferida | Qualitativa/categórica |
| Número de pares de luvas de inverno que a pessoa possui | Quantitativa/numérica |

Na execução de uma análise estatística, boa parte dos recursos (tempo, computadores, dinheiro, mão de obra etc.) será gasta na obtenção (coleta) e preparação dos dados necessários. Essa etapa anterior à análise pode consumir até 80% dos recursos e é fundamental para que as análises sejam bem-sucedidas. Os principais problemas que são resolvidos nesta etapa de preparação dos dados referem-se ao acesso à fonte dos dados, à compatibilização de diferentes formatos de dados muitas vezes provenientes de diferentes fontes e que serão usados por diferentes softwares, e à correção ou imputação de dados em função de observações com valor errado ou faltante.

## 1.4. Softwares

No início, os estudos estatísticos eram conduzidos sem nenhuma ferramenta eletrônica. A estatística é anterior ao surgimento dos computadores e calculadoras. Na época os estudos estatísticos se limitavam a poucos dados, caso contrário não seria possível concluir a análise em tempo hábil. Atualmente, porém, as análises estatísticas costumam envolver quantidades expressivas de observações, muito por conta da possibilidade de usar softwares para auxiliar em todo o processo estatístico.

A possibilidade de usar softwares facilita algumas etapas, principalmente relacionadas às operações matemáticas e à apresentação dos resultados em gráficos e tabelas. Mas o software não funciona sozinho, e é necessário que haja uma pessoa que entenda qual análise pode ser feita e como o software poderá ajudar.

O foco principal deste curso está nos conceitos estatísticos e na interpretação dos resultados. Há uma premissa de que algum software fará o esforço de manipulação e apresentação dos dados.

Existem diversos softwares estatísticos que poderiam ser usados como suporte para este curso. Softwares aplicados às ciências sociais, como o SPSS ou o STATA, ou softwares gratuitos, como o R. Mas este curso será feito com o apoio do Excel.

### 1.4.1. Excel

O Excel não é uma ferramenta estatística, na verdade. Ele foi desenvolvido na década de 1980, e sua função principal era planilhar informações de forma que pudessem ser somadas e subtraídas. Entretanto, com o passar do tempo o Excel

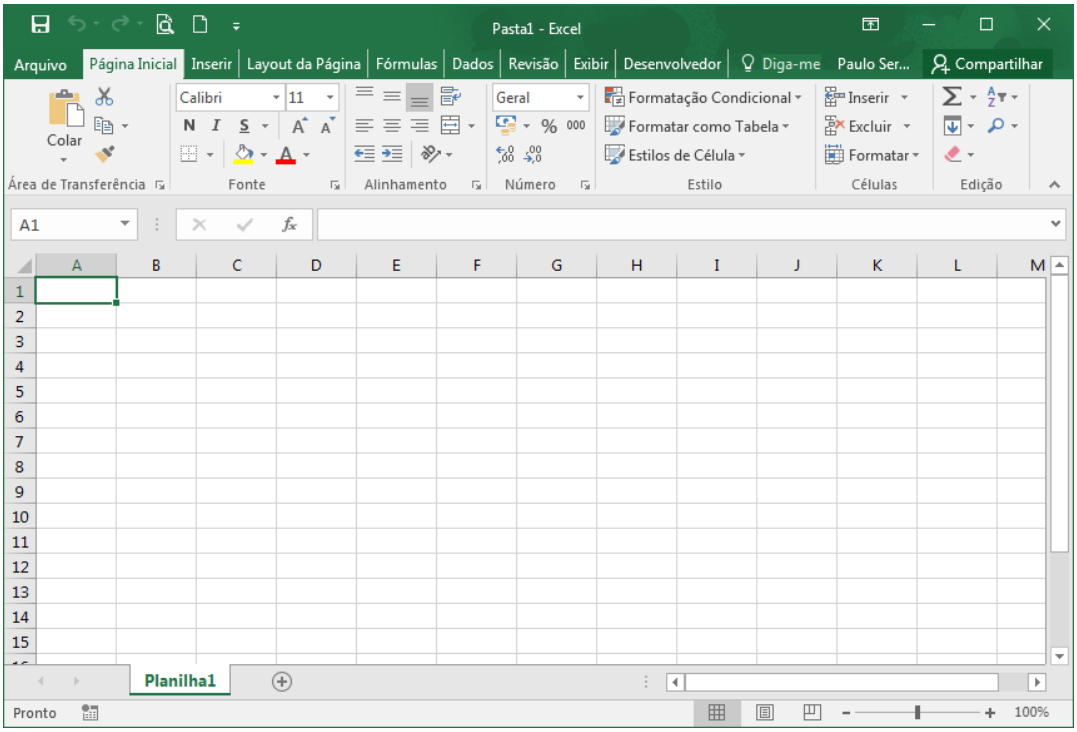
ganhou muita flexibilidade e hoje tem uma interface gráfica de alta qualidade, funções sofisticadas de integração com bancos de dados, de operações matemáticas, de análises estatísticas, de geração e manipulação de gráficos etc. Sua versatilidade é tão grande que permite que outras aplicações sejam desenvolvidas sobre sua própria plataforma.

Dentre todas as características do Excel, o principal motivo para usá-lo como suporte a este curso é sua popularidade e versatilidade. Por um lado, esse software já está disponível em praticamente todas os computadores que você vai usar, seja em casa ou no trabalho. Isso quer dizer que você não vai precisar comprar e/ou instalar um software específico para realizar esse curso. Softwares estatísticos podem ser bem caros, e a instalação de softwares em computadores no ambiente de trabalho pode requerer autorização, o que pode ser complicado.

Por outro lado, ganhar habilidade no Excel é conveniente para qualquer um. Muitas atividades e processos empresariais usam o Excel como suporte. Então, um curso de estatística que usa o Excel como ferramenta também ajudará você com diversas outras atividades.

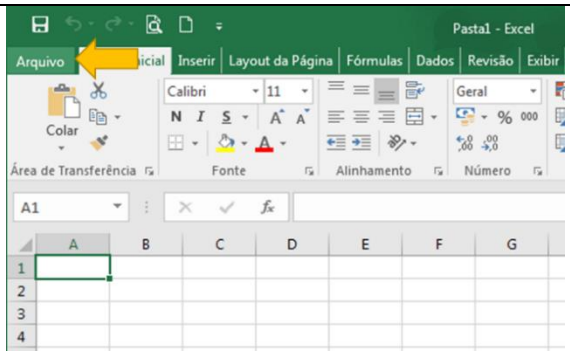
Esse curso apresentará as telas e as funções como estão disponíveis no Excel disponibilizado no Microsoft Office Professional Plus 2016. Se sua versão for diferente dessa, talvez algumas características sejam diferentes. Fique atento a isso! A interface inicial do Excel pode ser vista na Figura 1.

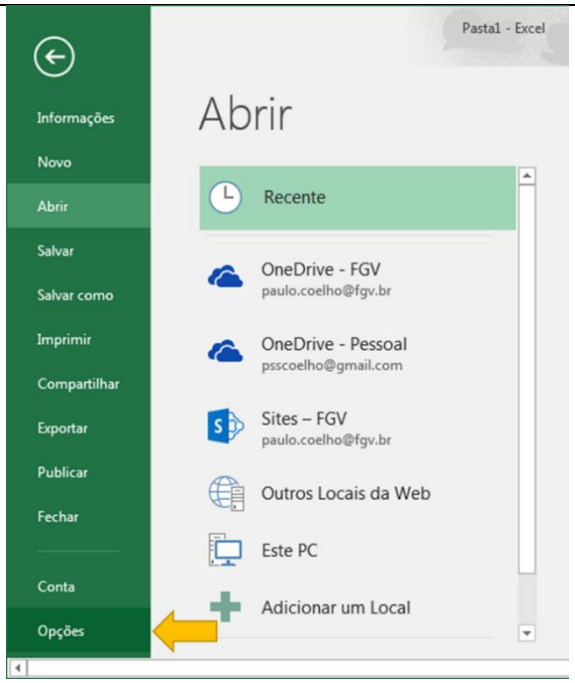
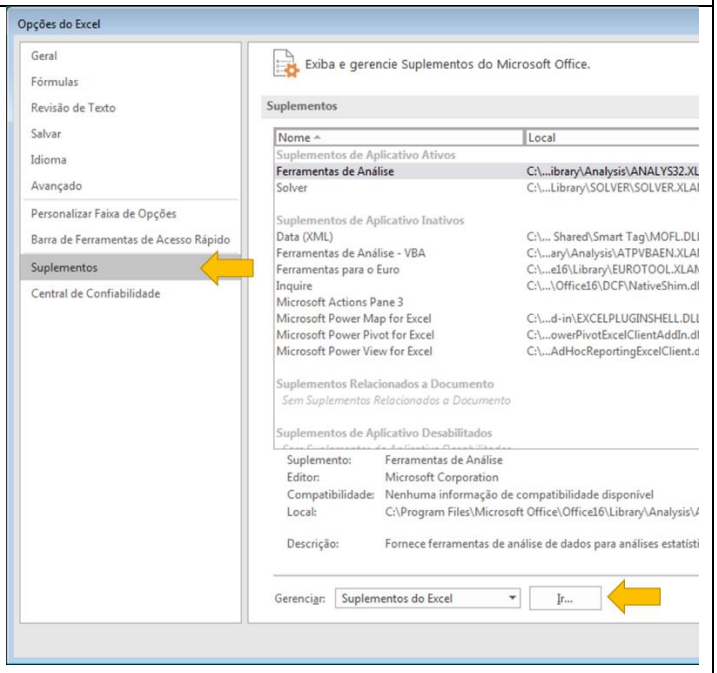
**Figura 1.** Interface inicial do Excel 2016




Se você não tem nenhuma familiaridade com o Excel, poderá ter bastante dificuldade com este curso. É importante ter em mente que o objeto deste curso é Estatística. O Excel será usado como ferramenta. Ao mesmo tempo, não é preciso ser especialista em Excel. Todas as funções e todas as funcionalidades que forem usadas serão cuidadosamente descritas.

Para seguir no curso, é recomendado que seja instalado um suplemento que vem disponível no Excel e que permite a execução de algumas análises estatísticas. O nome do suplemento é “Ferramenta de Análise”, e ele aparece disponível no menu “Dados” somente quando está habilitado. Veja abaixo os quatro passos necessários para habilitar o suplemento “Ferramenta de Análise” no Excel 2016:

| | |
|---|---|
| Passo 1: No Excel, acesse o menu “Arquivo”, que fica mais à esquerda no aplicativo |  |

| | |
|---|---|
| Passo 2: Na tela que se forma, há um menu vertical à esquerda. Acesse o ultimo menu que se chama “Opções” |  |
| Passo 3: Uma janela é aberta com o título “Opções do Excel”. Nesta tela tem um novo menu vertical. Você deve acessar a opção “Suplementos”, na parte inferior da lista. Depois disso deve clicar no botão chamado “Ir...” que surge na parte de baixo da janela. |  |

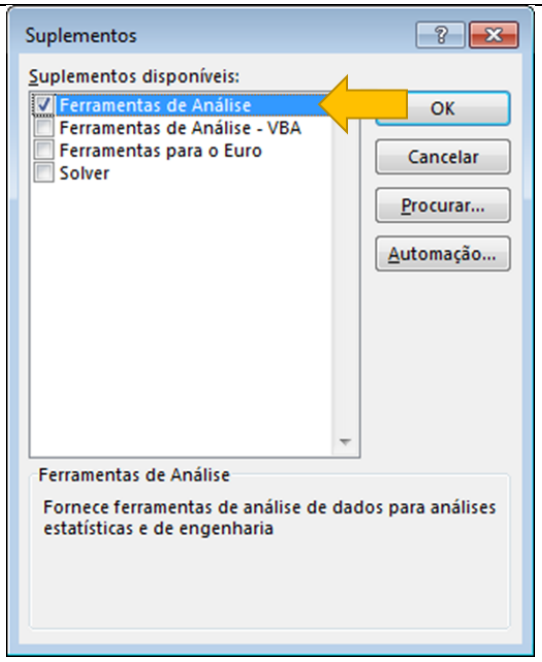
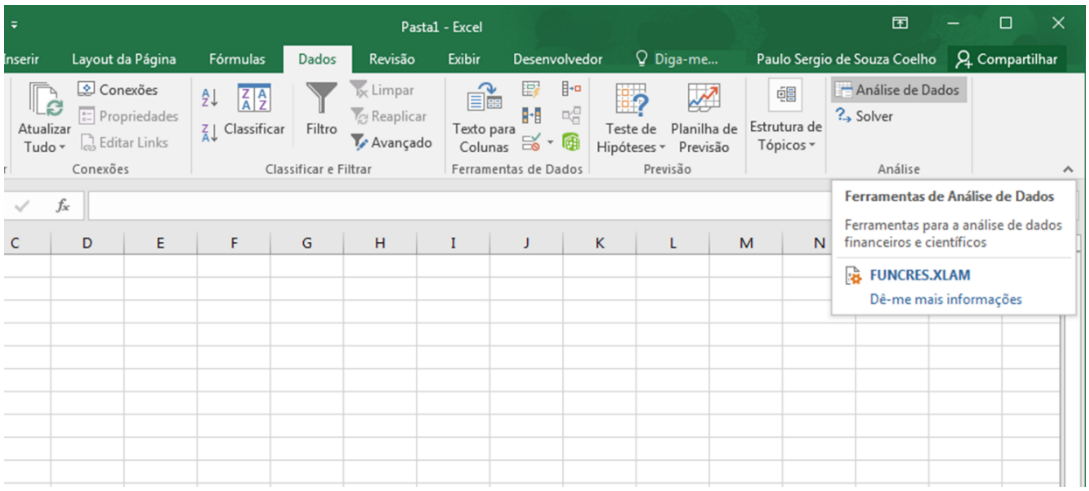
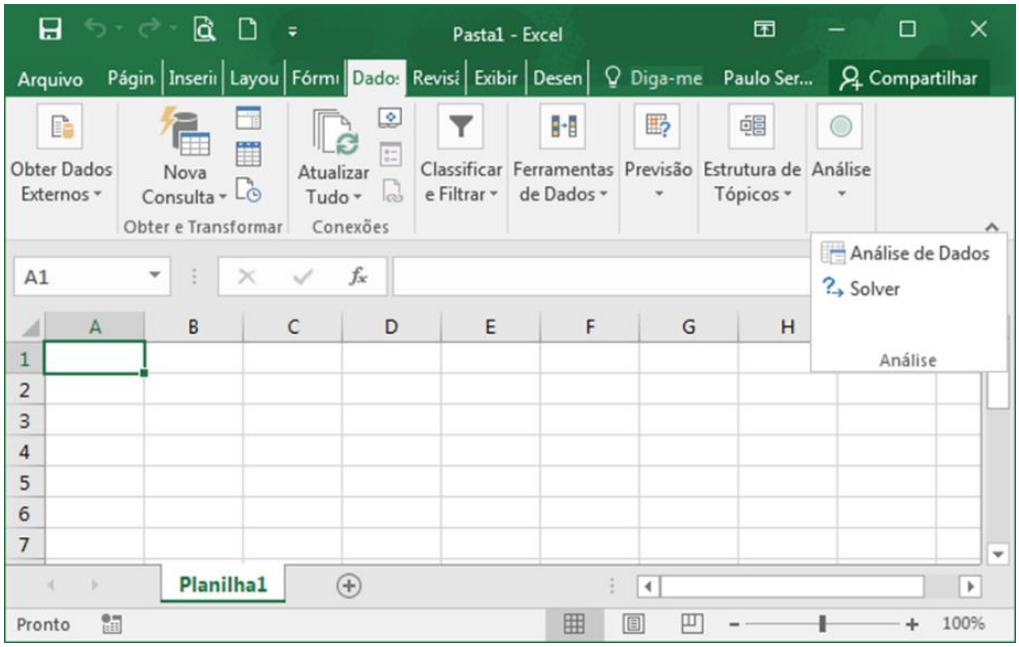
| | |
|---|---|
| Passo 4: Uma nova janela se abrirá com o nome “Suplementos”. Esta janela lista todos os suplementos que estão disponíveis para serem usados no Excel. Talvez a sua lista seja diferente da que está sendo apresentada ao lado, mas isso não é um problema. Assegure-se apenas de que a opção “Ferramentas de Análise” está selecionada e então clique em OK. |  |

**Figura 2.** O menu Dados do Excel com a opção de Análise de Dados no container Análise aberto




Para conferir se o suplemento está disponível, veja no menu Dados do Excel se há um container chamado “Análise”. A Figura 2 mostra uma tela do Excel com o container Análise aberto e a opção Análise de Dados aparecendo. Veja que a interface do Excel é dinâmica e algumas vezes os containers aparecem fechados. Quando isso correr é necessário clicar no container para exibir seu conteúdo, conforme a Figura 3.

**Figura 3.** O menu Dados do Excel com a opção de Análise de Dados no container Análise fechado



# 2. Apresentação de dados

A apresentação dos dados pode ser feita em forma de uma tabela analítica, contendo todas as informações. Essa talvez seja a forma mais básica de fazer uma apresentação dos dados, mas mesmo uma tabela pode requerer sofisticações, como ordenação segundo algum critério, ênfase em determinadas partes dos dados, totalizações globais ou parciais etc. Mas, além das tabelas, os gráficos são uma forma importante de organizar as informações permitindo enfatizar padrões e tendências.

## 2.1. Usando a tabela dinâmica do Excel

O Excel apresenta uma valiosa ferramenta para organizar e apresentar os dados, permitindo ordenação, filtro e agrupamento dinâmico. Essa ferramenta chama-se tabela dinâmica. Para construir uma tabela dinâmica, é necessário ter uma base de dados onde as variáveis estão organizadas em forma de tabela: cada coluna é uma variável, e cada linha é uma unidade observada.

**Caso pesquisa de operadora de celular**

Uma pesquisa foi feita para identificar padrões de comportamento entre usuários de celular. O questionário de pesquisa tinha apenas 4 perguntas:

**Questionário:**

Qual o seu sexo: {masculino feminino}

Qual a sua etnia: {branco negro outro}

Qual a sua idade:

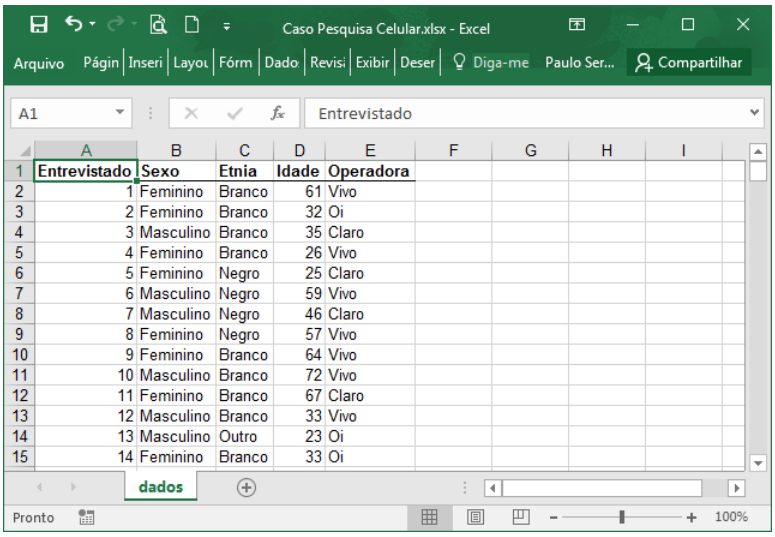
Qual a sua operadora de celular: {Vivo Oi Claro Tim}

A pergunta sobre a idade permitia como resposta qualquer número inteiro. Mas as outras 3 perguntas tinham respostas pré-selecionadas, conforme descritas acima.

Os dados de reposta estão disponíveis no arquivo **Caso Pesquisa Celular.xlsx**, que está reproduzido na Figura 4. O arquivo apresenta 5 colunas, sendo uma para cada variável observada na pesquisa e uma coluna adicional, que aparece como primeira variável, que serve para identificar o entrevistado. Essa identificação é um código

que serve para registrar que todas as informações de uma mesma linha são do mesmo entrevistado.

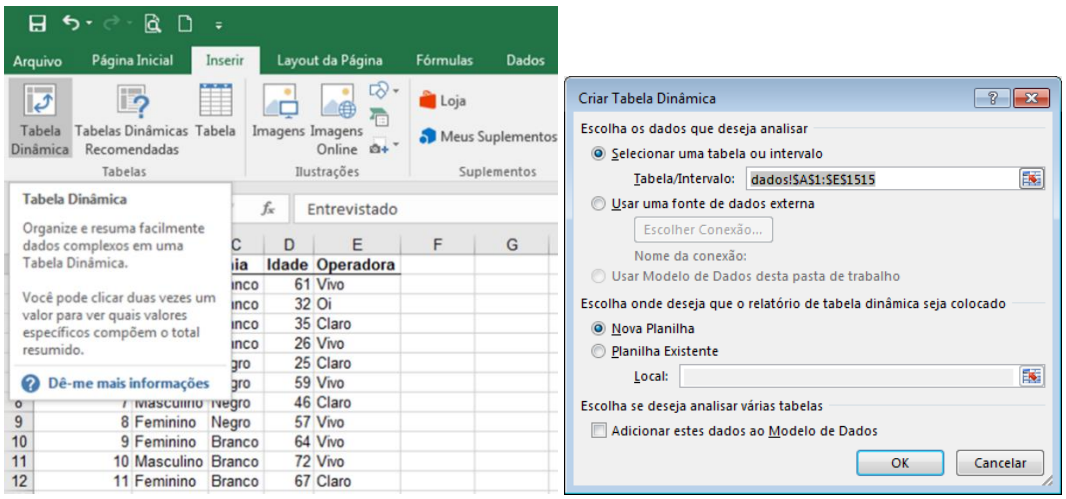
**Figura 4.** Parte do arquivo Caso Pesquisa Celular.xlsx




| | A | B | C | D | E |
|---|---|---|---|---|---|
| 1 | Entrevistado | Sexo | Etnia | Idade | Operadora |
| 2 | 1 | Feminino | Branco | 61 | Vivo |
| 3 | 2 | Feminino | Branco | 32 | Oi |
| 4 | 3 | Masculino | Branco | 35 | Claro |
| 5 | 4 | Feminino | Branco | 26 | Vivo |
| 6 | 5 | Feminino | Negro | 25 | Claro |
| 7 | 6 | Masculino | Negro | 59 | Vivo |
| 8 | 7 | Masculino | Negro | 46 | Claro |
| 9 | 8 | Feminino | Negro | 57 | Vivo |
| 10 | 9 | Feminino | Branco | 64 | Vivo |
| 11 | 10 | Masculino | Branco | 72 | Vivo |
| 12 | 11 | Feminino | Branco | 67 | Claro |
| 13 | 12 | Masculino | Branco | 33 | Vivo |
| 14 | 13 | Masculino | Outro | 23 | Oi |
| 15 | 14 | Feminino | Branco | 33 | Oi |

Para acionar a tabela dinâmica você precisa ter como célula ativa qualquer célula da tabela de dados do arquivo. Na Figura 4 a célula ativa é o rótulo “Entrevistado”. Qualquer rótulo ou qualquer valor pode estar selecionado antes de acionar a tabela dinâmica, que é feita a partir do menu Inserir, como pode ser visto na janela do Excel que está à esquerda na Figura 5.

**Figura 5.** Inserindo uma tabela dinâmica

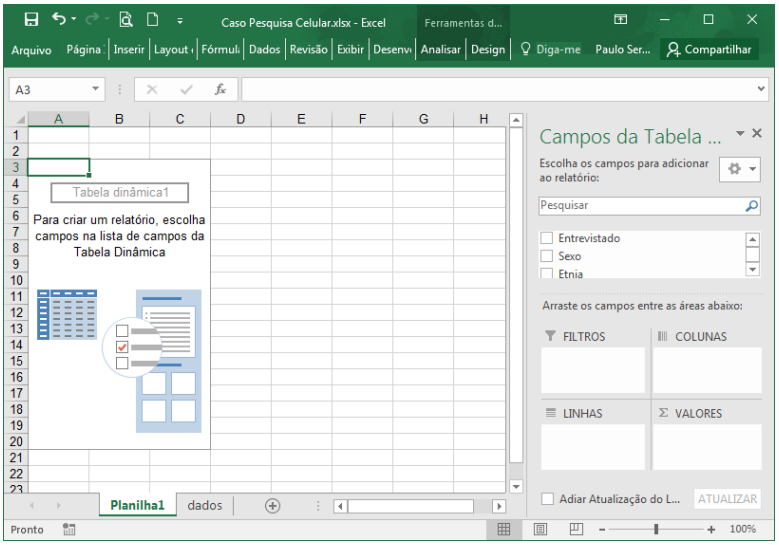



Para criar a tabela dinâmica, é necessário clicar no OK da janela “Criar Tabela Dinâmica”. Os parâmetros pré-selecionados nesta janela já estão corretos, mas é importante conferir que em “Tabela/Intervalo” está a referência a todo o conjunto de

dados e que “Nova Planilha” esteja selecionada como o local que o relatório será colocado.

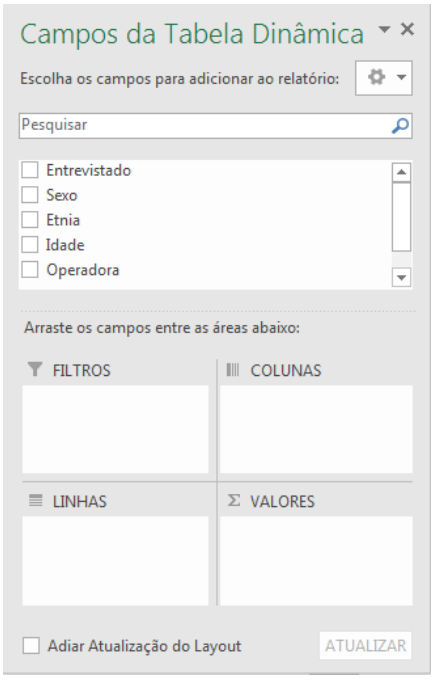
Se tudo tiver funcionado corretamente, você terá uma nova planilha no seu arquivo (uma nova aba na parte inferior da janela do Excel) com o nome “Planilha1”, onde a tabela dinâmica ganhará forma. A Planilha1 deverá ter a forma que aparece na Figura 6. Observe que há uma caixa sobre a planilha, ao lado esquerdo da tela do Excel com o nome “Tabela dinâmica 1” e há uma janela de comandos sob o título “Campos da Tabela Dinâmica” ao lado esquerdo da tela do Excel. Se a Tabela Dinâmica (caixa à esquerda) não estiver selecionada, a janela de comandos desaparecerá. Para a janela de comandos aparecer, basta clicar novamente na Tabela Dinâmica.

**Figura 6.** Planilha com Tabela Dinâmica



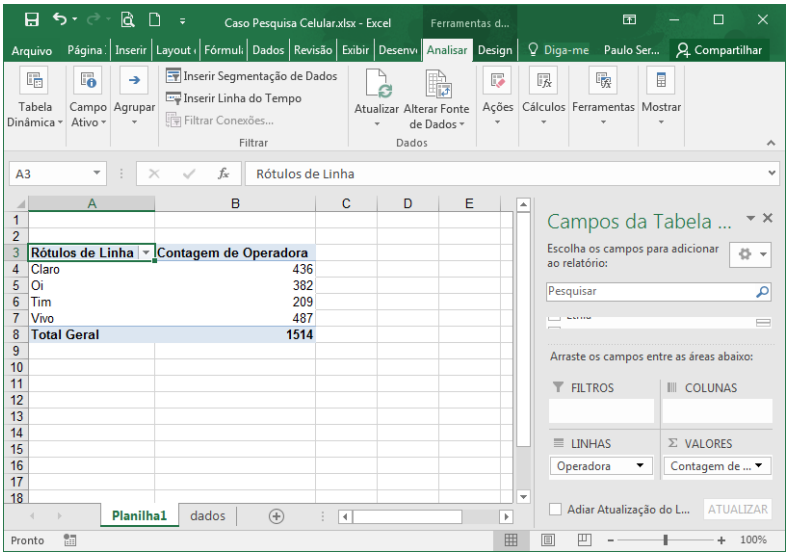

Você vai usar a janela de comandos para dar à Tabela Dinâmica um aspecto funcional, então precisa entender como funciona essa janela. Ela tem duas partes principais: a parte de cima, com a lista de variáveis disponíveis, conforme encontrado na planilha dados, e a parte de baixo, com as quatro áreas que a Tabela Dinâmica possui.

**Figura 7.** Janela de comandos campos da tabela dinâmica



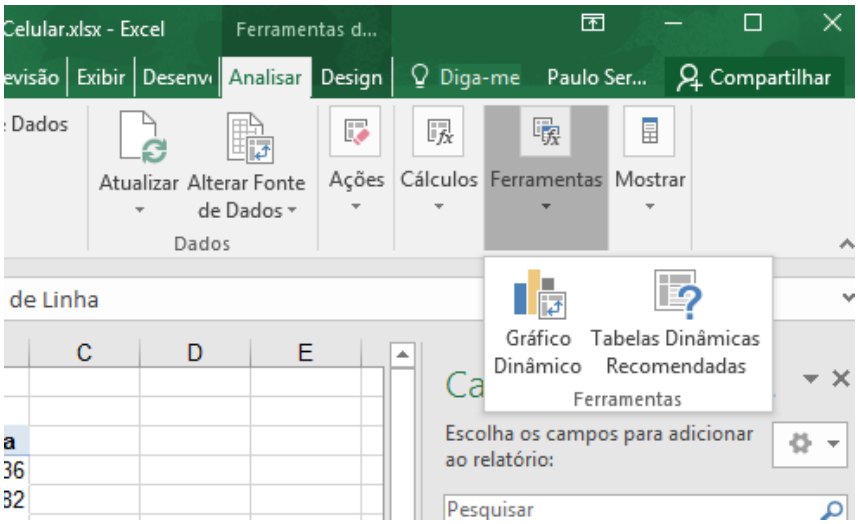

Por exemplo, se você clicar no nome da variável Operadora, que aparece na parte de cima da janela de comando, e arrastar para a área chamada de LINHAS, ou se você simplesmente clicar sobre a variável Operadora, sua Tabela dinâmica ganhará um aspecto diferente, que mostra que o conteúdo da variável Operadora é, de fato, as opções Claro, Oi, Tim e Vivo. Para contar quantas ocorrências existem em cada opção, você deve clicar novamente na variável Operadora e arrastar para a área VALORES. O resultado, após colocar a variável Operadora nas áreas de LINHAS e VALORES, pode ser visto na Figura 8.

**Figura 8.** Tabela com a variável Operadora nas áreas LINHAS e VALORES



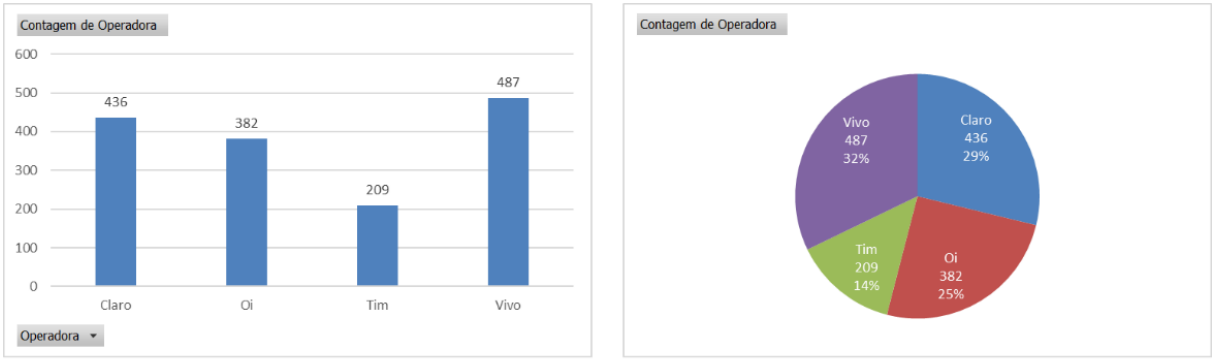
A Tabela Dinâmica permite ver a quantidade de respondentes que optou por cada operadora de celular, bem como a quantidade total de respostas. Para ver essas informações na forma de gráfico basta acessar a opção “Gráfico Dinâmico” que aparece no container “Ferramentas” que está no menu “Analisar” das “Ferramentas de Tabela Dinâmica”, conforme a Figura 9. Veja que este menu só aparece quando a célula ativa está sobre a Tabela Dinâmica.

**Figura 9.** Inserindo um gráfico dinâmico do container “Ferramentas” do menu “Analisar” das “Ferramentas de Tabela Dinâmica”




O Excel apresenta diversos gráficos e diversas opções para formatação do gráfico e para complementar informações ao gráfico. Algumas formas interessantes de apresentar essas informações estão disponíveis na Figura 10, onde já estão aplicadas algumas opções de rótulo e formato dos dados. Uma característica importante dos gráficos dinâmicos é que eles estão ligados à Tabela Dinâmica, de modo que uma alteração no gráfico vai alterar também a tabela dinâmica, e vice-versa.

**Figura 10.** Gráficos dinâmicos




(a) Gráfico de colunas

(b) Gráfico de pizza

Você poderá usar a ferramenta de Tabela Dinâmica para gerar quase todas as tabelas e gráficos necessários para apresentar os dados do seu projeto. O passo a passo no Excel para construir essas tabelas ou gráficos com as opções de formatação ou de detalhes não será detalhado aqui, já que este não é um curso de Excel. Mas a interface do Excel é bastante autoexplicativa, e há tutoriais na internet para aprender a manipular essa ferramenta e chegar ao formato final que você quiser.

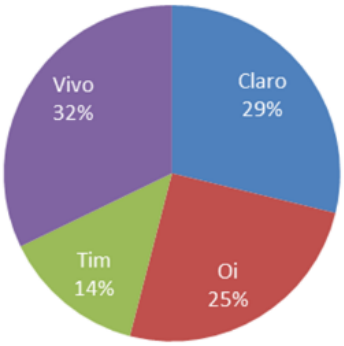
## 2.2. Dados qualitativos

A apresentação dos dados categóricos é, basicamente, exibir a frequência de ocorrência de cada categoria. Isso pode ser feito através de tabelas ou de gráficos. Por exemplo, podemos apresentar os dados sobre a operadora na forma de tabela ou na forma de gráfico (Figura 11).

A frequência de cada categoria pode ser apresentada em valores absolutos (quantidade) ou em valores relativos (percentuais). A frequência relativa é muito útil quando há interesse de comparar as ocorrências entre si, identificando os maiores e menores. A visão dos valores em percentual permite identificar facilmente se a diferença de tamanho entre as classes é significativa ou não. A frequência absoluta é útil quando a análise não é comparativa.

**Figura 11.** Tabela e gráfico para apresentar dados categóricos

| Operadora | Quantidade | % |
|---|---|---|
| Claro | 436 | 28,8% |
| Oi | 382 | 25,2% |
| Tim | 209 | 13,8% |
| Vivo | 487 | 32,2% |
| **Total Geral** | **1.514** | **100,0%** |




### 2.2.1. Tabelas de frequência e tabelas de dupla entrada

Quando duas variáveis estão sob análise, é possível usar as tabelas de frequência em um formato que permite analisar o comportamento segmentado pelas duas variáveis. Por exemplo, para verificar se a preferência por operadora é sensível ao gênero (sexo) do usuário, seria possível considerar uma das tabelas que podem ser vistas na Figura 12.

**Figura 12.** Opções de tabela de dupla entrada

| Operadora | Feminino | Masculino | Total Geral |
|---|---|---|---|
| Claro | 257 | 179 | 436 |
| Oi | 232 | 150 | 382 |
| Tim | 108 | 101 | 209 |
| Vivo | 281 | 206 | 487 |
| **Total Geral** | **878** | **636** | **1514** |

(a) Valores absolutos

| Operadora | Feminino | Masculino | Total Geral |
|---|---|---|---|
| Claro | 17,0% | 11,8% | 28,8% |
| Oi | 15,3% | 9,9% | 25,2% |
| Tim | 7,1% | 6,7% | 13,8% |
| Vivo | 18,6% | 13,6% | 32,2% |
| **Total Geral** | **58,0%** | **42,0%** | **100,0%** |

(b) Valores relativos ao total geral

| Operadora | Feminino | Masculino | Total Geral |
|---|---|---|---|
| Claro | 29,3% | 28,1% | 28,8% |
| Oi | 26,4% | 23,6% | 25,2% |
| Tim | 12,3% | 15,9% | 13,8% |
| Vivo | 32,0% | 32,4% | 32,2% |
| **Total Geral** | **100,0%** | **100,0%** | **100,0%** |

(c) Valores relativos ao total da coluna

| Operadora | Feminino | Masculino | Total Geral |
|---|---|---|---|
| Claro | 58,9% | 41,1% | 100,0% |
| Oi | 60,7% | 39,3% | 100,0% |
| Tim | 51,7% | 48,3% | 100,0% |
| Vivo | 57,7% | 42,3% | 100,0% |
| **Total Geral** | **58,0%** | **42,0%** | **100,0%** |

(d) Valores relativos ao total da linha

A tabela em (a) mostra os valores absolutos em cada cruzamento de variáveis. Por exemplo, há 257 mulheres que usam a Claro, enquanto há 179 homens que usam a Claro. O total de pessoas que usam a Claro aparece no Total Geral da linha, que é 436. Veja que o Total Geral das linhas, que medem as quantidades de pessoas que optaram por cada operador, são os mesmos valores que apareceram nas análises iniciais (veja Figura 8, Figura **10** e Figura **11**). Além disso, a linha de Total Geral

apresenta a quantidade de mulheres e homens que responderam à pesquisa: 878 e 636, respectivamente.

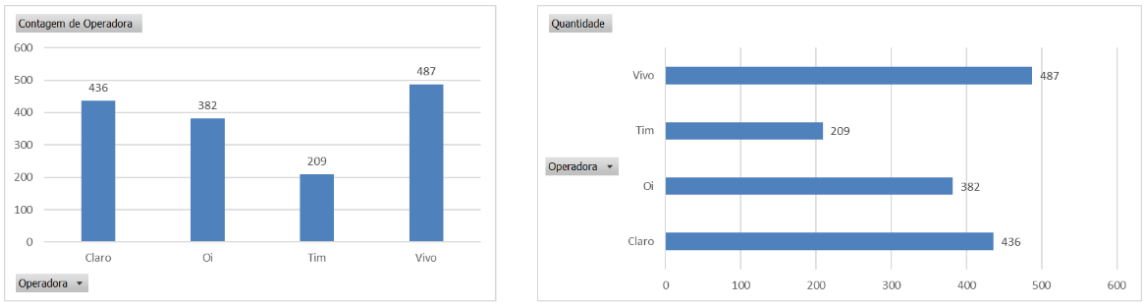
As demais tabelas mostram as frequências relativas em vez dos valores absolutos. Mas há uma diferença importante entre elas. A tabela em (b) mostra as frequências relativas ao total geral – total de respostas. Ou seja, afirma que as mulheres que usam Claro (que são 257, conforme visto na tabela (a)) representam 17% do total (que é 1.514, conforme visto na tabela (a)). Já a tabela em (c) mostra as frequências relativas ao total da coluna – total de cada sexo, ou seja, afirma que as mulheres que usam a Claro representam 29,3% do total de mulheres (257/878 dá 29,3%). Finalmente, a tabela em (d) mostra as frequências relativas ao total da linha – total de cada operadora.

### 2.2.2. Gráficos para dados categóricos

Os gráficos categóricos costumam ser apresentados em forma de colunas, barras ou pizza.

Os gráficos de coluna ou de barra têm basicamente a mesma utilidade: eles funcionam bem para mostrar as frequências absolutas. A única diferença entre eles é a disposição dos elementos gráficos. Isso pode ser observado na Figura 13. Já os gráficos de pizza têm maior utilidade para representar frequências relativas, pois os tamanhos das fatias da pizza são proporcionais à frequência de cada categoria, servindo, portanto, para comparação entre categorias. O gráfico de pizza para essa variável foi apresentado na Figura 11.

**Figura 13.** Gráficos para uma única variável categórica



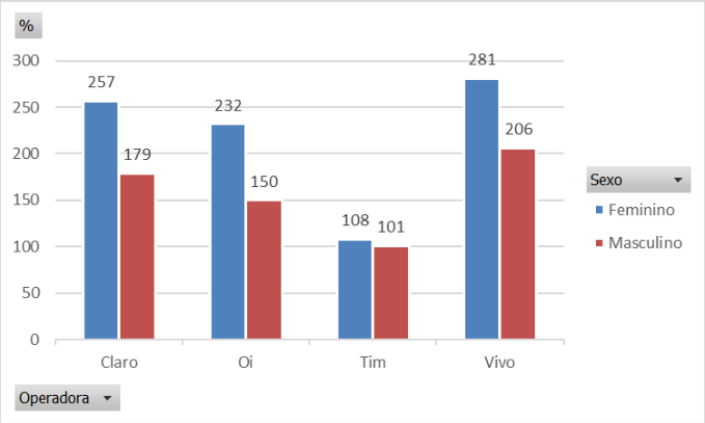

(a) Gráfico de colunas

(b) Gráfico de barra

Os gráficos de coluna e barra têm aplicação importante para as tabelas de dupla entrada, pois o recurso da cor das colunas ou das barras pode ser usado para

representar a outra variável. Veja, por exemplo, como fica a representação da Tabela que está na Figura 12 (a) através de um gráfico de colunas na Figura 14.

**Figura 14.** Gráfico de colunas para tabela de dupla entrada




## 2.3. Dados quantitativos

A apresentação de uma única variável quantitativa não é tão fácil de ser feita como no caso da variável qualitativa. Por exemplo, considere os dados do arquivo **Caso Passagens Rio Salvador.xlsx**. Há um total de 60 diferentes preços de passagens aéreas do Rio de Janeiro para Salvador. Esses preços foram cotados de diferentes companhias aéreas e em diferentes momentos. As informações disponíveis não incluem qual foi a companhia aérea nem quando a cotação de preço foi realizada. Os dados na forma original em que foram disponibilizados podem ser vistos na Tabela 2.

**Tabela 2.** Preços de passagem Rio-Salvador

| | | | | | |
|---|---|---|---|---|---|
| 950 | 2000 | 870 | 1100 | 1700 | 1350 |
| 1200 | 900 | 1050 | 1150 | 2000 | 1600 |
| 1050 | 1500 | 670 | 950 | 1400 | 1500 |
| 1100 | 1300 | 1250 | 1280 | 1500 | 1800 |
| 1300 | 700 | 1200 | 1700 | 1390 | 870 |

| | | | | | |
|---|---|---|---|---|---|
| 1420 | 2100 | 1100 | 1800 | 1750 | 1650 |
| 1280 | 2000 | 750 | 1300 | 2150 | 1550 |
| 900 | 1200 | 800 | 1350 | 1450 | 1250 |
| 1380 | 1450 | 800 | 1900 | 900 | 1200 |
| 1000 | 1700 | 1250 | 450 | 1550 | 1750 |

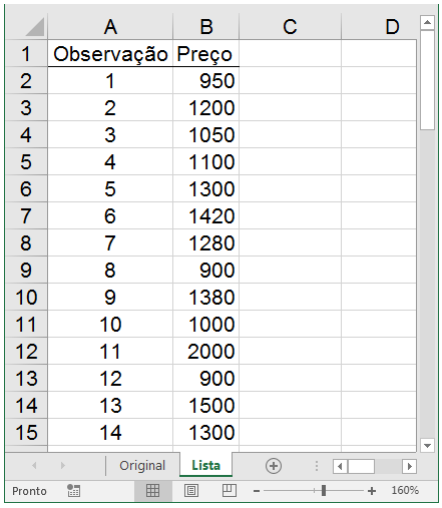
Na forma como estão disponíveis os dados, é muito difícil extrair alguma informação. Por exemplo, localizar o menor e o maior valores requer certo esforço e bastante atenção. Se você tentou localizar, tem grande chance de não ter encontrado os valores certos, que são 450 e 2.150, respectivamente.

### 2.3.1. Ordenação de dados numéricos

O maior problema na forma como os dados estão apresentados é a ausência de uma lista. As 60 observações representam uma única variável, portanto deveriam ser apresentadas em uma única coluna. A apresentação em forma de tabela até permite olhar todos os dados juntos, mas é muito pouco prática.

No arquivo **Caso Passagens Rio Salvador.xlsx**, há uma outra planilha que se chama “Lista”, onde os dados estão apresentados de forma mais adequada. A primeira coluna contém um identificador da observação (um número sequencial), e a segunda coluna contém as informações da variável que queremos analisar. Os dados não estão ordenados, como pode ser visto na Figura 15.

**Figura 15.** Dados dispostos em lista



| | A | B | C | D |
|---|---|---|---|---|
| 1 | Observação | Preço | | |
| 2 | 1 | 950 | | |
| 3 | 2 | 1200 | | |
| 4 | 3 | 1050 | | |
| 5 | 4 | 1100 | | |
| 6 | 5 | 1300 | | |
| 7 | 6 | 1420 | | |
| 8 | 7 | 1280 | | |
| 9 | 8 | 900 | | |
| 10 | 9 | 1380 | | |
| 11 | 10 | 1000 | | |
| 12 | 11 | 2000 | | |
| 13 | 12 | 900 | | |
| 14 | 13 | 1500 | | |
| 15 | 14 | 1300 | | |

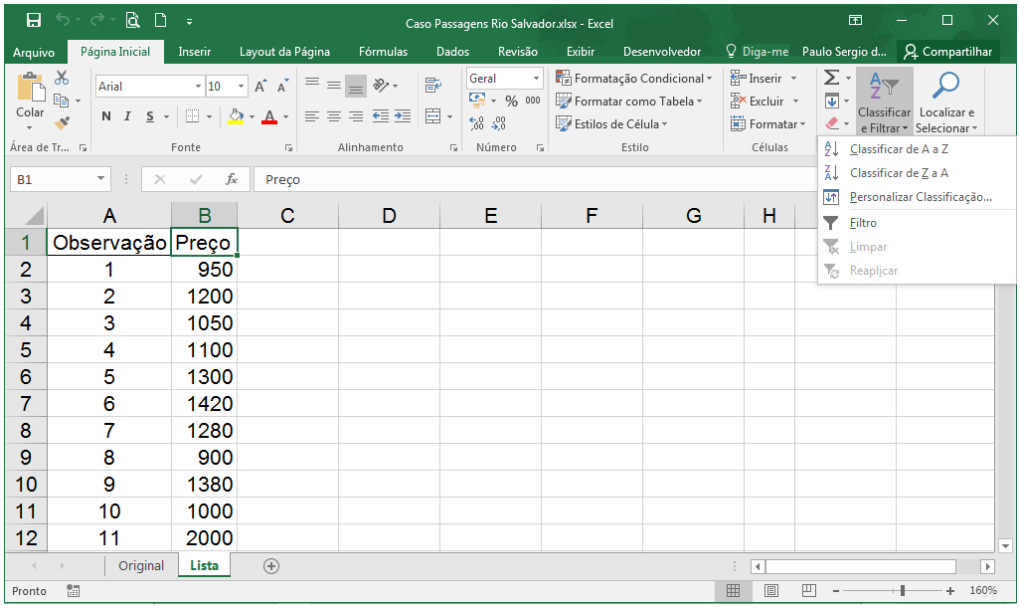


A partir dos dados em lista é possível ordená-los de forma física ou criar uma variável de índice que funcionará como um ranking. Essa estratégia é chamada de ordenação lógica, ou indireta.

Para realizar a ordenação física é possível usar a ferramenta “Classificar e Filtrar” do Excel ou aplicar o autofiltro e depois usar o botão no cabeçalho para ordenar.

Para acessar a ferramenta “Classificar e Filtrar”, veja na Figura 16. Os dois primeiros comandos fazem uma ordenação crescente e decrescente, respectivamente. A lista ficará ordenada pela variável onde está a célula ativa, no caso “Preço”. O comando “Personalizar Classificação” abre uma caixa de opções que permite definir níveis de classificação, o que é útil quando há diversas variáveis. Os níveis mais inferiores de classificação vão sendo usados quando há empate nos níveis anteriores. O comando “Filtro” aplica o autofiltro, que coloca em cada célula no topo da lista um botão que permite acessar comandos específicos de filtro (seleção) e ordenação.

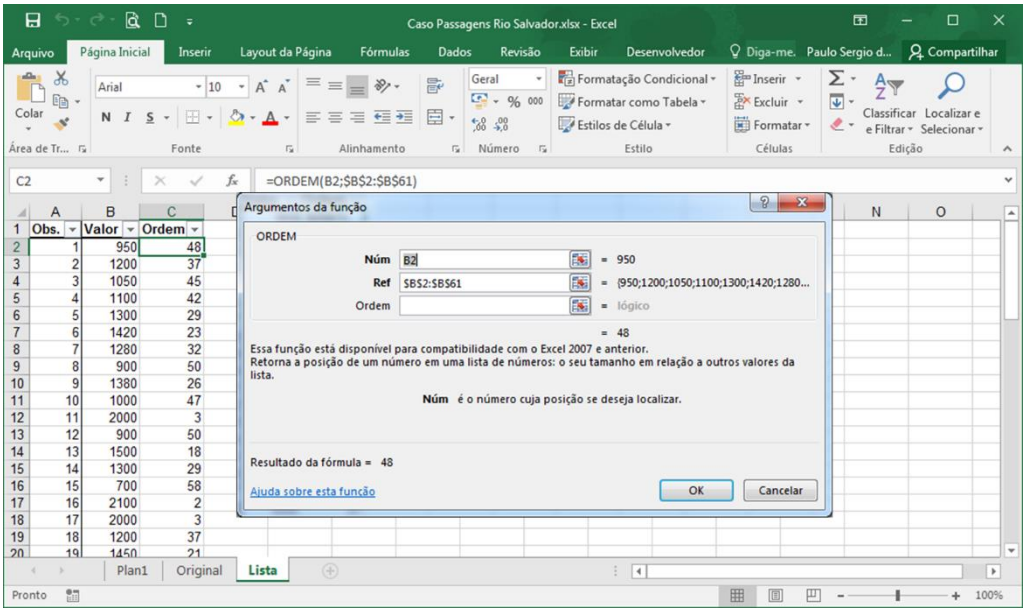
**Figura 16.** Ferramenta “Classificar e Filtrar”




| | A | B |
|---|---|---|
| 1 | Observação | Preço |
| 2 | 1 | 950 |
| 3 | 2 | 1200 |
| 4 | 3 | 1050 |
| 5 | 4 | 1100 |
| 6 | 5 | 1300 |
| 7 | 6 | 1420 |
| 8 | 7 | 1280 |
| 9 | 8 | 900 |
| 10 | 9 | 1380 |
| 11 | 10 | 1000 |
| 12 | 11 | 2000 |

A ordenação lógica, ou indireta, é feita criando-se uma nova variável na lista, que é a variável de índice. Essa variável informará a posição em que a observação se encontra numa lista ordenada. Para criar a variável de índice usamos a função ORDEM, conforme pode ser visto na Figura 17. A função ORDEM permite criar a variável índice para uma ordenação crescente ou decrescente. Isso é controlado com o último parâmetro.

**Figura 17.** Criando a variável índice para ordenação lógica

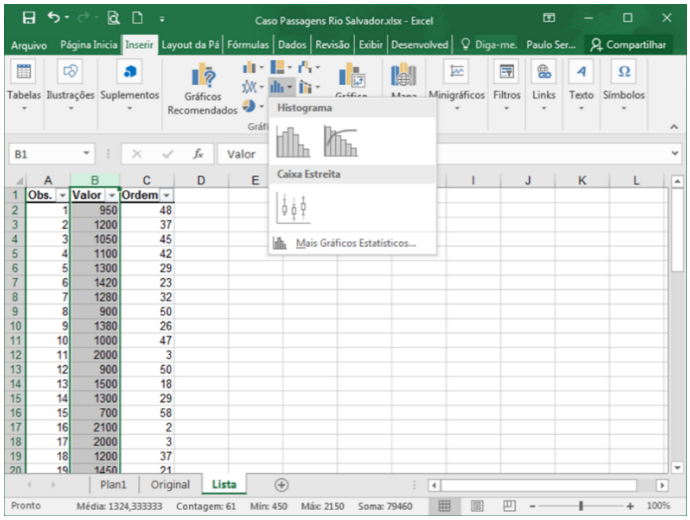



## 2.3.2. Gráficos para dados numéricos

As variáveis numéricas costumam ser apresentadas em gráficos muito específicos. Quando se analisa uma única variável, usa-se o histograma. Quando se analisam duas variáveis conjuntamente, usa-se o diagrama de dispersão.

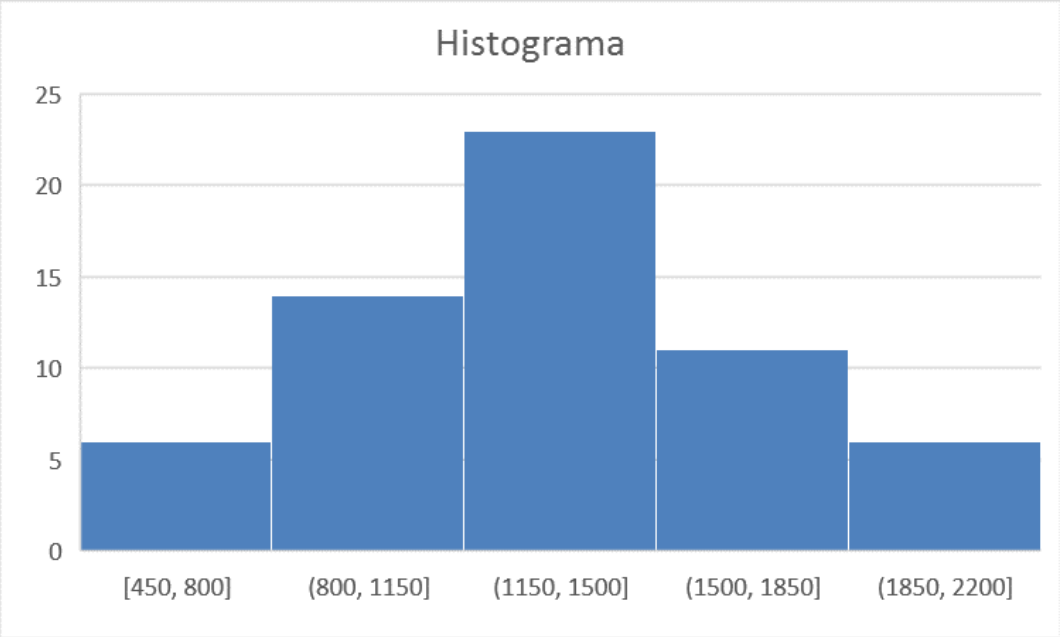
Para as novas versões do Excel, o histograma é gerado automaticamente como um subtipo dos Gráficos Estatísticos. Na Figura 18**Figura 17** pode-se ver onde são inseridos os Gráficos Estatísticos e que há 3 subtipos: o histograma, o Pareto e o "Caixa Estreita", geralmente chamado de box plot.

**Figura 18.** Gráficos estatísticos



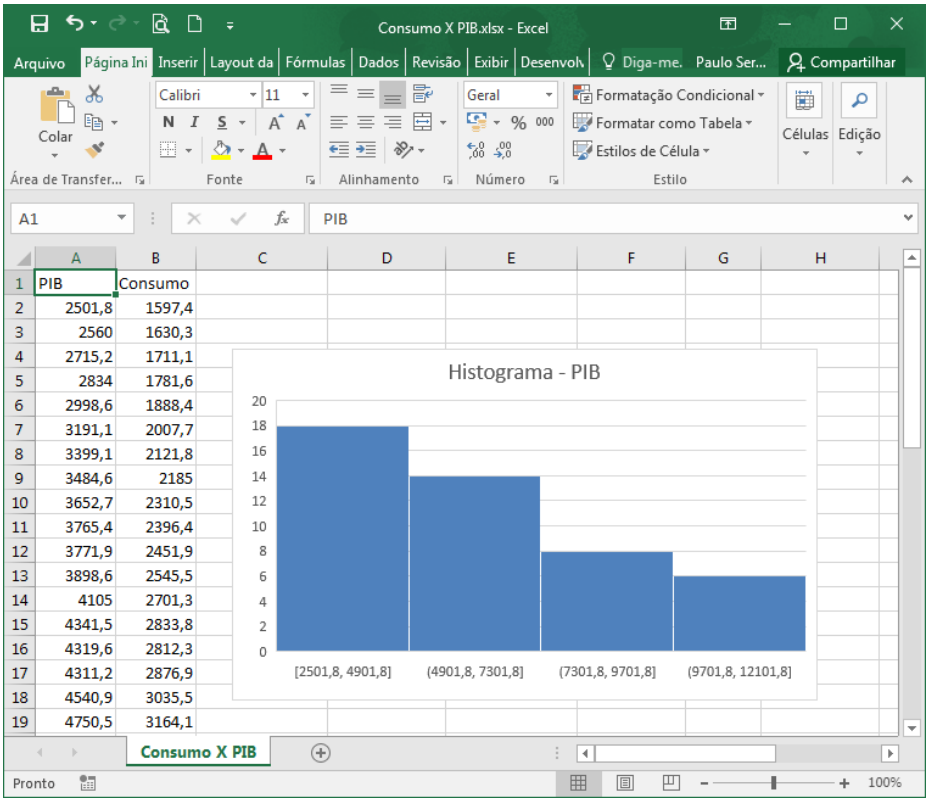
Para elaborar um histograma, é preciso criar intervalos e contar a quantidade de ocorrências em cada um deles. O histograma na Figura 19 foi obtido com a configuração padrão do Excel. Ele sinaliza que há seis observações entre os valores 450 e 800 (primeira coluna), 14 observações entre 800 e 1.150 (segunda coluna), e assim sucessivamente. Veja que o primeiro intervalo está descrito como [450, 800] indicando que ocorrências com valor entre 450 e 800 estão sendo contadas como pertencentes a este intervalo. Já o segundo intervalo está descrito como (800, 1150], indicando que o valor 800 não pertence ao primeiro intervalo.

**Figura 19.** Histograma




O histograma permite analisar os valores mais frequentes do preço. Percebe-se que os preços mais comuns são maiores que R$1.130,00 e até R$1.470,00. É possível ver também que o comportamento é quase simétrico ao redor deste segmento mais frequente; ou seja, a frequência de ocorrência vai diminuindo tanto nos segmentos dos preços maiores (à direita no histograma) quanto nos segmentos menores (à esquerda no histograma). Esse formato simétrico nem sempre é observado. Na Figura 20 é possível ver o histograma da variável PIB listada no arquivo **Consumo X PIB.xlsx**, que apresenta um formato assimétrico: os segmentos com menores valores de PIB têm frequência maior do que os segmentos com maiores valores de PIB. Ou seja, é mais fácil encontrar ocorrências de PIB menores e mais raro encontrar ocorrências de PIB maiores.

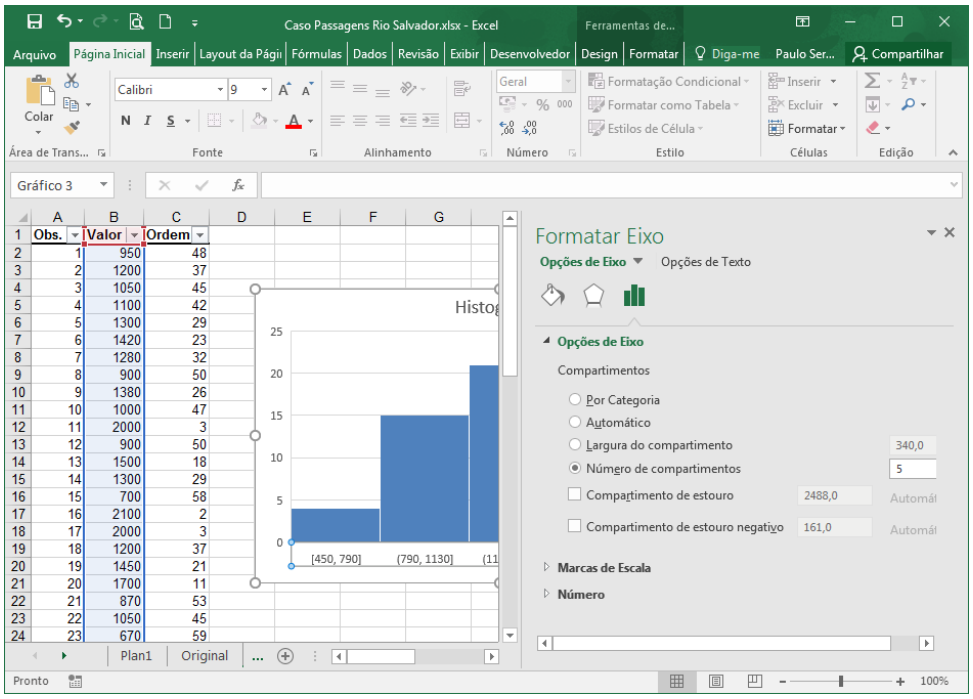
**Figura 20.** Histograma do PIB




| PIB | Consumo |
|---|---|
| 2501,8 | 1597,4 |
| 2560 | 1630,3 |
| 2715,2 | 1711,1 |
| 2834 | 1781,6 |
| 2998,6 | 1888,4 |
| 3191,1 | 2007,7 |
| 3399,1 | 2121,8 |
| 3484,6 | 2185 |
| 3652,7 | 2310,5 |
| 3765,4 | 2396,4 |
| 3771,9 | 2451,9 |
| 3898,6 | 2545,5 |
| 4105 | 2701,3 |
| 4341,5 | 2833,8 |
| 4319,6 | 2812,3 |
| 4311,2 | 2876,9 |
| 4540,9 | 3035,5 |
| 4750,5 | 3164,1 |

O histograma pode ser alterado, podendo haver mais ou menos colunas. Isso pode ser controlado formatando-se o eixo horizontal (clique sobre os valores do eixo horizontal para acessar a tela de diálogo), o que pode ser visto na Figura 21. O controle é feito principalmente através da quantidade de compartimentos (grupos ou colunas) ou da largura destes compartimentos. No exemplo da Figura 19, o histograma tem 5 compartimentos, com largura igual a 350. Aumentar a quantidade de compartimentos vai diminuir a largura, e vice-versa.

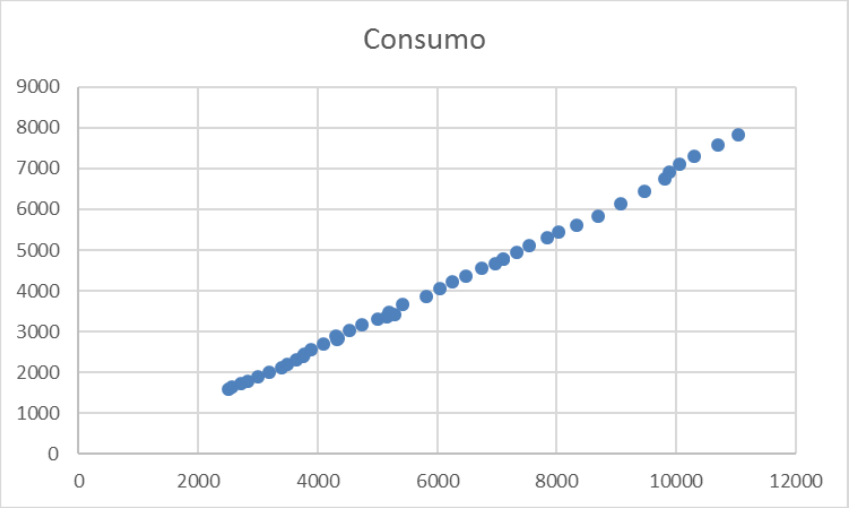
**Figura 21.** Configuração do histograma




Os outros dois gráficos estatísticos disponíveis são o gráfico de Pareto, que apresenta as colunas do histograma ordenadas da maior ou mais frequente para a menor ou menos frequente junto com a curva de frequência acumulada e relativa e o box plot (o Excel chama de “Caixa Estreita”), que informa algumas medidas da variável. Essas medidas serão examinadas posteriormente, e então o gráfico será mais bem entendido.

De volta ao arquivo **Consumo X PIB.xlsx**, é possível construir um gráfico que apresente a relação entre as duas variáveis listadas. Esse gráfico é chamado de Diagrama de Dispersão e serve para analisar o comportamento simultâneo de duas variáveis. Em geral, esse gráfico é usado para identificar tendências de correlação, como ocorre na Figura 22: a variável Consumo está sendo analisada contra o PIB. Cada ponto no gráfico representa um valor de Consumo (no eixo Y) e um valor de PIB (no eixo X). Isso é controlado através da caixa de diálogo “Selecionar Dados”. Percebe-se que quando o PIB é maior o Consumo é maior, e vice-versa.

**Figura 22.** Diagrama de dispersão




A análise simultânea de variáveis é estudada de forma mais completa em “Estatística Multivariada”. Por ora, nosso objetivo é a análise de cada variável individualmente. O diagrama de dispersão será abordado em Estatística II.

# 3. Estatística descritiva

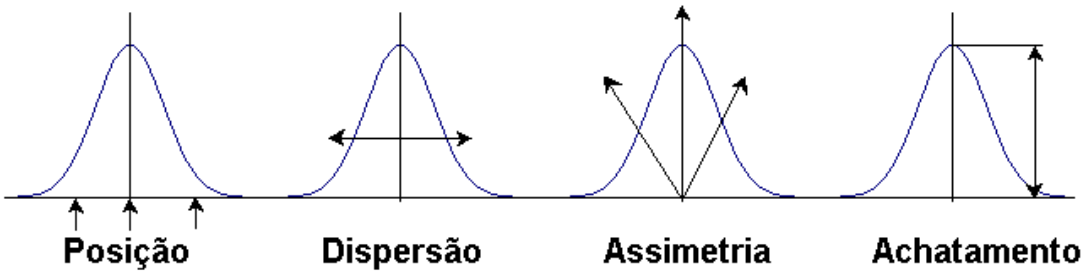
Neste capítulo serão apresentadas as técnicas estatísticas de resumo dos dados. Existem diversas medidas que servem para explicitar as características dos dados que estão sendo analisados. As medidas para variáveis numéricas são calculadas de forma diferente se as variáveis estão de forma agrupada ou não agrupada. Há medidas específicas para variáveis categóricas, que serão apresentadas quando forem descritas as medidas para variáveis numéricas em forma agrupada, pois cada grupo se comporta como se fosse uma categoria.

## 3.1. Dados numéricos não agrupados

As medidas usadas para dados numéricos são classificadas de acordo com o tipo de informação que fornecem, conforme a Figura 23. As medidas de posição são as mais abundantes (média, mínimo, máximo, mediana, quartis, decis, percentis) e muito usadas. São chamadas de indicadores de primeiro momento. As medidas de dispersão, ou indicadores de segundo momento, são mais específicas porque a informação que fornecem é derivada das medidas de posição (desvio padrão, desvio médio, variância, coeficiente de variação, amplitude e amplitudes entre percentis). As medidas de assimetria e achatamento são bem específicas e muito pouco usadas.

Na Figura 23, as linhas representam o contorno de distribuições de frequências que funcionam como o perfil do histograma de uma amostra. A forma básica apresentada é uma distribuição teórica muito importante, chamada de distribuição normal, que será estudada mais a fundo no Capítulo **Erro! Fonte de referência não encontrada.**. A distribuição normal tem comportamento considerado padrão e é comumente utilizada como base de comparação para as demais distribuições.

**Figura 23.** Tipos de medidas descritivas




### 3.1.1. Médias de Posição

As medidas de posição determinam valores para a distribuição (dados sob análise). Servem para resumir se a distribuição possui valores grandes ou pequenos: máximo, mínimo, média etc.

#### 3.1.1.1. Média aritmética simples

É a medida mais conhecida por todos, que serve como principal resumo dos dados, sendo normalmente chamada apenas de “média”.

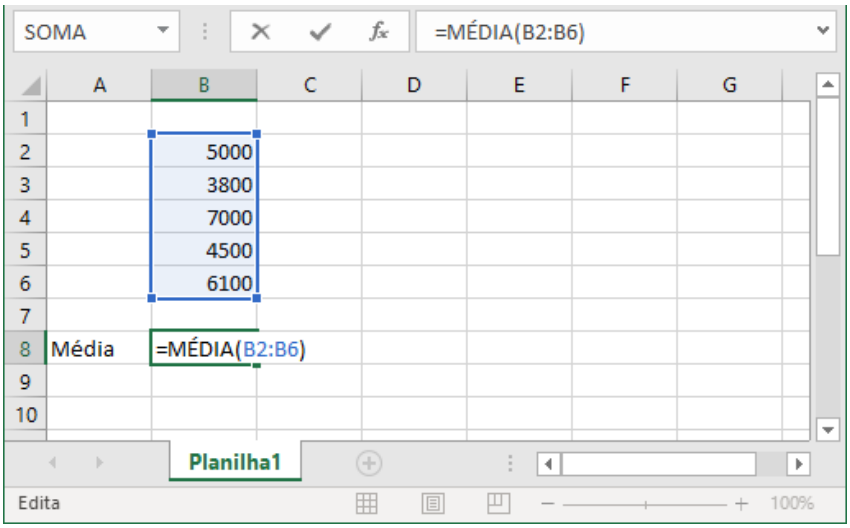
A média de um conjunto de dados é calculada somando-se todos os valores e dividindo esta soma pela quantidade de valores. Por exemplo, se nos últimos 5 meses a venda de automóveis fabricados em determinado país foi, respectivamente, de 5.000, 3.800, 7.000, 4.500 e 6.100 unidades, então a média da venda é calculada fazendo:

$$\frac{5.000 + 3.800 + 7.000 + 4.500 + 6.100}{5} = 5.280$$

A média das vendas dos últimos 5 meses foi igual a 5.280. Geralmente se diz que a venda média foi igual a 5.280. A interpretação desse conceito sugere que, se todos os meses vendesse a mesma quantidade, a venda seria de 5.280 e o total vendido nos 5 meses seria o mesmo.

Para calcular a média usando o Excel, é possível usar uma fórmula prática chamada MÉDIA. É possível ver na Figura 24 como fazer. Alternativamente, seria possível somar cada um dos valores digitados e dividir por 5, mas o uso da função MÉDIA é bem mais simples e objetivo.

**Figura 24.** A função MÉDIA no Excel




Formalizando, o conjunto de dados é formado por $n$ valores que são chamados genericamente de $x_1, x_2, x_3, \ldots x_n$. De forma ainda mais genérica, diz-se que os valores são $x_i$, onde $i = 1, 2, 3, \ldots, n$. Então, a média é definida como:

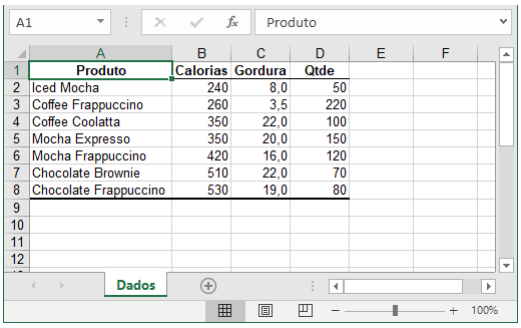
$$\mu \text{ ou } \bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

O símbolo $\sum$ é uma letra grega chamada sigma em forma maiúscula. Esse símbolo é usado para indicar somatório. Indicamos a média como $\mu$ se o conjunto de dados é a população ou $\bar{x}$ se o conjunto de dados é uma amostra. Para o exemplo das vendas de automóveis, foram fornecidas 5 observações. Portanto, $n = 5$. Além disso, são considerados $x_1 = 5.000$, $x_2 = 3.800$, $x_3 = 7.000$, $x_4 = 4.500$ e $x_5 = 6.100$. Então,

$$\bar{x} = \frac{\sum_{i=1}^{5} x_i}{5} = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = \frac{5.000 + 3.800 + 7.000 + 4.500 + 6.100}{5} = 5.280$$

**Exemplo:** Uma cafeteria tem um cardápio com algumas opções de bebidas geladas à base de café e/ou chocolate, e há algumas informações sobre estas bebidas, conforme disponível na Figura 25.

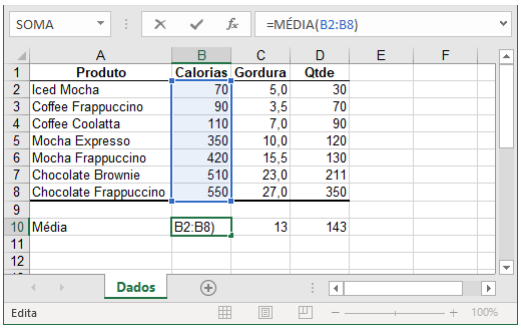
**Figura 25.** Informações sobre bebidas geladas



| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | Produto | Calorias | Gordura | Qtde | | |
| 2 | Iced Mocha | 240 | 8,0 | 50 | | |
| 3 | Coffee Frappuccino | 260 | 3,5 | 220 | | |
| 4 | Coffee Coolatta | 350 | 22,0 | 100 | | |
| 5 | Mocha Expresso | 350 | 20,0 | 150 | | |
| 6 | Mocha Frappuccino | 420 | 16,0 | 120 | | |
| 7 | Chocolate Brownie | 510 | 22,0 | 70 | | |
| 8 | Chocolate Frappuccino | 530 | 19,0 | 80 | | |
| 9 | | | | | | |
| 10 | | | | | | |
| 11 | | | | | | |
| 12 | | | | | | |

São sete diferentes bebidas, sobre as quais sabemos, além do nome, três informações: a quantidade de calorias, a quantidade de gordura e a quantidade vendida na última semana. É possível calcular a média de cada uma dessas variáveis:

**Figura 26.** Média das três variáveis



| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | Produto | Calorias | Gordura | Qtde | | |
| 2 | Iced Mocha | 70 | 5,0 | 30 | | |
| 3 | Coffee Frappuccino | 90 | 3,5 | 70 | | |
| 4 | Coffee Coolatta | 110 | 7,0 | 90 | | |
| 5 | Mocha Expresso | 350 | 10,0 | 120 | | |
| 6 | Mocha Frappuccino | 420 | 15,5 | 130 | | |
| 7 | Chocolate Brownie | 510 | 23,0 | 211 | | |
| 8 | Chocolate Frappuccino | 550 | 27,0 | 350 | | |
| 9 | | | | | | |
| 10 | Média | B2:B8) | 13 | 143 | | |
| 11 | | | | | | |
| 12 | | | | | | |

A partir das médias que foram calculadas, conclui-se que houve uma venda média de 143 unidades de cada produto, que é a média da variável quantidade. Também se conclui que cada produto tem, em média, 13g de gordura e 300 calorias.

### 3.1.1.2. Média ponderada

Quantas calorias foram consumidas em média na semana passada? Para responder a essa pergunta, a média calculada na Figura 26 não é útil; não foram consumidas em média 300 calorias! Isso porque as bebidas foram consumidas em quantidades desiguais: observa-se que a quantidade vendida é pequena para itens com poucas calorias e que a quantidade vendida é grande para itens ricos em calorias.

Para essa questão, a média (aritmética simples) não é útil. Usa-se a média aritmética ponderada. O cálculo da média das calorias deve considerar as quantidades de cada item, de forma que os itens com venda menor tenham pouca influência na média e

os itens com venda maior tenham mais influência na média. Diz-se que será feita a média das calorias com ponderação pela quantidade.

Formalizando, além dos $x_i$, que são os valores da variável de interesse (no caso em questão, as calorias de cada item), há os $\omega_i$, que são os pesos de ponderação (no caso em questão, as quantidades vendidas de cada item). Então, a média ponderada é calculada da seguinte forma:

$$\bar{x}_\omega = \frac{\sum_{i=1}^{n} x_i \times \omega_i}{\sum_{i=1}^{n} \omega_i} = \frac{x_1\omega_1 + x_2\omega_2 + \cdots + x_5\omega_5}{\omega_1 + \omega_2 + \cdots + \omega_5}$$

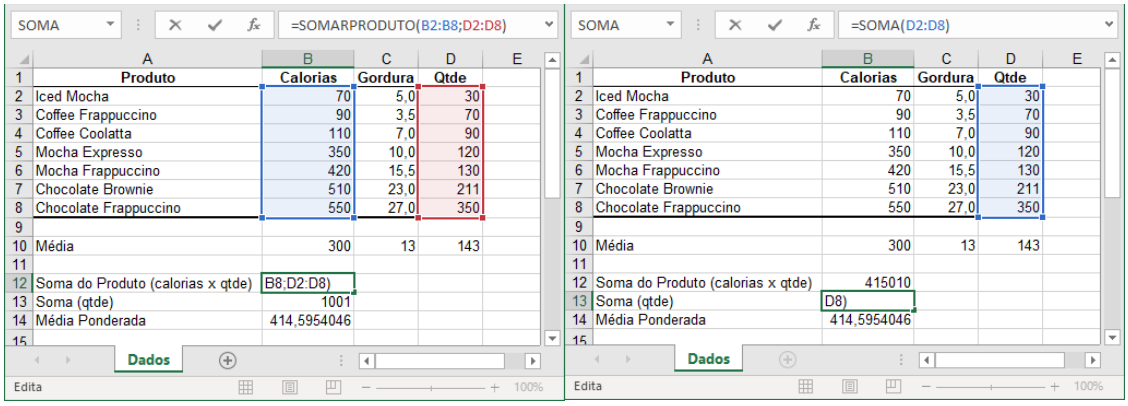
Para o caso das calorias, os valores da variável de interesse são $x_1=70$, $x_2=90$, $x_3=110$, $x_4=350$, $x_5=420$, $x_6=510$ e $x_7=550$. E os valores da variável de peso são $\omega_1=30$, $\omega_2=70$, $\omega_3=90$, $\omega_4=120$, $\omega_5=130$, $\omega_6=211$ e $\omega_7=350$. A média ponderada é, então, calculada da seguinte forma:

$$\bar{x}_\omega = \frac{70 \cdot 30 + 90 \cdot 70 + 110 \cdot 90 + 350 \cdot 120 + 420 \cdot 130 + 510 \cdot 211 + 550 \cdot 350}{30 + 70 + 90 + 120 + 130 + 211 + 350} = \frac{415.010}{1.001}$$
$$\cong 414{,}6$$

Nesse caso, a média ponderada é bem maior do que a média simples ($\bar{x} = 300$), indicando que o consumo médio de calorias é maior do que a quantidade média de calorias que estão nos itens.

O Excel não tem uma função pronta para calcular a média ponderada. É necessário realizar todos os cálculos acima. Entretanto, para o cálculo do numerador, é possível usar a função SOMARPRODUTO, e para o cálculo do denominador é possível usar a função SOMA, como está demonstrado nas duas imagens da Figura 27. Para calcular a média ponderada que está na célula B14, bastou dividir o valor obtido na célula B12 (soma dos produtos) pelo valor obtido na célula B13 (soma das quantidades).

**Figura 27.** Média Ponderada no Excel




### 3.1.1.3. Mediana

A mediana é o valor que divide o conjunto exatamente no meio, de forma que pelo menos 50% das observações são menores (ou iguais) à mediana, e pelo menos 50% são maiores (ou iguais) à mediana. Ela corresponde ao valor que ocupa a posição central quando os dados estão ordenados.

Quando $n$ é impar, a posição central existe, e então o elemento que estiver na posição $\frac{n+1}{2}$ é a mediana. Então:

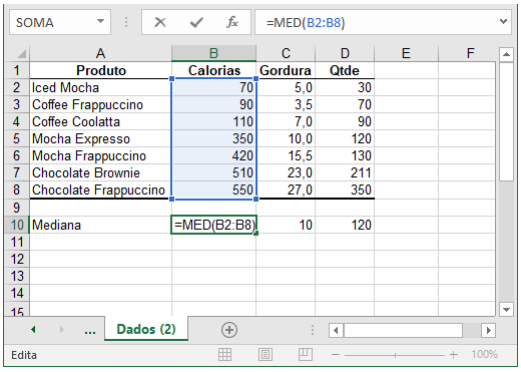
$$med = x_{\frac{n+1}{2}}$$

Mas quando $n$ é par, a posição central não existe. Haverá dois elementos centrais, um na posição $\frac{n}{2}$ e outro na posição $\frac{n}{2}+1$. Então

$$med = \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}$$

Quando $n$ é ímpar, a mediana é um dos valores do conjunto de dados, mas no caso de $n$ ser par, a mediana pode ser um valor que não está no conjunto de dados.

**Figura 28.** Calculando mediana com Excel: função MED




Os dados sobre bebidas geladas têm $n = 7$, portanto a mediana é um dos elementos do conjunto. Na Figura 28 é possível ver o uso da função MED para calcular a mediana. O Excel encontra a mediana sem precisar ordenar a lista.

Algumas vezes, a palavra mediana é usada de forma incorreta como sendo uma qualidade da média. Por exemplo, a quantidade média de calorias é 300, mas não se pode dizer que a quantidade mediana é 300. A mediana das calorias foi 350. Não se deve confundir os dois conceitos.

Uma característica importante da mediana é que ela é um indicador resistente a valores extremos. Sejam as seguintes observações:

| Pessoa | Patrimônio |
|---|---|
| Paulo | 22 mil |
| Gustavo | 25 mil |
| Camila | 28 mil |
| Jorge Paulo | 30 bilhões |

Calculando a média descobre-se que o patrimônio médio é de 7,5 bilhões, aproximadamente. Mas o patrimônio mediano é 26,5 mil. Ou seja, o patrimônio muito grande do Jorge Paulo está refletido na média, mas não na mediana. Indicadores resistentes são convenientes quando se deseja evitar que valores extremos (muito grandes ou muito pequenos) interfiram na medida.

Outra característica importante é que a mediana pode ser usada para dados categóricos, quando estes tiverem uma escala ordinal. Por exemplo, considere uma

turma de 39 alunos que são avaliados por conceitos de A (melhor) a E (pior). É sabido que:

- 10 estudantes receberam conceito A
- 8 estudantes receberam conceito B
- 20 estudantes receberam conceito C
- 1 único estudante ficou reprovado com conceito D

É possível definir que o conceito mediano é C, que é o conceito do 20º aluno mais bem classificado. Mas não é possível definir o conceito médio.

#### 3.1.1.4. Moda

A moda (também conhecida como “modo”) é o valor que ocorre com maior frequência. Semelhante aos itens que estão na moda, ou seja, que há muita gente usando, o valor modal é o mais visto no conjunto de dados sob análise.

Por exemplo, se, nos últimos 10 dias, o departamento de atendimento ao cliente de certa empresa recebeu as seguintes quantidades de reclamações:

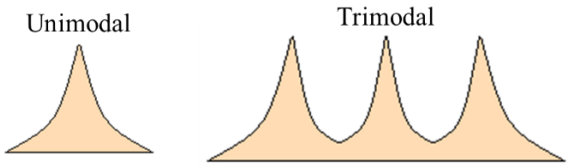
31 33 37 41 41 42 45 46 46 54

É possível verificar a existência de duas modas, pois 41 e 46 reclamações apareceram duas vezes cada.

A moda pode ocorrer mais de uma vez, como vimos, mas também pode não ocorrer, quando todos os valores aparecerem a mesma quantidade de vezes.

A moda é uma medida pouco utilizada como indicador dos dados sob análise. Em geral é mais usada para caracterizar o comportamento de uma distribuição amostral (assunto que está no Capítulo **Erro! Fonte de referência não encontrada.**). Na Figura 29 é possível ver duas distribuições amostrais diferentes, uma delas com uma única moda e a outra com três modas.

**Figura 29.** A moda para descrever o formato de distribuições amostrais




### 3.1.1.5. Média geométrica

A média geométrica de $n$ observações é obtida multiplicando os $n$ valores e depois extraindo a raiz de ordem $n$ deste produto. Ou seja:

$$\bar{x}_G = \sqrt[n]{x_1 \times x_2 \times \ldots \times x_n} = (\Pi_{i=1}^{n} x_i)^{\frac{1}{n}}$$

O símbolo $\Pi$ é a forma maiúscula da letra grega pi, e é usado para indicar o produtório dos termos.

É possível perceber a similaridade da fórmula da média aritmética com a média geométrica: enquanto aquela soma os termos e divide por *n*, esta multiplica os termos e tira a raiz de ordem *n*. Por isso, a média geométrica é usada em casos especiais, quando os valores da variável sob estudo se integram multiplicativamente, e não aditivamente. Isso é muito usado para taxas de variação, quando a média é calculada com base nos fatores multiplicativos.

Se determinado valor cresceu a uma taxa *R*, então se diz que o fator multiplicativo é 1+R. Por exemplo, se o preço de um produto era R$50,00 e ele aumentou 10% (R=0,10), então o novo preço é *50 × (1+R) = 50 × 1,1 = R$55,00*.

A taxa de crescimento média é obtida utilizando-se a média geométrica. Para isso, é preciso fazer:

$$\bar{R}_G = \sqrt[n]{(1 + R_1) \times (1 + R_2) \times \ldots \times (1 + R_n)} - 1$$

A taxa de crescimento média é comumente chamada de CAGR, se os dados forem anuais, ou de CMGR, se os dados forem mensais. A sigla é o acrônimo da expressão em inglês Compound Annual (ou Monthly) Growth Rate que significa taxa de crescimento composta anual (ou mensal).

Por exemplo, se no primeiro ano a inflação foi de 5%, e no segundo ano foi de 15%, a inflação média não é igual a 10% (que é a média aritmética conforme definida anteriormente). A média correta é calculada usando os fatores (o fator multiplicativo que é calculado como 1 + taxa) e a formulação da média geométrica, ou seja:

$$\bar{x}_G = \sqrt[2]{1{,}05 \times 1{,}15} - 1 = \sqrt{1{,}2075} - 1 = 0{,}098863$$

Ou seja, a inflação média foi de 9,8863%. Isso pode ser verificado partindo-se de um valor fictício e aplicando as taxas de crescimento uma de cada vez. O valor obtido depois desses dois crescimentos deve ser igual ao valor obtido considerando o crescimento médio duas vezes consecutivas.

**Aplicando as taxas de crescimento, uma de cada vez**: partindo de $X_1 = 100$, e aplicando-se o crescimento do primeiro ano, obtém-se o valor do segundo ano $X_2 = 100 \times (1{,}05) = 105$, e aplicando-se o crescimento do segundo ano se chega a $X_3 = 105 \times (1{,}15) = 120{,}75$.

**Aplicando a taxa média, duas vezes**: se a média fosse 10%, partindo de $X_1 = 100$ se obtém $X_2 = 100 \times (1{,}10) = 110$ e $X_3 = 110 \times (1{,}10) = 121$. Os valores são diferentes, o que indica que a média aritmética não pode ser usada. Usando a média de 9,8863% se obtém $X_2 = 100 \times (1{,}098863) = 109{,}8863$ e $X3 = 109{,}8863 \times (1{,}098863) = 120{,}75$. Esse valor é o mesmo obtido quando as taxas foram aplicadas simultaneamente, o que comprova que este é o valor médio correto do caso.

### 3.1.1.6. Medidas de posição relativa

Existem três grupos de medidas que servem para indicar os valores que separam as observações em grupos de tamanho definido, considerando lista ordenada. Essas medidas funcionam do mesmo jeito que a mediana:

- Existem três quartis, que dividem os dados em quatro partes, cada uma contendo pelo menos 25% das observações.
- Existem 9 decis, que dividem os dados em 10 partes, cada uma contendo pelo menos 10% das observações.
- Existem 99 percentis, que dividem os dados em 100 partes, cada uma contendo pelo menos 1% das observações.

Estes valores são obtidos da mesma forma que a mediana: ordenam-se os dados e são verificados os valores que ocupam as posições limítrofes ou uma média (ponderada) dos valores mais próximos, caso o valor limítrofe não exista.

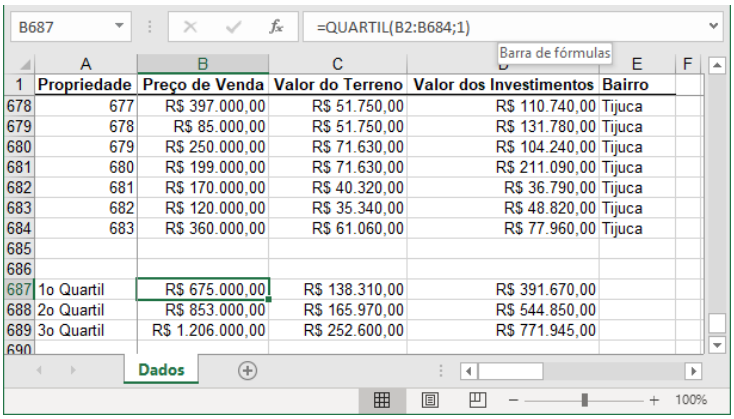
Sejam os dados disponíveis no arquivo **Caso Contrutora.xlxs**, referentes a 683 diferentes imóveis que determinada construtora tem listados. Para cada um dos imóveis sabem-se o bairro, o preço de venda, o valor do terreno e o valor dos investimentos que a construtora fez no terreno.

O Excel dispõe da função quartil, que pode ser usada como no exemplo da Figura 30. Veja que na função é informado o conjunto de dados e depois o número do quartil.

O primeiro quartil é tal que indica o valor que separa as 25% menores observações das demais 75%. Por exemplo, sabe-se que 25% dos imóveis têm preço de venda de até R$675 mil. Continuando a leitura dos valores, 25% dos imóveis têm preço de venda entre R$675 mil e R$853 mil, outros 25% têm preço de venda entre R$853 mil e R$1,206 milhão e, finalmente, os 25% maiores preços estão acima de R$1,205 milhão.

Vale frisar que para dividir o conjunto de dados em 4 partes são usados 3 quartis. O conceito de quarta parte é diferente do conceito de quartil: há quatro partes iguais, cada uma com 25% das observações, que são delimitadas por 3 quartis.

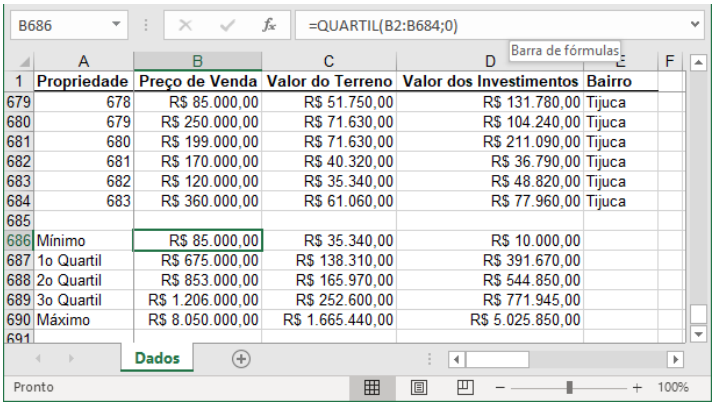
**Figura 30.** Calculando os quartis com o Excel




| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | Propriedade | Preço de Venda | Valor do Terreno | Valor dos Investimentos | Bairro | |
| 678 | 677 | R$ 397.000,00 | R$ 51.750,00 | R$ 110.740,00 | Tijuca | |
| 679 | 678 | R$ 85.000,00 | R$ 51.750,00 | R$ 131.780,00 | Tijuca | |
| 680 | 679 | R$ 250.000,00 | R$ 71.630,00 | R$ 104.240,00 | Tijuca | |
| 681 | 680 | R$ 199.000,00 | R$ 71.630,00 | R$ 211.090,00 | Tijuca | |
| 682 | 681 | R$ 170.000,00 | R$ 40.320,00 | R$ 36.790,00 | Tijuca | |
| 683 | 682 | R$ 120.000,00 | R$ 35.340,00 | R$ 48.820,00 | Tijuca | |
| 684 | 683 | R$ 360.000,00 | R$ 61.060,00 | R$ 77.960,00 | Tijuca | |
| 685 | | | | | | |
| 686 | | | | | | |
| 687 | 1o Quartil | R$ 675.000,00 | R$ 138.310,00 | R$ 391.670,00 | | |
| 688 | 2o Quartil | R$ 853.000,00 | R$ 165.970,00 | R$ 544.850,00 | | |
| 689 | 3o Quartil | R$ 1.206.000,00 | R$ 252.600,00 | R$ 771.945,00 | | |
| 690 | | | | | | |

É muito comum descrever os dados com cinco medidas: os limites totais (mínimo e máximo) e os três quartis. Os valores limites podem ser calculados no Excel com as funções MÍNIMO e MÁXIMO, respectivamente. Mas o Excel tem um atalho para calcular esses valores limites usando a função quartil. Na Figura 31 é possível ver esse atalho: o Excel retorna o mínimo quando se passa o valor 0 como parâmetro na função QUARTIL (e retorna o máximo quando se passa o valor 4).

**Figura 31.** Usando a função quartil para calcular mínimo

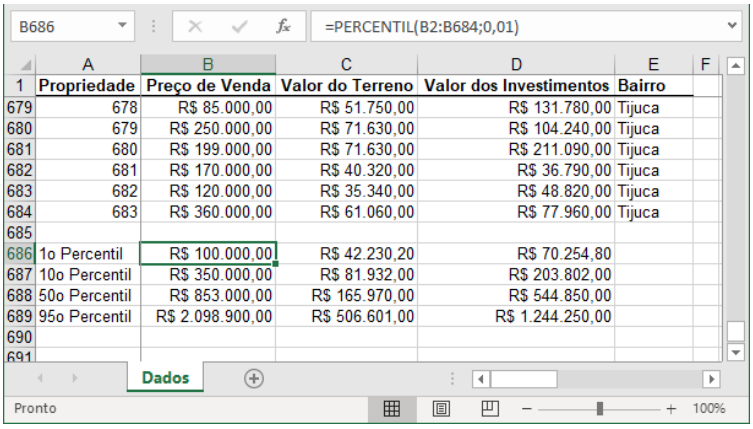



| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | Propriedade | Preço de Venda | Valor do Terreno | Valor dos Investimentos | Bairro | |
| 679 | 678 | R$ 85.000,00 | R$ 51.750,00 | R$ 131.780,00 | Tijuca | |
| 680 | 679 | R$ 250.000,00 | R$ 71.630,00 | R$ 104.240,00 | Tijuca | |
| 681 | 680 | R$ 199.000,00 | R$ 71.630,00 | R$ 211.090,00 | Tijuca | |
| 682 | 681 | R$ 170.000,00 | R$ 40.320,00 | R$ 36.790,00 | Tijuca | |
| 683 | 682 | R$ 120.000,00 | R$ 35.340,00 | R$ 48.820,00 | Tijuca | |
| 684 | 683 | R$ 360.000,00 | R$ 61.060,00 | R$ 77.960,00 | Tijuca | |
| 685 | | | | | | |
| 686 | Mínimo | R$ 85.000,00 | R$ 35.340,00 | R$ 10.000,00 | | |
| 687 | 1o Quartil | R$ 675.000,00 | R$ 138.310,00 | R$ 391.670,00 | | |
| 688 | 2o Quartil | R$ 853.000,00 | R$ 165.970,00 | R$ 544.850,00 | | |
| 689 | 3o Quartil | R$ 1.206.000,00 | R$ 252.600,00 | R$ 771.945,00 | | |
| 690 | Máximo | R$ 8.050.000,00 | R$ 1.665.440,00 | R$ 5.025.850,00 | | |
| 691 | | | | | | |



O Excel tem a função PERCENTIL, que funciona de maneira análoga à função QUARTIL. Deve-se observar que o percentil $i$ é indicado como um valor decimal $\frac{i}{100}$; ou seja, para calcular o 7º percentil, usa-se como referência o valor 0,07.

Figura 32. Função percentil no Excel




| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | Propriedade | Preço de Venda | Valor do Terreno | Valor dos Investimentos | Bairro | |
| 679 | 678 | R$ 85.000,00 | R$ 51.750,00 | R$ 131.780,00 | Tijuca | |
| 680 | 679 | R$ 250.000,00 | R$ 71.630,00 | R$ 104.240,00 | Tijuca | |
| 681 | 680 | R$ 199.000,00 | R$ 71.630,00 | R$ 211.090,00 | Tijuca | |
| 682 | 681 | R$ 170.000,00 | R$ 40.320,00 | R$ 36.790,00 | Tijuca | |
| 683 | 682 | R$ 120.000,00 | R$ 35.340,00 | R$ 48.820,00 | Tijuca | |
| 684 | 683 | R$ 360.000,00 | R$ 61.060,00 | R$ 77.960,00 | Tijuca | |
| 685 | | | | | | |
| 686 | 1o Percentil | R$ 100.000,00 | R$ 42.230,20 | R$ 70.254,80 | | |
| 687 | 10o Percentil | R$ 350.000,00 | R$ 81.932,00 | R$ 203.802,00 | | |
| 688 | 50o Percentil | R$ 853.000,00 | R$ 165.970,00 | R$ 544.850,00 | | |
| 689 | 95o Percentil | R$ 2.098.900,00 | R$ 506.601,00 | R$ 1.244.250,00 | | |
| 690 | | | | | | |
| 691 | | | | | | |



Na Figura 32 se vê a função PERCENTIL em ação. Percebe-se, por exemplo, que em apenas 1% dos imóveis se investiu até R$70.254,80, ou que em 5% dos imóveis se investiu mais do que R$1.244.250,00.

Na função PERCENTIL também é possível obter os valores mínimo e máximo dos dados, passando como parâmetros 0 e 1, respectivamente.

Os decis podem ser encontrados no Excel passando como parâmetros 0,1 (1º decil), 0,2 (segundo decil) e assim sucessivamente até 0,9 (nono e último decil).

Finalmente, observa-se que a mediana é uma medida de posição relativa. Ela é exatamente igual ao 2º quartil, ao 5% decil e ao 50% percentil.

**Medidas de tendência central**

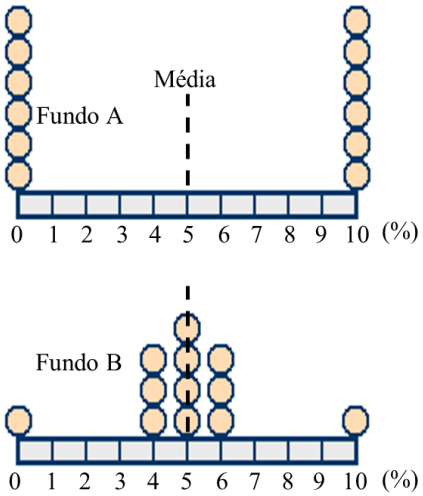
Algumas medidas de posição estabelecem medidas referentes ao centro da distribuição: média, mediana e moda são as principais.

**Medidas de dispersão**

Essas medidas lidam com informações relativas ao espalhamento dos dados, ou seja, a variabilidade. Por exemplo, podem estabelecer a largura da distribuição, como a amplitude, ou a variabilidade com o desvio (médio ou padrão). Servem para resumir se a distribuição está concentrada ou espalhada, ou seja, se os valores estão próximos ou distantes uns dos outros.

Por exemplo, na Figura 33 é possível ver os retornos mensais obtidos por dois fundos de ações brasileiros, com características semelhantes e durante o mesmo período (os últimos 12 meses). O Fundo A obteve retorno de 0% em 6 meses e um retorno de 10% em outros 6 meses. Já o Fundo B obteve retorno de 0% apenas em um mês, 4% em 3 meses, 5% em 4 meses, 6% em 3 meses e 10% em apenas um mês.

**Figura 33.** Retornos mensais de dois fundos diferentes




Considerando-se as 12 observações de cada um dos fundos, é possível calcular a média de cada um deles. No caso do Fundo A, a média é

$$x_A = \frac{0+0+0+0+0+0+10+10+10+10+10+10}{12} = 5$$

e, no caso do Fundo B,

$$x_B = \frac{0+4+4+4+5+5+5+5+6+6+6+10}{12} = 5$$

.

Curiosamente as médias são iguais entre si.

Entretanto os conjuntos guardam uma diferença importante entre si: o espalhamento. Analisando as rentabilidades do Fundo A, é possível observar que todas as ocorrências são 5 pontos percentuais acima ou abaixo da média, mas as rentabilidades do Fundo B estão mais frequentemente próximas à média.

Para sensibilizar mais a diferença, considera-se um investidor que procura um investimento que lhe proporcione um retorno de 5%, ou próximo disso. Se o investidor usou o Fundo A, ele nunca conseguiu, nos últimos 12 meses, alcançar a rentabilidade esperada – na verdade, nem chegou perto. Se, por outro lado, usou o Fundo B, em 4 meses obteve rentabilidade exatamente igual à esperada, que corresponde a 33,3% das vezes. Considerando uma tolerância de 1 ponto percentual para mais ou para menos, ou seja, contando as ocorrências em que a rentabilidade foi algum valor entre 4% e 6%, então são 83,3% das vezes. Isso ocorre porque as

ocorrências do Fundo A estão mais dispersas do que as ocorrências do Fundo B. Ou, por outro lado, as ocorrências do Fundo B estão mais concentradas do que as do Fundo A.

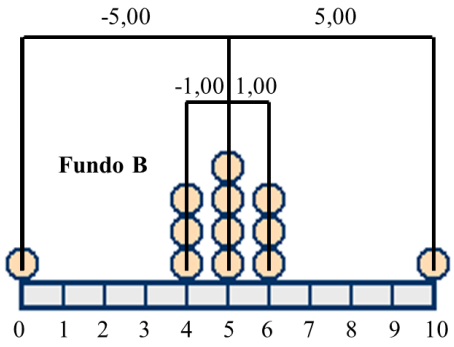
### 3.1.1.7. Desvio padrão e variância

A principal medida da dispersão dos dados é baseada no conceito de desvio. Desvio é sinônimo de diferença: um desvio rodoviário é seguir por um caminho diferente do planejado; um desvio de comportamento é observado quando uma pessoa tem atitudes diferentes das esperadas; desvio de verba ocorre quando o dinheiro público é usado de forma diferente da que deveria ser. No caso da estatística, desvio é uma medida da observação: mostra o quanto ela é diferente da média. Dessa forma, para cada ocorrência se calcula o desvio:

$$d_i = x_i - \bar{x}$$

Na Figura 34, veem-se os desvios de cada uma das rentabilidades observadas do Fundo B. Para a ocorrência de 10% de rentabilidade, o desvio é igual a 5, e para as três ocorrências de 6% de rentabilidade o desvio é igual a 1. Ou seja, quando a rentabilidade foi de 10%, ela foi diferente 5 pontos da média, e, quando a rentabilidade foi de 6%, ela foi apenas 1 ponto diferente da média.

**Figura 34.** Desvios para as rentabilidades do Fundo B




Por outro lado, quando a rentabilidade é de 0% o desvio é igual a -5. O sinal do desvio negativo indica que o valor observado é menor do que a média. Então, apesar de estar tão distante da média quanto a ocorrência de 10%, os desvios são diferentes.

Finalmente, as ocorrências com rentabilidade igual a 5% tem desvio igual a zero.

Ou seja, qualquer uma das ocorrências tem desvio, que podem ser positivos, negativos ou nulos.

Na busca por um indicador único que represente todas as ocorrências, é possível pensar no conceito de média dos desvios. Ou seja, o valor que dirá quanto, em média, as observações estão distantes da média. Mas esse valor será igual a zero, independentemente do conjunto sob análise.

Esta é uma propriedade da média: a soma de todos os desvios é igual a zero, ou, formalmente, $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$. Então, não é possível calcular o desvio médio porque, conforme pode ser visto na Figura 34, para cada desvio negativo há um desvio positivo com igual valor absoluto, de forma que a soma deles dá zero (e consequentemente a média também).

Os estatísticos resolveram esse problema de uma forma engenhosa: em vez de somar os desvios para obter a média, somaram os quadrados dos desvios. Como um número negativo elevado ao quadrado é positivo, a soma dos quadrados dos desvios é uma soma de parcelas sempre positivas (ou nulas). A média dos desvios ao quadrado é chamada de variância:

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \bar{x})^2}{N}$$

A variância é indicada pela letra grega sigma ($\sigma$), em sua forma minúscula, e aparece elevada ao quadrado. Isso porque a medida mais importante é o desvio padrão, que é a raiz quadrada da variância:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^{N}(x_i - \bar{x})^2}{N}}$$

Assim, no caso do Fundo A se calcula a variância:

$$\sigma_A^2 = \frac{(0-5)^2 + (0-5)^2 + \cdots (10-5)^2 + \cdots + (10-5)^2}{12} = \frac{300}{12} = 25$$

E então o desvio padrão:

$$\sigma_A = \sqrt{25} = 5$$

Já no caso do Fundo B, se calcula a variância:

$$\sigma_B^2 = \frac{(0-5)^2 + (4-5)^2 + \cdots + (5-5)^2 + (6-5)^2 + \cdots + (10-5)^2}{12} = \frac{56}{12} = 4{,}67$$

E então o desvio padrão:

$$\sigma_B = \sqrt{4{,}67} = 2{,}16$$

A variância é uma medida que tem pouca aplicação prática direta, pois seu valor tem um significado difícil de ser compreendido, tendo em vista que a unidade de medida é o quadrado da unidade de medida da variável sob estudo. No caso em questão, a variância do Fundo A é de 25% ao quadrado. Isso não faz sentido algum. O desvio padrão, por sua vez, tem compreensão direta, pois está na mesma unidade de medida dos dados observados: o desvio padrão do Fundo A é 5%.

Comparando as medidas entre os Fundos A e B, tanto a variância quanto o desvio padrão oferecem a mesma conclusão: o Fundo A tem medida de dispersão maior do que o Fundo B.

Quando os dados sob análise representam uma amostra, as fórmulas de variância e desvio padrão sofrem uma pequena, mas muito importante, alteração:

Variância amostral: $s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$

Desvio padrão amostral: $s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$

Além do fato de que são usadas letras modernas para indicar o desvio padrão e a variância amostrais (s ao invés de $\sigma$), o somatório é dividido por $n - 1$. Esse valor é denominado grau de liberdade do desvio padrão. Convém observar que o tamanho populacional é indicado por $N$ (maiúsculo) e o tamanho amostral é indicado por $n$ (minúsculo).

Os dados do Fundo AB representam uma amostra, e não uma população. É fácil decidir sobre isso, porque os fundos estão ativos, e novas rentabilidades serão

observadas, logo o que se conhece dele é apenas uma parte do conjunto de rentabilidades. Em geral, os dados sob observação são uma amostra. Para que os dados representem uma população essa informação deve estar muito clara.

Assim, já que os dados são amostrais, os cálculos feitos anteriormente para amostra e desvio padrão estão errados. Os valores corretos são obtidos com as fórmulas revistas acima:

$$s_A^2 = \frac{(0-5)^2 + (0-5)^2 + \cdots (10-5)^2 + \cdots + (10-5)^2}{11} = \frac{300}{11} = 27{,}27$$

$$s_A = \sqrt{27{,}27} = 5{,}22$$

$$s_B^2 = \frac{(0-5)^2 + (4-5)^2 + \cdots + (5-5)^2 + (6-5)^2 + \cdots + (10-5)^2}{11} = \frac{56}{11} = 5{,}09$$

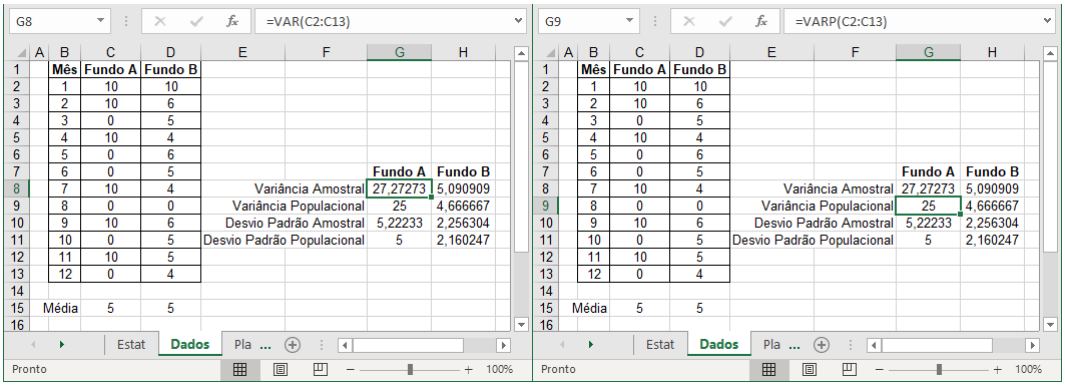
$$\sigma_B = \sqrt{4{,}67} = 2{,}26$$

As estatísticas (medidas amostrais) são sempre menores do que os parâmetros (medidas populacionais). Não há nenhum motivo para se calcular estatísticas e parâmetros para o mesmo conjunto de dados, ou seja, medidas amostrais e populacionais. O procedimento correto é determinar inicialmente se os dados representam uma amostra ou uma população e usar as medidas adequadas.

Independentemente de se usar medidas amostrais ou populacionais, a conclusão é a mesma: os dados do Fundo A são mais dispersos do que os dados do Fundo B, pois apresentam variância e desvio padrão maiores.

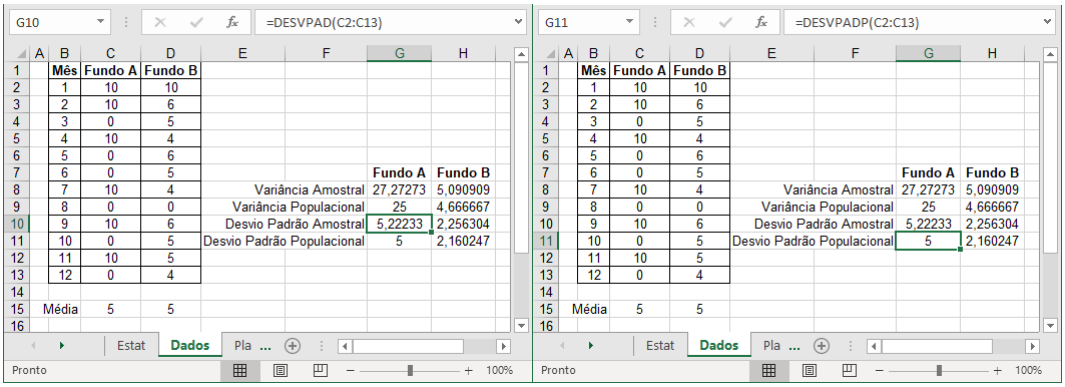
Para calcular a variância amostral no Excel, utiliza-se a função VAR, e, para calcular a variância populacional, utiliza-se a função VARP, como pode ser visto na Figura 35, que é oriunda do arquivo **Caso Fundo AB.xlsx**. Para calcular o desvio padrão amostral, utiliza-se a função DESVPAD, e, para calcular a variância populacional, utiliza-se a função DESVPADP, como se vê na Figura 36.

**Figura 35.** Variância populacional e amostral no Excel




Neste exemplo, foram usadas deliberadamente as funções amostrais e populacionais sobre o mesmo conjunto de dados, mas é importante deixar claro que isso não pode ser feito: se os dados representarem uma amostra, serão calculadas as estatísticas; se os dados representarem uma população, serão calculados os parâmetros.

**Figura 36.** Desvio padrão amostral e populacional no Excel




### 3.1.1.8. Coeficiente de variação

O desvio padrão é uma medida de dispersão absoluta, que poderá levar a distorções. Em uma situação de comparação de dois conjuntos de dados, o desvio padrão de um deles pode ser maior, sendo que a dispersão relativa é menor.

O coeficiente de variação captura o conceito de dispersão relativa. Sua formulação é a mesma para dados amostrais ou populacionais:

$$CV_{POPULAÇÃO} = \frac{\sigma}{\mu} \text{ e } CV_{AMOSTRA} = \frac{s}{\bar{x}}$$

Por exemplo, analisando o tempo que fornecedores levam para fazer as entregas, percebeu-se que o fornecedor A leva em média 10 dias, com desvio padrão igual a 2, e que o fornecedor B leva em média 40 dias com desvio padrão igual a 4.

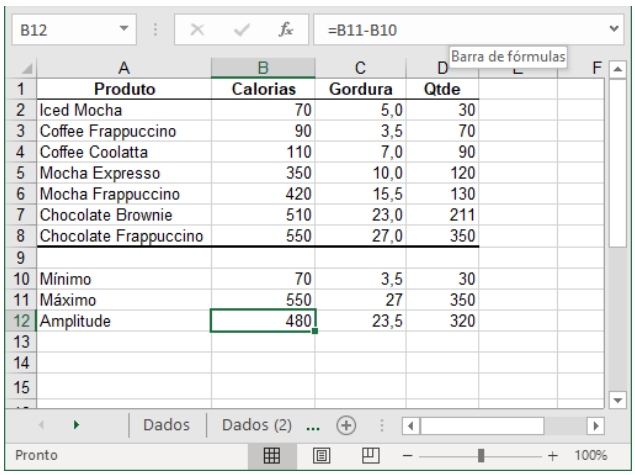
Calculando os desvios padrões obtém-se $CV_A = \frac{2}{10} = 0{,}2$ e $CV_B = \frac{4}{40} = 0{,}1$.

O desvio padrão indica que o tempo de entrega do fornecedor B é mais disperso do que o do fornecedor A. Entretanto o coeficiente de variação indica que a dispersão do fornecedor A representa 20% do prazo médio de entrega, enquanto a dispersão do fornecedor B é apenas 10%.

### 3.1.1.9. Amplitude

A amplitude é uma medida de dispersão que considera apenas os limites do conjunto de dados: o mínimo e o máximo. A amplitude define o quão distante eles estão. Por exemplo, considerando os dados das bebidas geladas, pode-se calcular as amplitudes das três variáveis, como pode ser visto na Figura 37. A amplitude é a maior distância que poderá ser observada considerando dois valores quaisquer do conjunto. Ou seja, é possível garantir que, tomando quaisquer dois itens, a diferença de gordura entre eles é no máximo 23,5 gramas.

**Figura 37.** Amplitude




| | A | B | C | D | F |
|---|---|---|---|---|---|
| 1 | **Produto** | **Calorias** | **Gordura** | **Qtde** | |
| 2 | Iced Mocha | 70 | 5,0 | 30 | |
| 3 | Coffee Frappuccino | 90 | 3,5 | 70 | |
| 4 | Coffee Coolatta | 110 | 7,0 | 90 | |
| 5 | Mocha Expresso | 350 | 10,0 | 120 | |
| 6 | Mocha Frappuccino | 420 | 15,5 | 130 | |
| 7 | Chocolate Brownie | 510 | 23,0 | 211 | |
| 8 | Chocolate Frappuccino | 550 | 27,0 | 350 | |
| 9 | | | | | |
| 10 | Mínimo | 70 | 3,5 | 30 | |
| 11 | Máximo | 550 | 27 | 350 | |
| 12 | Amplitude | 480 | 23,5 | 320 | |
| 13 | | | | | |
| 14 | | | | | |
| 15 | | | | | |

### 3.1.1.10. Amplitudes modificadas

Todas as medidas de dispersão examinadas são não resistentes a valores extremos. Os indicadores resistentes de dispersão são definidos com base nos indicadores

resistentes de posição, que são as medidas de posição relativa, ou seja, quartis e percentis.

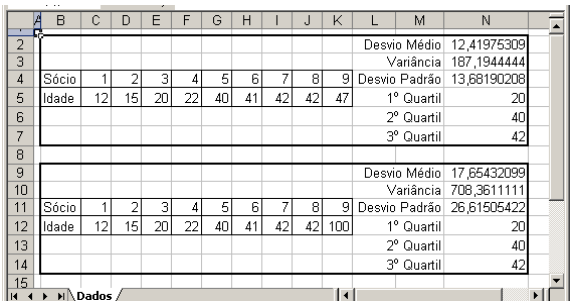
- **Amplitude interquartílica:** diferença entre o terceiro e primeiro quartis.
- **Amplitude semi-interquartílica**: metade da amplitude interquartílica.
- **Amplitude entre percentis 10-90** ou **entre percentis 5-95** etc.

Exemplo: os mpve sócios mais assíduos de um clube são premiados. Suas idades são observadas e iguais a 12, 15, 20, 22, 40, 41, 42, 42 e 47 anos. A amplitude interquartílica é calculada como:

$$AI = Q3 - Q1 = 42 - 20 = 22$$

Para perceber a resistência dessa medida a valores extremos, veja na Figura 38 o efeito de alterar a idade de um dos sócios de 47 para 100 anos de idade: a média, a variância e o desvio padrão são profundamente alterados. Mas os quartis e a amplitude interquartílica não são alterados. Os dados estão no arquivo **Caso Assiduidade Sócios.xlsx.**

**Figura 38.** Efeito de um valor extremo



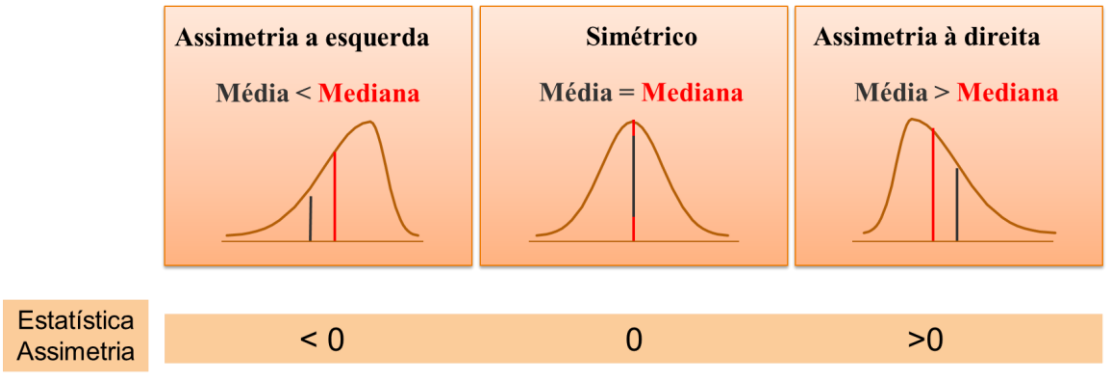
| | B | C | D | E | F | G | H | I | J | K | L | M | N |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 2 | | | | | | | | | | | Desvio Médio | | 12,41975309 |
| 3 | | | | | | | | | | | Variância | | 187,1944444 |
| 4 | Sócio | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | Desvio Padrão | | 13,68190208 |
| 5 | Idade | 12 | 15 | 20 | 22 | 40 | 41 | 42 | 42 | 47 | 1º Quartil | | 20 |
| 6 | | | | | | | | | | | 2º Quartil | | 40 |
| 7 | | | | | | | | | | | 3º Quartil | | 42 |
| 8 | | | | | | | | | | | | | |
| 9 | | | | | | | | | | | Desvio Médio | | 17,65432099 |
| 10 | | | | | | | | | | | Variância | | 708,3611111 |
| 11 | Sócio | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | Desvio Padrão | | 26,61505422 |
| 12 | Idade | 12 | 15 | 20 | 22 | 40 | 41 | 42 | 42 | 100 | 1º Quartil | | 20 |
| 13 | | | | | | | | | | | 2º Quartil | | 40 |
| 14 | | | | | | | | | | | 3º Quartil | | 42 |
| 15 | | | | | | | | | | | | | |

Dados

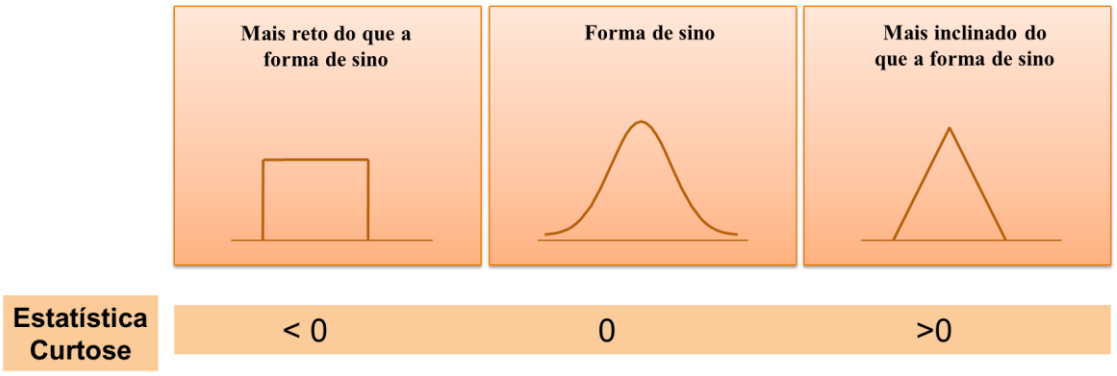
## 3.1.2. Formato da distribuição

Existem medidas que complementam a descrição dos dados: assimetria e curtose. A assimetria mede como determinado conjunto de dados não é simétrico:

Figura 39. Estatísticas de assimetria




A curtose mede a concentração de valores no centro da distribuição de um conjunto de dados em comparação com as caudas. É feita uma comparação com a distribuição normal, que é chamada de forma de sino:



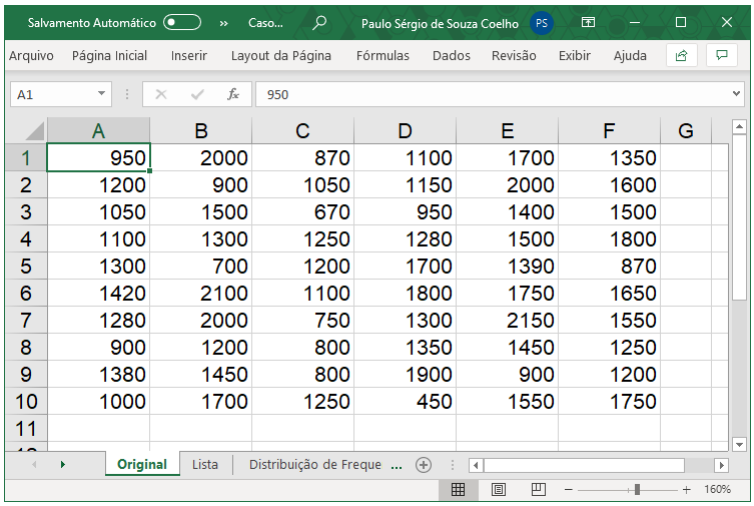

## 3.2. Dados numéricos agrupados

### 3.2.1. Distribuição de frequências

A distribuição de frequências é obtida a partir de dados numéricos granularizados, ou individualizados. Os dados são agrupados em faixas de valores, que podem ser definidas de diversas formas.

Foi mostrado na Seção **Erro! Fonte de referência não encontrada.** como é o processo de construção de um histograma a partir de dados numéricos granularizados. A distribuição de frequências é o resultado do processo intermediário para gerar o histograma.

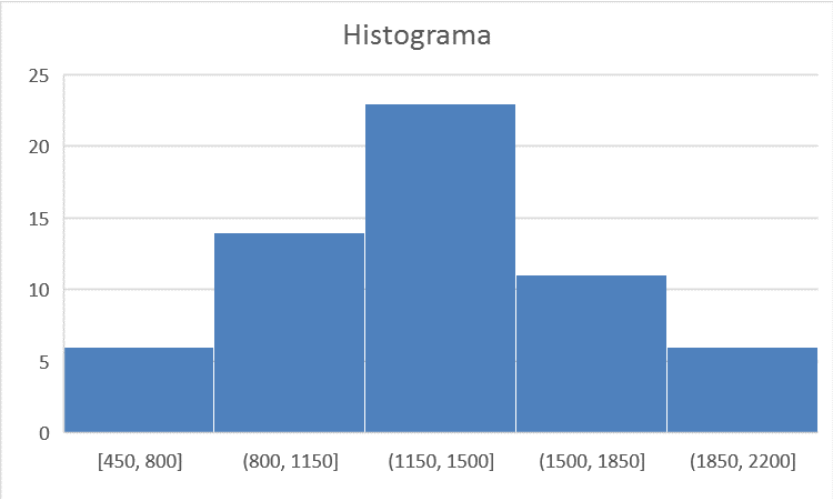
**Figura 40.** Dados granularizados




| | A | B | C | D | E | F | G |
|---|---|---|---|---|---|---|---|
| 1 | 950 | 2000 | 870 | 1100 | 1700 | 1350 | |
| 2 | 1200 | 900 | 1050 | 1150 | 2000 | 1600 | |
| 3 | 1050 | 1500 | 670 | 950 | 1400 | 1500 | |
| 4 | 1100 | 1300 | 1250 | 1280 | 1500 | 1800 | |
| 5 | 1300 | 700 | 1200 | 1700 | 1390 | 870 | |
| 6 | 1420 | 2100 | 1100 | 1800 | 1750 | 1650 | |
| 7 | 1280 | 2000 | 750 | 1300 | 2150 | 1550 | |
| 8 | 900 | 1200 | 800 | 1350 | 1450 | 1250 | |
| 9 | 1380 | 1450 | 800 | 1900 | 900 | 1200 | |
| 10 | 1000 | 1700 | 1250 | 450 | 1550 | 1750 | |
| 11 | | | | | | | |

A partir dos dados disponíveis no arquivo **Caso Passagens Rio Salvador.xlsx**, que estão disponíveis em forma granularizada como está na Figura 40, foi construído o histograma, que está na Figura 41.

**Figura 41.** Histograma

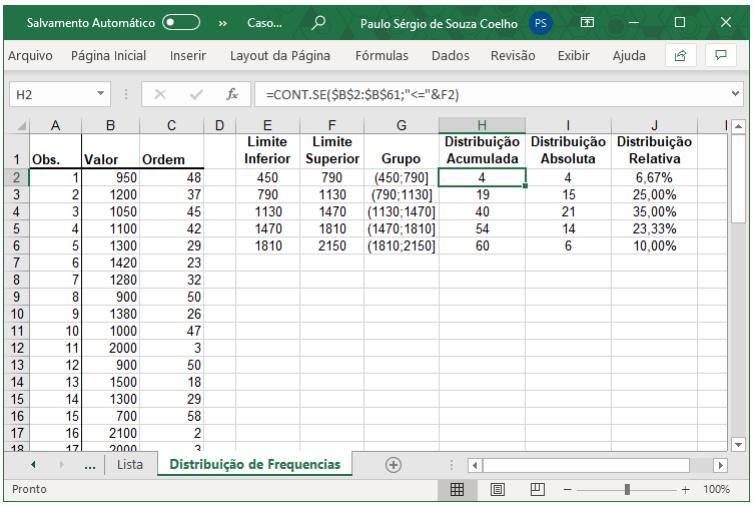



A distribuição de frequências é o relato descritivo do histograma. Como se vê na Figura 42, a distribuição de frequências define cada grupo ou classe através de seus limites inferior e superior. O limite inferior não pertence ao grupo, mas o limite superior sim. Ou seja, uma ocorrência exatamente igual a 790 será contabilizada no grupo 1 e não no grupo 2, já que é o limite superior do grupo 1 e o limite inferior do grupo 2. Isso está sendo expresso tanto nas colunas E e F como na formulação

matemática mais objetiva que está na coluna G: (450 ; 790] está na notação de segmento de reta onde parênteses indicam que o valor extremo não pertence ao segmento e colchete indica que o valor extremo pertence ao segmento.

A frequência está sendo apresentada de três formas diferentes. Além da frequência absoluta (distribuição absoluta) também há a frequência (ou distribuição) acumulada, que mostra a quantidade de observações que está no próprio grupo ou em grupos anteriores, e a frequência (ou distribuição) relativa (absoluta e relativa, para ser mais exato), que é a frequência absoluta expressa em percentuais do total, ou seja, relativiza o tamanho absoluto.

**Figura 42.** Distribuições de frequência




| | A | B | C | D | E | F | G | H | I | J |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | Obs. | Valor | Ordem | | Limite Inferior | Limite Superior | Grupo | Distribuição Acumulada | Distribuição Absoluta | Distribuição Relativa |
| 2 | 1 | 950 | 48 | | 450 | 790 | (450;790] | 4 | 4 | 6,67% |
| 3 | 2 | 1200 | 37 | | 790 | 1130 | (790;1130] | 19 | 15 | 25,00% |
| 4 | 3 | 1050 | 45 | | 1130 | 1470 | (1130;1470] | 40 | 21 | 35,00% |
| 5 | 4 | 1100 | 42 | | 1470 | 1810 | (1470;1810] | 54 | 14 | 23,33% |
| 6 | 5 | 1300 | 29 | | 1810 | 2150 | (1810;2150] | 60 | 6 | 10,00% |
| 7 | 6 | 1420 | 23 | | | | | | | |
| 8 | 7 | 1280 | 32 | | | | | | | |
| 9 | 8 | 900 | 50 | | | | | | | |
| 10 | 9 | 1380 | 26 | | | | | | | |
| 11 | 10 | 1000 | 47 | | | | | | | |
| 12 | 11 | 2000 | 3 | | | | | | | |
| 13 | 12 | 900 | 50 | | | | | | | |
| 14 | 13 | 1500 | 18 | | | | | | | |
| 15 | 14 | 1300 | 29 | | | | | | | |
| 16 | 15 | 700 | 58 | | | | | | | |
| 17 | 16 | 2100 | 2 | | | | | | | |

É possível ver diretamente no arquivo em Excel as fórmulas que foram usadas para obter as frequências: a distribuição acumulada foi obtida primeiro, através da função do Excel CONT.SE, que contabiliza apenas os valores abaixo do limite superior. As demais distribuições foram obtidas a partir da distribuição acumulada.

### 3.2.2. Proporção

A proporção é uma medida de tamanho relativo, ou seja, a própria distribuição de frequências absolutas acumuladas, conforme pode ser visto na Tabela 3.

**Tabela 3.** Frequências e probabilidades

| Grupo | Frequência | Proporção |
|---|---|---|
| **(450;790]** | 4 | 6,67% |
| **(790;1130]** | 15 | 25,00% |

| | | |
|---|---|---|
| **(1130;1470]** | 21 | 35,00% |
| **(1470;1810]** | 14 | 23,33% |
| **(1810;2150]** | 6 | 10,00% |

Podendo ser aplicada para dados numéricos que estão em forma agrupada ou em dados categóricos, a proporção é uma medida de tamanho relativo, que serve para mostrar a relevância da categoria ou grupo frente ao conjunto completo.

### 3.2.3. Média

O uso das proporções para calcular medidas numéricas como média e desvio padrão requer a identificação do ponto central de cada grupo, conforme pode ser visto na Tabela 4. Dados categóricos, apesar de terem frequência e proporção, não têm ponto central. Por isso não é possível calcular média ou desvio padrão de dados categóricos.

**Tabela 4.** Ponto central de cada grupo

| **Grupo** | **Ponto cent** $x_i$ | **Frequência** $f$ | **Proporção** $p$ |
|---|---|---|---|
| **(450;790]** | 620 | 4 | 6,67% |
| **(790;1130]** | 960 | 15 | 25,00% |
| **(1130;1470]** | 1300 | 21 | 35,00% |
| **(1470;1810]** | 1640 | 14 | 23,33% |
| **(1810;2150]** | 1980 | 6 | 10,00% |

É possível calcular a média usando a frequência absoluta, fazendo

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i f_i}{n}$$

Entretanto, como cada $p_i = \frac{f_i}{n}$ , é possível calcular a média fazendo uso direto das proporções:

$$\bar{x} = \sum_{i=1}^{n} x_i p_i$$

Desta forma, seguindo os dados da Tabela 4 obtemos:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i f_i}{n} = \frac{79.020}{60} = 1.317$$

Ou então:

$$\bar{x} = \sum_{i=1}^{n} x_i p_i = 1.317$$

Observa-se que o uso da distribuição absoluta (frequência) é mais intuitivo: está se considerando que cada grupo é representado pelo seu ponto central, que é contabilizado tantas vezes quanto a frequência do grupo, de forma que 60 valores estão sendo somados. Entretanto, o uso da distribuição relativa (proporção) é mais objetivo, levando a um procedimento de cálculo menor.

### 3.2.4. Variância e desvio padrão

Para obter a variância de um conjunto de dados que só está disponível de forma agrupada segue-se a fórmula:

$$s^2 = \sum_{i=1}^{n} \frac{(x_i - \bar{x})^2 \times f_i}{n-1} = \frac{7.959.060}{59} = 134.899{,}32$$

O desvio padrão é calculado a partir da variância, como já é conhecido:

$$s = \sqrt{s^2} = \sqrt{134.899{,}32} = 367{,}2864$$

Via de regra, os valores obtidos quando os dados estão na forma agrupada não são iguais aos valores obtidos quando analisamos os dados na forma granularizada, ou seja, individualizada. É possível ver como os valores são diferentes na Tabela 5.

**Tabela 5.** Diferença nas medidas a partir da forma em que estão os dados

| | Forma em que estão os dados | |
|---|---|---|
| Medida | Granularizados (não agrupados) | Agrupados |
| Média | 1.234,33 | 1.317 |

| | | |
|---|---|---|
| Variância (amostral) | 150.353,79 | 134.899,32 |
| Desvio padrão (amostral) | 387,7853 | 367,2864 |

Essa diferença ocorre porque quando os dados estão na forma agrupada há menos informação do que quando estão na forma granularizada. O procedimento de cálculo de estatísticas usando dados agrupados sugere que, em cada grupo, os dados são todos iguais ao ponto médio ou estão uniformemente distribuídos.

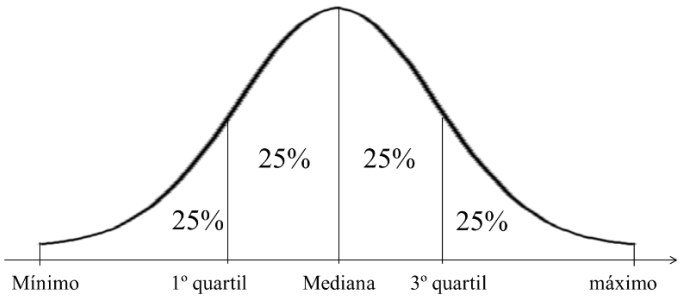
Como essa suposição geralmente não é verdadeira, os valores obtidos para as medidas são uma aproximação da medida verdadeira, que é aquela obtida com os dados granularizados. Dessa forma, é sempre preferível trabalhar com os dados em forma granularizada, ou individualizada. As medidas são calculadas com os dados na forma agrupada apenas quando os dados não estão disponíveis na forma granularizada.

### 3.2.5. Resumos exploratórios de dados

As medidas estatísticas são úteis para resumir características relevantes dos dados sob análise. O uso de várias medidas juntas é uma forma bem conveniente de ressaltar alguns aspectos dos dados.

O uso de cinco medidas é muito conveniente para analisar como se comportam os dados em uma forma bem resumida. As cinco medidas usadas são relativas e indicam: o mínimo, os quartis e o máximo, como podemos ver na Figura 43.

**Figura 43.** Resumo dos cinco números




A forma mais comum de usar os cinco números para resumir o comportamento dos dados é através de um gráfico conhecido como box plot (ou diagrama de caixa), que

está demonstrado na Figura 44. Esse diagrama pode ser apresentado de forma vertical.

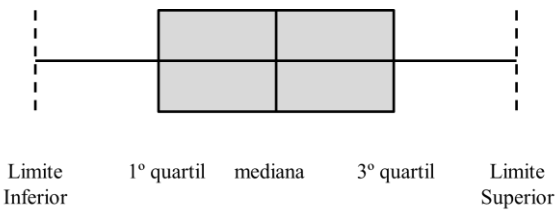
Os valores indicados como limites (inferior e superior) no box plot podem ser calculados de diversas formas. As formas mais comuns (o Excel usa a forma 3 a seguir com uma pequena alteração no procedimento 2) são:

1) Mínimo e máximo.

2) $LI=Q_1-1,5\times AI$ e $LS=Q3+1,5\times AI$, onde $AI$ é a amplitude interquartílica, que é definida como sendo $AI = \frac{Q3-Q1}{2}$.

3) Uma combinação das duas anteriores, de forma que o limite inferior seja o maior dos valores calculados das duas formas anteriores e o limite superior seja ao menor dos dois valores.

**Figura 44.** Box plot




O box plot permite analisar a assimetria dos dados comparando os tamanhos das regiões delimitadas pelos elementos no diagrama. A lógica da interpretação está descrita na Tabela 6 e pode ser vista graficamente na Figura 45.

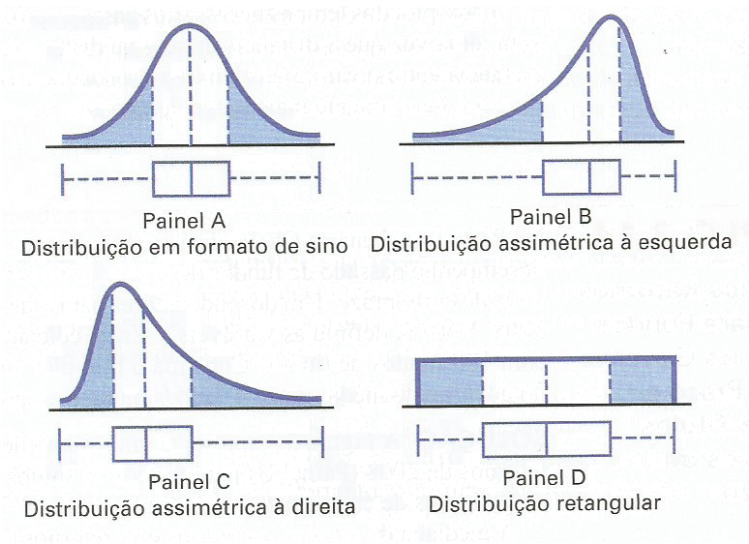
**Tabela 6.** Interpretando a assimetria

| | **Assimétrica à esquerda** | **Simétrica** | **Assimétrica à direita** |
|---|---|---|---|
| do lim. inferior até a mediana<br>X<br>da mediana até o lim. superior | > | = | < |
| do lim. inferior até o 1º quartil<br>X<br>do 3º quartil até o lim superior | > | = | < |

| | | | |
|---|---|---|---|
| do 1º quartil até a mediana<br>X<br>da mediana até o 3º quartil | > | = | < |

Comparando a distribuição simétrica (em formato de sino) com a distribuição assimétrica à esquerda se percebe que os elementos menores (limite inferior e primeiro quartil) estão mais afastados do que os elementos maiores (limite superior e terceiro quartil). E que o oposto ocorre quando a distribuição é assimétrica à direita.

**Figura 45.** Assimetria: distribuição de frequência X box plot




A distribuição retangular, também chamada de distribuição uniforme, é uma distribuição simétrica especial. É possível ver no box plot que as quatro regiões do gráfico têm o mesmo tamanho. A distribuição uniforme tem como característica fundamental o fato de que a amplitude de cada uma das quartas partes é igual.

## 3.3. Intervalos de concentração

A distribuição dos dados simétricos em forma de sino, como a distribuição normal, costuma apresentar uma concentração em torno da média. Quando os dados são assimétricos, a distribuição se concentra em um dos lados da média – à direita ou à esquerda.

Usando a média como medida de tendência central e o desvio padrão como medida de dispersão, é possível definir intervalos nos quais grandes volumes dos dados estão concentrados. Estes intervalos estão centralizados na média e têm seus

extremos definidos como uma distância da média. Essa distância é calculada com base no desvio padrão. A forma geral destes intervalos é a seguinte:

$$(\mu - k \times \sigma ; \mu + k \times \sigma)$$

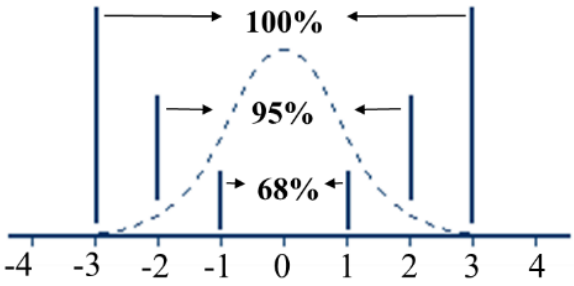
O valor do multiplicador $k$ é definido usando a Lei Empírica quando os dados têm distribuição simétrica em forma de sino e definido usando a Lei de Chebyshev quando os dados têm uma distribuição diferente da forma de sino. Quando não se sabe a forma da distribuição dos dados, é usada a Lei de Chebyshev, que tem aplicação genérica.

### 3.3.1. Lei empírica

Para um conjunto de dados com distribuição simétrica e em forma de sino, valem as seguintes proporções (aproximadas):

- 68% dos dados estão no intervalo $(\mu - 1 \times \sigma ; \mu + 1 \times \sigma)$, ou seja, $k = 1$.
- 95% dos dados estão no intervalo $(\mu - 2 \times \sigma ; \mu + 2 \times \sigma)$, ou seja, $k = 2$.
- 95% dos dados estão no intervalo $(\mu - 3 \times \sigma ; \mu + 3 \times \sigma)$, ou seja, $k = 3$.

**Figura 46.** Lei empírica




A Lei Empírica define o tamanho relativo dos intervalos de concentração para três diferentes valores do multiplicador do desvio padrão $k$.

**Exemplo**: sabe-se que a exata quantidade de bebida que está em uma garrafa de 600ml tem certa variação. Considere que a indústria fez uma análise estatística usando um equipamento de alta precisão e descobriu que o volume das garrafas tem uma distribuição simétrica, com forma de sino, com média igual a 610ml e desvio padrão igual a 3ml. A indústria está muito preocupada com a possibilidade de haver algumas garrafas com volume menor do que o indicado no rótulo. Como é possível

avaliar a possibilidade de que uma garrafa tenha menos que 600ml de volume efetivo?

**Solução**: Usando a Lei empírica é possível verificar que:

- 68% das garrafas têm volume entre $(\mu-1\times\sigma ;\mu+1\times\sigma) = (607; 613)$.
- 95% das garrafas têm volume entre $(\mu-2\times\sigma ;\mu+2\times\sigma) = (604; 616)$.
- 100% das garrafas têm volume entre $(\mu-3\times\sigma ;\mu+3\times\sigma) = (601; 619)$.

Portanto, em valores aproximados, todas as garrafas estarão acima de 601ml.

**Atenção**: os valores declarados pela Lei empírica são aproximados, e isso é especialmente importante para o terceiro intervalo. No exemplo acima, é possível que alguma garrafa tenha volume menor do que 601ml e até mesmo menor do que 600ml. Mas essa ocorrência é muito rara, também chamada de *outlier*.

### 3.3.2. Lei de Chebyshev

Para qualquer conjunto de dados, independentemente do formato de sua distribuição, a proporção mínima de valores compreendidos no intervalo $(\mu-k\times\sigma ;\mu+k\times\sigma)$ é definido em valores decimais por:

$$\left(1-\frac{1}{k^2}\right)$$

Para obter a proporção em percentual, o valor calculado acima deve ser multiplicado por 100.

A Lei de Chebyshev só pode ser usada para valores de $k$ maiores do que 1. Ao contrário da Lei Empírica, que define apenas três intervalos de concentração, a Lei de Chebyshev permite definir infinitos intervalos de concentração, para infinitos valores de $k > 1$.

**Exemplo**: Considerando o caso das bebidas, declarado anteriormente, $(\mu=610 \text{ e } \sigma=3)$, considere agora que a indústria não conseguiu determinar o formato da distribuição dos dados. Deseja-se determinar a proporção de garrafas que têm volume entre 601ml e 619ml.

**Solução**: como não se sabe o formato dos dados, é necessário usar Chebyshev. O intervalo (601; 619) foi obtido fazendo *k = 3* na fórmula $(\mu\text{-}k\times\sigma\,;\mu+k\times\sigma)$, e então, de acordo com a Lei de Chebyshev, a proporção é dada por

$$\left(1-\frac{1}{k^2}\right)=\left(1-\frac{1}{3^2}\right)=1-\frac{1}{9}=0{,}8889$$

Ou seja, é possível garantir que pelo menos 88,89% das garrafas têm volume entre 601ml e 613ml.

## 3.4. Detecção de Outliers

Outliers são valores discrepantes, ou valores extremos no conjunto de dados. Outliers são valores acentuadamente distintos dos demais e são incomuns e raros. Muitas vezes são valores errados, frutos de uma classificação errada ou um erro de cálculo. Mas, mesmo quando são valores corretos, por serem raros e discrepantes, costumam ser identificados e muitas vezes isolados.

Por exemplo, ao verificar o cadastro de uma operadora de cartões de crédito, foi encontrado um cliente com 128 anos de idade com perfil de uso muito intenso, incluindo boates, bares badalados. Uma investigação nessa ocorrência pode apontar um erro de cálculo (a idade era 28 anos, mas houve uma digitação errada do ano de nascimento), ou um erro de classificação (o usuário do cartão de crédito não é o titular, ou seja, o titular do cartão empresta o cartão para um neto – ou bisneto). Finalmente, pode ser que haja de fato uma pessoa com 128 anos que frequente boates e bares. Mas isso é muito inesperado!

O método mais usado para detectar um outlier é o cálculo do Escore Z da observação. Para calcular o Escore Z de uma observação, é necessário conhecer a média e o desvio padrão do conjunto de dados:

$$z=(x-\mu)/\sigma$$

O escore Z é uma medida da distância entre a observação x e a média μ. Só que esta distância está medida em unidades de desvio-padrão, ou seja, a distância é dada por z desvios-padrões.

O escore Z também é conhecido como escore reduzido ou escore padrão. Ele pode ser negativo, indicando que $x<\mu$, ou positivo, indicando que $x>\mu$. O valor de Z se relaciona com o multiplicador k dos intervalos de concentração.

Pelo método do Escore Z, valores superiores a 3 ou inferiores a -3 serão considerados outliers. Valores entre -3 e 3 são considerados normais.

Exemplo: considerando o exemplo da indústria de bebidas, que descobriu que os volumes reais de bebidas em suas garrafas seguiam uma distribuição com $\mu=610$ e $\sigma=3$, uma garrafa com 595ml pode ser considerada outlier? E uma com 605ml?

Solução:

Calculando o Escore Z se obtêm:

$Z_{595}=(595-610)/3=-15/3=-5$

$Z_{605}=(605-610)/3=-5/3=-1,67$

Então, como apenas valores menores que -3 são considerados outliers, a garrafa com 595ml é um outlier, mas a garrafa com 605ml não é outlier.

# 4. Probabilidade

Quando as pessoas precisam fazer avaliações sobre fatos que não sabem exatamente como são ou como serão, paira uma incerteza sobre as possibilidades. É assim quando se deseja avaliar se choverá amanhã ou quanto um concorrente vendeu no mês passado.

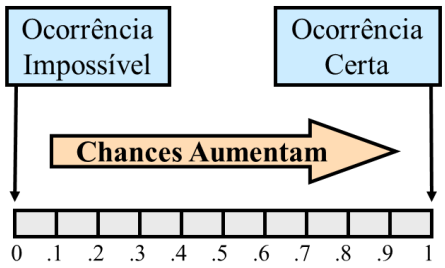
Para analisar a incerteza, a probabilidade é uma ferramenta fundamental que permitirá analisar e quantificar os riscos, facilitando os processos decisórios e as análises de cenários.

A origem das probabilidades está relacionada com jogos de azar (cartas, dados, roleta etc.) durante o século XVI. Hoje em dia, para as diversas áreas de negócio, há aplicações muito relevantes da probabilidade, sempre onde há casualidade ou incerteza associados a eventos futuros: reação dos consumidores, planejamento comercial e financeiro, consequências de impactos econômicos nas vendas e no crédito, tolerância das operações a falhas em processos etc.

Em busca de um conceito, pode-se dizer que probabilidade mede as chances de determinado evento ocorrer. A probabilidade mede a possibilidade: eventos impossíveis têm probabilidade zero e eventos certos tem probabilidade igual a um. Nunca um evento terá probabilidade negativa nem maior do que um.

Veja na Figura 47 a escala decimal da probabilidade. Na nossa cultura é muito comum analisar a probabilidade como um valor percentual. Os valores percentuais são obtidos multiplicando os valores decimais por 100.

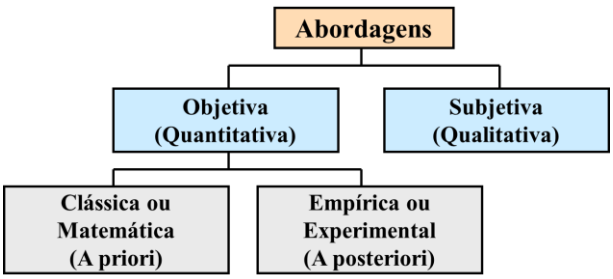
**Figura 47.** Escala de valores da probabilidade




## 4.1. Abordagens

O valor da probabilidade de determinado evento pode ser obtido de diferentes maneiras, ou diferentes abordagens. Na Figura 48 é possível ver como se estruturam as abordagens.

**Figura 48.** Abordagens da probabilidade




### Abordagem Clássica

A abordagem clássica parte de um conjunto de suposições que permitem obter o valor da probabilidade sem realização de experimentos. As suposições mais importantes são sobre os eventos são:

- mutuamente exclusivos, ou seja, quando determinado evento ocorre outro evento não pode ocorrer;
- equiprováveis, ou seja, têm a mesma probabilidade de ocorrer;
- coletivamente exaustivos, ou seja, todos os resultado possíveis são conhecidos e listados, de forma que a soma de suas probabilidades é igual a 1 (ou 100%)

Dessa forma, a probabilidade é obtida pela abordagem clássica fazendo:

$$p(A) = \frac{\text{quantidade de resultados a favor}}{\text{quantidade total de resultados}} = \frac{n(A)}{n(S)}$$

onde $p(A)$ é a probabilidade do evento $A$, $\mathrm{n}(S)$ é a quantidade total de resultados possíveis para o experimento e $n(A)$ é a quantidade de resultados em que, dentre os possíveis, $A$ é verificado.

**Exemplo**: Um dado não viciado de seis faces, cada uma delas rotulada com números de 1 a 6, será lançado. Qual a probabilidade de se observar o número 4 voltado para cima?

**Solução**: Existem 6 resultados possíveis, todos conhecidos: 1, 2, 3, 4, 5 e 6 (coletivamente exaustivos). Os resultados são mutuamente exclusivos (não é possível observar mais de um lado voltado para cima) e equiprováveis (é a mesma chance para qualquer um dos resultados. Logo, aplicando a abordagem clássica se obtém:

$$p(4) = \frac{n(4)}{n(\text{dado})} = \frac{1}{6} = 0{,}1667$$

**Abordagem experimental**

A abordagem experimental também é chamada de abordagem da frequência relativa. Quando as hipóteses da abordagem experimental não são verificadas ou não podem ser garantidas, é necessário realizar experimentos para criar ocorrências em que se possa contabilizar a quantidade de ocorrências a favor e a quantidade de ocorrências geral.

Os experimentos podem ser controlados, quando sua ocorrência é provocada para fins de medição, ou observados, quando a sua ocorrência independe do analista, cabendo a ele apenas observar e medir. Por exemplo, para controle de qualidade a indústria separa alguns itens produzidos para serem submetidos a testes. Alguns itens serão reprovados no teste e outros não serão. Daí a indústria poderá estimar a probabilidade de falha de um item qualquer, mesmo não tendo sido testado. Por outro lado, a conversão das vendas é estimada por observação: o gerente comercial observa quantas vezes o vendedor conseguiu realizar a venda e compara com o total

de clientes (oportunidades de venda) que ele teve. Essa comparação pode ser usada como a probabilidade de realizar (converter) a venda quando um cliente qualquer é abordado por aquele vendedor.

Para estimar a probabilidade de forma experimental, é necessário realizar o experimento diversas vezes para ter uma quantidade de ocorrências suficientemente grande. Daí se teria:

$$p(A) = \frac{\text{quantidade de ocorrências de } A}{\text{quantidade total de ocorrências}} = \frac{n(A)}{n(S)}$$

As duas fórmulas anteriores são muito parecidas, mas há uma diferença conceitual: no caso clássico não foi necessário fazer experimento nenhum. O tamanho do espaço amostral $n(S)$ e a quantidade de resultados a favor $n(A)$ são dados pelas circunstâncias.

**Exemplo**: Considere-se novamente o lançamento de um dado com seis faces numeradas de 1 a 6, mas agora se sabe que o dado possui um vício, ou seja, os resultados não são equiprováveis. Não é possível determinar de antemão qual face tem maior probabilidade de ocorrer ou qual tem menor. Qual a probabilidade de ocorrência do número 4?

**Solução**: Nessa nova situação é necessário realizar experimentos que permitam contar a quantidade de vezes que o número 4 aparece frente a uma quantidade total de lançamentos. Na Tabela 7 é possível ver um relatório de experimentos. Ao todo o dado foi lançado 100.000 vezes, e em 19.990 vezes foi observado o número 4 voltado para cima. Isso permitiu estimar a probabilidade como 0,1999, ou 19,99%.

**Tabela 7.** Experimentos de lançamento de um dado

| **Quantidade de lançamentos** | **Quantidade de ocorrências "4"** | **Proporção** |
|---|---|---|
| 6 | 2 | 2/6=0,3333 |
| 60 | 13 | 13/60=0,2167 |
| 600 | 122 | 122/600=0,2033 |
| 1.000 | 202 | 202/1.000=0,2020 |
| 10.000 | 2.008 | 2.008/10.000=0,2008 |

| | | |
|---|---|---|
| 100.000 | 19.990 | 19.990/100.000=0,1999 |

A Tabela 7 também apresenta quantidades parciais de lançamentos, e é importante notar que quando a quantidade de lançamentos é pequena a estimativa da probabilidade é muito instável. Com apenas 6 lançamentos é impossível obter 19,99% de probabilidade (ou dá 16,67%, se o 4 sair uma única vez, ou dá 33.33%, se o dado sair duas vezes). Por isso, é fundamental haver uma quantidade grande de experimentos para ter uma estimativa de probabilidade estável e razoável.

Observa-se que as probabilidades estimadas pela abordagem experimental são aproximações e só serão válidas se as amostras mantiverem as características das populações que as originaram. Isso é especialmente importante quando são usados dados históricos, já que o futuro nem sempre repete o passado.

**Abordagem subjetiva**

Geralmente essa abordagem é usada quando não é possível aplicar as abordagens matemáticas anteriores, ou seja, alguma das hipóteses necessárias para a abordagem clássica não está disponível e não há dados históricos ou condições de realizar um experimento.

A abordagem subjetiva é baseada na opinião pessoal de um ou mais indivíduos. Se os indivíduos forem conhecedores do cenário, o que ocorre quando são especialistas por estudo ou por experiência já vividas, os valores estimados têm maiores chances de estarem corretos ou terem erros pequenos. Por outro lado, a abordagem subjetiva está sujeita a tendenciosidades por conta do estado emocional ou mental do analista, de preconceitos e de outros tipos de prejulgamento. Além disso, probabilidades estimadas pela abordagem subjetiva são dificilmente explicadas quando questionadas. Exemplos:

- Uma pessoa resolve procurar uma franquia de uma loja de sapatos porque acha que terá uma rentabilidade garantida.
- Uma indústria decide procurar um novo produto para ser lançado baseado em feeling de mercado.
- Um investidor decide aplicar em renda fixa porque acha que esta é a melhor opção dentre as oportunidades de investimento oferecidas no mercado.

## 4.2. Conceitos fundamentais

- **Evento**: cada resultado possível. Por exemplo: quando um cliente entra na loja, podem-se desenhar dois eventos “clientes que compram” e “clientes que não compram”.
- **Evento simples**: uma única característica (ex.: clientes que compram, noites que chovem, carros vermelhos).
- **Evento combinado**: mais de uma característica (ex.: clientes que compram e pagam com cartão, noites que chovem mas estão quentes); ou mais de um evento simples (carros vermelhos e carros azuis).
- **Complemento**: A’ é o complemento do evento A se inclui todos os eventos que não fazem parte de A (ex.: se o evento A é “clientes que compram e pagam com cartão, então A’ é o evento combinado: “clientes que não compram” ou “clientes que compram e pagam com outra forma de pagamento que não cartão”).
- **Espaço amostral**: o conjunto de todos os eventos possíveis.

**Exemplo**: Um levantamento forneceu os seguintes dados sobre compensação salarial e bônus para altos executivos de corporações tecnológicas e financeiras (tabela de contingência)

**Tabela 8.** Compensação salarial de altos executivos

| | **Compensação total** | | | |
|---|---|---|---|---|
| **Área de Atuação** | **Menos de R$1** | **R$1M–R$2M** | **Mais de R$** | **Total** |
| Tecnológica | 17 | 21 | 7 | 45 |
| Financeira | 12 | 31 | 17 | 60 |
| Total | 29 | 52 | 24 | 105 |

É possível considerar:

— Evento simples: A: um executivo ser da área financeira.

— Evento Combinado: B: um executivo ser da área tecnológica e ganhar até R$1 milhão de compensação financeira.

— Complemento: O complemento ao evento A: “um executivo ser da área financeira” é o evento A’: “um executivo ser da área tecnológica”.

— Espaço amostral: um executivo ser da área financeira ou tecnológica, com qualquer valor de compensação financeira.

É possível, considerando a abordagem experimental, definir as probabilidades:

- P(área financeira)=60/105=0,5714, ou 57,14%
- P(compensação total entre R$1 e R$2 milhões)=52/105=0,4952, ou 49,52%
- P(área tecnológica e ganhar mais de R$2 milhões )=7/105=0,0667, ou 6,67%

### 4.2.1. Probabilidade marginal

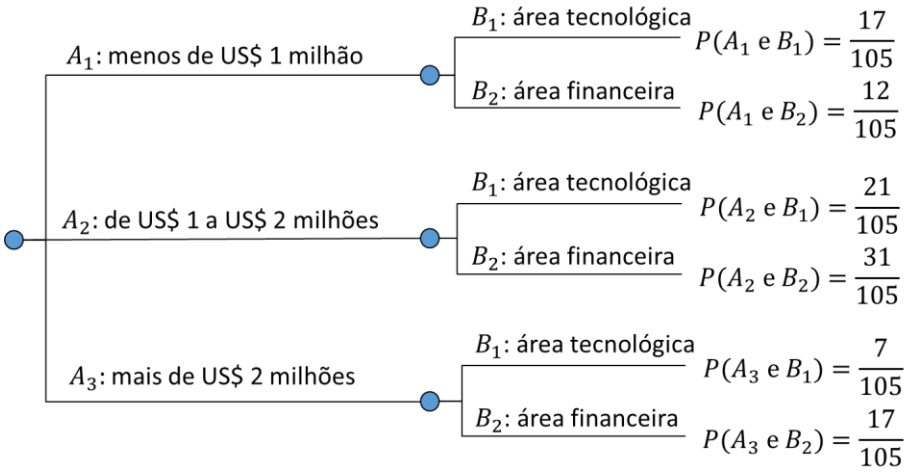
A probabilidade marginal aparece quando a probabilidade de um evento simples é dividida em parcelas relativas a todos os eventos compostos considerando aquele elemento simples. As parcelas são as probabilidades marginais.

Por exemplo, é possível definir que P (ganho até R$1 milhão) = P (ganho até R$1 milhão e área tecnológica) + P (ganho até R$1 milhão e área financeira). Nesse caso, as duas probabilidades marginais são P (ganho até R$1 milhão e área tecnológica) e P (ganho até R$1 milhão e área financeira).

De fato, é possível verificar que a soma das probabilidades marginais é igual à probabilidade do evento simples:

- P (ganho até R$1 milhão) = 29/105=0,2762 ou 27,62%;
- P (ganho até R$1 milhão e área tecnológica) = 17/105 = 16,19%; e
- P (ganho até R$1 milhão e área financeira) = 12/105 = 11,43%

**Figura 49.** Árvore de eventos




A representação gráfica de eventos através de um diagrama conhecido como árvore ajuda a identificar as probabilidades dos eventos marginais. A partir dos eventos marginais é possível calcular as probabilidades dos eventos simples:

$$P(A_1) = P(A_1 \text{ e } B_1) + P(A_1 \text{ e } B_2) = \frac{17}{105} + \frac{12}{105} = \frac{29}{105}$$

E também $P(B_1) = P(A_1 \text{ e } B_1) + P(A_2 \text{ e } B_1) + P(A_3 \text{ e } B_1) = \frac{17}{105} + \frac{21}{105} + \frac{7}{105} = \frac{45}{105}$

### 4.2.2. Probabilidade condicional

A probabilidade de determinado evento pode ser alterada quando determinados fatos são conhecidos. Por exemplo, a probabilidade de que o trânsito esteja mais congestionado do que o normal amanhã é estimada em 20%. Entretanto, se é sabido que estará chovendo amanhã, esta probabilidade aumenta para, digamos, 70%.

No exemplo acima, diz-se que P(trânsito)=20% e P(trânsito congestionado| chove)=70%. A segunda probabilidade é chamada de probabilidade condicional e se lê “a probabilidade de que o trânsito esteja congestionado dado que estará chovendo”.

A probabilidade de ocorrer o evento $A$, sendo que é conhecido que o evento $B$ ocorreu, é chamada de Probabilidade de ocorrer $A$ dado ocorre $B$ e é calculada como

$$P(A|B) = \frac{P(A \text{ e } B)}{P(B)}$$

Em geral, $\mathrm{P(A|B)} \neq \mathrm{P(B|A)}$.

Considerando-se os dados do exemplo anterior e as definições de eventos:

- $A_1$: ganhar menos de R$1 milhão
- $A_2$: ganhar entre R$1 milhão e R$2 milhões
- $A_3$: ganhar mais de R$2 milhões
- $B_1$: ser da área tecnológica
- $B_2$: ser da área financeira

é possível calcular:

- A probabilidade de ganhar menos de R$1 milhão é $P(A_1) = \frac{29}{105}$.
- A probabilidade ser da área tecnológica é $P(B_1) = \frac{45}{105}$.
- A probabilidade de ganhar menos de R$1 milhão e ser da área tecnológica é $P(A_1 \text{ e } B_1) = \frac{17}{105}$.
- A probabilidade de ganhar menos de R$1 milhão sendo da área tecnológica é $P(A_1 \mid B_1) = \frac{P(A_1 \text{ e } B_1)}{P(B_1)} = \frac{17/105}{45/105} = \frac{17}{45}$.

Uma maneira intuitiva de entender a probabilidade condicional é a mudança do universo: $P(A_1 \text{ e } B_1)$ é uma medida que considera o universo total de executivos, que é 105. Mas $P(A_1|B_1)$ refere-se apenas aos executivos que são da área tecnológica, que é 45. Assim, a primeira é 17/105 e a segunda é 17/45.

### 4.2.3. Eventos independentes

Um evento $A$ é independente do evento $B$ quando a ocorrência ou não ocorrência de $B$ não altera a probabilidade de ocorrência de $A$. Ou seja:

$$\mathrm{P(A|B)} = \mathrm{P(A)}$$

A independência é uma relação transitiva, ou seja, se $A$ é independente de $B$ então $B$ é independente de $A$, e então também vale:

$$\mathrm{P(B|A)} = \mathrm{P(B)}$$

Por consequência, tem-se:

$$\mathrm{P(A\ e\ B) = P(A) \times P(B)}$$

**Exemplo**: Para os dados a seguir, o evento “estar satisfeito com a compra” e o evento “tipo de TV comprado = LCD” são independentes ou não?

| | **Satisfeito com a compra?** | | |
|---|---|---|---|
| **Tipo de TV** | **Sim** | **Não** | **Total** |
| LCD | 96 | 8 | 104 |
| LED | 264 | 22 | 286 |
| Total | 360 | 30 | 390 |

**Solução**:

É necessário calcular uma probabilidade condicional e comparar com a probabilidade do evento simples. Por exemplo:

$$P(\text{satisfeito} \mid \text{TV = LCD}) = \frac{96}{104} = 92{,}31\%$$

$$P(\text{satisfeito}) = \frac{360}{390} = 92{,}31\%$$

Logo, são independentes. A probabilidade de estar satisfeito não é alterada por ter comprado uma TV de LCD ou não.

### 4.2.4. Teorema de Byes

Essa é uma ferramenta que permite usar informações já disponíveis para estimar probabilidades ainda desconhecidas. Um exemplo prático será útil para entender como o teorema é útil.

**Exemplo**: São dadas as seguintes informações:

a. A probabilidade de que uma pessoa esteja com uma certa doença é 0,03.
b. A probabilidade de que determinado teste dê positivo quando a pessoa está efetivamente doente é 0,90.

c. A probabilidade que este teste dê positivo quando a pessoa não está doente é de 0,02.

Deseja-se estimar:

1) A probabilidade de o resultado ser positivo para uma pessoa qualquer.
2) A probabilidade de que a pessoa esteja doente, dado que o teste deu positivo.

**Solução:** Definem-se os eventos:

- $D_1$: a pessoa está doente
- $D_2$: a pessoa não está doente
- $T_1$: o teste dá positivo
- $T_2$: o teste dá negativo

As informações prestadas no enunciado do exemplo são interpretadas da seguinte forma:

a. $\mathrm{P}(\mathrm{D}_1) = 0{,}03$
b. $\mathrm{P}(\mathrm{T}_1|\mathrm{D}_1) = 0{,}90$
c. $\mathrm{P}(\mathrm{T}_1|\mathrm{D}_2) = 0{,}02$

A partir das informações no enunciado, pode-se deduzir que:

a. $\mathrm{P}(\mathrm{D}_2) = 0{,}97$, pois $\mathrm{P}(\mathrm{D}_1)+\mathrm{P}(\mathrm{D}_2)=1$
b. $\mathrm{P}(\mathrm{T}_2|\mathrm{D}_1) = 0{,}10$, pois $\mathrm{P}(\mathrm{T}_1|\mathrm{D}_1) + \mathrm{P}(\mathrm{T}_2|\mathrm{D}_1) = 1$
c. $\mathrm{P}(\mathrm{T}_2|\mathrm{D2}) = 0{,}98$, pois $\mathrm{P}(\mathrm{T}_1|\mathrm{D}_2) + \mathrm{P}(\mathrm{T}_2|\mathrm{D}_2) = 1$

As probabilidades que se deseja estimar são:

1) $\mathrm{P}(\mathrm{T}_1)$
2) $\mathrm{P}(\mathrm{D}_1|\mathrm{T}_1)$

Os valores $\mathrm{P}(\mathrm{D}_1)$ e $\mathrm{P}(\mathrm{D}_2)$ são chamados de **probabilidades *a priori***, ou seja, probabilidades definidas antes de qualquer evidência empírica adicional: sem fazer o teste, espera-se que 3% das pessoas estejam doentes $(\mathrm{P}(\mathrm{D}_1) = 0{,}03)$.

Os valores $P(T_1|D_1)$, $P(T_2|D_1)$, $P(T_1|D_2)$ e $P(T_2|D_2)$ são chamados de **probabilidades empíricas**, pois são obtidos a partir de situações empíricas anteriores: depois de testar diversas pessoas que estavam de fato doentes, descobriu-se que o teste funcionou 90% das vezes ($P(T_1|D_1)=0,9$) e, consequentemente, que falhou 10% das vezes ($P(T_2|D_1)=0,1$); de forma análoga, depois de testar diversas pessoas que estavam de fato saudáveis, descobriu-se que o teste falhou 2% das vezes ($P(T_1|D_2)=0,02$) e, consequentemente, funcionou 98% das vezes ($P(T_2|D_2)=0,98$).

1) Já o valor $P(D_1|T_1)$ é chamado de **probabilidade *a posteriori***, pois são revisões do valor *a priori* em função das evidências empíricas.

O Teorema de Bayes estabelece que:

$$P(D_1 \mid T_1) = \frac{P(T_1 \mid D_1) \times P(D_1)}{P(T_1)}$$

E, usando as probabilidades marginais, é possível calcular

$$P(T_1) = P(T_1|D_1) \times P(D_1) + P(T_1|D_2) \times P(D_2)$$

Assim, para obter as respostas,

1) $P(T_1)=0,9 \times 0,03 + 0,02 \times 0,97 = 0,0464$
2) $P(D_1 \mid T_1) = \frac{0,9 \times 0,03}{0,0464} = 0,5819$

Dessa forma, se compreende que:

- A probabilidade de qualquer pessoa estar doente é 3% (probabilidade *a priori* $P(D_1) = 0,03$);
- A probabilidade de uma pessoa estar doente dado que fez o teste e o mesmo deu positivo é de 58,19% (probabilidade a posteriori $P(D_1|T_1)=0,5819$).

O teste atualiza a probabilidade estimada incialmente de 3% para 58,19%.

Formalizando, quando $B_1, B_2, \ldots B_k$ são vários eventos são mutuamente excludentes e coletivamente exaustivos, então para qualquer um deles, digamos $B_i$ se pode fazer:

$$P(B_i|A) = \frac{P(A|B_i) \times P(B_i)}{P(A|B_1) \times P(B_1) + P(A|B_2) \times P(B_2) + \cdots + P(A|B_k) \times P(B_k)}$$

## 4.3. Probabilidade de eventos compostos

As probabilidades dos eventos compostos podem ser calculadas com base nas probabilidades dos eventos simples que o compõem. Quando os eventos simples são combinados usando uma junção “OU”, pode ser usada a Lei da Adição. Quando os eventos simples são combinados usando uma junção “E”, pode ser usada a Lei da Multiplicação. Algumas hipóteses precisam ser verificadas para aplicar cada caso.

### 4.3.1. Lei de Adição

Combinações de eventos simples usando a junção “OU” podem ser exemplificadas nas seguintes situações:

- No lançamento de um dado, qual a probabilidade de tirarmos 1 ou 2?
- Em uma pesquisa entre 1.000 correntistas de um banco, qual a probabilidade de encontrarmos um investidor que aplique no fundo de ações ou no fundo de renda fixa?

As regras para o cálculo das probabilidades, as leis da adição, são duas, para cada uma das situações distintas:

Eventos mutuamente exclusivos: os eventos simples sob combinação são tais que a ocorrência de um deles assegura que o outro não poderá ocorrer. Neste caso:

$$\mathrm{P(A\ ou\ B)=P(A\cup B)=P(A)+P(B)}$$

Eventos não mutuamente exclusivos: os eventos simples sob combinação podem ocorrer simultaneamente. Neste caso:

$$\mathrm{P(A\ ou\ B)=P(A\cup B)=P(A)+P(B)\text{-}P(A\ e\ B)}$$

A segunda forma de enunciado da Lei é a mais completa, visto que no primeiro caso se tem $\mathrm{P(A\ e\ B)=0}$.

**Exemplo (mutuamente exclusivo):** Em uma empresa com 1.500 funcionários, 450 trabalham na área de Produção, 600 na área de Marketing, 300 na área de Finanças e 150 na área de Administração. A direção pretende implementar um plano de aposentadoria e decide enviar questionários a todos os empregados. 1) Quais as probabilidades de o primeiro questionário ser respondido por alguém de Produção?

2) E de Finanças?

3) E de Produção ou Marketing?

4) E de Produção e Marketing?

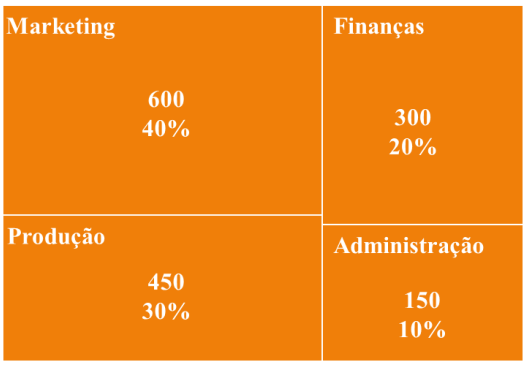
5) E de qualquer área que não seja Finanças?

**Solução:** É fácil perceber que os eventos “trabalhar na área de produção”, “trabalhar na área de marketing”, “trabalhar na área de finanças” e “trabalhar na área de administração” são mutuamente excludentes, pois a soma das frequências de cada um deles é igual a 1.500, que é o total.

Para capturar melhor os dados do problema, é montado um diagrama de Venn, onde cada conjunto de funcionários é representado por uma área delimitada. Os diagramas de Venn costumam ser representados por círculos ou regiões ovais, mas está sendo representado na Figura 50 por quadrados, sem nenhum motivo específico.

Cada quadrado representa o conjunto dos funcionários alocados em cada setor. Os conjuntos não tem sobreposição, porque os eventos são mutuamente exclusivos (uma interseção indicaria a existência de funcionários que estão simultaneamente em mais de um departamento). Em cada conjunto, indicamos a frequência absoluta e a relativa, que é a proporção e que será usadao como probabilidade do evento simples associado a esse conjunto.

**Figura 50.** Representação gráfica da alocação dos funcionários




Assim, observando o conjunto é possível estimar as probabilidades:

1) P(produção)=30%
2) P(finanças)=20%
3) P(produção ou marketing)=30%+40%=70%

4) P(produção e marketing)=0%
5) P(qualquer área que não finanças)=80%.

A lei da adição foi explicitamente usada no cálculo da 3ª probabilidade. Na 4ª probabilidade não há cálculo a ser feito, uma vez que foi identificado que não existem funcionários trabalhando simultaneamente em dois departamentos.

Finalmente, a última probabilidade pode ser estimada de duas formas, sempre usando a lei da adição: ou somando as probabilidades dos demais eventos (P(marketing)+P(produção)+P(administração)) ou subtraindo do universo a probabilidade de ser de finanças (100%-P(finanças)). A segunda forma de obter essa probabilidade está usando a lei da adição pois é como os eventos são mutuamente excludentes e exaustivos, então a soma de todas as probabilidades é igual a 100%.

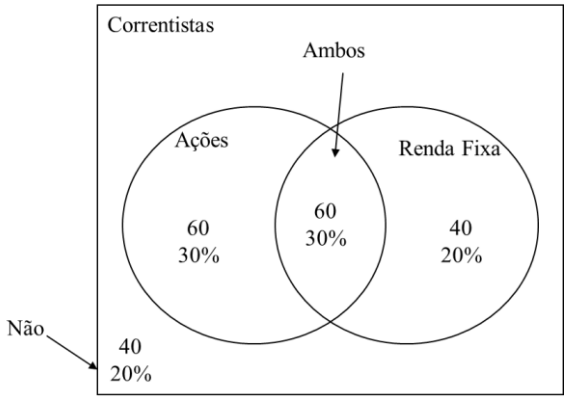
**Exemplo (não mutuamente exclusivo)**: Uma pesquisa entre 200 correntistas de um banco revela que, deste total, 120 investem em Ações e 100 em Renda Fixa. Se 60 investem em ambos, quais as probabilidades de selecionarmos:

1) Um investidor em Ações?
2) Um investidor em Renda Fixa?
3) Um investidor em Ações e Renda Fixa?
4) Um investidor em Ações ou Renda Fixa?
5) Um correntista que não invista em nenhum dos dois?

**Solução**: Nesse caso, a interseção já é declarada, ficando evidente que os eventos não são mutuamente excludentes. Em casos como esses, são feitos diagramas de Venn com interseções, e geralmente as frequências e probabilidades dos eventos compostos são identificadas primeiro.

Na Figura 51 é possível ver uma possível representação para este problema. A primeira frequência (e probabilidade) a ser estimada é de Ambos, que corresponde aos correntistas que investem em ações e em renda fixa. As frequências e probabilidades dos eventos simples descartando a interseção são calculadas depois. Finalmente, como a soma das frequências simples é 160, identifica-se que, dos 200 entrevistados, 40 não são investidores em ações nem renda fixa (investem em outras modalidades ou não investem). Essa identificação poderia ser feita também através da soma das probabilidades dos eventos simples, que dá 80%, menos do que 100%.

**Figura 51.** Representação gráfica dos correntistas




Assim é possível calcular:

1) P(ações)=120/200=60%
2) P(renda fixa)=100/200=50%
3) P(ações e renda fixa)=60%+50%-30%=80%
4) P(ações ou renda fixa)=30%+20%=50%
5) P(não)=20%

As probabilidades evidenciadas no diagrama da Figura 51 são, na verdade, referentes a eventos compostos: P(ações e não renda fixa)=30% e P(renda fixa e não ações)=20%. É importante manter em mente que a construção do diagrama precisa ser feita de forma que ocorrências puras (excluindo ocorrências simultâneas) fiquem evidenciadas.

### 4.3.2. Lei da multiplicação

Combinações de eventos simples usando a junção “E” podem ser exemplificadas nas seguintes situações:

- Considerando produtos em estoque, qual a probabilidade de pegarmos dois produtos sendo o primeiro com defeito de fabricação e o outro também?
- Considerando produtos em estoque, qual a probabilidade de pegarmos um produto defeituoso, retorná-lo ao estoque e retirar outro também defeituoso?

As duas situações exemplificam eventos dependentes e independentes, simultaneamente. As regras para o cálculo das probabilidades através das leis da multiplicação são duas, para cada uma das situações distintas:

**Eventos independentes**:

$$P(A \text{ e } B) = P(A) \times P(B)$$

**Eventos dependentes**:

$$P(A \text{ e } B) = P(A) \times P(A|B) = P(B) \times P(A|B)$$

A segunda forma de enunciado da lei é a mais completa, visto que no primeiro caso se tem P(B|A) = P (B) e também P (A|B) = P (A).

**Exemplo**: Uma loja tem três unidades de determinado produto em estoque. Sabe-se que um deles está defeituoso, mas não se sabe qual. Definindo o evento A como "pegar o primeiro produto e ele ser perfeito" e o evento B como "pegar o segundo produto e ele ser perfeito", determine:

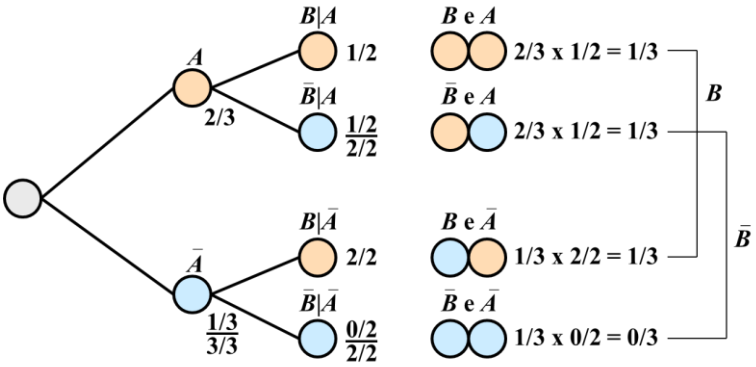
1) P(A)
2) P(B)
3) P(B|A) supondo que o primeiro produto volte ao estoque
4) P(B|A) supondo que o primeiro produto não volte ao estoque

**Solução**:

1) $P(A) = \frac{2}{3}$
2) $P(B) = \frac{2}{3}$

Esse resultado é facilmente aceito considerando-se a situação em que o produto que foi retirado no primeiro evento retorne ao estoque. Entretanto, o resultado não depende dessa suposição, ou seja, mesmo que a primeira peça não volte ao estoque, a probabilidade é a mesma. Isso pode ser verificado através da árvore de eventos na Figura 52.

**Figura 52.** Árvore de eventos para os produtos em estoque




3) $P(B|A) = P(B) = \frac{2}{3}$, já que os eventos são independentes

4) $P(B|A) = \frac{1}{2}$

A 4ª probabilidade é calculada considerando-se os dois últimos produtos em estoque que sobram depois de ter sido tirado um produto sem defeito. Sobrará um produto defeituoso e outro sem defeito.

# 5. Variáveis aleatórias e distribuições de probabilidade

O conceito do aleatório está associado ao conceito casual, que ocorre ao acaso. O lado que será observado para cima depois de se lançar uma moeda é aleatório. Isso quer dizer que não é possível determinar com certeza e precisão qual será o lado resultante de todos os lançamentos. Como são só dois resultados possíveis (e equiprováveis), um palpite tem 50% de chance de se consumar. Ou seja, uma previsão tem 50% de chance de estar correta.

Variáveis aleatórias são estudadas usando probabilidades. Isso porque, apesar de serem imprevisíveis com certeza e precisão, é sempre possível fazer previsões e controlar os níveis de certeza ou precisão com medidas de probabilidade.

As variáveis aleatórias possuem distribuição de probabilidades que permitem fazer medidas (média e desvio padrão), identificar os valores mais ou menos prováveis ou estabelecer previsões.

As variáveis aleatórias podem ser discretas ou contínuas. As distribuições de probabilidade discretas são estudadas através de tabelas, e as distribuições de probabilidade contínuas são estudadas através de gráficos.

## 5.1. Distribuição de probabilidades discreta

Uma distribuição de probabilidades discreta é:

- Uma lista dos resultados possíveis dessa variável.
- A lista precisa ser mutuamente excludente e coletivamente exaustiva.
- Para cada resultado possível da variável, há a probabilidade de ocorrência.

**Exemplo**: Uma empresa relacionou a quantidade de falhas diárias na rede dos seus computadores por dia conforme a

Tabela **9**. É possível ver a probabilidade de ocorrência de cada quantidade, de modo que, em um dia aleatório, há 35% de chance de não haver falha, 25% de chance de haver uma única falha, 20% de chance de haver exatamente duas falhas e assim sucessivamente.

**Tabela 9.** Variável aleatória discreta

| INTERRUPÇÕES POR DIA | PROBABILIDADE |
|---|---|
| **0** | 0,35 |
| **1** | 0,25 |
| **2** | 0,20 |
| **3** | 0,10 |
| **4** | 0,05 |
| **5** | 0,05 |

É possível verificar que a lista é mutuamente exclusiva, pois a quantidade de interrupções por dia é um único valor. Além disso, a lista é coletivamente exaustiva pois as probabilidades somam 1, ou seja, qualquer outro valor que não está listado tem probabilidade igual a 0.

### 5.1.1. Valor esperado de uma variável aleatória discreta

O valor esperado é a média aritmética da variável aleatória. No caso da variável aleatória discreta, esse valor é obtido seguindo o procedimento descrito na Seção **Erro! Fonte de referência não encontrada.** (baseado na média ponderada):

$$\mu = E(X) = \sum_{i=1}^{N} X_i P(X_i)$$

Onde

$X_i$ é i-ésimo valor da variável aleatória discreta, $X$

$P(X_i)$ é a probabilidade associada à $X_i$

**Exemplo**: Considerando os dados sobre as interrupções diárias da rede de computadores da empresa, é possível calcular:

| $x_i$ | $P(x_i)$ | $x_i P(x_i)$ |
|---|---|---|
| 0 | 0,35 | 0 |
| 1 | 0,25 | 0,25 |

| | | |
|---|---|---|
| 2 | 0,20 | 0,40 |
| 3 | 0,10 | 0,30 |
| 4 | 0,05 | 0,20 |
| 5 | 0,05 | 0,25 |
| **Soma** | **1** | **1,40** |

Dessa forma, $\mu=1,40$.

O valor esperado é igual a um valor que não é possível, o que pode parecer contraditório. A quantidade de interrupções em um dia jamais será 1,4. Em um dia qualquer pode haver 1 ou 2 interrupções, mas nunca 1,4. Apesar de não ser um valor possível, é a média aritmética e equivale ao valor central da distribuição. Seu uso como previsão para um determinado dia é pouco intuitivo, mas se a previsão for para o total de interrupções em 10 dias fica bem evidente que 14 (10 x 1,4) é uma previsão robusta.

### 5.1.2. Variância de desvio padrão de uma variável aleatória discreta

A variância é calculada antes do desvio padrão, pois é o quadrado deste. Calcula-se a variância como a média aritmética dos desvios quadrados da variável aleatória em relação ao valor esperado. No caso da variável aleatória discreta, esse valor é obtido seguindo um procedimento semelhante ao descrito na Seção **Erro! Fonte de referência não encontrada.** (a diferença é que o procedimento aqui refere-se às dispersões populacionais):

$$\sigma^2 = E\big(X - E(X)\big)^2 = \sum_{i=1}^{N} \big(X_i - E(X)\big)^2 P(X_i)$$

Onde

$Xi$ é i-ésimo valor da variável aleatória discreta, $X$

$E(X)$ é o valor esperado da variável aleatória discreta $X$

$P(Xi)$ é a probabilidade associada à $Xi$

**Exemplo**: considerando os dados sobre as interrupções diárias da rede de computadores da empresa, onde já se calculou $E(X) = 1,4$, é possível calcular:

| $x_i$ | $P(x_i)$ | $x_i - E(X)$ | $(x_i - E(X))^2 P(x_i)$ |
|---|---|---|---|
| 0 | 0,35 | -1,4 | 0,686 |
| 1 | 0,25 | -0,4 | 0,04 |
| 2 | 0,20 | 0,6 | 0,072 |
| 3 | 0,10 | 1,6 | 0,256 |
| 4 | 0,05 | 2,6 | 0,338 |
| 5 | 0,05 | 3,6 | 0,648 |
| **Soma** | **1** | | **2,04** |

Dessa forma, $\sigma 2=2,04$, e então $\sigma = \sqrt{\sigma^2} = \sqrt{2,04} = 1,4283$

## 5.2. Modelos teóricos de distribuição de probabilidades discretas

Algumas variáveis aleatórias têm um comportamento geral que já foi capturado por um modelo teórico. Essas variáveis podem ser estudadas usando esse modelo teórico, o que representa uma simplificação para o analista.

### 5.2.1. Distribuição binomial

Alguns eventos podem ter apenas dois estados:

- No lançamento de uma moeda, tirar cara ou não tirar cara.
- No final da montagem industrial, um produto sair defeituoso ou não sair defeituoso.
- Numa resposta a uma pergunta, acertar ou não acertar a resposta.

Nessas situações, uma das respostas possíveis é chamada de Sucesso, e a outra, de Insucesso. A classificação não depende de juízo de valor, ou seja, é possível dizer que, quando a peça sai defeituosa, isso é um Sucesso. Essa classificação serve apenas para indicar as probabilidades, conforme abaixo.

- P(S) = p e
- P(I) = 1 - p

A distribuição binomial está relacionada à repetição de eventos como esses. Por exemplo:

- No lançamento de uma moeda 10 vezes, quantas vezes se observou Cara?
- No final da montagem industrial de 1.000 produtos, quantos saem defeituosos?
- Numa prova com 50 questões, quantos acertos são obtidos?

Formalizando, em uma Distribuição se tem:

- Uma repetição de $n$ eventos.
- Cada evento pode ter como resultado Sucesso $(S)$ ou Insucesso $(I)$.
- A quantidade de sucessos observados $(X)$ nas $n$ repetições (ou tentativas).

É possível calcular:

$$P(X) = C_n^X \times p^X \times (1-p)^{n-X}$$

onde $C_n^X = \frac{n!}{x!(n-X)!}$ é a quantidade de combinações de $n$ resultados possíveis tomados em grupos de X resultados.

É possível ainda definir:

$$\mathrm{E(X)=n\times p}$$

$$\mathrm{Var(X)=n\times p\times (1\text{-}p)}$$

**Exemplo**: O percentual de peças defeituosas em uma linha de produção é de 5%. Um lote de 10 peças está sendo examinado e se deseja saber de antemão a probabilidade de que que sejam encontradas:

a) Exatamente 2 peças defeituosas.
b) Até 2 peças defeituosas.
c) Mais do que 2 peças defeituosas.
d) A quantidade esperada de peças defeituosas e o desvio padrão.

**Solução**: Esta é uma situação representada pela distribuição binomial, pois

- Observar uma peça e ela ter ou não ter defeito se enquadra no evento com dois resultados.
- Examinar 10 peças é uma repetição do evento acima.

Então, sendo uma distribuição binomial, e chamando de Sucesso observar a peça e ela estar defeituosa, são dados os parâmetros:

- $p=0,05$, probabilidade de sucesso em cada evento (análise de 1 peça)
- $n=10$, são dez repetições do evento (análise de 10 peças)

a) Deseja-se conhecer a probabilidade associada a $x=2$, ou seja, $P(X = 2) = C_{10}^{2} \times 0,05^{2} \times 0,95^{8} = 45 \times 0,0025 \times 0,6634 = 0,0746$, ou 7,46%

b) Deseja-se conhecer a probabilidade associada a $X\leq2$, ou seja, $P(X\leq2)=P(X=0)+P(X=1)+P(X=2)=0,5987+0,3151+0,0746=0,9885$

c) Deseja-se conhecer a probabilidade associada a $X>2$, ou seja, $P(X>2)=P(X=3)+P(X=4)+\cdots+P(X=9)+P(X=10)$. Em vez de calcular 8 probabilidades, é possível simplificar o cálculo observando que a soma das probabilidades de todos os eventos possíveis é igual a 1, ou seja, $P(X=0)+P(X=1)+P(X=2)+P(X=3)+\cdots+P(X=10)=1$. Então, $P(X=3)+\cdots+P(X=10)=1-P(X=0)+P(X=1)+P(X=2)$. Assim, $P(X>2)=1-0,9885=0,0115$, ou 1,15%.

d) $E(X)=10\times0,05=0,5$

$Var(X)=10\times0,05\times0,95=0,475.$

e) Este exemplo foi resolvido criando o conceito de que Sucesso é pegar uma peça e ela estar defeituosa. Essa escolha resultou em $p=0,05$. Se fosse usado o conceito de que Sucesso é pegar uma peça e ela não estar defeituosa (estar perfeita), se teria $p=0,95$. Os cálculos seriam iguais, mas para calcular a probabilidade pedida em a) se tem, neste caso, $X=8$. Ou seja, em um lote com 10 peças ter exatamente duas defeituosas implica em ter exatamente 8 perfeitas.

O Excel disponibiliza uma função para calcular as probabilidades de uma distribuição binomial. A função chama-se DISTR.BINOM e pode calcular a probabilidade pontual (da letra a do exemplo) ou acumulada (da letra b do exemplo), alterando apenas o último parâmetro da função:

a) DISTR.BINOM(2 ; 10 ; 0,05; 0)

b) DISTR.BINOM(2 ; 10 ; 0,05; 1)

### 5.2.2. Distribuição de Poisson

A Distribuição de Poisson é usada para medir a probabilidade de que ocorra um determinado número de ocorrências dentro de uma área de oportunidade. Por exemplo:

- Quantidade de defeitos na pintura da parede, que tem $10m^2$.
- Número de falhas do sistema durante um dia, que tem 24 horas.
- Quantidade de quebra-molas na rodovia, que tem 100km.

Ao contrário da distribuição binomial, a quantidade de ocorrências considerada na distribuição de Poisson não tem limite máximo, já que não são frutos de repetição: a pintura em uma parede com $10m^2$ pode ter 10, 50 ou 100 defeitos. A área de oportunidades é uma dimensão contínua e em geral se refere a tempo (minutos, dias, meses), peso (quilo, grama), tamanho (metros, quilômetros), área ou volume.

Para que a distribuição de Poisson possa ser aplicada, algumas condições precisam ser verificadas:

- A probabilidade de ocorrência é a mesma em qualquer parte da área de oportunidade. Por exemplo, os primeiros $2m^2$ de pintura podem ter defeitos da mesma forma que quaisquer outros $2m^2$.
- As quantidades de eventos que ocorrem em diferentes áreas de oportunidade são independentes. Por exemplo, nas primeiras horas do dia pode não haver falha e nas horas seguintes haver, ou vice-versa.
- A probabilidade de ocorrência de dois ou mais eventos vai ficando menor à medida que a área de oportunidade diminui. Esta probabilidade tende a zero.

A Distribuição de Poisson é definida através de um único parâmetro: $\lambda$ (lambda, uma letra grega). Ele representa a quantidade de ocorrências média na área de oportunidade, por exemplo:

- $\lambda = 3$ defeitos/$m^2$ de pintura
- $\lambda = 0{,}1$ falha/hora do sistema

- $\lambda = 3$ quebra-molas/km na rodovia

Para definir a probabilidade de ocorrência de $X$ eventos na área de oportunidade de tamanho igual ao definido por $\lambda$, deve-se fazer:

$$P(X) = \frac{e^{-\lambda}\lambda^{X}}{X!}$$

Onde $e=2,71828...$ é uma constante matemática chamada de número natural.

**Exemplo**: Em certa empresa é conhecido o número médio de acidentes de trabalho: 0,1 por dia. Para o próximo mês (30 dias), deseja-se saber a probabilidade de:

a) Não ocorrer acidente.
b) Ocorrerem até 2 acidentes.
c) Ocorrerem 2 ou mais acidentes.

**Solução**: Pelo enunciado, depreende-se que $\lambda=0,1$ acidentes por dia. Como as indagações são relativas a um mês inteiro (30 dias) é possível transformar $\lambda=0,1\times30=3$ acidentes por mês. Então:

a) $P(X=0) = \frac{e^{-3}3^{0}}{0!} = 0,0498$
b) P(X≤2)=P(X=0)+P(X=1)+P(X=2)=0,0498+0,1494+0,224=0,4232
c) P(X≥2)=1-P(X≤1)=1-0,0498+0,1494=0,8008

O Excel disponibiliza uma função para calcular as probabilidades de uma distribuição de Poisson. A função chama-se DIST.POISSON e pode calcular a probabilidade pontual (da letra a do exemplo) ou acumulada (da letra b do exemplo), alterando apenas o último parâmetro da função:

a) DIST.POISSON(0 ; 3 ; 0)
b) DIST.POISSON(0 ; 3 ; 1)

### 5.2.3. Distribuição hipergeométrica

A distribuição hipergeométrica modela uma situação um pouco parecida com a situação da distribuição binomial: também há uma repetição em quantidade fixa de eventos que têm apenas duas possibilidades de ocorrência, chamadas de sucesso e insucesso.

A diferença é que na distribuição binomial a probabilidade de ocorrência do sucesso é fixa, e na distribuição hipergeométrica a probabilidade muda. Isso porque a distribuição binomial considera que a população é infinita, e a hipergeométrica reconhece que a população é finita. Por exemplo, se no estoque há 4 peças e 2 são defeituosas, a probabilidade de tirar 1 peça defeituosa é 50%. Mas a partir do primeiro evento, o segundo muda: a probabilidade de tirar a segunda peça e ela ser defeituosa será de 33,3%, caso a primeira peça tenha sido defeituosa, e de 66,7% caso a primeira peça não tenha sido defeituosa.

Por conta da finitude da população, a distribuição hipergeométrica é calculada assim:

$$P(X) = \frac{C_A^X \times C_{N-A}^{n-X}}{C_N^n}$$

Onde: $n$: tamanho da amostra

$N$: tamanho da população

$A$: número de interesse na população

$X$: número de interesse na amostra

**Exemplo**: Uma comissão de 3 representantes diplomáticos precisa ser formada a partir de um total de 10 diplomatas. A seleção será por sorteio totalmente aleatório, mas dos 10 diplomatas somente 4 falam alemão. Qual é a probabilidade de que a comissão venha a conter:

a) Ninguém que fale alemão?
b) Pelo menos 1 diplomata que fale alemão?
c) Não mais do que 1 diplomata que fale alemão?

**Solução**: Como a população de diplomatas é finita, o problema é modelado por uma distribuição hipergeométrica, sendo considerados:

- $\mathrm{n} = 3$
- $\mathrm{N} = 10$
- $\mathrm{A} = 4$

E então:

$$\frac{C_A^X \times C_{N-A}^{n-X}}{C_N^n}$$

a) $P(X=0)=\frac{C_4^0 \times C_{10-4}^{3-0}}{C_{10}^3}=\frac{1\times 20}{120}=0{,}1667$

b) P(X≥1)=1-P(X=0)=1-0,1667=0,8333

c) P(X≤1)=P(X=0)+P(X=1)=0,1667+0,5=0,6667

O Excel disponibiliza uma função para calcular as probabilidades de uma distribuição hipergeométrica. A função chama-se DIST.HIPERGEOM.N e pode calcular a probabilidade pontual (da letra a do exemplo) ou acumulada (da letra c do exemplo), alterando apenas o último parâmetro da função:

a) DIST.HIPERGEOM.N(0 ;3 ; 4 ; 10 ;0)

c) DIST.HIPERGEOM.N(1 ;3 ; 4 ; 10 ;1)

O valor esperado e a variância da distribuição hipergeométricas são definidos assim:

$$E(X)=\frac{nA}{N}$$

$$Var(X)=\left(\frac{nA(N-A)}{N^2}\right)\left(\frac{N-n}{N-1}\right)$$

## 5.3. Distribuição de probabilidade contínua

Variáveis discretas são usadas para contar e variáveis contínuas são usadas para medir. Enquanto as variáveis discretas relacionam quantidade de ocorrências, as variáveis contínuas medem tamanhos, volumes, tempo etc. Por consequência da continuidade, existem duas importantes diferenças das variáveis aleatórias contínuas se comparadas com as discretas:

1) Não é possível relacionar as probabilidades em uma tabela, já que os valores contínuos são infinitos.
2) A probabilidade de uma variável contínua ser exatamente igual a determinado valor é zero. Por exemplo, é impossível um piloto de corrida conseguir fazer uma volta em certo circuito em exatamente 2 minutos (e zero segundos e zero

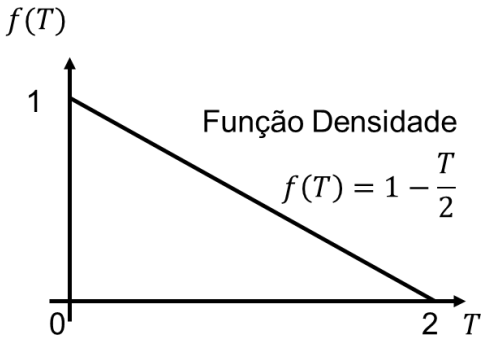
milésimos de segundo), mesmo quando ele já conseguiu fazer essa mesma volta em um tempo menor, digamos 1 minuto e meio.

Por conta dessas diferenças, as variáveis contínuas são estudadas em gráficos de funções chamadas de **função de densidade**, e não em tabelas. As probabilidades sempre vão se referir a um intervalo de valores possíveis e serão calculadas como áreas delimitadas por esses gráficos.

**Exemplo**: O tempo que leva desde que o banco abre as portas até a entrada do primeiro cliente é, no máximo, 2 horas. A probabilidade de ocorrência foi modelada pela função de densidade $f(T) = 1 - \frac{T}{2}$, onde $T$ é o tempo de chegada e $0 \leq T \leq 2$.

Isso é interpretado graficamente conforme consta na Figura 53. No eixo das abcissas (horizontal) estão os valores da variável aleatória $T$. No eixo das ordenadas estão os valores da densidade $f(T)$. A função de densidade é, neste caso, uma linha reta decrescente e está desenhada apenas nos valores possíveis para $T$, ou seja, entre 0 e 2.

**Figura 53.** Função densidade




Deseja-se saber o tempo corrido desde a abertura do banco até a chegada do primeiro cliente. Qual a chance de que este tempo seja:

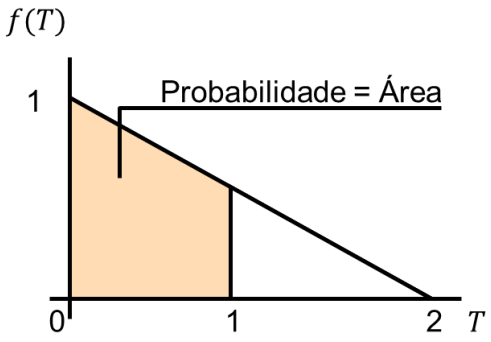
a) De até 1 hora?
b) Maior do que 1 hora e meia?
c) Entre 1 hora e 1 hora e meia?

**Solução**:

a) O valor procurado é $P(X \leq 1)$.

A análise gráfica ajuda a entender que essa probabilidade equivale a uma área embaixo do gráfico da função de densidade:

**Figura 54.** Área equivalente a P (X ≤ 1)




Essa área é calculada usando ferramentas do cálculo. A área embaixo do gráfico é uma integral definida:

$$\int_0^1 f(T)dT = \int_0^1 1 - \frac{T}{2}dt = T - \frac{T^2}{4}\Big|_0^1 = \left(1 - \frac{1}{4}\right) - \left(0 - \frac{0}{4}\right) = 0{,}75$$

Ou seja, a probabilidade é 75%.

A integral calculada acima, quando feita com um ponto genérico de $X$, é chamada de **Função de probabilidade acumulada** da variável aleatória. Ela ficaria assim:

$$F(X) = \int_{-\infty}^{X} f(T)dT = \int_0^X 1 - \frac{T}{2}dt = T - \frac{T^2}{4}\Big|_0^X = X - \frac{X^2}{4}$$

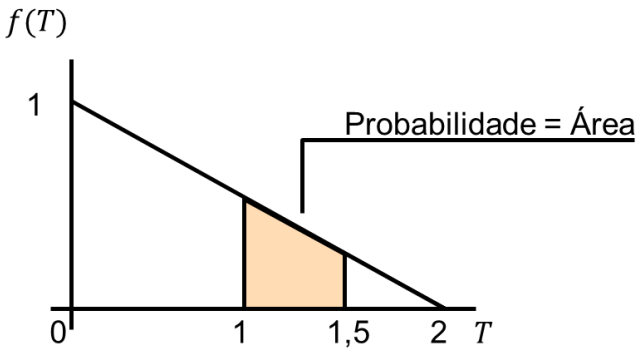
Para os cálculos seguintes será considerado que a probabilidade de ocorrência até um valor $X$ pode ser calculada usando:

$$F(X) = X - \frac{X^2}{4}$$

b) $P(X \geq 1{,}5) = 1 - P(X \leq 1{,}5) = 1 - \left(1{,}5 - \frac{1{,}5^2}{4}\right) = 1 - 0{,}9375 = 0{,}0625$ ou 56,25%

c) $P(1 \leq X \leq 1{,}5)$ é uma área interna ao gráfico, como pode ser visto na Figura 55.

**Figura 55.** $P(1 \leq X \leq 1,5)$

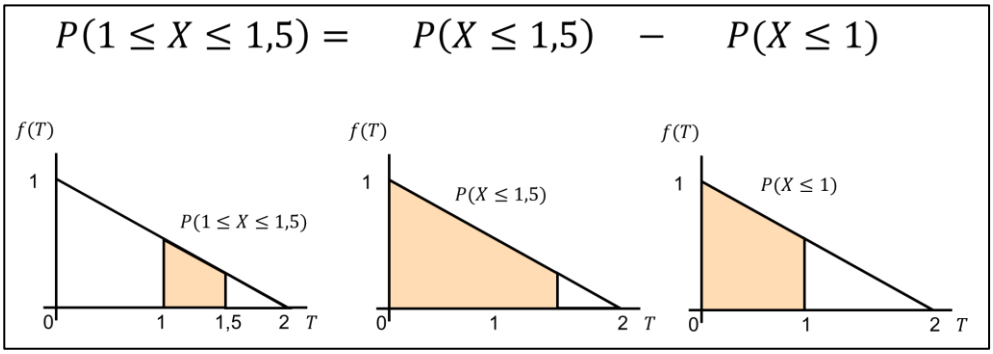



Essa área pode ser calculada diretamente através da integral:

$$\int_1^{1,5} f(T)dt = T - \frac{T^2}{4}\Big|_1^{1,5} = \left(1,5 - \frac{1,5^2}{4}\right) - \left(1 - \frac{1^2}{4}\right) = 0,9375 - 0,75 = 0,1875$$

Ou, alternativamente, fazendo uma composição de áreas:

**Figura 56.** Composição de áreas para o cálculo de probabilidades




Percebe-se que o cálculo vai, inclusive, levar à mesma composição numérica: $P(1 \leq x \leq 1,5) = 0,9375 - 0,75 = 0,1875$.

Essa segunda forma é preferível à primeira, por conta de diversas facilidades que serão consideradas nos modelos teóricos. Isso ficará evidente nos próximos exemplos.

## 5.4. Modelos teóricos de distribuição de probabilidades continuas

Os comportamentos de algumas variáveis aleatórias são agrupados em modelos teóricos. O estudo desses modelos teóricos representa ganhos operacionais. Entre

os modelos teóricos contínuos que serão abordados, a variável normal tem especial importância para todo o desenvolvimento teórico da estatística.

### 5.4.1. Distribuição normal

Também é chamada de Distribuição de Gauss ou, ainda, Distribuição Gaussiana, em homenagem a Carl Friedrich Gauss, matemático que viveu nos séculos XVIII e XIX que desenvolveu a formulação matemática que dá suporte a esta distribuição.

A distribuição normal é a distribuição mais usada na estatística, por conta de várias aplicações possíveis para ela, tanto no mundo real (físico ou de negócios) quanto em teorias estatísticas.

A distribuição normal é descrita por dois parâmetros: a média populacional, $\mu$, e o desvio padrão populacional, $\sigma$. A função de densidade da distribuição normal tem a seguinte formulação:

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$$

Onde $e$ é o numero natural, a constante matemática aproximada por 2,71828.

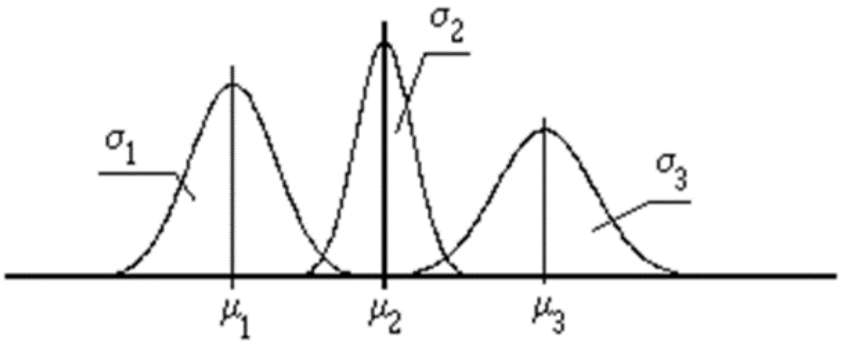
$\pi$ é pi, a constante matemática aproxima por 3,14159

$\mu$ é a média populacional, um dos parâmetros da distribuição

$\sigma$ é o desvio padrão populacional, o outro parâmetro da distribuição

A função de densidade, quando representada graficamente, apresenta uma curva em forma de sino simétrica ao redor da média. Na Figura 57 é possível ver três diferentes gráficos de distribuição normal, com diferentes de valores de média e de desvio padrão.

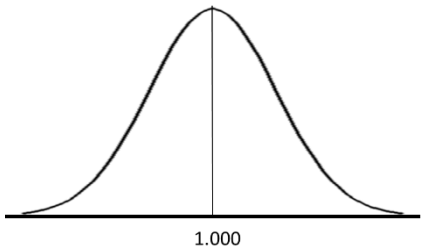
**Figura 57.** Três diferentes funções de densidade normal




**Exemplo**: Certo posto de gasolina observa que o volume total de gasolina vendida ao longo de um dia apresenta uma quantidade média de 1.000 litros, com desvio padrão de 150 litros, e que a distribuição é aproximadamente normal. Qual a probabilidade de que em determinado dia haja uma venda de até 1.150 litros?

**Solução**: Uma distribuição normal com média $\mu=1.000$ e desvio padrão $\sigma=150$ tem formato semelhante ao representado na Figura 58.

**Figura 58.** Distribuição normal com $\mu=1.000$ e $\sigma=150$

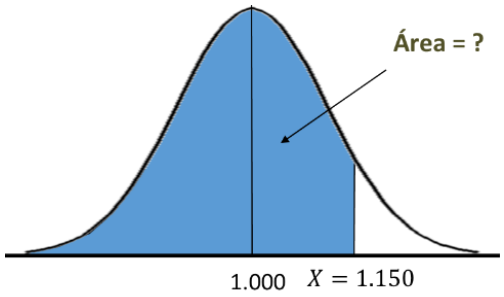



Para medir a probabilidade que está pedida, $P(X\leq1.150)$ basta achar a área que está destacada na Figura 59. Para tanto, é preciso resolver a seguinte integral definida:

$$F(X) = \int_{-\infty}^{X} f(X)dx = \int_{-\infty}^{X} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2} dx$$

O que não é trivial. Essas integrais têm difícil solução e em geral não são resolvidas quando precisamos obter essas probabilidades. Existem tabelas prontas para obter essas probabilidades, e faremos uso delas. A forma mais comum dessa tabela está disponível no **Erro! Fonte de referência não encontrada.**.

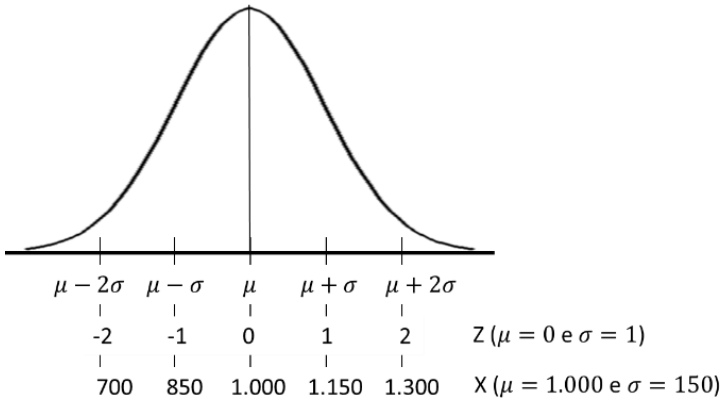
**Figura 59.** Probabilidade associada a $X \leq 1.150$




A tabela está estruturada sobre a distribuição normal padrão, que é uma distribuição com $\mu=0$ e $\sigma=1$. Mas é possível usar esta tabela para qualquer distribuição. Basta observar na Figura 60 que as áreas definidas pelos valores de *Z* são iguais às áreas definidas pela distribuição de *X* para valores equivalentes. A equivalência é dada pela transformação do Escore Z (a mesma definida na Seção **Erro! Fonte de referência não encontrada.**):

$$Z = \frac{X - \mu}{\sigma}$$

**Figura 60.** Relação entre a normal padrão e outras distribuições normais




Assim, para saber a probabilidade associada ao valor de 1.150 litros, faz-se:

$$Z = \frac{1.150 - 1.000}{150} = 1$$

Olhando na Tabela disponível no Erro! Fonte de referência não encontrada., tem-se que a área associada a 1,00 é igual a 0,3413. Veja na definição da própria tabela

que essa área é da média até 1,00. A área total deve ser acrescida de 0,5, sendo, então, 0,8413.

O Excel oferece uma função para calcular a área total acumulada até o valor de X, sem necessidade de calcular o valor do Escore Z. Essa função é a **DIST.NORM.N**, que para cálculo de probabilidade deve ter seu último parâmetro sempre igual a 1. Então, obtém-se 0,8413 ao fazer

= DIST.NORM.N(1150 ; 1000; 150; 1)

**Exemplo**: Para os dados do exemplo anterior ($\mu=1.000$ e $\sigma=150$), se deseja ainda saber a probabilidade de, em determinado dia, vender:

a) menos do que 1.210 litros.
b) mais do que 1.210 litros.
c) exatamente 1.210 litros.

**Solução**: O valor de Z associado a $X=1.210$ é $Z = \frac{1.210-1000}{150} = 1,40$.

Então:

a) $P(X\leq1.210)=P(Z\leq1,40)$. Olhando na tabela o valor associado a $Z=1,40$ é 0,4192. Portanto $P(X\leq1.210)=0,9192$.
b) $P(X \geq 1.210) = 1 - P(X \leq 1.210) = 1 - 0,9192 = 0,0808$.
c) De acordo com os conceitos iniciais sobre variáveis contínuas, $P(X=1.210)=0$. Isso é intuitivo no sentido de que a probabilidade é uma área, e para haver área tem que haver um intervalo nos valores sob estudo de $X$. Uma consequência importante disso é que, para solucionar os dois itens anteriores, se poderia dizer $P(X<1.210)$ pois $P(X\leq1.210)=P(X<1.210)+P(X=1.210)$.

**Exemplo**: Para os dados do exemplo anterior ($\mu=1.000$ e $\sigma=150$), deseja se saber a probabilidade de, em determinado dia, vender:

a) menos do que 800 litros.
b) mais do que 1.100 litros.
c) entre 800 e 1.100 litros.

**Solução**: O valor desejado é $P(X \leq 800)$. O valor de Z associado a $X=800$ é

$$Z = \frac{800-1000}{150} = -1{,}33$$.

Olhando na Tabela disponível no Erro! Fonte de referência não encontrada., é possível verificar que não há valores negativos. Mas se pode usar da simetria da distribuição normal.

O valor associado a $Z=1{,}33$é 0,4082 então isso quer dizer que $P(0 \leq Z \leq 1{,}33)=0{,}4082$. Pela simetria, conclui-se que $P(-1{,}33 \leq Z \leq 0)=0{,}4082$, ou seja, $P(800 \leq X \leq 1.000)=0{,}4082$. Então, o valor procurado é obtido fazendo $P(X \leq 800)=0{,}5-0{,}4082=0{,}0918$.

*a)* O valor desejado é $P(X \geq 1.100)$. O valor de Z associado a $X=1.100$ é $Z=(1.100-1000)/150=0{,}67$. Olhando no Erro! Fonte de referência não encontrada. é possível verificar que o valor associado a $Z=0{,}67$ é 0,2486, ou seja, $P(0 \leq Z \leq 0{,}67)=P(1.000 \leq X \leq 1.100)=0{,}2486$. Assim, é possível verificar que $P(X \geq 1.100)=0{,}5-0{,}2486=0{,}2514$.

*b)* O valor desejado é $P(800 \leq X \leq 1.100)$, o que pode ser feito fazendo $P(X \leq 1.100)-P(X \leq 800)=0{,}7486-0{,}0918=0{,}6568$.

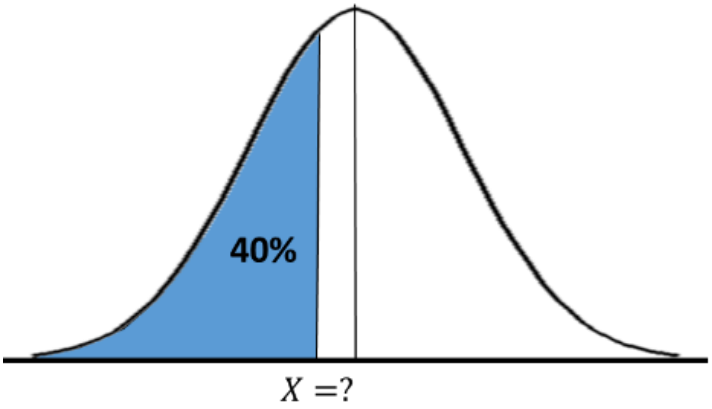
Muitas aplicações da distribuição normal envolvem a busca do valor que está associado a certa probabilidade. Chama-se de Distribuição Inversa.

**Exemplo**: Para os dados do exemplo anterior (μ=1.000 e σ=150), deseja-se, ainda, saber qual a quantidade vendida em um dia que é maior do que 40% dos outros dias.

**Solução**: O que se deseja determinar é o valor que divide a área da curva normal 40% ao lado esquerdo e 60% ao lado direito, como pode ser visto na Figura 61.

Para encontrar esse valor usando a tabela de distribuição normal, procura-se a área de 10% (porque a tabela relaciona desde a média até o valor de X) e verifica-se qual é o Z obtido.

**Figura 61.** Distribuição inversa




Neste caso, o valor está entre 0,25 e 0,26. Substituindo-se os valores negativos (pois sabemos que o valor de X é menor do que a média, logo Z é negativo) na fórmula do Z Escore, obtém-se:

$$Z = (X - \mu)/\sigma \rightarrow \begin{cases} -0{,}25 = \dfrac{X - 1000}{150} \rightarrow X = 1000 - 37{,}5 = 962{,}5 \\ -0{,}26 = \dfrac{X - 1000}{150} \rightarrow X = 1000 - 39 \rightarrow X = 961 \end{cases}$$

Ou seja, o valor está entre 961 e 962,5.

Alternativamente, é possível usar a função do Excel INV.NORM.N., que resulta no valor exato: 961,9979.

### 5.4.2. Distribuição uniforme

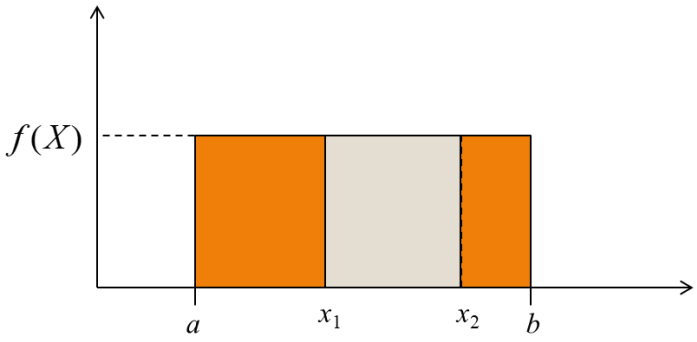
Também chamada de distribuição retangular, a distribuição uniforme tem a propriedade de que a probabilidade é a mesma em qualquer lugar do intervalo (a;b), sendo *a* e *b* os parâmetros da distribuição. Sua função de densidade é assim descrita:

$$f(X) = \begin{cases} \dfrac{1}{b-a} & \text{se } a < X < b \\ 0 & \text{caso contrário} \end{cases}$$

Conforme pode ser visto na Figura 62, a probabilidade pode ser calculada da seguinte forma:

$$P(x_1 \leq X \leq x_2) = (x_2 - x_1) \times \frac{1}{b-a}$$

**Figura 62.** Distribuição uniforme




A partir disso é possível definir também:

Média: $\mu = \frac{a+b}{2}$

Variância: $\sigma^2 = \frac{(b-a)^2}{12}$ e desvio padrão = $(b-a)\frac{\sqrt{3}}{6}$

**Exemplo**: O tempo de voo programado para uma operação entre São Paulo e Rio de Janeiro é de 35 minutos. Entretanto, sabe-se que o tempo é uniformemente distribuído entre 34 e 44 minutos. Assim:

a) Qual é a probabilidade de o deslocamento ter até 40 minutos?
b) Qual é a probabilidade de o deslocamento ter entre 35 e 40 minutos?
c) Qual é a probabilidade de o deslocamento ter mais de 35 minutos?
d) Quais os valores para a média aritmética e o desvio padrão do tempo de deslocamento?

**Solução**: Pelos dados do problema, a distribuição uniforme tem parâmetros $a = 34$ e $b = 44$ minutos. Então, é possível resolver as questões:

a) A pergunta pode ser interpretada como $P(X \leq 40) = P(34 \leq X \leq 40)$, já que 34 é o mínimo. Então, aplicando a fórmula:

$$P(x_1 \leq X \leq x_2) = (x_2 - x_1) \times \frac{1}{b-a}$$

Obtém-se:

$$P(34 \leq X \leq 40) = (40 - 34) \times \frac{1}{44 - 34} = 0{,}6$$

b) $P(35 \leq X \leq 40) = (40 - 35) \times \frac{1}{44-34} = 0{,}5$

c) $P(35 \leq x \leq 44) = (44 - 35) \times \frac{1}{44-34} = 0{,}9$

d) $\mu = \frac{a+b}{2} = \frac{34+44}{2} = 39$ e $\sigma = (b - a)\frac{\sqrt{3}}{6} = 10\frac{\sqrt{3}}{6} = \frac{5\sqrt{3}}{3}$

## 5.5. Distribuição exponencial

A distribuição exponencial é muito usada para representar o tempo decorrido entre eventos, como, por exemplo:

- Tempo entre a chegada de clientes.
- Tempo entre acessos à internet.
- Tempo entre pedidos de histórico escolar.

A distribuição exponencial é definida por um único parâmetro: λ, que é a média aritmética da quantidade de ocorrências por momento de tempo.

A função de densidade é a seguinte:

$$f(X)=\lambda e^{(-\lambda X)} \text{ " para " } X>0$$

Onde $e$ é o número natural (constante matemática igual a 2,171828)

λ é a média aritmética do número de ocorrências na unidade de tempo

$X$ é qualquer valor da variável contínua em que $0<X<\infty$

A probabilidade pode ser calculada assim:

$$P(X \leq x_1) = 1 - e^{-\lambda x_1}$$

E também estão definidas:

Média: $\mu = \frac{1}{\lambda}$

Variância: $\sigma^2 = \frac{(b-a)^2}{12}$

**Exemplo**: Na meia hora de mais uso, observou-se que 20 clientes chegam para usar o caixa eletrônico do banco. Se um cliente acabou de chegar, qual é a probabilidade de que o próximo cliente chegue em até 2 minutos?

**Solução**: Pelo enunciado é possível definir o valor do parâmetro λ:

Em minutos: $\lambda = \frac{20}{30} = \frac{2}{3}$ clientes por minuto.

Em horas: $\lambda = \frac{20}{0{,}5} = 40$ clientes por hora.

Então, é possível calcular as probabilidades:

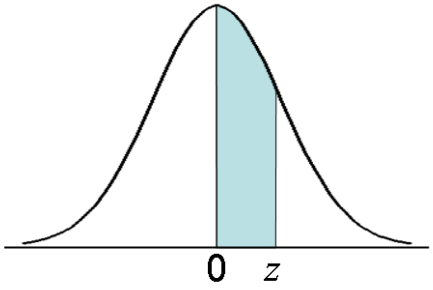
Em minutos: $P(X < 2) = 1 - e^{-\frac{2}{3} \times 2} = 0{,}736$

Em horas: $P\left(X < \frac{2}{60}\right) = 1 - e^{-40 \times \frac{2}{60}} = 0{,}736$

Os valores finais são idênticos, o que sinaliza que a escolha da unidade tempo é indiferente. Entretanto a escolha da unidade facilita a interpretação. No presente problema, a escolha em minutos é mais intuitiva, e fica mais fácil interpretar o que está sendo feito.

# 6. Anexo – Tabela de distribuição normal

Áreas da Curva Norn
Padrão




| *z* | **0,00** | **0,01** | **0,02** | **0,03** | **0,04** | **0,05** | **0,06** | **0,07** | **0,08** | **0,09** |
|---|---|---|---|---|---|---|---|---|---|---|
| **0,0** | 0,0000 | 0,0040 | 0,0080 | 0,0120 | 0,0160 | 0,0199 | 0,0239 | 0,0279 | 0,0319 | 0,0359 |
| **0,1** | 0,0398 | 0,0438 | 0,0478 | 0,0517 | 0,0557 | 0,0596 | 0,0636 | 0,0675 | 0,0714 | 0,0753 |
| **0,2** | 0,0793 | 0,0832 | 0,0871 | 0,0910 | 0,0948 | 0,0987 | 0,1026 | 0,1064 | 0,1103 | 0,1141 |
| **0,3** | 0,1179 | 0,1217 | 0,1255 | 0,1293 | 0,1331 | 0,1368 | 0,1406 | 0,1443 | 0,1480 | 0,1517 |
| **0,4** | 0,1554 | 0,1591 | 0,1628 | 0,1664 | 0,1700 | 0,1736 | 0,1772 | 0,1808 | 0,1844 | 0,1879 |
| **0,5** | 0,1915 | 0,1950 | 0,1985 | 0,2019 | 0,2054 | 0,2088 | 0,2123 | 0,2157 | 0,2190 | 0,2224 |
| **0,6** | 0,2257 | 0,2291 | 0,2324 | 0,2357 | 0,2389 | 0,2422 | 0,2454 | 0,2486 | 0,2517 | 0,2549 |
| **0,7** | 0,2580 | 0,2611 | 0,2642 | 0,2673 | 0,2704 | 0,2734 | 0,2764 | 0,2794 | 0,2823 | 0,2852 |
| **0,8** | 0,2881 | 0,2910 | 0,2939 | 0,2967 | 0,2995 | 0,3023 | 0,3051 | 0,3078 | 0,3106 | 0,3133 |
| **0,9** | 0,3159 | 0,3186 | 0,3212 | 0,3238 | 0,3264 | 0,3289 | 0,3315 | 0,3340 | 0,3365 | 0,3389 |
| **1,0** | 0,3413 | 0,3438 | 0,3461 | 0,3485 | 0,3508 | 0,3531 | 0,3554 | 0,3577 | 0,3599 | 0,3621 |
| **1,1** | 0,3643 | 0,3665 | 0,3686 | 0,3708 | 0,3729 | 0,3749 | 0,3770 | 0,3790 | 0,3810 | 0,3830 |
| **1,2** | 0,3849 | 0,3869 | 0,3888 | 0,3907 | 0,3925 | 0,3944 | 0,3962 | 0,3980 | 0,3997 | 0,4015 |
| **1,3** | 0,4032 | 0,4049 | 0,4066 | 0,4082 | 0,4099 | 0,4115 | 0,4131 | 0,4147 | 0,4162 | 0,4177 |
| **1,4** | 0,4192 | 0,4207 | 0,4222 | 0,4236 | 0,4251 | 0,4265 | 0,4279 | 0,4292 | 0,4306 | 0,4319 |
| **1,5** | 0,4332 | 0,4345 | 0,4357 | 0,4370 | 0,4382 | 0,4394 | 0,4406 | 0,4418 | 0,4429 | 0,4441 |
| **1,6** | 0,4452 | 0,4463 | 0,4474 | 0,4484 | 0,4495 | 0,4505 | 0,4515 | 0,4525 | 0,4535 | 0,4545 |
| **1,7** | 0,4554 | 0,4564 | 0,4573 | 0,4582 | 0,4591 | 0,4599 | 0,4608 | 0,4616 | 0,4625 | 0,4633 |
| **1,8** | 0,4641 | 0,4649 | 0,4656 | 0,4664 | 0,4671 | 0,4678 | 0,4686 | 0,4693 | 0,4699 | 0,4706 |
| **1,9** | 0,4713 | 0,4719 | 0,4726 | 0,4732 | 0,4738 | 0,4744 | 0,4750 | 0,4756 | 0,4761 | 0,4767 |
| **2,0** | 0,4772 | 0,4778 | 0,4783 | 0,4788 | 0,4793 | 0,4798 | 0,4803 | 0,4808 | 0,4812 | 0,4817 |
| **2,1** | 0,4821 | 0,4826 | 0,4830 | 0,4834 | 0,4838 | 0,4842 | 0,4846 | 0,4850 | 0,4854 | 0,4857 |
| **2,2** | 0,4861 | 0,4864 | 0,4868 | 0,4871 | 0,4875 | 0,4878 | 0,4881 | 0,4884 | 0,4887 | 0,4890 |
| **2,3** | 0,4893 | 0,4896 | 0,4898 | 0,4901 | 0,4904 | 0,4906 | 0,4909 | 0,4911 | 0,4913 | 0,4916 |
| **2,4** | 0,4918 | 0,4920 | 0,4922 | 0,4925 | 0,4927 | 0,4929 | 0,4931 | 0,4932 | 0,4934 | 0,4936 |
| **2,5** | 0,4938 | 0,4940 | 0,4941 | 0,4943 | 0,4945 | 0,4946 | 0,4948 | 0,4949 | 0,4951 | 0,4952 |
| **2,6** | 0,4953 | 0,4955 | 0,4956 | 0,4957 | 0,4959 | 0,4960 | 0,4961 | 0,4962 | 0,4963 | 0,4964 |

| | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| **2,7** | 0,4965 | 0,4966 | 0,4967 | 0,4968 | 0,4969 | 0,4970 | 0,4971 | 0,4972 | 0,4973 | 0,4974 |
| **2,8** | 0,4974 | 0,4975 | 0,4976 | 0,4977 | 0,4977 | 0,4978 | 0,4979 | 0,4979 | 0,4980 | 0,4981 |
| **2,9** | 0,4981 | 0,4982 | 0,4982 | 0,4983 | 0,4984 | 0,4984 | 0,4985 | 0,4985 | 0,4986 | 0,4986 |
| **3,0** | 0,4987 | 0,4987 | 0,4987 | 0,4988 | 0,4988 | 0,4989 | 0,4989 | 0,4989 | 0,4990 | 0,4990 |

# 7. Bibliografia

## 7.1. Bibliografia básica


[1] LEVINE David M., STEPHAN, David F. e SZABAT, Kathryn A.. **Estatística - Teoria e Aplicações usando MS Excel em Português.** 7ª ed. Rio de Janeiro: LTC, 2016.

[2] BUSSAB, W.; MORETIN, P. A.; **Estatística básica**. 8ª ed. Sao Paulo: Editora Saraiva, 2014.

[3] MCCLAVE, J.T.; BENSON, P. G.; SINCICH, T. **Estatística para administração e economia**, 10. ed. São Paulo. Pearson, 2015.


## 7.2. Bibliografia complementar


— SEBER, J.A.F.; WILD, C.J. **Encontros com o acaso: um primeiro curso de análise de dados e inferência.** Rio de Janeiro: LTC, 2004

— AGRESTI, A.; FINLAY, B. **Métodos Estatísticos para as Ciências Sociais**. Porto Alegre: Penso, 2012

— FIELD, A. **Descobrindo a Estatística usando o SPSS**. Porto Alegre: Artmed, 2009.