ESTATÍSTICA II



CERTIFICAÇÃO
DE QUALIDADE

FGV

Fundação Getulio Vargas

Programa de Certificação de Qualidade

Curso:

Graduação em Administração

Estatística II

Professor Elaborador:

Paulo Sérgio de Souza Coelho

Doutor em Sistemas Computacionais pela Universidade Federal do Rio de Janeiro (2005), formado em Matemática pela Universidade Estadual de Feira de Santana (1996), com mestrados em Engenharia de Sistemas e Computação pela Universidade Federal do Rio de Janeiro (2000) e em Administração pelo Ibmec-RJ (2003). Atualmente, é Superintendente de Educação Executiva da FGV – Rio de Janeiro e professor adjunto na Faculdade de Ciências Econômicas da UERJ. Foi também superintendente do Programa de Certificação de Qualidade da FGV e executivo no Banco Itaú com cargos de Gerente de Estratégia de Vendas (Cartão Americanas) e Gerente de Pricing e CRM (Cartão Ponto Frio). Atuou como especialista em Métodos Quantitativos na área comercial da Globex Utilidades (Ponto Frio). Foi professor adjunto na Escola de Engenharia da UFF, na EBAPE-FGV e nas Faculdades Ibmec-RJ, atuando nos níveis de graduação, mestrado e pós-graduação (*lato sensu*). Pesquisa em Administração e Economia, principalmente na linha sobre Processos Decisórios, tendo por base Economia Comportamental, Econometria e Pesquisa Operacional, atuando em temas como processos decisórios, inteligência de negócios, data science, otimização e simulação.

Sumário

Capítulo 1. Amostragem e distribuição amostral 6
1.1. População e amostra 6
1.2. Amostragem ou censo 8
1.3. Inferência e métodos de amostragem 9
1.4. Métodos de amostragem 10
1.4.1. Amostra aleatória simples 11
1.4.2. Amostra aleatória sistemática 11
1.4.3. Amostra aleatória estratificada 12
1.4.4. Amostra por conglomerados 13
1.5. Validade da amostragem 13
1.6. Distribuição amostral da média 14
1.7. Teorema do limite central 20
1.8. Distribuição amostral da proporção 21
Capítulo 2. Intervalo de confiança da média 23
2.1. Estimador e estimativa 23
2.2. Nível de confiança 24
2.3. Intervalo de confiança 24
2.4. Intervalo de confiança da média 27
2.4.1. Casos da média 32
Capítulo 3. Estimativa intervalar 36
3.1. Proporção 36
3.2. Determinando o tamanho da amostra 38
3.2.1. Para estimar a proporção 38
3.2.2. Para estimar a média 39
3.3. Total da população 40

3.4. Total da diferença 41
3.5. Intervalo de confiança unilateral..... 43
Capítulo 4. A inferência através do teste de hipóteses 45
4.1. Hipóteses do teste 45
4.2. Erros no teste de hipóteses 46
4.3. Metodologias para teste de hipóteses..... 47
4.3.1. Testando pelo intervalo de confiança 48
4.3.2. Estatística de teste..... 49
4.3.3. Metodologia do valor-P 52
4.3.4. Comparando as metodologias de teste 53
4.4. Nível de significância e decisão estatística 53
4.5. Teste unilateral..... 54
Capítulo 5. Teste de hipóteses: casos 57
5.1. Os casos da média 57
5.1.1. Desvio-padrão populacional conhecido 57
5.1.2. Desvio-padrão populacional desconhecido 59
5.2. O caso da proporção..... 60
5.3. Os casos da diferença das médias 62
5.3.1. Quando as amostras estão emparelhadas 65
5.4. O caso da diferença das proporções 66
Capítulo 6. ANOVA 69
6.1. Projeto com fator único 76
6.2. Projeto com dois fatores 82
Capítulo 7. Testes do qui-quadrado 87
7.1. Teste de aderência 87
7.2. Tabela de contingência de dupla entrada 90
7.3. Teste de homogeneidade 91

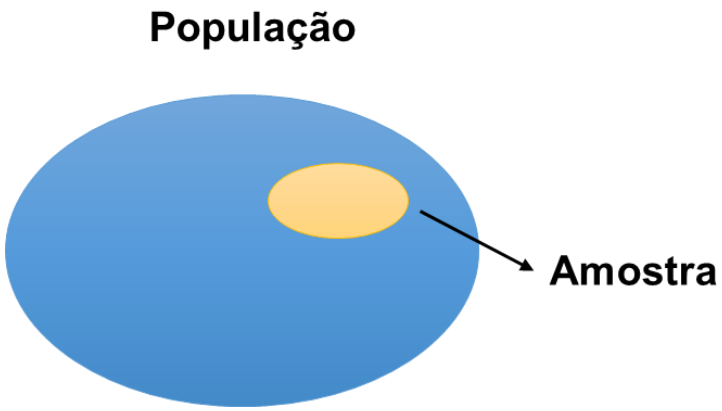
7.4. Teste de independência 93
Capítulo 8. Estatística multivariada 96
8.1. Apresentação – diagrama de dispersão 96
8.2. Descrição – covariância 99
8.3. Covariância de variáveis aleatórias e combinação de variáveis 103
8.4. Descrição – correlação 105
8.5. Inferência para a correlação 107
8.6. Regressão linear simples 109
8.6.1. Decomposição da variação da variável dependente 114
8.6.2. Análise dos resíduos 118
8.6.3. Inferências no modelo de regressão 119
Capítulo 9. Anexos 125
9.1. Tabela de distribuição normal 125
9.2. Tabela de distribuição de Student 127
9.3. Tabela de distribuição F com $\alpha = 0,01$ 129
9.4. Tabela de distribuição F com $\alpha = 0,05$ 131
9.5. Tabela de distribuição F com $\alpha = 0,10$ 133
9.6. Tabela de distribuição de qui-quadrado 135
Capítulo 10. Bibliografia 137

Capítulo 1. Amostragem e distribuição amostral

Vamos começar com uma pequena revisão de um dos conceitos apresentados no curso de Estatística I, que é a relação entre população e amostra. A maior parte deste curso vai fazer importantes comparações do comportamento desses dois conjuntos de dados.

1.1. População e amostra

Esses são, provavelmente, os conceitos mais elementares da estatística. E, felizmente, são muito simples de se compreender. Em linhas bem simples, a amostra é um subconjunto da população. É importante manter em mente que a população é o conjunto de observações ou indivíduos que se deseja estudar, mas que, por algum motivo, não está disponível. A amostra é a parte da população que está disponível.



Por exemplo, quando se utiliza a estatística para fazer uma previsão do resultado da eleição, a população é formada por todos os eleitores. No caso da eleição para presidente no Brasil em 2018, a população de eleitores era de mais de 147 milhões de pessoas. Mas as pesquisas são geralmente são feitas com menos de 3 mil eleitores. Então a amostra é representada por 3 mil pessoas dentre os 147 milhões de pessoas que estão na população.

Os dados da população são chamados de parâmetros populacionais. Os dados equivalentes na amostra são chamados de estatísticas amostrais. Por exemplo,

para as eleições de 2018, a idade média do eleitor era de aproximadamente 43 anos (dados do TSE). Mas determinada pesquisa, com 3 mil eleitores, apontou que a idade média foi de 45 anos (pois a pesquisa, por motivos aleatórios, acabou selecionando pessoas com mais idade). Nesse caso se diz que a média de 43 anos é o parâmetro populacional, também chamado de parâmetro verdadeiro, e a média de 45 anos é a estatística amostral, também chamada de estimativa.

A razão de analisar amostras em vez de analisar a população é, em última análise, custo. Isso fica bem evidente no exemplo eleitoral. O custo de consultar os 147 milhões de eleitores é tão alto que só é feito pela máquina pública, com todos os funcionários da justiça eleitoral e ainda contando com milhares de pessoas que trabalham no processo gratuitamente (mesários de seção, consolidadores, transportadores), em instalações públicas ou fornecidas gratuitamente pela iniciativa privada (em geral escolas e universidades). O custo dessa consulta populacional é tão alto que não pode ser arcado por uma empresa privada. Por isso, empresas de pesquisa de opinião consultam apenas 3 mil pessoas, o que é financeiramente viável. A estatística é a ferramenta que permite que uma amostra tão pequena, quando comparada com a população, possa ser usada para dar informações que representem a população.

Além disso, algumas pesquisas requerem a destruição do objeto sob análise. No exemplo do controle de volume das garrafas de cerveja, o equipamento que faz a medição exata do líquido que está dentro da garrafa precisa acessar todo o líquido; ou seja, a garrafa já fechada e pronta para o consumo é aberta ainda na fábrica, e toda a cerveja é colocada no equipamento que fará a medição do volume. Depois dessa medição a cerveja é descartada. Então, não seria possível analisar toda a população de garrafas industrializadas, caso contrário nenhuma garrafa de cerveja chegaria às prateleiras para ser vendida.

É importante saber se os dados sob análise representam toda a população ou apenas uma amostra. O cálculo de algumas estatísticas é feito de forma diferente quando se tem uma amostra ou uma população sob análise. Mais que isso, em alguns momentos serão usadas informações amostrais para inferir parâmetros populacionais. Essas questões serão apresentadas e discutidas posteriormente.

1.2. Amostragem ou censo

O processo de amostragem é uma alternativa a realizar um censo, ou seja, consultar toda a população. A análise da amostra é sempre mais simples (leia-se rápida e barata) do que o censo. Em geral a amostragem é preferida por alguns motivos:

- Algumas populações são infinitas, o que é evidente quando pensamos que determinados fatos que queremos analisar estão ligados ao tempo e muitos ainda não ocorreram. Por exemplo, o conjunto de dados sobre a variação de preços de um mercado é infinito, ou, pelo menos, indeterminado. Apesar de todas as observações já ocorridas serem conhecidas, não é possível conhecer as observações que ainda vão ocorrer, mas fazem parte do conjunto.
- Alguns testes são destrutivos, e então a amostragem seleciona os elementos que serão testados – e destruídos. Com isso, é possível garantir a quantidade que será testada, preservando o restante para o uso destinado. É o caso de teste de resistência de produtos ou de composição de substâncias.
- Algumas populações são difíceis ou impossíveis de serem consultadas. Quando isso acontece, geralmente há restrições de tempo, de recursos físicos, humanos ou financeiros, que sinalizam que a amostragem é melhor. É o caso da pesquisa de opinião – por exemplo, a pesquisa eleitoral. A eleição é o censo, ou seja, a consulta a toda a população. As empresas de pesquisa de opinião fazem uma amostra dessa população evitando os altos custos envolvidos em realizar o censo.
- Algumas populações apresentam uma grande volatilidade, e o censo não é suficiente para garantir sua estrutura por conta da mudança dos elementos sob observação. Nesse caso, uma amostra é o bastante para perceber como os elementos tendem a se comportar.

Entretanto, algumas situações indicam a aplicação do censo:

- Quando a população é muito pequena, a amostragem não é eficiente, uma vez que determinados padrões são percebidos em apenas poucos elementos, que podem não ser amostrados.

- Quando a população apresenta uma elevada variabilidade, ocorre um problema semelhante: os padrões são tão diversos que é necessário considerar uma amostra muito grande, chegando ao limite de precisar consultar cada elemento, se cada um for único.
- A necessidade de precisão absoluta também requer o censo. Aliás, o censo populacional, realizado pelo IBGE, tem exatamente este papel.
- Finalmente, quando os dados da população já estão disponíveis, não é necessário fazer a amostra, basta consultar os dados.

1.3. Inferência e métodos de amostragem

A inferência é o conjunto de princípios matemáticos e estatísticos que permite que conclusões válidas sobre a população sejam obtidas analisando apenas a amostra. Conforme será apresentado, a inferência é feita por duas estratégias diferentes: a estimação e o teste de hipóteses.

O processo de amostragem é a extração de informações, muitas vezes numéricas. Seja, por exemplo, o estudo da quantidade de café que está efetivamente embalada para venda. Apesar de a embalagem dizer que há 500 gramas de café na embalagem, haverá alguma variação. Algumas embalagens podem ter 501 gramas, outras 598 gramas etc. Variações menores que 1 grama podem ser observados com equipamentos mais precisos. Ao selecionar alguns elementos que serão amostrados, ou seja, algumas embalagens de café, somente uma informação será coletada: o peso efetivo. Apenas o peso será coletado, apesar de haver diversas outras informações além do peso (físicas como volume e densidade, aromática, visual como cor e tamanho do grão etc.). Dessa forma, a amostra não é composta por embalagens de café, mas pelo peso real observado nessas embalagens de café.

Depois de realizada a amostragem, o processo seguinte é definir a distribuição amostral, ou seja, as características desta amostra que permitirão analisar o comportamento da população de onde a amostra foi extraída. Falaremos disso oportunamente.

Durante o processo de amostragem, é importante garantir que a amostra atenda às necessidades da inferência. O processo de amostragem é chamado de

probabilístico quando permite que todos os elementos da população tenham as mesmas chances de serem selecionados, ou seja, a probabilidade de ser escolhido é a mesma para todos os elementos da população.

Uma amostra probabilística é também chamada de não tendenciosa, no sentido de que a amostra tende a capturar todas as características aleatórias da população. Mas essa característica não é sempre necessária. Alguns métodos de amostragem são não probabilísticos, e apresentam um viés de seleção que altera as chances de algum elemento, ou grupo de elementos, ser selecionado.

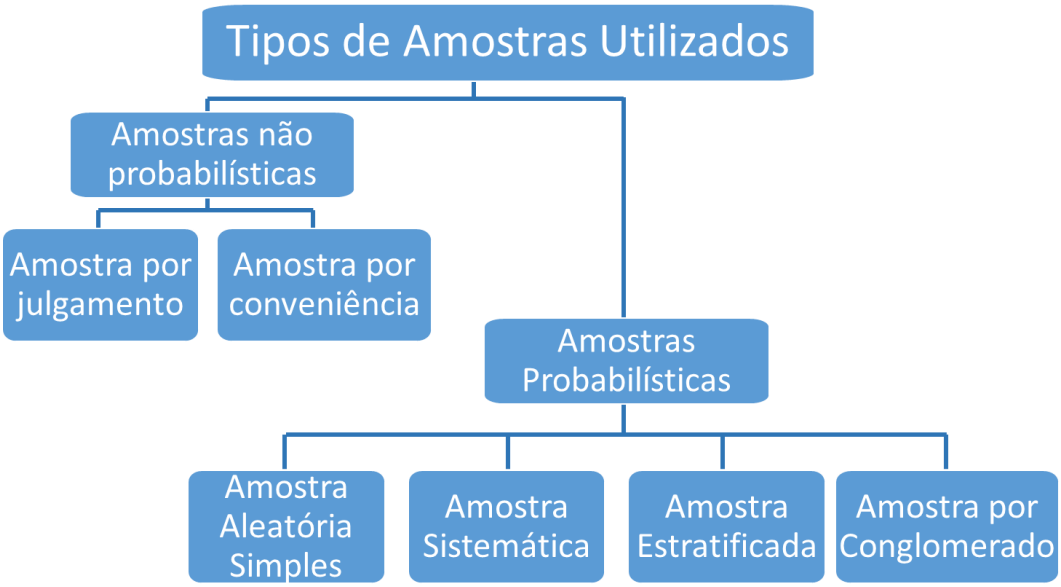
A amostragem probabilística conduz a uma inferência não tendenciosa, ou seja, a estimação e o teste de hipóteses são conduzidos, de forma que é possível fazer uma avaliação objetiva dos erros amostrais cometidos.

1.4. Métodos de amostragem

O esquema demonstrado na **Erro! Fonte de referência não encontrada.** facilita o entendimento sobre os tipos de amostra mais utilizados. Vamos falar sobre os métodos probabilísticos, uma vez que são mais importantes para a estatística.

A diferença entre os métodos é baseada na adaptabilidade em relação a determinadas situações envolvendo a coleta dos dados e as características da população. Alguns métodos podem ser mais adequados do que outros em função do cenário. Entretanto, do ponto de vista estatístico, não há um método melhor do que o outro. A característica comum a todos é o uso de amostras aleatórias, que garante que a chance de cada amostra de certo tamanho ser selecionada é a mesma.

Figura 1. Tipos de amostra utilizados



1.4.1. Amostra aleatória simples

Cada elemento da população é aleatoriamente escolhido se participará da amostra ou não. O método mais comum para realizar uma amostragem aleatória simples é um sorteio dos elementos que serão selecionados.

Por exemplo, para selecionar uma amostra de 50 alunos de uma universidade que tem 1.000 alunos, faz-se um sorteio, usando cartões e uma urna. O sorteio é feito sem reposição, ou seja, quando um aluno é selecionado ele não pode mais ser selecionado novamente.

Esse sorteio pode ser físico, com uma urna e cartões ou outro dispositivo, ou pode ser virtual. Os computadores têm ferramentas para gerar números aleatórios (pseudoaleatórios, na verdade), que podem ser usados para simular um sorteio. Sorteios virtuais são usados em que a atividade é corriqueira e frequente.

1.4.2. Amostra aleatória sistemática

O procedimento inclui uma ordenação prévia dos elementos populacionais antes da seleção. Essa ordenação pode ser por ordem alfanumérica ou outro critério qualquer.

O primeiro elemento é selecionado de forma aleatória, como o processo anterior: um sorteio ou algo semelhante. Os demais elementos são selecionados a partir de uma lei de formação, geralmente periódico: a cada 50 elementos, ou a cada 100 elementos etc.

Por exemplo, para amostrar 50 alunos dentre os 1.000 da universidade, sorteia-se o primeiro elemento aleatoriamente. Estando ordenados, a partir deste primeiro são contados 20 até o próximo que será amostrado, depois mais 20, e assim sucessivamente. A lista provavelmente chegará ao fim antes de a amostragem ser concluída, o que acontecerá sempre que o primeiro aluno sorteado não estiver entre os 20 primeiros. Nesse caso, a contagem recomeça do início, como se o 1º aluno fosse o 1.001º, e assim por diante. Ao fim do processo, 50 alunos terão sido selecionados para compor a amostra.

Esse procedimento é muito comum em processos produtivos, onde há uma ordenação natural no tempo de produção e a sistemática é feita por tempo. Por exemplo, a cada hora são realizadas amostragens.

1.4.3. Amostra aleatória estratificada

Esse é o processo mais complexo e depende de um conhecimento prévio sobre algumas características da população, o que geralmente é proporcionado por um censo.

O procedimento divide a população em estratos seguindo características relevantes para o estudo. A amostragem respeita a proporção de cada estrato e replica essa proporção. A seleção é aleatória dentro dos estratos, de forma que cada elemento dentro daquele estrato tem as mesmas chances de ser selecionado.

No esforço de realizar a amostragem dos 1.000 alunos da universidade, podem ter sido definidos os estratos com base na área de estudo dos alunos. Se na população são observados 400 estudantes da área tecnológica, 500 da área biomédica e 100 da área de ciências humanas, então a amostra seleciona aleatoriamente 20 alunos de tecnologia, 25 de biomedicina e 5 de ciências humanas. Dessa forma, a amostra e a população têm identicamente 40%, 50% e 10% de elementos dentro dos estratos definidos.

A necessidade de considerar os estratos pode ser solucionada com uma outra estratégia, descrita a seguir. O processo de amostragem é aleatório e simples, e a análise numérica é feita atribuindo pesos diferentes de acordo com o estrato ao qual a observação pertence. Por exemplo, ao considerar a média, pondera-se com peso 4 para os alunos de tecnologia, com peso 5 os alunos de biomedicina e com peso 1 os alunos de ciências humanas.

Os estratos podem ser mais complexos, considerando outras dimensões. Por exemplo, além da área de estudo poderiam ser considerados estratos por faixa etária, sexo, renda etc.

O processo de amostragem estratificada é realizado cautelosamente pelas pesquisas de opinião. Por exemplo, pesquisa eleitoral, precisa considerar a diversidade populacional que influencia no posicionamento político. A localização geográfica do eleitor, sua idade e sexo, sua renda, são fatores importantes que tendem a impactar diretamente sua escolha.

1.4.4. Amostra por conglomerados

Um conglomerado é um subconjunto da população que é representativo desta população. São designações que ocorrem naturalmente, como municípios, distritos eleitorais, bairros etc.

Na seleção da amostra, pesos são dados a cada subgrupo para refletir a divisão da população em estratos.

Por exemplo, suponha os conglomerados: 2 milhões de eleitores na capital e 8 milhões de eleitores no interior de certo estado. A análise estratificada em um único conglomerado pode ser suficiente, mas geralmente requer grandes amostras.

1.5. Validade da amostragem

Os erros mais comuns em uma pesquisa são:

- Cobertura: a preocupação é saber se todas as características da população foram capturadas e na proporção (peso) adequada. Um erro de cobertura gera o que é conhecido como **viés de seleção**.

- Falta de resposta: todos os dados amostrados puderam ser coletados? Algumas informações estão inacessíveis, por conta de proteção, sigilo, dificuldade de acesso etc. Nesses casos, ocorre o **viés de falta de resposta**.
- Amostragem: dentro da amostra são percebidas variações aleatórias, ou dispersões. O tamanho dessas variações precisa estar de acordo com as variações percebidas na população. Essa questão está diretamente associada ao conceito chamado de **margem de erro**, que será objeto deste curso.
- Medição: os **erros de medição** ocorrem quando há falha no processo de medição, por erro de equipamento ou falha de transmissão, ou, ainda, quando a informação é alterada de forma proposital (quando consultadas, algumas pessoas podem mentir sobre determinados assuntos comportamentais ou financeiros).

Quando a amostragem é realizada, o pesquisador precisa estar atento à validade, de forma que os erros e vieses sejam contornados ou controlados. A margem de erro é um conceito que será explorado e controlado nas abordagens que serão feitas.

1.6. Distribuição amostral da média

Considere uma população que tem como média o valor μ. Chamamos essa média populacional de parâmetro da população. Um parâmetro populacional é constante, no sentido de que o processo de realizar amostras não altera seu valor.

Quando uma amostra é realizada, a média dessa amostra é chamada de $\bar{X}$. Chamamos essa média amostral de estatística da amostra. A estatística da amostra é variável, no sentido de que cada amostra tem um valor potencialmente diferente, mesmo que o valor populacional μ esteja fixo.

Por exemplo, se fôssemos estudar a estatura dos brasileiros adultos (com 18 anos ou mais), a população iria conter um conjunto com milhões de valores. A estatura média de todos estes brasileiros adultos seria o parâmetro populacional μ. Se considerássemos uma amostra aleatória de 100 pessoas, o valor da média

dessas 100 pessoas seria a estatística dessa amostra $\bar{X}$. Certamente, e isso fica mais evidente se formos bem precisos na medição e na média, o valor de $\bar{X}$ não seria igual ao valor de μ. Além disso, se fosse feita uma outra amostra, com outros 100 brasileiros adultos, haveria uma nova média amostral, digamos $\bar{X}_2$. Muito provavelmente, $\bar{X}_2 \neq \bar{X}$.

A amostra e os valores que são capturados dessa amostra servem para **inferir** os valores populacionais. Ou seja $\bar{X}$ serve para inferir μ. O processo de inferência possui erros e incertezas que são controlados por técnicas estatísticas.

A distribuição amostral refere-se a uma estatística amostral. Existe a distribuição amostral da média, da variância, da proporção etc. Uma característica fundamental da distribuição amostral é o tamanho da amostra, n. A distribuição amostral é usada, principalmente, como ferramenta de controle do erro amostral e servirá como controle básico das inferências.

A distribuição amostral relaciona todos os possíveis resultados para a estatística considerada e as probabilidades de ocorrência deles. Na maioria das situações, os parâmetros têm domínio contínuo, logo a distribuição amostral é uma distribuição de probabilidades contínua, descrita através de parâmetros importantes.

Para entender uma distribuição amostral das médias, vamos seguir um exemplo extremamente simplificado da realidade e criar uma distribuição de frequências de um processo de amostragem. Essa distribuição de frequências será a própria distribuição amostral da média, e perceberemos como construir a distribuição amostral sem precisar criar a distribuição de frequências.

Vamos considerar inicialmente uma população que tem apenas 5 elementos. Seja uma região que contém apenas cinco empresas atuantes em determinado setor. Essas empresas apresentaram os seguintes resultados após o encerramento do último balanço: 3, 4, 5, 6 e 7 (milhões de reais). É fácil perceber que:

$$\mu = 5{,}00 \quad \sigma^2 = 2{,}00 \quad \sigma = 1{,}41$$

Esta é uma população muito pequena, e já se conhece o censo. Naturalmente, não há vantagem alguma em realizar amostras, mas vamos fazer assim mesmo. O motivo é entender o processo de amostragem, e nada melhor do que uma situação bem simples para perceber a mecânica de processos que podem ficar bem complexos.

Suponha que tenha sido feita uma pesquisa com três executivos dessas empresas, sem saber de que empresa eram. A esses executivos foi perguntado quanto foi o último resultado da empresa em que trabalham. Suponha que se obtiveram, como resposta, os valores 3, 4 e 5. Neste caso, temos:

$$\bar{X} = 4{,}00$$

Observa-se um **erro amostral** que é:

$$\epsilon = \bar{X} - \mu = -1{,}00$$

O erro amostral é uma consequência da amostragem. Não se espera que a amostra conduza para um valor de $\bar{X}$ que seja exatamente igual a μ, ou seja, já se espera que ocorra algum erro amostral. Esse erro amostral pode ser positivo ou negativo. Se, por exemplo, as respostas dos três executivos levassem a 4, 5 e 7, então se teria:

$$\bar{X} = 5{,}33 \quad \epsilon = +0{,}33$$

O valor das estatísticas e dos erros amostrais vai variar principalmente por três fatores:

1. Os valores amostrados, que podem gerar valores maiores ou menores como os dois exemplos. É possível encontrar, inclusive, valores de $\bar{X}$ exatamente iguais a μ, de forma que ϵ = 0.
2. O tamanho da amostra, pois amostras maiores apresentam menor variabilidade e menor erro amostral.

3. O parâmetro sob estudo. Se o motivo de realizar a amostra é obter uma estimativa para o desvio-padrão, por exemplo, teria sido observado no primeiro exemplo que s = 1,00, e então o erro amostral seria ϵ_s = -0,41.

Além disso, é importante observar que, em geral, o valor de μ não é conhecido. Portanto o erro amostral $\epsilon = \bar{X} - \mu$ não pode ser calculado. É importante manter em mente que o exemplo que estamos construindo tem motivação didática. Somente ao final do exemplo será possível capturar os elementos importantes para o processo de inferência.

A distribuição amostral relaciona todos os possíveis resultados em amostras do mesmo tamanho. Para o exemplo que estamos considerando, todas as amostras possíveis com n = 3 elementos e com reposição estão demonstradas na Tabela 1. São 125 diferentes amostras.

Além da amostra, é possível ver, na Tabela 1, o valor da estatística amostral $\bar{X}$ que seria obtido se essa amostra fosse considerada. Como estamos considerando todas as amostras possíveis, o conjunto de valores de $Y = \bar{X}$ representa uma população: a população de todas as estatísticas que podem ser obtidas com amostra de tamanho n = 3 do conjunto sob estudo (as cinco empresas).

Tabela 1. Amostras possíveis da população de cinco empresas

Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$	Amostra	$Y = \bar{x}$
3,3,3	3,00	3,6,6	5,00	4,5,4	4,33	5,3,7	5,00	5,7,5	5,67	6,6,3	5,00	7,4,6	5,67
3,3,4	3,33	3,6,7	5,33	4,5,5	4,67	5,4,3	4,00	5,7,6	6,00	6,6,4	5,33	7,4,7	6,00
3,3,5	3,67	3,7,3	4,33	4,5,6	5,00	5,4,4	4,33	5,7,7	6,33	6,6,5	5,67	7,5,3	5,00
3,3,6	4,00	3,7,4	4,67	4,5,7	5,33	5,4,5	4,67	6,3,3	4,00	6,6,6	6,00	7,5,4	5,33
3,3,7	4,33	3,7,5	5,00	4,6,3	4,33	5,4,6	5,00	6,3,4	4,33	6,6,7	6,33	7,5,5	5,67
3,4,3	3,33	3,7,6	5,33	4,6,4	4,67	5,4,7	5,33	6,3,5	4,67	6,7,3	5,33	7,5,6	6,00
3,4,4	3,67	3,7,7	5,67	4,6,5	5,00	5,5,3	4,33	6,3,6	5,00	6,7,4	5,67	7,5,7	6,33
3,4,5	4,00	4,3,3	3,33	4,6,6	5,33	5,5,4	4,67	6,3,7	5,33	6,7,5	6,00	7,6,3	5,33
3,4,6	4,33	4,3,4	3,67	4,6,7	5,67	5,5,5	5,00	6,4,3	4,33	6,7,6	6,33	7,6,4	5,67
3,4,7	4,67	4,3,5	4,00	4,7,3	4,67	5,5,6	5,33	6,4,4	4,67	6,7,7	6,67	7,6,5	6,00
3,5,3	3,67	4,3,6	4,33	4,7,4	5,00	5,5,7	5,67	6,4,5	5,00	7,3,3	4,33	7,6,6	6,33
3,5,4	4,00	4,3,7	4,67	4,7,5	5,33	5,6,3	4,67	6,4,6	5,33	7,3,4	4,67	7,6,7	6,67
3,5,5	4,33	4,4,3	3,67	4,7,6	5,67	5,6,4	5,00	6,4,7	5,67	7,3,5	5,00	7,7,3	5,67
3,5,6	4,67	4,4,4	4,00	4,7,7	6,00	5,6,5	5,33	6,5,3	4,67	7,3,6	5,33	7,7,4	6,00
3,5,7	5,00	4,4,5	4,33	5,3,3	3,67	5,6,6	5,67	6,5,4	5,00	7,3,7	5,67	7,7,5	6,33
3,6,3	4,00	4,4,6	4,67	5,3,4	4,00	5,6,7	6,00	6,5,5	5,33	7,4,3	4,67	7,7,6	6,67
3,6,4	4,33	4,4,7	5,00	5,3,5	4,33	5,7,3	5,00	6,5,6	5,67	7,4,4	5,00	7,7,7	7,00
3,6,5	4,67	4,5,3	4,00	5,3,6	4,67	5,7,4	5,33	6,5,7	6,00	7,4,5	5,33		

Então, é possível calcular os parâmetros para a população de estatísticas:

$$\mu_Y = 5{,}00$$

$$\sigma_Y^2 = 0{,}67$$

$$\sigma_Y = 0{,}82$$

Cada amostra traz uma estimativa, $Y = \bar{X}$. O conjunto de todas as estimativas pode ser chamado de estimador de μ. Cada estimativa está associada a uma amostra, que é aleatória. Portanto o estimador, população de estimativas, é uma variável aleatória.

Há interpretações importantes para os valores observados acima e que podem ser generalizados para todos os procedimentos de amostragem da média com reposição de valores:

1. $E(\bar{X}) = \mu$

Isso quer dizer que o valor esperado da média amostral é a média populacional. A interpretação é que a estimação é feita sem viés: $\bar{X}$ tende ao valor de μ. Estimadores não viesados são muito importantes para a estatística, apesar de não serem únicos.

2. $\sigma(\bar{X}) = \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{1{,}41}{\sqrt{3}} = 0{,}82$

Isso quer dizer que a dispersão do estimador está associada à dispersão da população. A dispersão do estimador é menor do que a dispersão da população, e essa diferença se dá exclusivamente em função do tamanho amostral. É fácil ver que quanto maior o valor de n menor será o valor de $\sigma_{\bar{X}}$.

O desvio-padrão das médias amostrais $\sigma_{\bar{X}}$ é também chamado de erro-padrão do estimador. Isso porque, para calcular o desvio-padrão, compara-se a média dos erros amostrais:

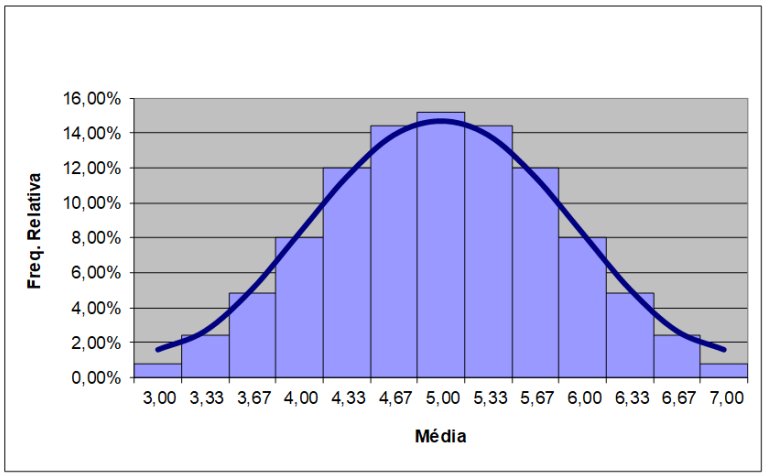
$$\frac{1}{N}\sum (Y - E(Y)^2 = \frac{1}{N}\sum (\bar{X} - \mu)^2$$

Em função das pequenas dimensões da população e da amostra, é possível ver que os valores de $\bar{X}$ são poucos e repetem bastante. Então, é possível construir uma distribuição de frequência, que está na **Erro! Fonte de referência não encontrada.**.

Não é por acaso que a distribuição de frequências, ao ser observada em um histograma, se assemelha à distribuição normal. Isso será formalizado na seção seguinte.

Figura 2. Distribuição de frequência dos valores de $\bar{X}$ ou distribuição amostral de $\bar{X}$

$Y = \bar{X}$	Freqüência	
	Absoluta	Relativa
3,00	1	0,80%
3,33	3	2,40%
3,67	6	4,80%
4,00	10	8,00%
4,33	15	12,00%
4,67	18	14,40%
5,00	19	15,20%
5,33	18	14,40%
5,67	15	12,00%
6,00	10	8,00%
6,33	6	4,80%
6,67	3	2,40%
7,00	1	0,80%
Total	**125**	**100%**



Quando o processo de amostragem é feito sem reposição, pode ocorrer uma alteração no comportamento da dispersão da distribuição amostral. Isso ocorre quando a população é finita. Assim, quando a população é finita e a amostragem é sem reposição, deve-se considerar no cálculo do erro-padrão o fator de correção:

$$FC = \sqrt{\frac{N-n}{N-1}}$$

onde N é o tamanho da população e n é o tamanho da amostra.

Observa-se que o fator de correção se torna desnecessário em certas situações, pois ele pode ficar muito próximo de 1. Isso ocorre quando a amostra tem tamanho bem reduzido frente ao tamanho da população.

Então, usa-se o fator de correção quando a amostragem é feita sem reposição e o tamanho amostral é significativo frente ao tamanho populacional (costuma-se considerar n > 0,05N). No caso da distribuição amostral das médias, o erro-padrão ficaria assim: $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$.

1.7. Teorema do limite central

Para uma população normalmente distribuída, a distribuição amostral das médias terá formato aproximadamente normal, independentemente do tamanho da amostra.

Para toda e qualquer população, a distribuição amostral das médias tenderá à distribuição normal, desde que o tamanho da amostra seja suficientemente grande (geralmente se usa n ≥ 30).

Dessa forma, a distribuição amostral das médias é uma distribuição normal com parâmetros:

$$\begin{cases} E(\bar{X}) = \mu \\ \sigma_{\bar{X}} = \dfrac{\sigma}{\sqrt{n}} \end{cases}$$

O desvio-padrão das médias amostrais, ou erro-padrão do estimador, deve ser multiplicado pelo fator de correção se for o caso.

Exemplo: Os preços de certo modelo de smartphone seguem uma distribuição normal, com média igual R$700,00 e desvio-padrão de R$100,00. Pretende-se estimar:

a) A probabilidade de que um aparelho desse modelo selecionado ao acaso esteja com preço menor do que R$750,00.
b) A probabilidade de que a média de 10 aparelhos desse modelo, selecionados ao acaso, tenha preço inferior a R$750,00.

Solução: Seja X o preço dos aparelhos. O enunciado afirma que X segue uma distribuição normal com μ = 700 e σ = 150.

a) Para estimar a probabilidade de que aparelhos tenham preço abaixo de 750, usa-se a distribuição normal. Por exemplo, no Excel é possível usar a fórmula =DIST.NORM.N(750;700;150;1). Então, P(X < 750) = 0,6306 = 63,06%

b) Para estimar a probabilidade relativa à média de 10 observações, é necessário conhecer os parâmetros da distribuição amostral da média com n = 10. De acordo como que foi visto antes, é possível determinar que $E(\bar{X}) = \mu = 700$ e $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{150}{\sqrt{10}} = 47{,}43$. Então, para saber a probabilidade de que a média seja menor do que 750, usa-se novamente a distribuição normal, mas com os novos parâmetros (novo desvio-padrão), e a fórmula é =DIST.NORM.N(750;700;47,43;1). Então, $P(\bar{X} < 750) = 0{,}8541 = 85{,}41\%$.

A partir desse exemplo, compreende-se que, apesar de serem parecidas, as questões a) e b) são muito diferentes uma da outra. Mais ainda, que é possível usar o mesmo procedimento de cálculo para obter os resultados, e que alterando apenas o valor do desvio-padrão (erro-padrão no caso da distribuição amostral) se obtém a probabilidade correta.

1.8. Distribuição amostral da proporção

A proporção é uma estatística usada para quantificar a ocorrência de determinado valor. A proporção verdadeira, o parâmetro populacional, é indicada por π, e a estatística amostral é indicada por p. O valor de p é definido com base na quantidade de ocorrências relativamente ao tamanho da amostra: $p = \frac{x}{n}$, onde x é a quantidade de ocorrências e n é o tamanho da amostra. Para amostras suficientemente grandes, sendo nπ > 5 e n(1 - π) > 5, a distribuição amostral de $p = \frac{x}{n}$ é aproximadamente normal com os parâmetros:

- Valor esperado (média): E(p) = π

- Desvio-padrão (erro-padrão): $$\sigma_p = \sqrt{\frac{\pi(1-\pi)}{n}}$$

Exemplo: O gerente de uma agência de um banco de investimentos sabe que 40% de todos os depositantes têm contas múltiplas no banco. Foi selecionada uma amostra com 200 depositantes. Qual a probabilidade de que, nesta amostra, haja 60 ou menos depositantes com contas múltiplas?

Solução: Inicialmente se observa que o tamanho da amostra é suficiente, pois nπ = 80 e n(1 - π) = 120, sendo ambos maiores do que 5. Então é possível estabelecer que a distribuição de probabilidades da proporção segue aproximadamente uma distribuição normal com parâmetros E(p) = π = 0,4 e $\sigma_p = \sqrt{\frac{\pi(1-\pi)}{n}} = 0{,}0346$. Assim, é possível calcular $P\left(p \leq \frac{60}{200}\right)$ usando a distribuição normal. Usando o Excel, fazendo =DIST.NORM.N(0,3;0,4;0,0346;1).

Portanto, P(p ≤ 0,3) = 0,0019 = 0,19%.

Capítulo 2. Intervalo de confiança da média

Vamos considerar uma situação real, um exemplo, para nortear os princípios de estimação de um parâmetro.

Exemplo: A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma amostra com o faturamento de 60 empresas. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que o desvio-padrão do faturamento das 5.000 empresas é de R$380,00 como se pode estimar o faturamento médio das 5.000 empresas?

O exemplo projeta o principal problema da estimativa: como a média amostral pode ser generalizada para a média populacional? Ou, de outra forma, quais mecanismos de controle dão confiança de que a média amostral representa a média populacional?

Essa questão é chamada de inferência: deseja-se inferir a média da população a partir de elementos obtidos na amostra. O procedimento de inferência é feito em três etapas:

- Seleção de uma amostra aleatória extraída da população em estudo.
- Escolha do estimador a ser usado.
- Realização dos cálculos necessários.

2.1. Estimador e estimativa

O estimador, que foi definido anteriormente como o conjunto de estimativas, também pode ser visto como a função matemática que avalia o parâmetro populacional com base nas estatísticas amostrais. Já a estimativa é o valor que o estimador assume em uma amostra em particular, ou seja, a estimativa é a aplicação da função matemática que representa o estimador em determinada amostra. É importante entender que o estimador gera estimativas quando usado em diferentes amostras.

O estimador pode ser pontual ou intervalar. O estimador pontual é um único valor, e o estimador intervalar é uma faixa de valores. Entendendo que o estimador é uma tentativa de determinar o valor do parâmetro populacional, o estimador por ponto tenta determinar o valor exato, e o estimador intervalar tenta

determinar uma faixa de valores onde o parâmetro deve estar. Veja exemplos a seguir:

Tabela 2. Exemplos de estimador

Parâmetro	Estimador pontual	Estimador intervalar
Média	A venda média da loja é de 100 pares de sapatos por dia.	A venda média da loja situa-se entre 80 e 120 pares de sapato por dia.
Proporção	O candidato X terá 45% dos votos válidos.	Margem de erro de 2pp, ou seja, o candidato X terá de 43% a 47%.
Desvio-padrão	O desvio-padrão dos retornos mensais do Ibovespa é de 12%a.m.	O desvio-padrão dos retornos mensais do Ibovespa situa-se entre 11%a.m. e 15%a.m.

2.2. Nível de confiança

Vamos aprender a construir o estimador intervalar por um processo chamado intervalo de confiança. A distribuição amostral da estatística será usada para estabelecer o intervalo onde o parâmetro estimado deverá estar. O intervalo de confiança será construído com base na probabilidade *a priori* de que contenha o parâmetro populacional. Essa probabilidade é denominada nível de confiança e é indicada por $(1 - \alpha)$, sendo $0 < \alpha < 1$. O nível de confiança costuma ser expresso em percentual.

Geralmente, é usado o nível de confiança de 95% (situação na qual $(1 - \alpha) = 95\%$). Alternativamente, são usados 99% ou 90% quando se deseja obter estimativas com maior confiança ou, em oposto, com maior precisão, respectivamente. Esses três níveis de confiança são os mais usados, mas é possível construir intervalos de confiança para quaisquer níveis (exceto os limites 0% e 100%).

2.3. Intervalo de confiança

Voltando ao exemplo que abriu o capítulo:

> A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma amostra com o faturamento de 60 empresas. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que o desvio-padrão

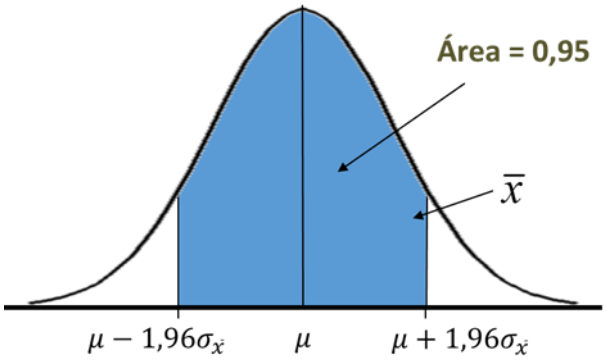
do faturamento das 5.000 empresas é de R$380,00, deseja-se estimar o faturamento médio das 5.000 empresas.

Neste problema sabemos que o tamanho populacional é N = 5.000e o tamanho amostral é n = 60. Sabemos ainda que o desvio-padrão populacional é σ = 380 e que a média amostral é $\bar{X} = 3.542$.

Se realizássemos outra amostragem, obteríamos outro valor de média amostral, digamos $\bar{X}_2$. E se fizéssemos outra amostragem ainda, um $\bar{X}_3$. Esse exercício foi feito exaustivamente no capítulo anterior, no exemplo das cinco empresas (veja a seção 0). O que sabemos é que as médias amostrais $\bar{X}_i$ seguem uma distribuição normal com média igual a μ e desvio-padrão igual a $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ (as condições acima estão dentro das condições do teorema do limite central).

Usando a distribuição normal, é possível construir um intervalo de concentração ao redor da média μ considerando um percentual desejado de concentração. A **Erro! Fonte de referência não encontrada.** mostra o intervalo que concentra 95% das médias amostrais.

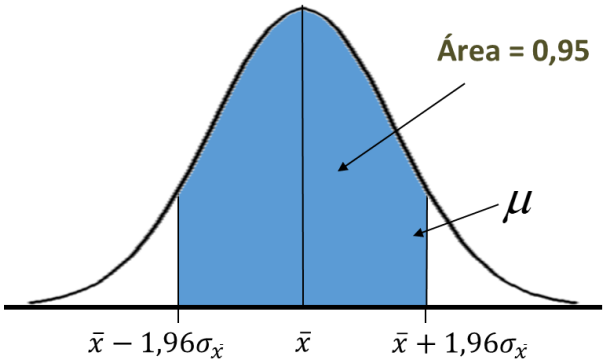
Figura 3. Intervalo de concentração para as médias amostrais



O intervalo de concentração como está proposto não pode ser determinado para o exemplo acima, pois o valor de μ não é conhecido. Então, ao usar os mesmos

limites para construir um intervalo ao redor de $\bar{X}$, obtém-se o intervalo como está proposto na **Erro! Fonte de referência não encontrada.**.

Figura 4. Intervalo de 95% de confiança



Se a média amostral que calculamos tem 95% de chance de estar no intervalo proposto na **Erro! Fonte de referência não encontrada.**, então a média populacional tem 95% de chance de estar incluída no intervalo, como proposto na **Erro! Fonte de referência não encontrada.**.

O intervalo de confiança para um parâmetro é um intervalo real (conjunto numérico) no qual esperamos que o valor verdadeiro do parâmetro populacional esteja contido. Os limites do intervalo são calculados com base no nível de confiança, previamente definido, e nas informações amostrais obtidas.

O procedimento genérico para construção de um intervalo de confiança pode ser descrito em cinco passos:

1. Após a coleta dos dados amostrais, calcule a estimativa pontual (T) para o parâmetro sendo estudado (P).
2. Determine o erro-padrão da estimativa (E).

Usa-se o fator de correção se a amostragem for sem reposição e de grande volume em uma população finita.

3. Estabeleça o nível de confiança desejado (1 – α).
4. Verifique qual distribuição amostral é adequada ao estudo, e, com base no nível de confiança estabelecido em 3, determine seus índices (i).

5. O intervalo de confiança será dado por:

$$(T - i \times E) < P < (T + i \times E)$$

Vamos ver como essas etapas se aplicam no caso da estimativa da média.

2.4. Intervalo de confiança da média

Resgatando novamente o exemplo:

A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma amostra com o faturamento de 60 empresas. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que o desvio-padrão do faturamento das 5.000 empresas é de R$380,00, deseja-se estimar o faturamento médio das 5.000 empresas.

De onde extraímos:

N = 5.000

n = 60

σ = 380

$\bar{X} = 3.542$.

Deseja-se construir um intervalo de confiança com 68,26% de confiança.

Adaptando o procedimento genérico de construção do intervalo de confiança para o caso em questão, temos:

1. A estimativa pontual já foi calculada: $\bar{x} = 3.542$
2. O erro-padrão é $$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{380}{\sqrt{60}} = 49{,}06$$
3. De acordo com o solicitado, (1 - α) = 68,26%
4. A distribuição adequada é a distribuição normal. Procurando na tabela o valor de z para probabilidade de 0,3413, encontramos $z_{\alpha/2} = 1{,}00$
5. O intervalo de confiança será dado por:

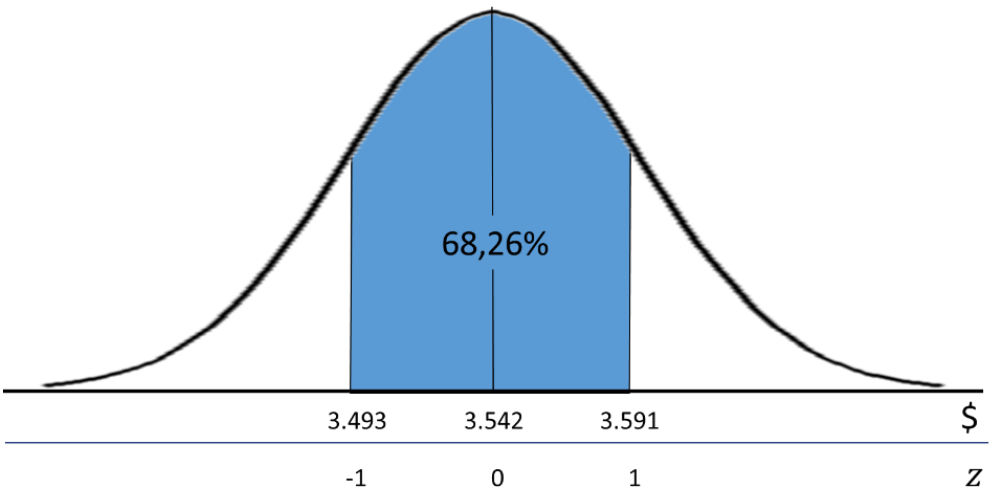
$$(\bar{x} - z_{\alpha/2} \times \sigma_{\bar{x}}) < \mu < (\bar{x} + z_{\alpha/2} \times \sigma_{\bar{x}})$$

$$\mu = \bar{x} \pm z_{\alpha/2} \times \sigma_{\bar{x}} = 3.542 \pm 1{,}00 \times 49{,}06$$

$$3.492{,}94 < \mu < 3.591{,}06$$

É muito conveniente interpretar o intervalo construído na forma gráfica como está na **Erro! Fonte de referência não encontrada.**.

Figura 5. Intervalo de 68,26% de confiança para o faturamento médio



Portanto, temos 68,26% de confiança quando afirmamos que o faturamento médio das 5.000 empresas (média populacional) é algum valor entre 3.493 e 3.591, ou seja, a afirmação 3.493 < μ < 3.591 é feita com 68,26% de chance de estar correto. Se usássemos a estatística amostral $\bar{X} = 3.542$ como estimativa pontual, teríamos uma chance muito menor de estarmos certos (na verdade, como estamos trabalhando sobre variáveis aleatórias contínuas, a chance de que μ = 3.452 é zero). Portanto, a utilização de intervalos de confiança nos dá chances de estimar corretamente o parâmetro populacional.

Exemplo 2: Refazer o exemplo anterior, mas considerando agora um nível de confiança de 95%.

A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma amostra com o faturamento de 60 empresas. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que o desvio-padrão do faturamento das 5.000 empresas é de R$380,00, deseja-se estimar um intervalo de confiança com 95% de confiança.

Com a alteração do nível de confiança, os passos 3 e 4 serão alterados, e, consequentemente, o valor final também. A solução está a seguir, com ênfase nas alterações:

1. A estimativa pontual já foi calculada: $\bar{x} = 3.542$
2. O erro-padrão é $$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{380}{\sqrt{60}} = 49{,}06$$
3. **De acordo com o solicitado, (1 - α) = 95%**
4. **A distribuição adequada é a distribuição normal. Procurando na tabela o valor de z para probabilidade de 0,4750, encontramos** $\boldsymbol{z_{\alpha/2} = 1{,}96}$
5. O intervalo de confiança será dado por:

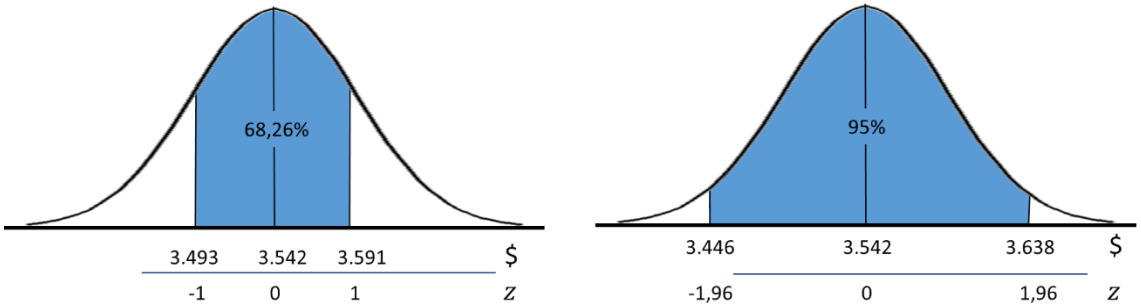
$$\boldsymbol{z_{\alpha/2} = 1{,}96}\left(\bar{x} - z_{\alpha/2} \times \sigma_{\bar{x}}\right) < \mu < \left(\bar{x} + z_{\alpha/2} \times \sigma_{\bar{x}}\right)$$

$$\mu = \bar{x} \pm z_{\alpha/2} \times \sigma_{\bar{x}} = \mathbf{3.542 \pm 1{,}96 \times 49{,}06}$$

$$\mathbf{3.445{,}84 < \mu < 3.638{,}16}$$

Quando alteramos o nível de confiança, alteramos o valor de $z_{\alpha/2}$, e então, consequentemente, os valores limites do intervalo de confiança. Para obter maiores chances de acerto, obtêm-se intervalos mais amplos, ou seja, que cobrem uma quantidade maior de valores possíveis para a média populacional. Isso pode ser interpretado graficamente na **Erro! Fonte de referência não encontrada.**, onde é possível ver os intervalos com 68,26% e com 95% simultaneamente.

Figura 6. Intervalos com 68,26% e 95% de confiança para a média



Exemplo 3: Refazer o exemplo anterior (considerando nível de confiança de 95%), mas considerando agora que a amostra tivesse 30 observações.

A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma **amostra com o faturamento de 30 empresas**. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que o desvio-padrão do faturamento das 5.000 empresas é de R$380,00, deseja-se estimar um intervalo de confiança com 95% de confiança.

Com a alteração do tamanho da amostra, o cálculo do erro-padrão no passo 2 será alterado. Consequentemente os limites do intervalo também serão alterados. A solução está abaixo, com ênfase nas alterações:

1. A estimativa pontual já foi calculada: $\bar{x} = 3.542$
2. O erro-padrão é $$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{380}{\sqrt{30}} = 69,38$$
3. De acordo com o solicitado, (1 - α) = 95%
4. A distribuição adequada é a distribuição normal. Procurando na tabela o valor de z para probabilidade de 0,4750, encontramos $z_{\alpha/2} = 1,96$
5. O intervalo de confiança será dado por:

$$(\bar{x} - z_{\alpha/2} \times \sigma_{\bar{x}}) < \mu < (\bar{x} + z_{\alpha/2} \times \sigma_{\bar{x}})$$

$$\mu = \bar{x} \pm z_{\alpha/2} \times \sigma_{\bar{x}} = 3.542 \pm 1,96 \times 69,38$$

$$3.406,01 < \mu < 3.677,98$$

O tamanho da amostra está diretamente associado à segurança da informação gerada. Ao diminuirmos o tamanho da amostra, a segurança quanto à estimativa do intervalo também diminui. Mas o nível de confiança desejado se manteve constante em 95%. Então, o intervalo de confiança ficou mais amplo para compensar a perda de segurança provocada pela redução da amostra. O recíproco também é verdadeiro: se o tamanho da amostra aumentar o intervalo de confiança ficaria menos amplo.

Como regra, fixados todos os demais parâmetros (inclusive o nível de significância), o tamanho da amostra é inversamente relacionado com a amplitude do intervalo: quanto maior a amostra, menor é a amplitude do intervalo, e vice-versa – quanto menor a amostra, maior é a amplitude do intervalo.

Exemplo 4: Refazer o Exemplo 2 (amostra com 60 elementos e nível de confiança de 95%), mas considerando agora que o desvio-padrão populacional é de R$180,00.

A fim de determinar o faturamento diário das 5.000 empresas de uma região, coletou-se uma amostra com o faturamento de 60 empresas. A média encontrada nesta amostra foi de R$3.542,00. Sabendo-se que **o desvio-padrão do faturamento das 5.000 empresas é de R$180,00**, deseja-se estimar um intervalo de confiança com 95% de confiança.

Com a alteração do desvio-padrão, o cálculo do erro-padrão no passo 2 será alterado. Consequentemente os limites do intervalo também serão alterados. A solução está a seguir, com ênfase nas alterações:

1. A estimativa pontual já foi calculada: $\bar{x} = 3.542$
2. O erro-padrão é $$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{180}{\sqrt{60}} = 23,24$$
3. De acordo com o solicitado, (1 - α) = 95%
4. A distribuição adequada é a distribuição normal. Procurando na tabela o valor de z para probabilidade de 0,4750, encontramos $z_{\alpha/2} = 1,96$
5. O intervalo de confiança será dado por:

$$\left(\bar{x} - z_{\alpha/2} \times \sigma_{\bar{x}}\right) < \mu < \left(\bar{x} + z_{\alpha/2} \times \sigma_{\bar{x}}\right)$$

$$\mu = \bar{x} \pm z_{\alpha/2} \times \sigma_{\bar{x}} = \mathbf{3.542 \pm 1,96 \times 23,24}$$

$$\mathbf{3.496,45 < \mu < 3.587,55}$$

A dispersão está inversamente relacionada com a segurança na estimativa. Em geral, conjuntos mais dispersos dão menos segurança do que conjuntos mais concentrados. A amplitude do intervalo de confiança diminuiu como consequência da redução da dispersão populacional, pois esta redução trouxe mais segurança para a estimativa.

A interpretação do significado do intervalo de confiança é alvo constante de equívoco. O intervalo de confiança está correto (1 - α)% das vezes. Isso quer dizer que (1 - α)% das vezes o intervalo calculado conterá o parâmetro. O incorreto é achar que o parâmetro estará dentro do intervalo (1 - α)% das vezes. A diferença dessas duas formas de interpretar o significado do intervalo está em reconhecer onde está a aleatoriedade. O intervalo de confiança é estimado com base na amostra e tem aleatoriedade. O parâmetro populacional (média) é fixo. Portanto, o que varia é o intervalo, e não a média populacional.

2.4.1. Casos da média

É possível usar o roteiro anterior, baseado na distribuição normal, sempre que a população também é normal. Se a população não for normal, ou se não se souber exatamente o seu formato, o roteiro anterior pode ser usado se a amostra for suficientemente grande (costuma-se usar n ≥ 30). Isso está em acordo com o Teorema do Limite Central.

Quando a população não é normal (ou não se sabe o seu formato) e a amostra é pequena, substitui-se o índice z da distribuição normal pelo k da distribuição de Chebyshev. Esse assunto não será aprofundado neste curso, porque raramente são usadas amostras pequenas.

Além disso, o roteiro anterior só pode ser usado quando o desvio-padrão populacional (σ) é conhecido. Veja que geralmente não se sabe de nada sobre a população, então essa situação é muito comum.

Diante do desconhecimento do valor de σ, as seguintes alterações são necessárias no processo de estimação do intervalo de confiança:

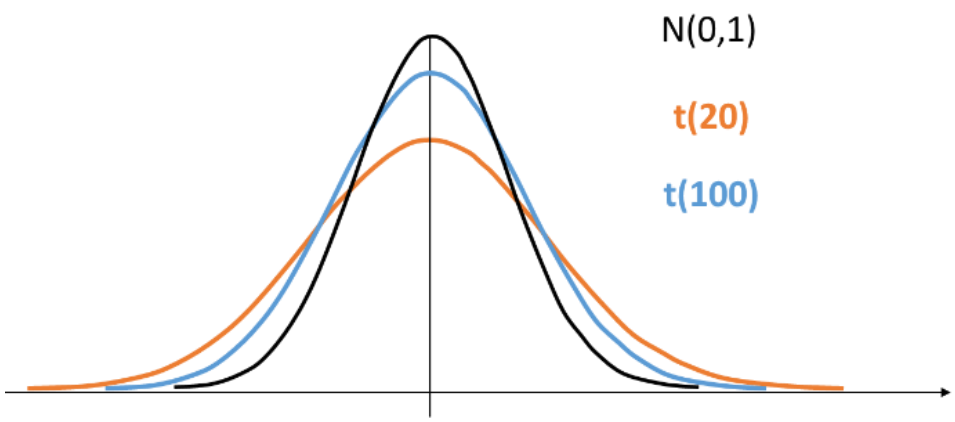
- Na etapa 2, o desvio-padrão amostral s é usado no lugar do desvio-padrão populacional desconhecido σ. E então o erro-padrão é calculado como $s_{\bar{x}} = \frac{s}{\sqrt{n}}$.
- Na etapa 4, usa-se o índice baseado na Distribuição de Student com grau de liberdade (n - 1) para determinar o índice t, em vez do índice z. Então, o intervalo de confiança será dado por $(\bar{x} - t_{\alpha/2} \times s_{\bar{x}}) < \mu < (\bar{x} + t_{\alpha/2} \times s_{\bar{x}})$.

A alteração na etapa 2 é óbvia: na ausência do parâmetro, usa-se a estatística. Entretanto a alteração na etapa 4 não é tão óbvia. Ocorre que, ao utilizarmos o s no lugar do σ, estamos inserindo uma volatilidade na análise, o que gera perda de segurança. Para garantir o mesmo nível de confiança (1 - α)%, torna-se necessário ampliar o intervalo de confiança. As Distribuições de Student foram desenvolvidas com esse propósito:

- Têm formato semelhante ao formato da Distribuição Normal – formato de sino.
- Apesar de ter formato semelhante, as Distribuições de Student são mais amplas, ou seja, têm maior dispersão.
- Consequentemente, os valores que encontramos para t são maiores em termos absolutos que os correspondentes valores de z. E quanto maior o grau de liberdade, mais próximo t se torna de z.

Na **Erro! Fonte de referência não encontrada.** é possível ver como se comportam as distribuições. Veja que, por serem mais dispersas do que a Distribuição Normal, as Distribuições de Student vão gerar valores mais amplos para seus índices, considerando o mesmo nível de confiança.

Figura 7. Distribuição normal e distribuições de Student com 20 e 100 graus de liberdade



A tabela com diversos valores para a distribuição de Student pode ser vista no Anexo 0. A partir do nível de confiança (1 - α)% é possível encontrar o nível de significância α. As colunas da tabela relacionam a significância em uma das caudas, ou seja, $\alpha/2$. Então, para achar o valor de t com 95% de confiança e 50 graus de liberdade, olha-se a coluna 0,025 e a linha de 50 graus de liberdade e se encontra o valor 2,0086.

Tabela 3. Localizando o valor do t crítico

	nível de Significância				
	0,1	0,05	0,025	0,01	0,005
40	1,3031	1,6839	2,0211	2,4233	2,7045
41	1,3025	1,6829	2,0195	2,4208	2,7012
42	1,3020	1,6820	2,0181	2,4185	2,6981
43	1,3016	1,6811	2,0167	2,4163	2,6951
44	1,3011	1,6802	2,0154	2,4141	2,6923
45	1,3006	1,6794	2,0141	2,4121	2,6896
50	1,2987	1,6759	2,0086	2,4033	2,6778

Também é possível usar o Excel para determinar o valor procurado. O Excel tem uma função para usar o nível de significância α inteiro que é **INV.T.BC(α ; g.l.)**. Ou, alternativamente, é possível acionar a função **INV.T(1-α/2 ; g.l.).**

Por exemplo, para achar o valor de t considerando 50 graus de liberdade e um nível de confiança de 95%, é possível fazer =INV.T.BC(0,05; 50) ou então =INV.T(0,975;50).

Exemplo: Deseja-se estimar o gasto médio dos clientes de certa livraria. Sabe-se de outras pesquisas que esses gastos são normalmente distribuídos. Foram coletados os gastos de 15 indivíduos selecionados aleatoriamente e se observou média de R$150,00 e desvio-padrão de R$20,00. Qual a estimativa intervalar para a média salarial da população com 95% de confiança?

Solução:

1. A estimativa pontual já foi calculada: $\bar{x} = 150$
2. O erro-padrão é $$s_{\bar{x}} = \frac{s}{\sqrt{n}} = \frac{20}{\sqrt{15}} = 5{,}16$$
3. De acordo com o solicitado, (1 - α) = 95%
4. **A distribuição adequada é a distribuição de Student, com n – 1 = 14 graus de liberdade. O valor de t é** $\boldsymbol{t_{\alpha/2} = 2{,}1448}$
5. O intervalo de confiança será dado por:

$$(\bar{x} - t_{\alpha/2} \times s_{\bar{x}}) < \mu < (\bar{x} + t_{\alpha/2} \times s_{\bar{x}})$$

$$\mu = \bar{x} \pm z_{\alpha/2} \times \sigma_{\bar{x}} = 150 \pm 2{,}14 \times 5{,}16$$

$$138{,}96 < \mu < 161{,}04$$

Capítulo 3. Estimativa intervalar

Vamos ver como a técnica de estimação intervalar pode ser usada para outras situações além da média aritmética.

3.1. Proporção

Exemplo: Um estudo foi realizado para verificar se as pessoas que ganham na loteria trocam de emprego. Foram enviados questionários para ganhadores de mais do que US$50 mil em loterias. Houve 576 respostas, das quais apenas 63 sinalizaram ter deixado o emprego até um ano depois de ganharem.

Deseja-se estimar o valor de π, a proporção verdadeira (populacional) das pessoas que deixaram o emprego até um ano depois de terem ganhado US$50 mil ou mais na loteria. Isso pode ser feito de duas formas:

1. Estimação pontual: A estimação pontual do parâmetro populacional π é a estatística amostral $p = \frac{x}{n}$.

Sendo x a quantidade de pessoas que trocaram o emprego até um ano depois de ganharem na loteria e n a quantidade de pessoas que responderam ao questionário, é possível calcular:

$$p = \frac{63}{576} = 0{,}1094 = 10{,}94\%$$

2. Estimação Intervalar: Pelo que vimos na distribuição amostral da proporção (veja seção 1.8), para amostras suficientemente grandes, a distribuição amostral de $p = \frac{x}{n}$ é aproximadamente normal com:

- Média: $\mu_p = \pi = \frac{x}{n}$
- Desvio-padrão: $\sigma_p = \sqrt{\frac{\pi(1-\pi)}{n}}$, estimado por $s_p = \sqrt{\frac{p(1-p)}{n}}$

Onde *p* = proporção verdadeira de sucessos da população; x = número de sucessos na amostra; e n = tamanho da amostra.

Assim, seguindo a metodologia descrita na seção 2.3, é possível fazer:

1. A estimativa pontual já foi calculada: $p = \frac{x}{n} = \frac{63}{576} = 0{,}1094$
2. O erro-padrão é $s_p = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0{,}1093 \times (1 - 0{,}1093)}{576}} = 0{,}0130$
3. Considerando (1 - α) = 95%
4. Encontramos $z_{\alpha/2} = 1{,}96$
5. O intervalo de confiança será dado por:

$$(p - z_{\alpha/2} \times \sigma_p) < \pi < (p + z_{\alpha/2} \times \sigma_p)$$

$$\pi = p \pm z_{\alpha/2} \times \sigma_p = 0{,}1094 \pm 1{,}96 \times 0{,}0130$$

$$0{,}0839 < \mu < 0{,}1349$$

Observação: A substituição de π por p no cálculo do erro-padrão é importante no processo amostral, pois o valor de π é desconhecido. Entretanto, isso representa uma aproximação, que só permanece válida enquanto o tamanho da amostra é suficientemente grande. Muitos pesquisadores adotaram a regra de que o tamanho da amostra é suficientemente grande se o intervalo $p \pm 2\sqrt{\frac{p(1-p)}{n}}$ não contiver 0 ou 1.

Para o exemplo que estávamos fazendo:

$$0{,}1094 \pm 2\sqrt{\frac{0{,}1094(1 - 0{,}1094)}{576}} = 0{,}1094 \pm 0{,}0260$$

Então, como o intervalo (0,834 ;0,1354) não contém 0 ou 1, a amostra fica validada, e a aproximação está sob controle.

3.2. Determinando o tamanho da amostra

O tamanho da amostra está diretamente associado ao erro amostral que se está cometendo ao usar um intervalo de confiança. Dessa forma, amostras maiores geram erros menores. Então, na hora de fazer a pesquisa, é conveniente saber quantas observações precisam ser colhidas.

3.2.1. Para estimar a proporção

O intervalo de confiança da proporção que é dado por

$$(p - z_{\alpha/2} \times \sigma_p) < \pi < (p + z_{\alpha/2} \times \sigma_p) \quad \text{ou} \quad \pi = p \pm z_{\alpha/2} \times \sigma_p$$

tem erro amostral máximo dado por

$$e = z_{\alpha/2} \times \sigma_p = z_{\alpha/2} \times \sqrt{\frac{p \times (1-p)}{n}}$$

Ou seja, a distância $|p - \pi|$ é, no máximo, igual a e.

Então, se $e = z_{\alpha/2} \times \sqrt{\frac{p \times (1-p)}{n}}$, resolvendo, encontra-se $n = \left(\frac{z_{\alpha/2}}{e}\right)^2 \times p(1-p)$. Portanto, para um valor desejável de e, é possível calcular o tamanho ideal da amostra, somente se p for conhecido. Quando p não é conhecido, é possível usar p = 0,5 como uma escolha conservadora (p = 0,5 maximiza o valor de n). Então, estima-se o tamanho ideal da amostra fazendo:

$$n = \left(\frac{z_{\alpha/2}}{e}\right)^2 \times 0{,}25$$

O valor encontrado deve ser arredondado para cima.

Exemplo: O Ibope vai realizar uma pesquisa eleitoral e deseja, com 95% de confiança, respostas com margem de erro de, no máximo 2 pontos percentuais. Quantas pessoas devem ser pesquisadas?

Solução: De acordo com o enunciado, a margem de erro desejada é e = 0,02.Então:

$$n = \left(\frac{z_{\alpha/2}}{e}\right)^2 \times 0{,}25 = \left(\frac{1{,}96}{0{,}02}\right)^2 \times 0{,}25 = 2.401$$

Ou seja, o Ibope precisa consultar apenas 2.401 pessoas para ter uma margem de erro de no máximo 2 pontos percentuais.

3.2.2. Para estimar a média

O intervalo de confiança da média que é dado por

$$\left(\bar{X} - z_{\alpha/2} \times \sigma_{\bar{X}}\right) < \mu < \left(\bar{X} + z_{\alpha/2} \times \sigma_{\bar{X}}\right) \text{ ou } \mu = \bar{X} \pm z_{\alpha/2} \times \sigma_{\bar{X}}$$

tem como erro amostral máximo dado por

$$e = z_{\alpha/2} \times \sigma_{\bar{X}} = z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}}$$

que, resolvendo, se encontra

$$n = \left(\frac{z_{\alpha/2} \times \sigma}{e}\right)^2 .$$

Portanto, para um valor desejável de e, é possível calcular o tamanho ideal da amostra, somente se σ for conhecido. Quando não for possível fazer qualquer suposição sobre σ, será necessário realizar uma amostragem piloto para ter uma primeira estimativa. O valor encontrado para n deve ser arredondado para cima.

Exemplo: Uma empresa precisa estimar o ticket médio das suas vendas diárias, e vai construir uma estimativa intervalar. A estimativa será feita com 95% de confiança e deseja-se que o erro seja de, no máximo, R$5,00. Para determinar o tamanho ideal da amostra, foi feita uma estimativa de s = R$20,00.

Solução: Aplicando a fórmula, $n = \left(\frac{z_{\alpha/2} \times \sigma}{e}\right)^2 = \left(\frac{1{,}96 \times 20}{5}\right)^2 =$ 61,47.

Arredondando para cima, a amostra deve ter pelo menos 62 observações.

3.3. Total da população

Total é o indicador de soma. O total é a soma de todos os valores do conjunto:

$$T = \sum X_i$$

É um indicador muito usado em auditoria.

A estimativa pontual do total pode ser feita a partir da média amostral, fazendo:

$$T = N \times \bar{X}$$

E a estimativa intervalar pode ser feita a partir da estimativa intervalar da média amostral:

$$T = N \times \bar{X} \pm N \times t_{\alpha/2} \times \frac{s}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

Onde $\sqrt{\frac{N-n}{N-1}}$ é o fator de correção necessário para populações finitas e amostragem sem reposição. Lembrando que ele pode ser suprimido sempre que n ≤ 0,05N.

Exemplo: Um auditor verifica que foram emitidos 1.500 recibos e deseja estimar o valor total desses recibos. Uma amostra de 80 recibos é selecionada com os seguintes resultados:

- Média = R$1.050,27
- Desvio-padrão = R$237,26

Estimar o valor total destes 1.500 recibos com 95% de confiança.

Solução: Aplicando o procedimento,

1. A estimativa pontual é: $T = N \times \bar{X} = 1.500 \times 1.050{,}27 = 1.575.405$

2. O erro-padrão é

$$N \times \frac{s}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}} = \frac{237{,}26}{\sqrt{80}} \times \sqrt{\frac{1500-80}{1500-1}} = 38.727{,}03$$

3. Considerando (1 – α) = 95%

4. Com 79 graus de liberdade, encontramos $t_{\alpha/2} = 1{,}9905$

5. O intervalo de confiança será dado por:

$$N \times \bar{X} \pm N \times t_{\alpha/2} \times \frac{s}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

$$= 1.575.405 \pm 1{,}9905 \times 38.727{,}03$$

$$= 1.575.405 \pm 77.086{,}15$$

$$1.498.318{,}85 < T < 1.652.491{,}15$$

3.4. Total da diferença

O total da diferença, ou diferença total, é um indicador muito usado em auditoria, ou seja, na análise dos registros históricos para validação das atividades das organizações. Esse indicador é construído a partir da diferença entre o valor efetivamente observado e o valor que deveria ter ficado registrado. O total da diferença é a soma de todas as diferenças do conjunto:

$$T_D = \sum D_i$$

A estimativa pontual do total pode ser feita a partir da média amostral, fazendo:

$$T_D = N \times \bar{D}$$

E a estimativa intervalar pode ser feita a partir da estimativa intervalar da média amostral:

$$T_D = N \times \bar{D} \pm N \times t_{\alpha/2} \times \frac{s_D}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

Onde o fator de correção $\sqrt{\frac{N-n}{N-1}}$ se faz necessário, pois a populações é finita e a amostragem é feita sem reposição. Lembrando que ele pode ser suprimido sempre que n ≤ 0,05N.

Exemplo: Um auditor observa que, dentro de uma amostra de 50 relatórios de vendas, 14 apresentam erro. Ele observou a diferença entre o valor relatado e o que fora efetivamente vendido para toda a amostra, e os dados são:

- Média = 13,8068
- Desvio-padrão = 37,427

O auditor deseja estimar um intervalo de confiança de 95% para o total da diferença de uma população de 1.000 relatórios.

Solução: Aplicando o procedimento,

1. A estimativa pontual é: $T = N \times \bar{D} = 1.000 \times 13{,}8068 = 13.806{,}80$
2. O erro-padrão é $\frac{s_D}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}} = \frac{37{,}427}{\sqrt{50}} \times \sqrt{\frac{1.000-50}{1.000-1}} = 5.161{,}54$
3. Considerando (1 - α) = 95%
4. Com 49 graus de liberdade, encontramos $t_{\alpha/2} = 2{,}0096$
5. O intervalo de confiança será dado por:

$$N \times \bar{D} \pm N \times t_{\alpha/2} \times \frac{s_D}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}$$

$$= 13.806{,}80 \pm 1{,}9905 \times 5.161{,}54$$

$$= 13.806{,}80 \pm 10.372{,}50$$

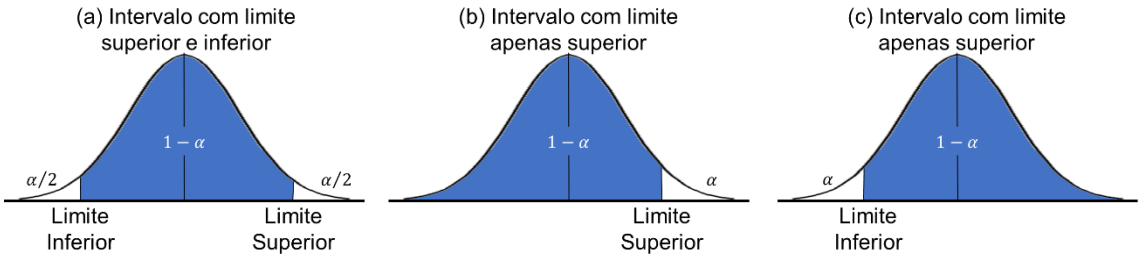
$$3.434{,}30 < D < 24.179{,}30$$

3.5. Intervalo de confiança unilateral

Os intervalos de confiança que construímos até agora eram todos bilaterais, no sentido de que estabeleciam limites inferior e superior para o parâmetro sob estudo. Dessa forma, a região de confiança ficava centralizada, com metade da significância (o complemento) de cada lado.

Entretanto, em algumas situações é necessário usar um intervalo unilateral, ou seja, com apenas um limite, podendo ser superior ou inferior. Nesses casos, a região de confiança ficará de um lado, e a significância, concentrada do outro lado. Na **Erro! Fonte de referência não encontrada.**8, é possível ver os tipos de intervalo.

Figura 8. Intervalos bilateral e unilaterais



A estimativa do limite unilateral é feita concentrando a significância, de forma que, em vez de se usar $z_{\alpha/2}$, usa-se z_{α}, e, em vez de usar $t_{\alpha/2}$, usa-se t_{α}.

Exemplo: Em certa empresa, as contas só devem ser pagas quando a fatura é gerada por um supervisor. A taxa de exceção tolerável a esse controle é de 4%.

No ano passado foram efetuados 1 milhão de pagamentos. Uma auditoria analisou 400 casos de pagamentos e observou oito situações em que o pagamento foi feito sem uma fatura gerada.

Como a proporção pode ser estimada por intervalo?

Solução: Se a quantidade de pagamentos efetuados sem a fatura gerada representar menos do que 4%, não haverá problema de conformidade. Por isso, é importante sondar apenas o limite superior.

Aplicando o procedimento,

1. A estimativa pontual da proporção é: $p = \frac{x}{n} = \frac{8}{400} = 0{,}02$
2. O erro-padrão é $\sqrt{\frac{p(1-p)}{n}} \times \sqrt{\frac{N-n}{N-1}} = \sqrt{\frac{0{,}02 \times 0{,}98}{400}} \times \sqrt{\frac{1.000.000-400}{1.000.000-1}} = 0{,}0070$
3. Considerando (1 - α) = 95%
4. Encontramos $z_{\alpha} = 1{,}6449$

5. O limite superior será dado por:

$$p + z_{\alpha} \times \sqrt{\frac{p(1-p)}{n}} \times \sqrt{\frac{N-n}{N-1}}$$

$$= 0{,}02 + 1{,}6449 \times 0{,}0070$$

$$= 0{,}02 + 0{,}0115$$

$$\pi < 0{,}0315$$

Capítulo 4. A inferência através do teste de hipóteses

Uma propaganda de veículos informava que determinado modelo tinha um aproveitamento médio de 12km/l de combustível.

Do ponto de vista estatístico, essa afirmação representa uma hipótese sobre um parâmetro populacional – nesse caso, a média. Isso não quer dizer que todos os carros têm aproveitamento igual a 12km/l. É esperado que alguns carros tenham aproveitamento maior que 12km/l e outros tenham aproveitamento menor que 12km/l. Com isso, a média deve ser igual a 12km/l.

Portanto, se considerarmos uma amostra e verificarmos um aproveitamento médio amostral igual a 9km/l, não necessariamente poderemos garantir que a propaganda foi enganosa. Por outro lado, ainda que encontremos a média amostral igual a 12km/l, não será possível garantir que a população também tenha média igual a 12km/l.

A variabilidade amostral vai gerar uma estatística que provavelmente é diferente do parâmetro. Entretanto, de acordo com o Teorema do Limite Central, dentro de certas condições, é possível analisar essa diferença à luz da distribuição amostral do parâmetro.

4.1. Hipóteses do teste

Em termos estatísticos, uma hipótese é definida como uma afirmação sobre o valor numérico de um *parâmetro* populacional. Num teste de hipótese, são consideradas duas hipóteses complementares:

Hipótese nula (H_0):

- Geralmente é aquela contra a qual buscamos evidências.
- Tem o sinal de igualdade.

Hipótese alternativa (H_1 ou H_a):

- Geralmente é aquela a favor da qual buscamos evidências.
- Não tem o sinal de igualdade.

O procedimento estatístico de testar a hipótese parte da suposição de que a hipótese nula é verdadeira. A hipótese alternativa é a afirmação complementar à afirmação nula, ou seja, é válida sempre quando a hipótese nula não é verdadeira. Voltando ao exemplo da propaganda do veículo com aproveitamento médio de 12 km/l, formulam-se H_0 e H_1:

- H_0: $\mu = 12$ km/l.
- H_1: $\mu \neq 12$ km/l.

Se o aproveitamento for maior do que o anunciado, então o consumidor é beneficiado. Mas, se o aproveitamento for menor do que o anunciado, então o consumidor é prejudicado. Entretanto, da forma como estão enunciadas as hipóteses, não será possível definir se a autonomia é maior ou menor do que a anunciada. Será testada apenas a possibilidade de o aproveitamento médio ser diferente dos 12 km/l anunciados (e, por diferente, entende-se maior ou menor, indiferentemente). Veremos posteriormente que é possível fazer o teste de hipóteses de forma a isolar o lado sendo testado (se maior ou menor).

4.2. Erros no teste de hipóteses

O teste de hipóteses é um procedimento de inferência, o que significa que trabalhamos com incerteza. Para termos 100% de certeza, seria necessário analisar toda a população. Portanto, o resultado final do teste pode ser correto ou errado.

Na Tabela , é possível ver os quatro diferentes resultados do teste de hipóteses. As duas colunas da tabela retratam como pode ser a população. Muitas vezes chamados de estado da natureza, a verdade sobre a população não pode ser determinada previamente, pois a população é desconhecida. Apesar de não ser possível determinar com certeza exata, sabe-se que a hipótese nula H_0 pode ser verdadeira ou falsa, que são, respectivamente, as situações das colunas da tabela. No exemplo do anúncio do automóvel, H_0 ser verdadeiro quer dizer que a autonomia média é exatamente igual a 12km/l. H_0 ser falso quer dizer que a autonomia média é qualquer valor diferente de 12km/l.

As decisões que podem ser tomadas no teste de hipóteses estão relatadas nas linhas da Tabela 4. É possível decidir que H_0 não deve ser rejeitada, como está

na primeira linha, ou que H_0 deve ser rejeitada, como está na segunda linha. Então, comparando a decisão com os possíveis estados da natureza, tem-se a possibilidade de tomar uma decisão correta ou cometer um erro.

Tabela 4. Tipos de erro no teste de hipóteses

Resultado	**H_0 é verdadeira**	**H_0 é falsa**
Não Rejeita H_0	Decisão Correta	Erro Tipo II
Rejeita H_0	Erro Tipo I	Decisão Correta

Assim, a decisão baseada em amostras nos expõe a erros, que podem ser de dois tipos:

- **Erro Tipo I:** Rejeitarmos a hipótese formulada sendo ela verdadeira.
- **Erro Tipo II:** Não rejeitarmos (ou seja, aceitarmos) a hipótese formulada sendo ela falsa.

Sobre o anúncio de que o aproveitamento médio é de 12 km/l, deve-se considerar:

- H_0: $\mu = 12$ km/l.
- H_1: $\mu \neq 12$ km/l.

Temos:

- **Erro Tipo I:** o aproveitamento médio verdadeiro (populacional) é 12 km/l, e a análise amostral nos leva a concluir que é diferente – maior ou menor do que 12 km/l.
- **Erro Tipo II:** o aproveitamento médio verdadeiro não é 12 km/l (é maior ou menor), mas a análise amostral não nos permitiu concluir isso, por isso acabamos aceitando essa hipótese como possível.

4.3. Metodologias para teste de hipóteses

Há três metodologias para conduzir um teste de hipóteses:

- **Intervalo de confiança:** a partir da estimativa intervalar do parâmetro sendo testado, é possível verificar a hipótese nula.

- **Estatística de teste:** transforma os valores envolvidos em estatísticas de teste – por exemplo, valores da distribuição normal padrão, que são comparados com valores críticos, predefinidos para o teste.
- **Valor-P:** a partir da distribuição amostral da estatística de teste, pode-se determinar as probabilidades associadas, que são comparadas com níveis críticos, predefinidos para o teste.

Vamos examinar o princípio de funcionamento desses casos a partir do seguinte exemplo:

Exemplo: Para avaliar o anúncio que dizia que o aproveitamento do combustível médio de certa marca de veículos é de 12 km/l, foi feita uma amostra aleatória de 64 veículos desta marca. Analisando a amostra, descobriu-se média igual a 11,5 km/l e desvio-padrão igual a 1,5km/l.

4.3.1. Testando pelo intervalo de confiança

Começamos estimando o intervalo de confiança. Vamos analisar com 95% de confiança (ou seja, nível de confiança igual a $\alpha = 0{,}05$). Nesse nível de confiança, e com 63 graus de liberdade, encontramos $t_{\alpha/2} = 1{,}9983$. Então, $\mu = 11{,}5 \pm 1{,}9983 \times \frac{1{,}5}{\sqrt{64}}$. Ou seja:

$$11{,}13 < \mu < 11{,}87$$

Analisando o intervalo de confiança, vemos que o valor anunciado de 12km/l não está contido no intervalo. Como esse é o intervalo de valores que acreditamos conter a média populacional, conclui-se que a hipótese $H_0: \mu = 12km/l$ deve ser rejeitada.

Conclusão: Rejeita H_0.

Realizar o teste de hipóteses através do intervalo de confiança é muito intuitivo, mas nem sempre vai funcionar. O intervalo não funcionará quando for necessário testar hipóteses unilaterais, ou seja, quando for importante discernir entre ser maior ou menor. Além disso, o cálculo do intervalo de confiança envolve

determinar os dois extremos. O procedimento baseado na estatística de teste, descrito a seguir, requer apenas o cálculo de um único valor. Além disso, a estatística de teste calculada não depende do nível de significância, sendo possível usar o mesmo valor calculado para realizar testes com diferentes níveis de significância. O intervalo de confiança, ao contrário, é específico para o nível de significância (que, por sua vez, representa um nível de confiança específico).

4.3.2. Estatística de teste

A metodologia baseada em estatística de teste se concentra na diferença entre a estatística amostral e o parâmetro populacional hipotético. A hipótese nula do teste bilateral sugere que a diferença não seja muito grande. Conforme veremos, essa diferença é medida em termos relativos, de acordo com a dispersão da amostra, e comparada com um valor limite, de acordo com o nível de significância adotado.

Voltando ao exemplo do anúncio que dizia que o aproveitamento era de 12 km/l e que se descobriu média igual a 11,5 km/l e desvio-padrão igual a 1,5km/l em uma amostra de 64 veículos da marca, formulamos as hipóteses:

$$\begin{cases} H_0: \mu = 12\text{km/l} \\ H_1: \mu \neq 12\text{km/l} \end{cases}$$

E a partir dos dados amostrais tínhamos:

$$n = 64 \text{ , } s = 1{,}5\text{km/l} \text{ , } s_{\bar{x}} = \frac{s}{\sqrt{n}} = 0{,}1875$$

Assim, medimos a distância, em valores reais do aproveitamento de combustível:

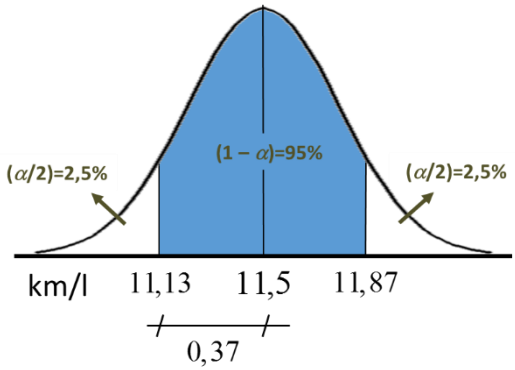
$$\bar{X} - \mu = -0{,}5\text{km/l} \text{ .}$$

O valor real de 0,5km/l sugere que a distância é pequena, mas o raciocínio estatístico não toma decisão com base apenas no valor real da diferença. Construímos anteriormente o intervalo de confiança para a média amostral, e obtivemos o seguinte resultado:

$$11{,}13 < \mu < 11{,}87$$

Esse resultado pode ser interpretado graficamente como está na **Erro! Fonte de referência não encontrada.**9.

Figura 9. Valores esperados para a média populacional



Interpretando o intervalo de confiança em termos de distâncias, é esperado que a distância entre a média populacional e a média amostral seja de, no máximo, 0,37. Portanto o valor 0,5 de distância é grande!

A forma mais adequada de determinar se a medida é grande ou pequena é relativizando a distância pela dispersão:

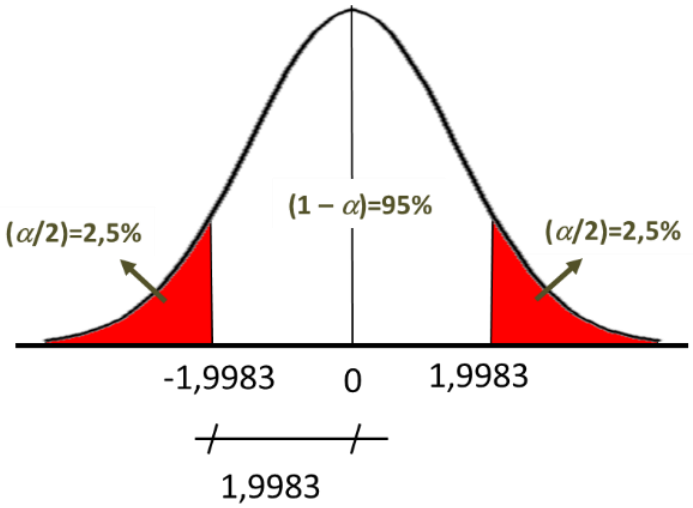
$$\frac{\bar{X} - \mu}{s_{\bar{X}}} = -\frac{0{,}5}{0{,}1875} = -2{,}87$$

A medida relativizada pela dispersão dessa forma está em unidades-padrão e não tem medida: são 2,87 unidades-padrão, não são medidas em km/l. Esses valores seguem a distribuição de Student e podem ser comparados com os níveis críticos da distribuição.

Na **Erro! Fonte de referência não encontrada.**0 é possível ver a região que compreende os valores esperados dentro da distribuição de Student. Dessa forma, pode-se concluir que a distância entre a média amostral e o valor hipotético para a média populacional é grande se a estatística de teste for maior que 1,9983 ou menor do que -1,9983. Dizemos que essa é a região de rejeição e costumamos indicar assim:

Rejeita-se H_0 se $|t| > t_{\alpha/2}$

Figura 80. Região de rejeição com base nos valores padronizados



Para conduzir o teste de hipóteses usando a estatística de teste, basta seguir as seguintes etapas:

1. Formule a hipótese nula (H_0) e a hipótese alternativa (H_1).
2. Determine o nível de significância α.
3. Identifique a estatística de teste adequada.
4. Defina o tamanho amostral *n* e obtenha uma amostra aleatória da população de interesse.
5. Especifique a região de rejeição (determinada em função do nível de significância do teste *a* e, eventualmente, de algumas características amostrais).
6. A partir da amostra, determine os valores da estatística de teste.
7. Tome a decisão (**rejeitar** ou **não rejeitar** H_0).

Para o exemplo em questão, as etapas são seguidas da seguinte forma:

1. São $\begin{cases} H_0: \mu = 12\text{km/l} \\ H_1: \mu \neq 12\text{km/l} \end{cases}$.
2. Seguiremos com $\alpha = 0{,}05$.
3. Como o desvio-padrão é desconhecido, usaremos a distribuição t de Student. Então, $t_{teste} = \frac{\bar{X} - \mu}{s_{\bar{X}}}$.
4. A amostra foi obtida com $n = 64$, $\bar{X} = 11{,}5$ e $s = 1{,}5$.
5. Como $t_{\alpha/2} = 1{,}9983$, então deve-se rejeitar H_0 se $|t_{teste}| > 1{,}9983$, ou seja, t_{teste}<-1,9983 ou se t_{teste}>1,9983.
6. $t_{teste} = \frac{11{,}5 - 12}{0{,}1875} = -2{,}67$.
7. Decisão: **rejeita-se H_0**.

4.3.3. Metodologia do valor-P

A terceira maneira de analisar as hipóteses sob teste se concentra em comparar a área definida pelo valor da estatística de teste (chamada de Valor-P) e o tamanho do nível de significância (α).

O Valor-P pode ser interpretado como uma probabilidade associada a H_0. Portanto, valores pequenos do Valor-P (menores do que α) sugerem a rejeição de H_0. Na **Erro! Fonte de referência não encontrada.**1, é possível ver o formato dessa área para o teste em questão. Cada área (vermelha) tem tamanho 0,0038, então Valor-P = 0,0076. Sendo Valor-P pequeno, pois é menor do que α = 0,05, então H_0 : μ = 12 km/l é rejeitada. No Excel, a área à esquerda é obtida fazendo:

= DIST.T(-2,67;63;1)

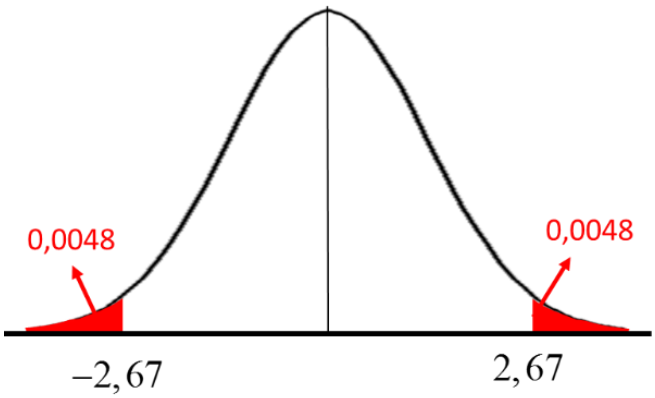
Para encontrar a área à direita bastaria fazer:

= DIST.T.CD(2,67;63)

Para encontrar o valor-P total, bastaria somar os dois valores acima, ou multiplicar um deles por 2. Ou, diretamente do Excel, pode-se fazer:

= DIST.T.BC(2,67;63)

Figura 91. Valor-P: área definida pelo valor da estatística de teste



Valor-P=2x0,0048=0,0096

4.3.4. Comparando as metodologias de teste

As metodologias podem ser mais adequadas em uma situação ou outra, mas é importante manter em mente que sempre que for usado o mesmo nível de significância (ou confiança equivalente), as conclusões serão as mesmas. Ou seja, mudar a metodologia não muda a decisão.

As regras de decisão pela rejeição da hipótese nula H_0 são as seguintes:

- **Intervalo de confiança:** quando o valor populacional da hipótese nula não está no intervalo de confiança.
- **Estatística de teste**: quando a estatística obtida em módulo é maior do que o valor crítico da distribuição amostral escolhida. Se for a distribuição normal é $|Z_{teste}| > Z_{\alpha/2}$; se for a distribuição de Student é $|t_{teste}| > t_{\alpha/2}$.
- **Valor-P**: quando o Valor-P é menor do que o nível de significância, ou seja, Valor-P < α.

4.4. Nível de significância e decisão estatística

Dissemos anteriormente que o nível de significância do teste estatístico está diretamente relacionado com a hipótese nula do teste. Na verdade, o nível de significância é um controle para a probabilidade de ocorrência do Erro Tipo I.

A Tabela **5**5 amplia o conteúdo da Tabela 4 declarando as probabilidades de ocorrência dos Erros Tipo I e II. É possível ver que a probabilidade de ocorrência do Erro Tipo I é α, o nível de significância do teste, e que a probabilidade de ocorrência do Erro Tipo II é β.

Tabela 5. Controle das probabilidades no teste de hipóteses

Resultado	**Situação real**	
	H_0 é verdadeira	**H_0 é falsa**
Não rejeita H_0	Decisão correta Confiança = $(1-\alpha)$ %	**Erro Tipo II** P = β %
Rejeita H_0	**Erro Tipo I** Significância = α %	Decisão correta Eficácia = $(1-\beta)$ %

O teste de hipóteses controla apenas o risco de se cometer o Erro Tipo I, porque esse erro é considerado mais grave. O teste parte da suposição de que H_0 é verdadeira e busca evidências que comprovem que não é. Essas evidências precisam ser fortes o bastante para que a decisão estatística seja de rejeitar H_0; do contrário, a decisão é não rejeitar H_0.

Para entender melhor a lógica do teste de hipóteses, é possível comparar o processo decisório estatístico a um tribunal, onde há um réu acusado se defendendo da acusação. Nesse tribunal, o réu é inocente até que se prove o contrário. Ou seja, é necessário coletar evidências fortes o bastante para rejeitar a hipótese presumida de inocência. Assim, teríamos: H_0: o réu é inocente; e H_1: o réu é culpado.

4.5. Teste unilateral

O teste unilateral ocorre quando a hipótese alternativa especifica se o parâmetro é maior ou menor do que o valor.

Voltando ao exemplo do anúncio que dizia que o aproveitamento era de 12 km/l e que se descobriu média igual a 11,5 km/l e desvio-padrão de 1,5km/l numa amostra de 64 veículos da marca.

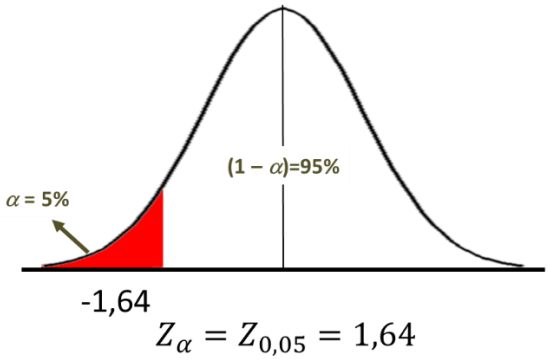
Entendendo agora que, se o aproveitamento for maior do que 12km/l não haverá prejuízo para o consumidor, formulamos as hipóteses por um teste unilateral:

$$\begin{cases} H_0: \mu \geq 12\text{km/l} \\ H_1: \mu < 12\text{km/l} \end{cases}$$

Nota-se que a hipótese alternativa está relacionada com apenas um lado do teste, neste caso, o esquerdo. A forma como a hipótese nula é anunciada em um teste de hipóteses unilateral não é importante, mas alguns autores permanecem com o sinal de igualdade. Assim, o teste acima seria o mesmo se a hipótese nula estivesse descrita da seguinte maneira: H_0: μ = 12km/l.

Por isso a região de rejeição está em apenas um lado, com a área total da significância, como pode ser visto na **Erro! Fonte de referência não encontrada.**.

Figura 102. Região de rejeição para um teste unilateral com α = 0,05



Na hora de selecionar a metodologia usada para realizar o teste, é importante atentar que os testes unilaterais requerem o nível de significância inteiro, em vez de dividir pela metade. Assim, se a metodologia é pelo intervalo de confiança, é importante considerar o intervalo unilateral. Se a metodologia é pela estatística de teste, deve-se comparar com o valor crítico Z_α ou t_α, e, neste caso, se o sinal de H_1 é <, então rejeita-se H_0 quando $t_{teste} < -t_\alpha$. Porém, se o sinal de H_1 é >, então rejeita-se H_0 quando $t_{teste} > t_\alpha$.

Voltando ao exemplo, e aplicando a metodologia da estatística de teste:

1. São $\begin{cases} H_0: \mu \geq 12\text{km/l} \\ H_1: \mu < 12\text{km/l} \end{cases}$.
2. Seguiremos com α = 0,05.
3. Como o desvio-padrão é desconhecido, usaremos a distribuição t de Student, e então $t_{teste} = \dfrac{\bar{X} - \mu}{s_{\bar{X}}}$.
4. A amostra foi obtida com n = 64: $\bar{X} = 11{,}5$ e s = 1,5.
5. Como o sinal de H_1 é <, deve-se rejeitar H_0 se $t_{teste} < -t_\alpha$. Ou seja, $t_{teste} < -1{,}64$.

6. $t_{teste} = \frac{11,5 - 12}{0,1875} = -2,67.$

7. Decisão: **Rejeita-se H_0**.

Capítulo 5. Teste de hipóteses: casos

Para conduzir um teste de hipóteses, alguns elementos precisam ser observados. São eles:

- O teste é unilateral ou bilateral?
- Como as hipóteses são formuladas?
- Qual é a estatística de teste e como pode ser calculada?
- Qual a região de rejeição, a partir do nível de confiança estipulado?

Nos próximos capítulos essas perguntas serão sistematizadas em fichas para cada um dos testes apresentados. Essas fichas são, portanto, o resumo para o plano de execução dos testes.

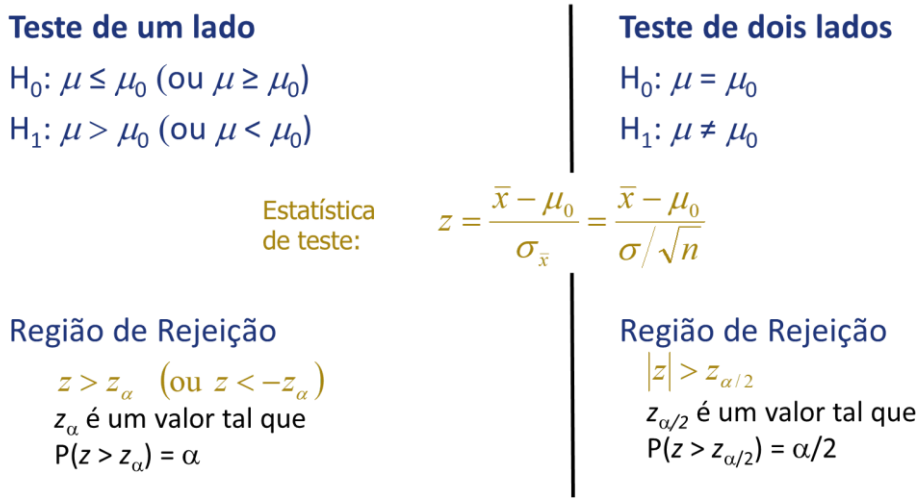
5.1. Os casos da média

Vamos sistematizar o teste de hipóteses da média em dois casos distintos. Para ambos, supõe-se que a população que originou a amostra tem distribuição normal ou a amostra é suficientemente grande (n ≥ 30). A diferença entre os casos é o conhecimento do valor do desvio-padrão populacional:

- Quando o desvio-padrão populacional é conhecido (tem-se σ), é possível calcular $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ e usa-se a distribuição normal para realizar o teste.
- Quando o desvio-padrão populacional não é conhecido (não se tem σ), é necessário calcular $s_{\bar{X}} = \frac{s}{\sqrt{n}}$ e usa-se a distribuição de Student com n – 1 graus de liberdade.

5.1.1. Desvio-padrão populacional conhecido

Figura 113. σ conhecido



Exemplo: O tempo médio de secagem de um certo tipo de pintura é normalmente distribuído com média de 75 minutos e desvio-padrão de 9 minutos. Químicos propuseram um novo aditivo que reduziria o tempo médio de secagem, sem alterar os demais parâmetros dos tempos de secagem. Foi observado o processo de secagem em 25 diferentes testes com o novo aditivo, e observou-se um tempo médio de 65 minutos.

Em função do elevado custo do novo aditivo, é necessário buscar evidências fortes de que o tempo reduziu mais que 10%. Qual deve ser a orientação estatística para a decisão?

Solução: A redução necessária de 10% implica que o tempo médio de secagem deve ser menor do que 67,5. A amostra é pequena (n < 30), mas a população é normal. Assim, aplica-se o teste de hipóteses:

1. $\begin{cases} H_0: \mu \geq 67{,}5 \\ H_1: \mu < 67{,}5 \end{cases}$
2. $\alpha = 0{,}05$
3. $Z_{teste} = \frac{\bar{X} - \mu}{\sigma_{\bar{X}}}$
4. n = 25, $\bar{X} = 65$ e σ = 9

5. Rejeita H_0 se $Z_{teste} < -1{,}64$

6. $$Z_{teste} = \frac{65 - 67{,}5}{9 / \sqrt{25}} = -1{,}39$$

7. Decisão: não rejeita H_0.

Como não se rejeita H_0, não temos evidências fortes o bastante de que o aditivo reduziu em pelo menos 10% o tempo de secagem. O valor-P para esse teste pode ser calculado e é Valor-P=0,0823.

5.1.2. Desvio-padrão populacional desconhecido

Figura 124. σ desconhecido

Teste de um lado	**Teste de dois lados**
$H_0: \mu \leq \mu_0$ (ou $\mu \geq \mu_0$)	$H_0: \mu = \mu_0$
$H_1: \mu > \mu_0$ (ou $\mu < \mu_0$)	$H_1: \mu \neq \mu_0$
Estatística de teste: $t = \frac{\bar{x} - \mu_0}{s_{\bar{x}}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$	
Região de Rejeição $t > t_\alpha \quad (t < -t_\alpha)$ t_α é baseada em uma distribuição com n -1 graus de liberdade, e é um valor tal que $P(t > t_\alpha) = \alpha$	Região de Rejeição $\lvert t \rvert > t_{\alpha/2}$ $t_{\alpha/2}$ baseada em uma distribuição com n -1 graus de liberdade, e é um valor tal que $P(t > t_{\alpha/2}) = \alpha/2$

Exemplo: A quantidade desejada de sílica (SiO2) em certo tipo de cimento é 10ppu (partes por unidade). Para controle de qualidade, a indústria de cimento fez um teste com 64 amostras independentes e aleatórias, que apontou média de 9ppu e desvio-padrão de 3,6ppu. Nada é sabido sobre a população.

Solução: Apesar de não se conhecer nada sobre a população, a amostra é suficientemente grande (n > 30). Assim, aplica-se o teste de hipóteses:

1. $$\begin{cases} H_0: \mu = 10 \\ H_1: \mu \neq 10 \end{cases}$$

2. $\alpha = 0{,}05$
3. $t_{teste} = \dfrac{\bar{X} - \mu}{s_{\bar{X}}}$
4. n = 64, $\bar{X} = 9$ e s = 3,6
5. Rejeita H_0 se $|t_{teste}| > 2{,}00$
6. $t_{teste} = \dfrac{9 - 10}{3{,}6 / \sqrt{64}} = -2{,}22$
7. Decisão: Rejeita H_0.

Como H_0 é rejeitada, temos evidências fortes o bastante de que a quantidade de sílica não é 10ppu. O valor-P para esse teste pode ser calculado e é Valor-P = 0,03.

5.2. O caso da proporção

Figura 135. Teste de hipóteses da proporção

Teste de dois Lados	**Teste de um Lado**
$H_0: \pi = \pi_0$	$H_0: \pi = \pi_0$
$H_1: \pi \neq \pi_0$	$H_1: \pi > \pi_0$ (ou $\pi < \pi_0$)
Estatística de teste: $z = \dfrac{p - \pi_0}{\sqrt{\pi_0(1-\pi_0)/n}}$	
Região de Rejeição	Região de Rejeição
$\lvert z \rvert > z_{\alpha/2}$	$z > z_\alpha \quad (z < -z_\alpha)$

$p = x/n$ = proporção amostral de sucessos;
Suposição: O tamanho da amostra n é suficientemente grande de modo que o intervalo $p \pm 2\sqrt{p(1-p)/n}$ não contenha 0 nem 1.

Exemplo: O programa de pontuação de um cartão de crédito é rentável para a operadora se até 15% dos usuários resgatarem seus pontos. Portanto, se mais

de 15% dos clientes resgatarem os pontos, o programa precisa ser reestruturado.

É necessário reestruturar o programa se, feita uma amostragem com 500 clientes, foi verificado que 85 clientes resgataram os pontos?

Solução: A amostra aponta para uma proporção de $p = \frac{X}{n} = \frac{85}{500} = 0{,}17$, ou seja, 17% dos clientes amostrados fizeram o resgate. Se a decisão for tomada com base no valor amostral, o programa deve ser reestruturado. Entretanto a decisão deve ser tomada com base no valor populacional.

O teste de hipóteses vai ajudar a avaliar se há evidências suficientes para que seja feita a reestruturação do programa. Mas para realizar o teste é necessário ver se a amostra é grande o bastante. $p \pm 2\sqrt{\frac{p(1-p)}{n}} = 0{,}17 \pm 2\sqrt{\frac{0{,}17 \times 0{,}83}{500}}$
dá o intervalo (0,1364 ;0,2036), que não contém 0 nem 1. Portanto o teste pode ser aplicado. Assim, segue-se a metodologia:

1. $\begin{cases} H_0: \pi \leq 0{,}15 \\ H_1: \pi > 0{,}15 \end{cases}$.
2. $\alpha = 0{,}05$.
3. $Z_{teste} = \frac{p - 0{,}15}{\sigma_p}$, onde $\sigma_p = \sqrt{\frac{\pi_0(1-\pi_0)}{n}}$.
4. n = 64, $\bar{X} = 9$ e s = 3,6.
5. Rejeita H_0 se $Z_{teste} > Z_{0{,}05}$, ou seja, $Z_{teste} > 1{,}645$.
6. $Z_{teste} = \frac{0{,}17 - 0{,}15}{\sqrt{\frac{0{,}15 \times 0{,}85}{500}}} = \frac{0{,}02}{0{,}0160} = 1{,}25$.
7. Decisão: Não rejeita H_0.

A não rejeição de H_0 quer dizer que não há evidências suficientes para sinalizar que o programa esteja com problemas de rentabilidade. Não há evidências de que o programa precise ser reestruturado.

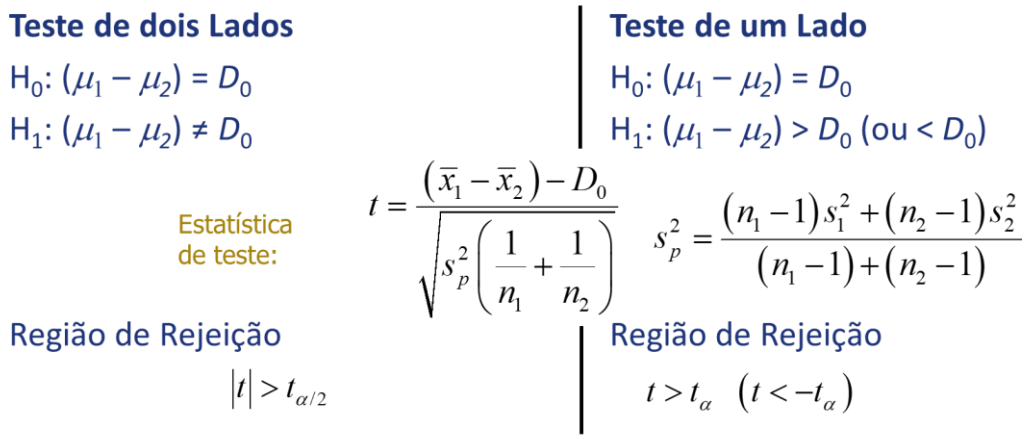
5.3. Os casos da diferença das médias

Às vezes, a inferência feita envolve mais de uma população. É o caso de quando se deseja comparar cenários diferentes, momentos diferentes etc. A pergunta subjacente ao teste é como as médias dessas populações se relacionam umas com as outras.

O procedimento só pode ser aplicado quando as populações são normais e com a mesma variância. Nesse caso, para determinar o melhor estimador para a variância populacional, usa-se uma variância agrupada, que pondera as variâncias amostrais de cada uma das amostras. A ficha com os elementos necessários para fazer o teste está na **Erro! Fonte de referência não encontrada.**6. São considerados os seguintes elementos:

- μ_1: média populacional da 1ª população
- μ_2: média populacional da 2ª população
- D_0: diferença hipotética entre as médias populacionais
- n_1: tamanho da amostra feita na 1ª população
- n_2: tamanho da amostra feita na 2ª população
- $\bar{X}_1$: média amostral da amostra feita na 1ª população
- $\bar{X}_2$: média amostral da amostra feita na 2ª população
- s_1^2: variância amostral da amostra feita na 1ª população
- s_2^2: variância amostral da amostra feita na 2ª população

Figura 14. Teste para comparar duas médias



Exemplo: A análise de uma amostra aleatória de ocorrências de venda de certa lanchonete que consiste em 20 ocorrências sinalizou que os clientes gastaram, em média, R$29,80. Uma segunda amostra aleatória foi feita em outra semana, quando foi feita uma publicidade adicional. Com 25 ocorrências, descobriu-se gasto médio de R$34,70. Os desvios-padrão amostrais foram R$4,00 e R$5,00, respectivamente.

Os dados indicam que os gastos médios reais são diferentes? Suponha que a distribuição dos gastos é normal e que a variância não mudou nas semanas analisadas. Use nível de significância $\alpha = 0{,}01$.

Solução: Perguntar se os gastos médios reais são diferentes equivale a perguntar se as médias populacionais são diferentes, considerando população os gastos dos clientes em uma semana. Essa pergunta pode ser descrita como $\mu_1 \neq \mu_2$, mas pode ser reformulada para $\mu_1 - \mu_2 \neq 0$, o que permitirá aplicar o teste conforme formatado na **Erro! Fonte de referência não encontrada.**.

De acordo com o exemplo, as suposições básicas para realizar o teste são atendidas: as populações são normais e possuem variâncias iguais.

A partir dos dados são identificados:

Estatística	**1ª amostra**	**2ª amostra**

Tamanho	$n_1 = 20$	$n_2 = 25$
Média	$\bar{X}_1 = 29{,}80$	$\bar{X}_2 = 34{,}70$
Variância amostral	$s_1^2 = 4^2 = 16$	$s_2^2 = 5^2 = 25$

Então, é possível calcular:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 - 1) + (n_2 - 1)} = \frac{(20 - 1) \times 16 + (25 - 1) \times 25}{(20 - 1) + (25 - 1)} = 21{,}02$$

Em seguida, aplicando-se a metodologia:

1. $\begin{cases} H_0: \mu_1 - \mu_2 = 0 \\ H_1: \mu_1 - \mu_2 \neq 0 \end{cases}$.
2. $\alpha = 0{,}01$.
3. $t_{teste} = \dfrac{(\bar{X}_1 - \bar{X}_2) - 0}{\sqrt{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$.
4. $n_1 = 20$; $n_2 = 25$; $\bar{X}_1 = 29{,}80$; $\bar{X}_2 = 34{,}70$; $s_1^2 = 4^2 = 16$; $s_2^2 = 5^2 = 25$.
5. Rejeita H_0 se $|t_{teste}| > t_{0{,}005}$, ou seja, $|t_{teste}| > 2{,}6951$.
6. $t_{teste} = \dfrac{(\bar{X}_1 - \bar{X}_2) - 0}{\sqrt{s_p^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \dfrac{29{,}8 - 34{,}7}{\sqrt{21{,}02 \times \left(\frac{1}{20} + \frac{1}{25}\right)}} = -3{,}56.$
7. Decisão: Rejeita H_0.

A rejeição da hipótese nula é interpretada como evidência suficiente para garantir que as semanas apresentaram gastos médios diferentes.

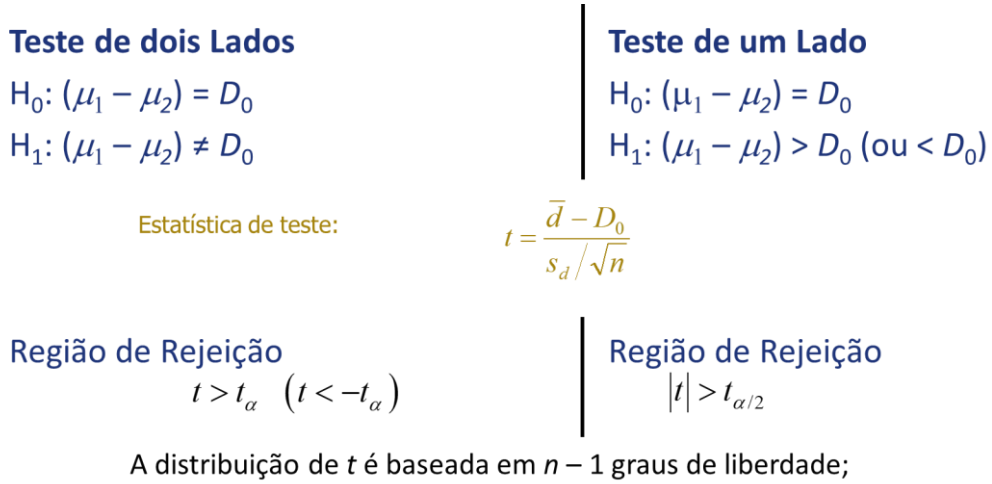
5.3.1. Quando as amostras estão emparelhadas

O procedimento examinado anteriormente funciona para amostragens realizadas de qualquer forma. Entretanto, quando as amostras estão emparelhadas, há um procedimento mais simples que pode ser usado.

As amostras estão emparelhadas quando a amostragem é realizada de forma que há uma relação entre cada um dos elementos de uma população com cada um dos elementos da outra população. As observações são colocadas em pares. Isso é muito comum quando se observa o efeito de determinado experimento e é possível observar antes e depois do experimento.

Por exemplo, pessoas podem realizar um teste antes e depois de receberem um treinamento. Então, cada pessoa terá uma nota antes do treinamento e outra depois. É possível definir uma terceira informação, que é a diferença entre as notas. Então, o procedimento de teste para amostras emparelhadas pode se concentrar especificamente na variável de diferença, como no quadro a seguir:

Figura 157. Diferença das médias, variáveis emparelhadas



Exemplo: Determinada empresa investe muito em treinamento e deseja buscar evidências de que o treinamento melhora a performance dos empregados. Um estudo foi realizado com 10 funcionários que participaram de determinado treinamento. Foi feito um teste que resulta em uma nota. Observou-se que a nota

média que os funcionários atingiram foi reduzida em 1,1 pontos, em média. O desvio-padrão das diferenças foi 0,5.

É possível garantir que a nota média verdadeira não aumentou e que, portanto, o treinamento é ineficiente?

Solução: Os dados apresentam a variável de diferença, de forma que $\bar{d} = 1{,}1$ e $s_d = 0{,}5$. Então, é possível seguir a metodologia.

1. $\begin{cases} H_0: d = \mu_1 - \mu_2 \geq 0 \\ H_1: d = \mu_1 - \mu_2 < 0 \end{cases}$.
2. $\alpha = 0{,}05$.
3. $t_{teste} = \dfrac{\bar{d} - 0}{s_d / \sqrt{n}}$.
4. $n = 10$; $\bar{d} = -1{,}1$; $s_d = 0{,}5$.
5. Rejeita H_0 se $t_{teste} < -t_{0{,}05}$, ou seja, $t_{teste} < -1{,}8331$.
6. $t_{teste} = \dfrac{-1{,}1}{0{,}5 / \sqrt{10}} = -6{,}9570$.
7. Decisão: Rejeita H_0.

A rejeição da hipótese nula significa que há evidências suficientes de que o treinamento está piorando o desempenho dos funcionários.

5.4. O caso da diferença das proporções

Da mesma forma que se pode comparar médias de populações diferentes, também é possível comparar proporções de populações diferentes. Neste caso haverá duas amostras, que vão gerar diferentes proporções amostrais. Essas proporções serão definidas como:

$$p_1 = \frac{X_1}{n_1} \quad p_2 = \frac{X_2}{n_2}$$ e

A partir dessas informações, será considerada uma proporção agrupada:

$$p = \frac{X_1 + X_2}{n_1 + n_2}$$

Para usar a ficha da **Erro! Fonte de referência não encontrada.**8, basta considerar que q é o complemento de p, e então:

$$q = 1 - p \text{, } q_1 = 1 - p_1 \text{ e } q_2 = 1 - p_2$$

Figura 168. Diferença das proporções

Teste de dois Lados	**Teste de um Lado**
$H_0: (\pi_1 - \pi_2) = D_0$	$H_0: (\pi_1 - \pi_2) = D_0$
$H_1: (\pi_1 - \pi_2) \neq D_0$	$H_1: (\pi_1 - \pi_2) > D_0$ (ou < 0)

Estatística de teste: $z = \dfrac{(p_1 - p_2) - D_0}{\sqrt{pq\left(1/n_1 + 1/n_2\right)}}$

Região de Rejeição	Região de Rejeição
$z > z_\alpha \quad (z < -z_\alpha)$	$\lvert z \rvert > z_{\alpha/2}$

Para aplicar o teste, deve-se considerar as suposições de que as amostras são suficientemente grandes, de modo que os intervalos abaixo não contêm 0 nem 1:

$$p_1 \pm 2\sqrt{\frac{p_1 \times q_1}{n_1}} \quad p_2 \pm 2\sqrt{\frac{p_2 \times q_2}{n_2}} \text{ e}$$

Exemplo: Uma amostra de 300 adultos residentes em área urbana de um estado específico revelou que 63 são favoráveis ao aumento do limite de velocidade nas estradas de 55km/h para 65km/h, enquanto uma amostra de 180 habitantes

rurais mostrou que 75 são favoráveis a este aumento. Esses dados indicam que a opinião sobre o aumento do limite de velocidade é diferente para os dois grupos de habitantes?

Solução: Inicialmente, verificamos que $p_1 = \frac{X_1}{n_1} = \frac{63}{300} = 0{,}2100$ e $p_2 = \frac{X_2}{n_2} = \frac{75}{180} = 0{,}4167$

Avaliando quanto às suposições:

$$p_1 \pm 2\sqrt{\frac{p_1 \times q_1}{n_1}} = 0{,}21 \pm 2\sqrt{\frac{0{,}21 \times 0{,}79}{300}}$$

que resulta no intervalo (0,1630 ;0,2570).

$$p_2 \pm 2\sqrt{\frac{p_2 \times q_2}{n_2}} = 0{,}4167 \pm 2\sqrt{\frac{0{,}4167 \times 0{,}5833}{180}}$$

que resulta no intervalo (0,3432 ;0,4901). Como os dois intervalos acima não incluem 0 ou 1, a metodologia pode ser aplicada:

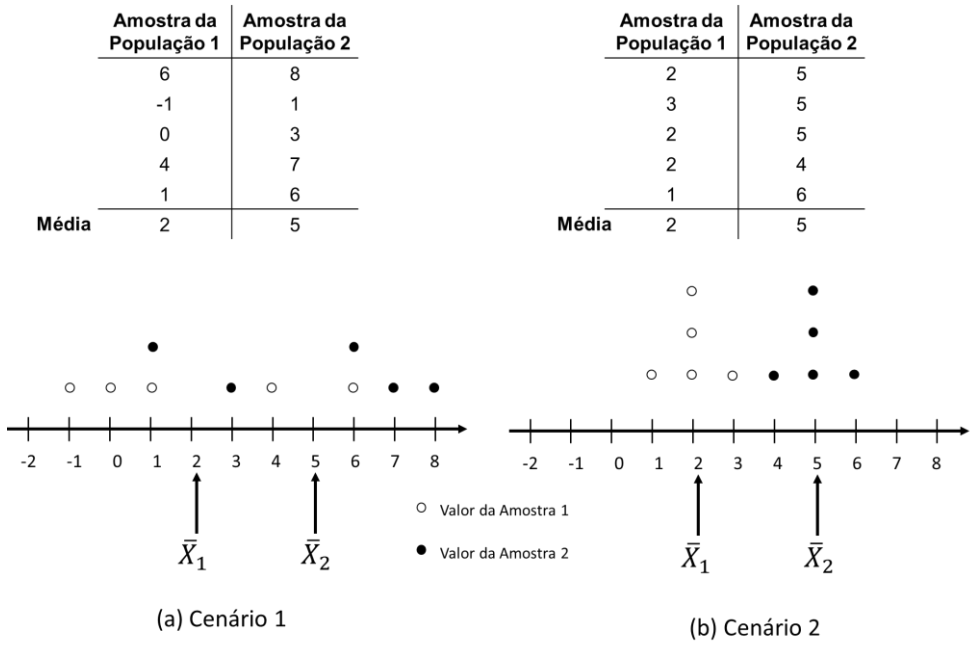
1. $\begin{cases} H_0: \pi_1 - \pi_2 = 0 \\ H_1: \pi_1 - \pi_2 \neq 0 \end{cases}$.
2. $\alpha = 0{,}05$.
3. $Z_{teste} = \dfrac{(p_1 - p_2) - 0}{\sqrt{p \times q \times \left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$.
4. Rejeita H_0 se $|Z_{teste}| > Z_{0{,}025}$, ou seja, $|Z_{teste}| > 1{,}96$.
5. $Z_{teste} = \dfrac{(0{,}21 - 0{,}4167) - 0}{\sqrt{0{,}2875 \times 0{,}7128 \times \left(\frac{1}{300} + \frac{1}{180}\right)}} = -4{,}8440$.
6. Decisão: Rejeita H_0.

Capítulo 6. ANOVA

ANOVA é a abreviação de Analysis of Variance, que é traduzido como Análise da Variância. É um método de comparação de médias mais poderoso do que o teste de hipóteses, pois permite que sejam comparadas médias oriundas de mais de duas populações. A mecânica da ANOVA é baseada na dispersão das amostras, medida pela variância. Para entender o processo, vamos começar examinando um caso bem simples, comparando apenas duas médias, μ_1 e μ_2, e analisando amostras bem pequenas, $n_1 = 5$ e $n_2 = 5$.

Na **Erro! Fonte de referência não encontrada.**19, é possível ver dois diferentes cenários. No lado esquerdo da figura está o Cenário 1, onde há amostras extraídas de duas populações. As médias amostrais são $\bar{X}_1 = 2$ e $\bar{X}_2 = 5$. É possível examinar as amostras na tabela ou no gráfico logo a seguir. No lado direito da figura está o Cenário 2, que tem amostras do tamanho das do Cenário 1 e também possui médias amostrais $\bar{X}_1 = 2$ e $\bar{X}_2 = 5$. Entretanto, comparando os cenários, percebe-se que as observações têm comportamentos bem diferentes. Analisando o Cenário 1, é normal ter menos confiança para rejeitar a hipótese $\mu_1 = \mu_2$ do que analisando o Cenário 2.

Figura 19. Dois cenários para comparação das médias



O procedimento da ANOVA é baseado na comparação de duas variações: a variação **entre** as médias amostrais e a variação **dentro** das amostras. Há ganho de confiança para rejeitar a hipótese $\mu_1 = \mu_2$ quando a variação entre as médias for grande ao ser comparada com a variação dentro das amostras. Nos dois cenários da **Erro! Fonte de referência não encontrada.**19, a variação entre as médias é a mesma. Entretanto, a variação dentro da amostra 1 é maior no Cenário 1 e menor no Cenário 2. Assim, a comparação relativa entre as variações é maior no Cenário 2, o que resulta em mais confiança. Para conduzir um teste formal de hipóteses, é necessário quantificar essas duas medidas de variação.

A variação **dentro das amostras** é medida pela Média dos Quadrados Dentro (MQD) das amostras:

$$MQD = \frac{SQD}{n-c} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j}\left(X_{ij} - \bar{X}_j\right)^2}{n-c}$$

Onde:

- c : quantidade de grupos

- n_j: tamanho da amostra do grupo j
- X_{ij}: i-ésimo valor do grupo j
- $\bar{X}_j$: média aritmética da amostra do grupo j

Por outro lado, pode-se medir a **variação entre** as médias amostrais com a Média dos Quadrados Entre (MQE) as médias amostrais:

$$MQE = \frac{SQE}{c-1} = \frac{\sum_{j=1}^{c} n_j \left(\bar{X}_j - \bar{\bar{X}}\right)^2}{c-1}$$

Onde:

- $\bar{\bar{X}} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j} X_{ij}}{n}$ é a grande média, ou seja, a média aritmética de todas as observações, de todos os grupos.
- $n = \sum_{j=1}^{c} n_j$ é o total de observações, ou seja, a soma dos tamanhos das amostras.

A comparação é objetiva através de um teste de hipóteses. O teste é formalizado assim:

1. Hipóteses: $\begin{cases} H_0: \mu_1 = \mu_2 = \cdots = \mu_c \\ H_1: \text{Nem todas as } \mu_j \text{ são iguais}, j = 1,2,\ldots,c \end{cases}$.
2. Nível de significância: α.
3. Estatística de teste: $F_{teste} = \frac{MQE}{MQD}$.
4. Informações amostrais são obtidas.
5. Rejeita H_0 se $F_{teste} > F_{\alpha}$, com gln=$c-1$ e gld = $n-c$.

A distribuição amostral utilizada para realizar o teste de hipóteses é a distribuição F. Assim como na distribuição normal ou na distribuição de Student, os valores críticos para F podem ser obtidos através de uma tabela ou através de

ferramentas computacionais, como o Excel. Entretanto os valores de F dependem de dois graus de liberdade: o grau de liberdade do numerador (gln) e o grau de liberdade do denominador (gld), que são definidos com base nos graus de liberdade das variâncias que compõem F_{teste}. A tabela apresenta os valores críticos de F em várias colunas, variando os graus de liberdade do numerador, e em várias linhas, variando os graus de liberdade do denominador. E então há uma tabela para cada nível de significância. Os Anexos 0, 0 e 0 contêm as tabelas com as distribuições dos valores críticos de F para os níveis de significância mais comumente utilizados.

Exemplo – Cenário 1:

As amostras do Cenário 1 são:

	Amostra da população 1	**Amostra da população 2**
	6	8
	-1	1
	0	3
	4	7
	1	6
Média	2	5

Solução – Cenário 1:

Os dados amostrais permitem definir: $n_1 = 5$, $\bar{X}_1 = 2$, $n_2 = 5$ e $\bar{X}_2 = 5$.

Então, a grande média é calculada:

$$\bar{\bar{X}} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j} X_{ij}}{n} = \frac{(6-1+0+4+1)+(8+1+3+7+6)}{10} = 3{,}5$$

.

A variação entre as médias é:

$$MQE = \frac{SQE}{c-1} = \frac{\sum_{j=1}^{c} n_j\left(\bar{X}_j - \bar{\bar{X}}\right)^2}{c-1} = \frac{5(2-3{,}5)^2 + 5(5-3{,}5)^2}{2-1} = 22{,}5.$$

A variação dentro das médias é:

$$MQD = \frac{SQD}{n-c} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j}\left(X_{ij} - \bar{X}_j\right)^2}{n-c}$$
$$= \frac{((6-2)^2 + \cdots + (1-2)^2) + ((8-5)^2 + \cdots + (6-5)^2)}{(5-1)+(5-1)} = 8{,}5$$

E a estatística $F = \frac{MQE}{MQD} = \frac{22{,}5}{8{,}5} = 2{,}65$.

Assim, é possível conduzir o teste de hipóteses

1. Hipóteses: $\begin{cases} H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 \neq \mu_2 \end{cases}$.
2. Nível de significância: $\alpha = 0{,}05$.
3. Estatística de teste: $F_{teste} = \frac{MQE}{MQD}$.
4. $MQE = 22{,}5$ e $MQD = 8{,}5$.
5. Com gln= $c-1$ e gld = $n-c$ temos que rejeitar H_0 se $F_{teste} > 5{,}32$.
6. $F_{teste} = \frac{22{,}5}{8.5} = 2{,}65$.
7. Decisão: não rejeita H_0.

Ou seja, não há evidências suficientes para garantir que as médias não são iguais.

Observação: O valor crítico de F pode ser calculado de duas formas:

1) Olhando para a tabela.

	1	2	3
2	18,51	19,00	19,16
3	10,13	9,55	9,28
4	7,71	6,94	6,59
5	6,61	5,79	5,41
6	5,99	5,14	4,76
7	5,59	4,74	4,35
8	5,32	4,46	4,07
9	5,12	4,26	3,86
10	4,96	4,10	3,71

2) Usando o Excel.

$$=INV.F(1 - \alpha; gln; gld)$$

Ou seja, =INV.F(0,95;1;8)

Exemplo – Cenário 2:

As amostras são:

	Amostra da população 1	**Amostra da população 2**
	2	5
	3	5
	2	5
	2	4
	1	6
Média	2	5

Solução – Cenário 2:

Os dados amostrais permitem definir: $n_1 = 5$, $\bar{X}_1 = 2$, $n_2 = 5$ e $\bar{X}_2 = 5$

Então, a grande média é calculada:

$$\bar{\bar{X}} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j} X_{ij}}{n} = \frac{(2+3+2+2+1)+(5+5+5+4+6)}{10} = 3{,}5$$

.

A variação entre as médias é:

$$MQE = \frac{SQE}{c-1} = \frac{\sum_{j=1}^{c} n_j\left(\bar{X}_j - \bar{\bar{X}}\right)^2}{c-1} = \frac{5(2-3{,}5)^2 + 5(5-3{,}5)^2}{2-1} = 22{,}5$$

A variação dentro das médias é:

$$MQD = \frac{SQD}{n-c} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j}\left(X_{ij} - \bar{X}_j\right)^2}{n-c}$$
$$= \frac{((2-2)^2 + \cdots + (1-2)^2) + ((5-5)^2 + \cdots + (6-5)^2)}{(5-1)+(5-1)} = 0{,}5$$

.

E a estatística $F = \frac{MQE}{MQD} = \frac{22{,}5}{0{,}5} = 45$.

Assim, é possível conduzir o teste de hipóteses

1. Hipóteses: $\begin{cases} H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 \neq \mu_2 \end{cases}$.
2. Nível de significância: $\alpha = 0{,}05$.
3. Estatística de teste: $F_{teste} = \frac{MQE}{MQD}$.
4. MQE = 22,5 e MQD = 0,5.
5. Com gln = $c-1$ e gld = $n-c$ temos que rejeitar H_0 se $F_{teste} > 5{,}32$.
6. $F_{teste} = \frac{22{,}5}{8.5} = 45$.
7. Decisão: Rejeita H_0.

Ou seja, há evidências suficientes para garantir que as médias não são iguais.

Comparando os dois exemplos, vemos que os Cenários 1 e 2 guardam muitas similaridades, dentre as quais a mais importante é que as médias amostrais são as mesmas, $\bar{X}_1 = 2$ e $\bar{X}_2 = 5$. Uma dessas similaridades está nos valores para a

variância: os dois cenários apresentaram MQE iguais. Entretanto, como as dispersões dentro das amostras são muito diferentes, os indicadores de variância dentro das amostras são bem diferentes, o que alterou o resultado do teste acentuadamente.

O método ANOVA possui três importantes pressupostos:

- **Aleatoriedade e independência**: depende da qualidade da amostragem.
- **Normalidade**: é superado se as amostras forem grandes o bastante.
- **Homogeneidade de variâncias**: não é um problema grave se as amostras tiverem tamanho semelhante.

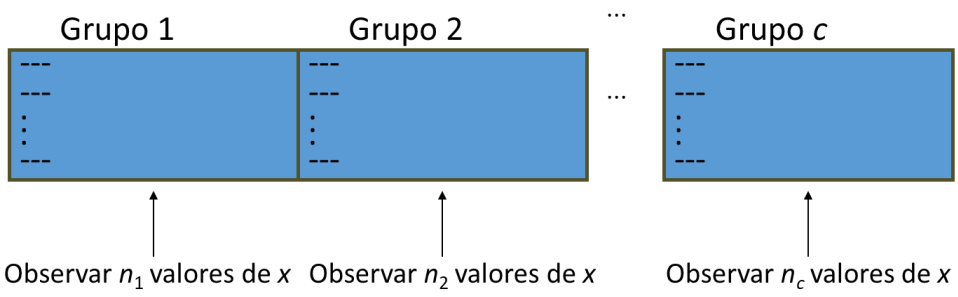
As populações que estão sob análise para a ANOVA podem estar sendo caracterizadas por algum fator. O mais comum é que haja apenas um fator que caracteriza as populações, mas vamos examinar também quando houver dois fatores, podendo haver ou não repetição de observações dentro do conjunto de definições dos fatores.

6.1. Projeto com fator único

O projeto para ANOVA com fator único é exatamente o que foi destrinchado na abertura do capítulo. Só que havia apenas dois grupos, e é possível que haja mais de dois. É o tipo de ANOVA mais utilizado.

Generalizando, serão comparadas as médias de c diferentes grupos, sendo que cada grupo é baseado numa amostra com n_j observações.

Figura 17. Estrutura do projeto com fator único



Como as expressões para realizar o teste já foram apresentadas, vamos abordar o problema através de um exemplo prático.

Exemplo: Uma indústria e distribuidora de minicomputadores emprega um grande número de vendedores e tem três tipos de remuneração:

- Só comissão.
- Salário fixo.
- Salário fixo (reduzido) mais comissão.

Considere o problema de comparar as vendas mensais dos vendedores que recebem só comissão com as vendas mensais dos que recebem só salário e com as vendas mensais dos que recebem salário e comissão. A diferença observada nas médias amostrais é evidência suficiente para sustentar que há diferença nas médias verdadeiras?

Os dados a seguir estão em milhares de dólares, e são de um determinado mês, com vendedores de cada sistema de remuneração escolhidos aleatoriamente:

	Comissão	**Salário fixo**	**Comissão e salário**
	165	120	140
	98	115	156
	130	90	220
	210	126	112
	195	107	134
	187	155	235
	240	80	
Médias amostrais	175,00	113,29	166,17

Solução: Observa-se que a forma do salário constitui um fator que diferencia os três grupos; cada um tem uma forma distinta. Os dados amostrais permitem definir:

$c = 3$, $n_1 = 7$, $\bar{X}_1 = 175$, $n_2 = 7$, $\bar{X}_2 = 113{,}29$, $n_3 = 6$ $\bar{X}_3 = 166{,}17$.

Então, $n = \sum n_j = 20$, e a grande média é: $\bar{\bar{X}} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j} x_{ij}}{n} = 150{,}75$.

A variação entre as médias é $MQE = \frac{SQE}{c-1} = \frac{\sum_{j=1}^{c} n_j\left(\bar{X}_j - \bar{\bar{X}}\right)^2}{c-1} = 7.683{,}74$.

A variação dentro das médias é $MQD = \frac{SQD}{n-c} = \frac{\sum_{j=1}^{c}\sum_{i=1}^{n_j}\left(X_{ij} - \bar{X}_j\right)^2}{n-c} = 1.769{,}43.$

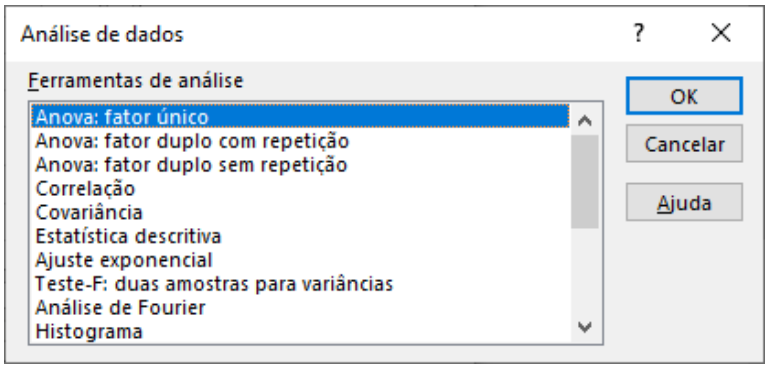
Assim, é possível conduzir o teste de hipóteses:

1. Hipóteses: $\begin{cases} H_0: \mu_1 = \mu_2 = \mu_3 \\ H_1: \text{pelo menos uma } \mu_j \text{ é diferente} \end{cases}$.
2. Nível de significância: α = 0,05.
3. Estatística de teste: $F_{teste} = \frac{MQE}{MQD}$.
4. $MQE = 7.683{,}74$ e $MQD = 1.69{,}43$.
5. Com gln = $c - 1 = 2$ e gld = $n - c = 17$, temos que rejeitar H_0 se $F_{teste} > 3{,}59$.
6. $F_{teste} = \frac{MQE}{MQD} = \frac{7.683{,}74}{1.769{,}43} = 4{,}34$.
7. Decisão: Rejeita H_0.

Ou seja, há evidências suficientes para garantir que pelo menos uma das médias não é igual às demais. O processo descrito foi resolvido de forma manual. O

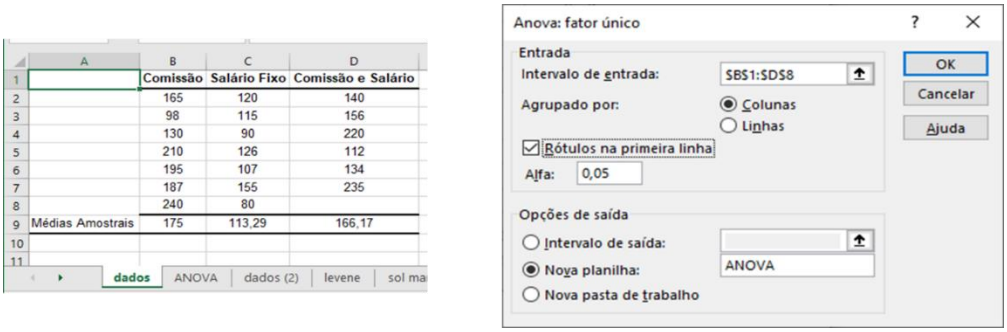
Excel foi utilizado para isso, e os dados e as fórmulas estão disponíveis no arquivo **Aula 06 Comissão_Salário.xlsx**. Mas também é possível usar uma ferramenta do Excel para fazer os cálculos.

Figura 18. Lista de ferramentas para “Análise de Dados”



A **Erro! Fonte de referência não encontrada.** mostra as ferramentas disponíveis para análise de dados. Essa tela aparece na barra de ferramentas “Dados”, quando habilitada no menu de suplementos das opções de configuração do Excel. Como se vê, há três ferramentas para ANOVA: o fator único, o fator duplo sem repetição e o fator duplo com repetição. A primeira ferramenta refere-se ao exemplo que estamos seguindo aqui. O preenchimento da sua tela deve ser feito conforme a **Erro! Fonte de referência não encontrada.**.

Figura 19. Parâmetros para ANOVA fator único



O Excel se mostrará uma ferramenta extremamente eficiente para fazer a ANOVA, pois os diversos cálculos estão todos embutidos na ferramenta. As informações calculadas pelo Excel podem ser vistas na Tabela 6 e estão agrupadas em duas partes: RESUMO, que fala dos grupos, e ANOVA, que fala das estatísticas MQE e MQD. Além de haver diversos cálculos intermediários, o Excel mostra o $F_{0,05}$ e o Valor-P para o teste.

Tabela 6. Saída da ANOVA fator único – Excel

Anova: fator único

RESUMO

Grupo	*Contagem*	*Soma*	*Média*	*Variância*
Comissão	7	1225	175	2341,333333
Salário Fixo	7	793	113,2857143	606,5714286
Comissão e Salário	6	997	166,1666667	2478,566667

ANOVA

Fonte da variação	*SQ*	*gl*	*MQ*	*F*	*valor-P*	*F crítico*
Entre grupos	15367,4881	2	7683,744048	4,342503706	0,029959766	3,591530568
Dentro dos grupos	30080,2619	17	1769,427171			
Total	45447,75	19				

Considere como guia dos valores que foram calculados pelo Excel a **Erro! Fonte de referência não encontrada.**7, que mostra o racional para obter cada um dos valores.

Tabela 7. Valores calculados pelo Excel

Anova: fator único

RESUMO

Grupo	*Contagem*	*Soma*	*Média*	*Variância*
Grupo 1	n_1	$\sum_{i=1}^{n_1} x_1$	$\bar{x}_1$	s_1^2
Grupo 2	n_2	$\sum_{i=1}^{n_2} x_2$	$\bar{x}_2$	s_2^2
...	...	...	...	...
Grupo *c*	n_c	$\sum_{i=1}^{n_c} x_c$	$\bar{x}_c$	s_c^2

ANOVA

Fonte da variação	*Gl*	*SQ*	*MQ*	*F*	*valor-P*	*F crítico*
Entre grupos	$c-1$	*SQE*	$MQE = \frac{SSE}{c-1}$	$F = \frac{MQE}{MQD}$	$P(x > F)$	F_α
Dentro dos grupos	$n-c$	*SQD*	$MQD = \frac{SSD}{n-c}$			
Total	$n-1$	STQ				

A ANOVA faz uma repartição da variação total. A variação total pode ser definida como:

$$STQ = \sum_{j=1}^{c} \sum_{i=1}^{n_j} \left(X_{ij} - \bar{\bar{X}}\right)^2$$

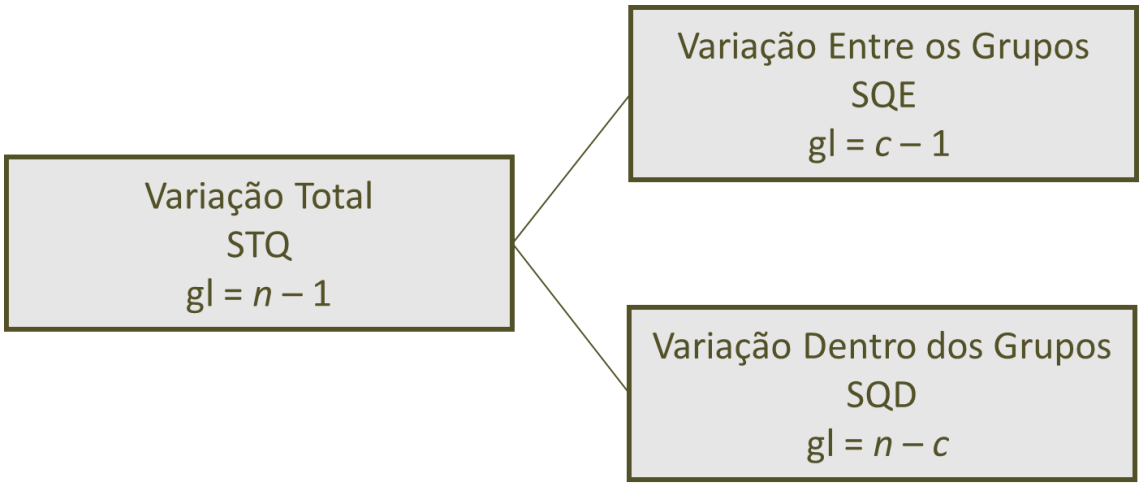
E é possível mostrar que:

$$STQ = SQE + SQD$$

Onde $MQE = \frac{SQE}{c-1}$ e $MQD = \frac{SQD}{n-c}$.

A representação na **Erro! Fonte de referência não encontrada.**3 mostra essa decomposição.

Figura 203. Repartindo a variação total – ANOVA de fator único



6.2. Projeto com dois fatores

Vamos examinar este tipo de projeto a partir de um exemplo.

Exemplo: Uma companhia fabrica juntas de vedação cortadas a partir de folhas de borracha, plástico ou cortiça. A capacidade produtiva de suas máquinas depende do tipo de material que está operando e da própria máquina em si.

A companhia deseja comparar a média de produção por hora de duas máquinas de corte diferentes e determinar se uma máquina é mais produtiva do que a outra. Deseja descobrir, ainda, se uma máquina é mais produtiva com um material ou com o outro.

Os dados a seguir foram obtidos com as máquinas operando uma hora para cada um dos materiais, em ordem aleatória.

Máquina	Cortiça	Borracha	Plástico
M1	4,31	3,36	4,01
	4,27	3,42	3,94
	4,4	3,48	3,89
M2	3,94	3,91	3,48
	3,81	3,8	3,53
	3,99	3,85	3,42

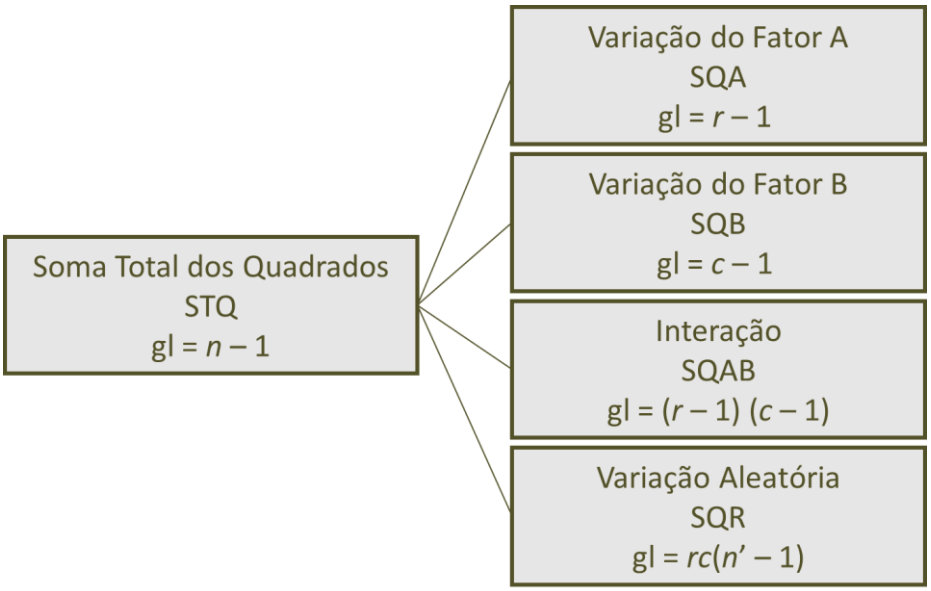
Os dados estão apresentados em uma tabela dupla de um experimento fatorial 2x3 (2 máquinas e 3 materiais). Esse experimento possui três replicações (repetições) para cada combinação de fatores. Em um experimento fatorial, quando a diferença entre as médias do Fator A depende dos diferentes níveis do Fator B, dizemos que os fatores A e B interagem. Se a diferença das médias é independente dos níveis de B, então não há interação entre os fatores A e B.

É definido que o fator A tem r níveis e o fator B tem c níveis. Define-se também n' como sendo a quantidade de repetições que existem dentro de cada célula – sendo que existem r × c células, que são os grupos formados pelos diferentes cruzamentos de fatores.

No exemplo proposto, temos que o fator A é o tipo de material e então r = 3 (cortiça, borracha e plástico). O fator B é a máquina, e então c = 2 (máquina M1 e máquina M2). Finalmente, n' = 3, pois para cada material e cada máquina há 3 observações.

Na **Erro! Fonte de referência não encontrada.** é possível ver como a variação total é repartida quando há um projeto de dois fatores.

Figura 21. Repartindo a variação total – projeto com dois fatores



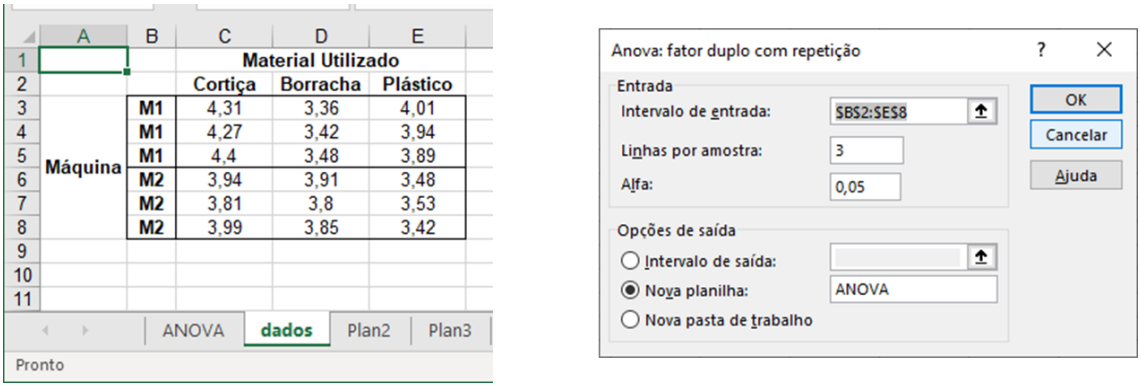
É possível demonstrar que:

$$STQ = SQA + SQB + SQAB + SQR$$

Onde SQR representa a variação aleatória, ou a variação dentro das células.

Para obter a análise para o exemplo, vamos usar a ferramenta do Excel chamada ANOVA: fator duplo com repetição. Os parâmetros da tela devem ser preenchidos conforme a **Erro! Fonte de referência não encontrada.**.

Figura 22. Parâmetros para ANOVA – fator duplo e com repetição



		Material Utilizado		
		Cortiça	Borracha	Plástico
Máquina	M1	4,31	3,36	4,01
	M1	4,27	3,42	3,94
	M1	4,4	3,48	3,89
	M2	3,94	3,91	3,48
	M2	3,81	3,8	3,53
	M2	3,99	3,85	3,42

O resultado da análise do Excel está agrupado em duas partes. Na parte do resumo, que está demonstrado na **Erro! Fonte de referência não encontrada.**, é possível ver algumas estatísticas amostrais de alguns grupos. Primeiro as células relativas à Máquina M1 e depois as células relativas à Máquina M2. Finalmente, são demonstradas as estatísticas amostrais de todos as observações de cada um dos níveis do Fator A (cortiça, borracha e plástico).

Tabela 8. Resultados no Excel – resumos

RESUMO	Cortiça	Borracha	Plástico	Total
M1				
Contagem	3	3	3	9
Soma	12,98	10,26	11,84	35,08
Média	4,326667	3,42	3,946667	3,897778
Variância	0,004433	0,0036	0,003633	0,158394
M2				
Contagem	3	3	3	9
Soma	11,74	11,56	10,43	33,73
Média	3,913333	3,853333	3,476667	3,747778
Variância	0,008633	0,003033	0,003033	0,045694
Total				
Contagem	6	6	6	
Soma	24,72	21,82	22,27	
Média	4,12	3,636667	3,711667	
Variância	0,05648	0,058987	0,068937	

Entretanto, a parte mais rica da análise está na tabela ANOVA, que permite fazer os testes. Essas informações podem ser vistas na **Erro! Fonte de referência não encontrada.**. O Excel identifica o fator A como Amostra e o fator B como Colunas.

Assim, a primeira linha da ANOVA apresenta um teste para as médias dos diferentes tipos de material. Como F_{teste} = 23,04 é maior do que o valor crítico F_{α} = 4,75, rejeita-se a hipótese nula de que as médias de desempenho para os diferentes tipos de material são iguais.

A segunda linha da ANOVA apresenta um teste para as médias das diferentes máquinas. Como F_{teste} = 92,38 é maior do que o valor crítico F_{α} = 3,88, rejeita-se a hipótese nula de que as médias de desempenho para as diferentes máquinas são iguais.

Tabela 9. Resultados no Excel – testes

ANOVA

Fonte da variação	*SQ*	*gl*	*MQ*	*F*	*valor-P*	*F crítico*
Amostra	0,10125	1	0,10125	23,04046	0,000434	4,747225
Colunas	0,811944	2	0,405972	92,38306	5,15E-08	3,885294
Interações	0,768033	2	0,384017	87,38685	7,03E-08	3,885294
Dentro	0,052733	12	0,004394			

A terceira linha da ANOVA permite testar a interação entre os fatores. Como F_{teste} = 87,38 é maior do que o valor crítico F_{α} = 3,88, rejeita-se a hipótese nula de que não há interação entre os fatores, ou seja, conclui-se que há interação entre os fatores. A interação entre os fatores quer dizer que as máquinas têm comportamento diferente uma da outra ao alterar o material. Ou seja, uma máquina pode ser mais eficiente com determinado material enquanto a outra máquina pode ser mais eficiente com outro material.

A partir dos resumos pode-se perceber que o desempenho médio da máquina M1 é maior com Cortiça e pior com Borracha. Já a máquina M2 tem maior desempenho com Cortiça e tem o pior desempenho com Plástico. Essa diferença percebida na amostra é a interação entre os fatores. A análise sugere que há evidência suficiente para garantir que as populações devem ter média diferente também.

Capítulo 7. Testes do qui-quadrado

Os testes do qui-quadrado aplicam-se à proporção, que são medidas especialmente importantes para variáveis categóricas.

Lembrando: uma variável categórica é aquela que tem seu domínio em um conjunto finito e limitado de diferentes valores não numéricos. Geralmente, são o resultado de um experimento multinomial. A amostragem de uma variável categórica costuma resumir a quantidade de ocorrências de cada categoria – a distribuição de frequências. Por exemplo, quantas medalhas de ouro, prata ou bronze ou quantas unidades de cada cor. Também são variáveis categóricas informações sobre classe, grupo, tipo etc.

Os testes qui-quadrado são procedimentos de inferência que comparam frequências observadas em uma amostra com frequências esperadas em função de alguma hipótese. Podem ser:

- **Teste de aderência:** verifica se a amostra pode ter sido extraída de uma população com determinada distribuição teórica.
- **Teste de independência:** verifica se as dimensões de uma população são independentes.
- **Teste de homogeneidade:** verifica se diversas populações são homogêneas.

Qualquer que seja a finalidade, o teste de aderência compara frequências observadas com frequências esperadas. Por exemplo, suponha que um analista esportivo considera que certa delegação de atletas deverá conquistar um total de 10 medalhas, sendo 2 de ouro, 3 de prata e 5 de bronze. Essa é a frequência esperada, cujas proporções são de 20% para ouro, 30% para prata e 50% para bronze. Quando os jogos ocorrem a delegação alcança um total de 15 medalhas, sendo 6 de ouro e 9 de prata. Então, há uma diferença entre frequência observada e frequência esperada (no caso de ouro são 6 e 2, respectivamente) e há uma diferença nas proporções observadas e esperadas (no caso de ouro, são 40% e 20%, respectivamente).

7.1. Teste de aderência

Seja uma variável com k categorias (domínio natural ou alterado). Assim, temos:

Categoria	1	2	...	*k*	Total
Frequência observada	o_1	o_2	...	o_k	*n*
Frequência esperada	e_1	e_2	...	e_k	*n*

O teste investiga se a diferença entre as frequências esperadas e as observadas é significativa através da estatística:

$$\chi^2_{teste} = \sum_{i=1}^{k} \frac{(o_i - e_i)^2}{e_i}$$

Essa estatística é chamada de qui-quadrado, sendo qui o nome da letra grega χ. A estatística é diretamente proporcional à diferença entre as frequências observadas e esperadas. Então, é formado o teste de aderência:

- Hipótese de teste: $\begin{cases} H_0: \pi_1 = p_1, \pi_2 = p2, \ldots, \pi_k = p_k \\ H_1: \text{algum } \pi_i \neq p_i \end{cases}$.
- Estatística de teste: $\chi^2_{teste} = \sum_{i=1}^{k} \frac{(o_i - e_i)^2}{e_i}$.
- Região de rejeição: $\chi^2_{teste} > \chi^2_{\alpha}$, que segue uma distribuição com k - 1 graus de liberdade.

Os valores críticos da distribuição χ^2 estão disponíveis no Anexo 0. Como alternativa, é possível usar o Excel e fazer:

=INV.QUIQUA.CD(α; gl)

Exemplo: Determinado modelo de automóvel está sendo produzido em apenas quatro cores: prata, vermelho, azul e verde. A montadora tem uma expectativa de que a preferência de compra dos clientes será de 70% para prata, 5% para vermelho, 10% para azul e 15% para verde. O volume de pedidos observado foi de 500 automóveis prata, 110 verdes, 100 azuis e 40 vermelhos. Há evidências de que a preferência dos clientes é diferente da expectativa inicial da montadora?

Solução: A frequência esperada não está disponível, apenas a proporção esperada. Como o total de pedidos é de 750 unidades, geramos as frequências esperadas fazendo:

$$e_i = n \times f_i$$

Então, é possível montar a tabela de frequências observadas e esperadas a seguir:

Categoria	Prata	Vermelho	Azul	Verde	Total
o_i	500	40	100	110	750
e_i	525	37,50	75	112,50	750

Com isso, é possível conduzir o teste:

- Hipótese de teste: $\begin{cases} H_0: \pi_1 = 70\% \text{ e } \pi_2 = 5\% \text{ e } \pi_3 = 10\% \text{ e } \pi_4 = 15\% \\ H_1: \pi_1 \neq 70\% \text{ ou } \pi_2 \neq 5\% \text{ ou } \pi_3 \neq 10\% \text{ ou } \pi_4 \neq 15\% \end{cases}$.
- Estatística de teste: $\chi^2_{teste} = \sum_{i=1}^{k} \frac{(o_i - e_i)^2}{e_i} = 9{,}75$.

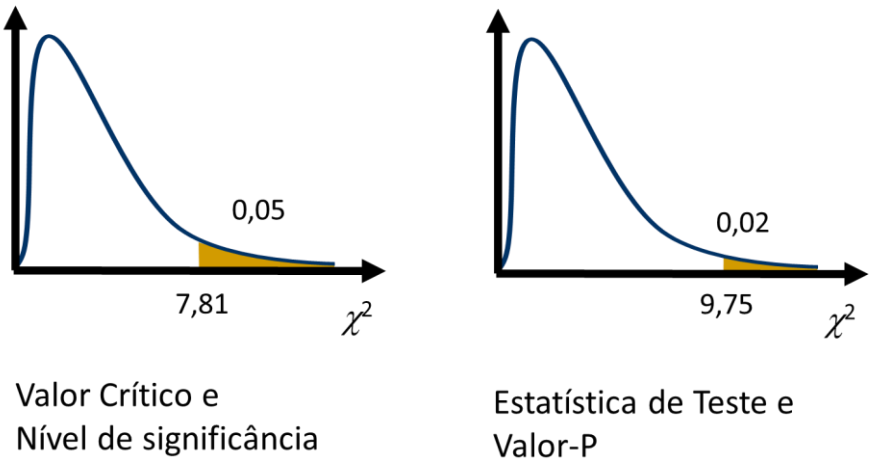
Com k – 1 = 3 graus de liberdade, $\chi^2_{\alpha} = 7{,}81$:

- Região de rejeição: $\chi^2_{teste} > 7{,}81$.

Conclusão, rejeitamos H_0. Ou seja, a proporção de veículos consumidos é diferente da proporção esperada pela indústria montadora. O valor-P para o teste do qui-quadrado pode ser calculado usando o Excel:

=DIST.QUIQUA.CD(χ^2_{teste}; g.l.)

Figura 26. Valores críticos e Valor-P para a distribuição χ^2



7.2. Tabela de contingência de dupla entrada

Uma tabela como a que está demonstrada na tabela é classificada como dupla entrada porque tem várias linhas diferentes (total de I linhas) e várias colunas diferentes (total de J colunas). Dessa forma, a tabela tem I × J ocorrências (células).

Tabela 10. Tabela de contingência de dupla entrada

	1	**2**	**...**	**J**
1	n_{11}	n_{12}	...	n_{1J}
2	n_{21}	n_{22}	...	n_{2J}
...	...	...	...	...
I	n_{I1}	n_{I2}	...	n_{IJ}

Quando os valores que estão dentro das células representam uma frequência, há duas possíveis interpretações para as “entradas”, ou seja, para as linhas e colunas:

1. I populações, com J categorias: teste de homogeneidade

Por exemplo, são I diferentes lojas, que possuem clientes com diferentes tipos de comportamento, e são J diferentes formas de pagamento (crédito, débito, dinheiro, cheque etc.). Então, considerando que cada loja representa uma população diferente, são J populações. E, se cada forma de pagamento é uma categoria, são I categorias.

2. Uma só população, mas que está decomposta por dois fatores diferentes: teste de independência

Por exemplo, se são I departamentos de venda na loja (mesma loja, mesma população) e J formas de pagamento.

7.3. Teste de homogeneidade

Vamos abordar o problema através de um exemplo:

Exemplo: Uma empresa embala um certo produto em latas de três tamanhos diferentes, cada uma utilizando uma linha de produção distinta.

Um engenheiro de controle de qualidade realizou uma amostragem.

Tabela 11. Frequências observadas de não conformidade

Linha de produção	Razões de não conformidade					Tamanho da amostra
	Mancha	Rachadura	Localização	Faltando	Outros	
1	34	65	17	21	13	150
2	23	52	25	19	6	125
3	32	28	16	14	10	100
Total	89	145	58	54	29	375

Os dados sugerem que as proporções em que caem várias categorias de não conformidade não são as mesmas para as três linhas de produção?

Solução: De acordo com o enunciado, é possível considerar que cada máquina é uma população diferente. A questão que surge se traduz em: a proporção de falhas é idêntica para as diferentes linhas de montagem? Caso sim, a homogeneidade é a hipótese nula.

- Hipótese de teste:

$$\begin{cases} H_0: \pi_{11} = \pi_{21} = \pi_{31}, \pi_{12} = \pi_{22} = \pi_{32}, \dots, \pi_{15} = \pi_{25} = \pi_{35} \\ H_1: H_0 \text{ não é verdadeira} \end{cases}$$

Onde π_{ij} é a proporção da categoria j na população i. Sendo que i = 1,2,3 é a linha de produção correspondente e j = 1 é mancha; j = 2 é rachadura; j = 3 é localização; j = 4é faltando; e j = 5 é outros.

A hipótese de homogeneidade sugere que as frequências esperadas dependem exclusivamente das quantidades totais. Então, a frequência esperada para a categoria j da população i é obtida fazendo:

$$e_{ij} = \frac{(\text{total da linha } i) \times \text{total da coluna } j}{\text{tamanho total da amostra}}$$

Usando essa estratégia, é possível montar uma tabela com todas os valores esperados, como está na **Erro! Fonte de referência não encontrada.**. Por exemplo, a frequência esperada de manchas na linha de produção 1 é calculada fazendo:

$$e_{11} = \frac{150 \times 89}{375} = 35{,}60$$

Tabela 12. Frequências esperadas de não conformidade

Linha de produção	Razões de não conformidade					Tamanho da amostra
	Mancha	Rachadura	Localização	Faltando	Outros	
1	35,60	58,00	23,20	21,60	11,60	150
2	29,67	48,33	19,33	18,00	9,67	125
3	23,73	38,67	15,47	14,40	7,73	100
Total	89	145	58	54	29	375

O teste compara as frequências observadas da **Erro! Fonte de referência não encontrada.** com as frequências esperadas da **Erro! Fonte de referência não encontrada.**12:

- Estatística de teste: $\chi^2_{teste} = \sum_{i=1}^{I}\sum_{j=1}^{J} \frac{(o_i j - e_{ij})^2}{e_{ij}} = 14{,}16$

A distribuição inerente define o valor crítico χ^2_{α} a partir de (I - 1)(J - 1) graus de liberdade.

- Região de rejeição: $\chi^2_{teste} > 15{,}51$, considerando α = 0,05 e 8 graus de liberdade.

A conclusão é que a hipótese nula não pode ser rejeitada (o Valor-P é 0,078). Ou seja, as populações podem ser homogêneas, o que quer dizer que as razões de não conformidade têm a mesma proporção ao comparar uma linha de montagem com outra.

7.4. Teste de independência

Conforme veremos a partir do exemplo a seguir, a mecânica do teste de independência é idêntica à mecânica do teste de homogeneidade.

Exemplo: Um estudo da relação entre as condições das instalações nos postos de combustíveis e da agressividade na composição do preço dos combustíveis está resumido abaixo:

Tabela 13. Quantidade de postos, por política de preço e tipo de instalação

Instalações	Política de Preço			Total
	Agressiva	Neutra	Não agressiva	
Muito simples	24	15	17	56
Padrão	52	73	80	205
Moderno	58	86	36	180
Total	134	174	133	441

Num nível de 0,01 de significância, os dados sugerem que as condições das instalações e a política de preços são independentes uma da outra?

Solução: As frequências esperadas são calculadas com base na hipótese de independência:

$$e_{ij} = \frac{(\text{total da linha } i) \times \text{total da coluna } j}{\text{tamanho total da amostra}}$$

E então as frequências esperadas podem ser vistas na Tabela 14.

Tabela 14. Frequências esperadas de postos de combustível

Instalações	Política de Preço			Total
	Agressiva	Neutra	Não agressiva	
Muito simples	17,02	22,10	16,89	56
Padrão	62,29	80,88	61,83	205
Moderno	54,69	71,02	54,29	180
Total	134	174	133	441

O teste pode ser conduzido:

- Hipótese de teste: $\begin{cases} H_0: \pi_{ij} = \pi_i \times \pi_j, \text{ para } i = 1,2,3 \text{ e } j = 1,2,3 \\ H_1: H_0 \text{ não é verdadeira} \end{cases}$

A interpretação de π_{ij} pode ser feita de duas formas: é a proporção da categoria j dentro da categoria i ou, ao contrário, é a proporção da categoria i dentro da categoria j. O valor π_i é a proporção da categoria i em toda a população, e π_j é a proporção da categoria j em toda a população.

- Estatística de teste: $\chi^2_{teste} = \sum_{i=1}^{I}\sum_{j=1}^{J} \frac{(o_i j - e_{ij})^2}{e_{ij}} = 22,47$

- Região de rejeição: $\chi^2_{teste} > 13,28$, considerando α = 0,05 e 4 graus de liberdade.

A conclusão é de que a hipótese nula pode ser rejeitada (o Valor-P é 0,004). Ou seja, os fatores não são independentes. Assim, a política de preços varia de conforme o tipo de instalação.

Capítulo 8. Estatística multivariada

A estatística tem ferramentas próprias para lidar com ocorrências simultâneas de variáveis. É muito conveniente estudar fenômenos que estão relacionados de uma forma única, tirando proveito dessa relação. Por exemplo, é esperado que indivíduos mais altos tenham mais peso, ou que famílias com maior renda tenham maior patrimônio.

Os Diagramas de Dispersão são usados para dados numéricos consistindo em observações emparelhadas, feitas a partir de duas variáveis numéricas. Uma variável é medida no eixo vertical, e a outra, no eixo horizontal. Diagramas de Dispersão são usados para determinar possíveis relações entre duas variáveis numéricas.

Exemplo: Este exemplo norteará os diversos conceitos do capítulo.

Um fazendeiro sabe a importância da quantidade de fertilizante que utiliza. O lucro que será observado ao final da safra depende, entre outras coisas, da quantidade de fertilizante utilizada. Matematicamente:

$$\text{Lucro} = f(\text{Fertilizante})$$

Os dados a seguir referem-se a sete safras em que diferentes quantidades de fertilizante foram utilizadas e diferentes lucros foram auferidos:

Tabela 13. Dados do fazendeiro: fertilizante e lucro

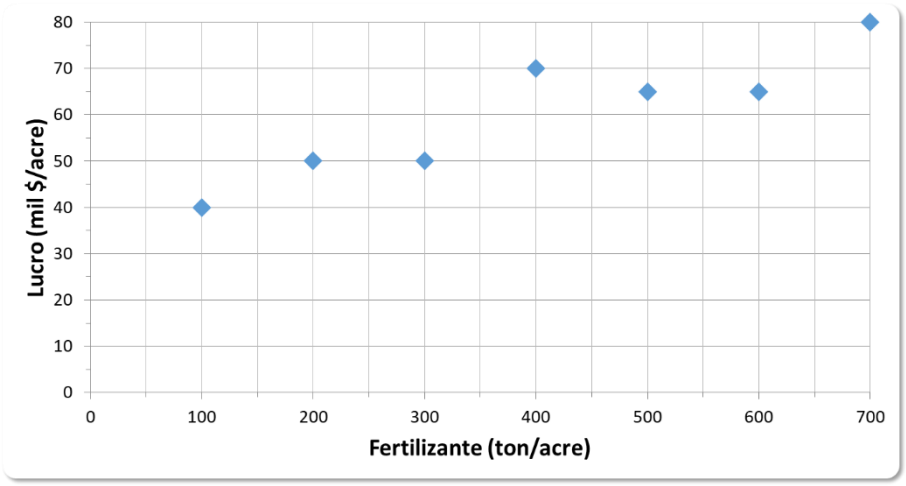
Fertilizante (ton./acre)	Lucro (mil R$/acre)
100	40
200	50
300	50
400	70
500	65
600	65
700	80

8.1. Apresentação – diagrama de dispersão

O diagrama de dispersão equivale ao plano cartesiano, onde é feita a escolha de qual variável estará no eixo horizontal (eixo x, ou eixo das abcissas) e qual

variável estará no eixo vertical (eixo y, ou eixo das ordenadas). Na **Erro! Fonte de referência não encontrada.**, a variável lucro foi escolhida para estar no eixo das ordenadas, porque assume-se que o lucro é função do fertilizante, y = f(x).

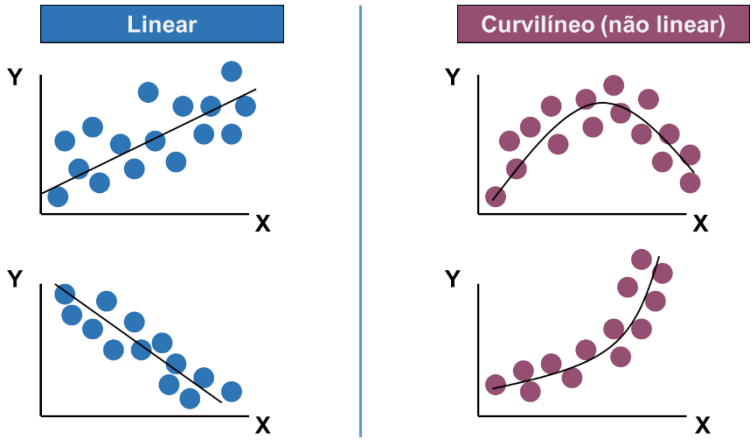
Figura 27. Diagrama de dispersão para os dados do fazendeiro



A análise do diagrama de dispersão identifica a relação entre as variáveis, permitindo classificar o tipo e identificar a intensidade. Na **Erro! Fonte de referência não encontrada.**, é possível ver que os tipos de relacionamento são linear ou não linear. Os relacionamentos lineares são muito importantes. Primeiro porque são muito frequentes, ou porque muitos relacionamentos não lineares conseguem ser transformados matematicamente em relacionamentos lineares. Além disso, os relacionamentos lineares são bem simples, o que os tornam fáceis de serem modelados e interpretados.

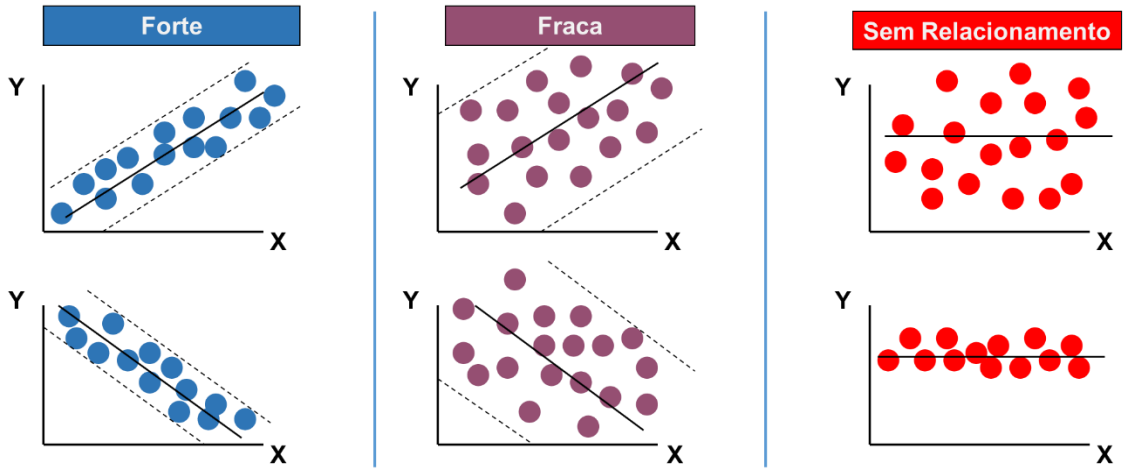
O tipo do relacionamento sugere um modelo de representação. Os relacionamentos lineares são modelados por uma reta. Os relacionamentos não lineares podem ser modelados por parábolas, gráficos exponenciais, logaritmos, entre outros.

Figura 23. Tipos de relacionamento entre variáveis



A partir da suposição do tipo (e da forma) de relacionamento entre as variáveis, é possível usar o diagrama de dispersão para interpretar a intensidade do relacionamento. Diz-se que o relacionamento é forte quando o diagrama fica mais parecido com o modelo subjacente. Na **Erro! Fonte de referência não encontrada.**, é possível ver exemplos de relacionamentos lineares fortes, quando comparados com relacionamentos lineares fracos. A proximidade dos pontos com a reta determina a força do relacionamento.

Figura 29. Intensidade do relacionamento entre variáveis



A última coluna da **Erro! Fonte de referência não encontrada.** mostra dois exemplos classificados como sem relacionamento. O exemplo anterior apresenta uma nuvem de pontos que não tem forma. Já o exemplo que está na parte de baixo da última coluna sugere a existência de um modelo linear horizontal. Entretanto, o modelo linear horizontal é uma situação especial de falta de relacionamento (idem para uma situação que seja um modelo linear vertical). Não há relacionamento sempre que a alteração do valor de uma das variáveis não está associada à alteração do valor da outra variável.

8.2. Descrição – covariância

A covariância é um indicador que, no caso populacional, pode ser calculado assim:

$$\sigma_{XY} = \frac{SQXY}{N}$$

Onde $SQXY = \sum XY - N \times \bar{X} \times \bar{Y}$, sendo N o tamanho da população. Se o conjunto de dados sob análise representar uma amostra, a covariância deve ser calculada assim:

$$s_{XY} = \frac{SQXY}{n-1}$$

Onde $SQXY = \sum XY - n \times \bar{X} \times \bar{Y}$, sendo n o tamanho da amostra.

A covariância pode ser não nula (positiva ou negativa) ou apresentar um resultado nulo. Para o caso de um valor não nulo, a interpretação será:

Covariância positiva:

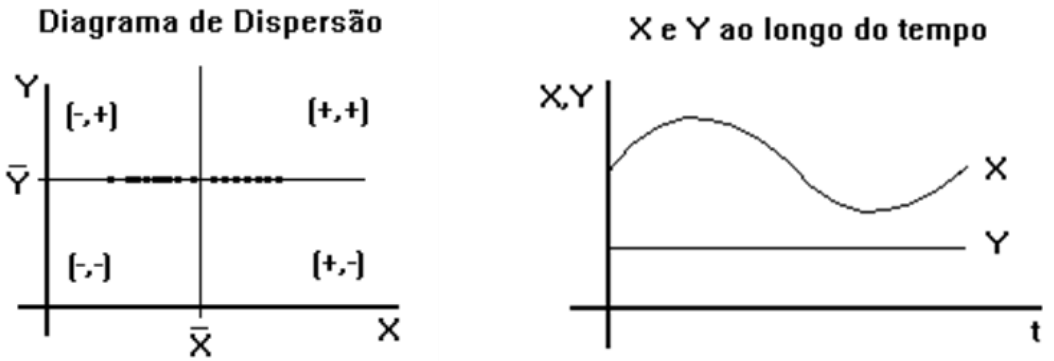
- X e Y linearmente dependentes com relacionamento positivo.
- Se X aumenta, é esperado que Y também aumente, e vice-versa.

Covariância negativa:

- X e Y linearmente dependentes com relacionamento negativo
- Se X sobe, Y cai; se X cai, Y sobe.

Para o caso de um valor nulo, deveremos observar que, se duas variáveis forem independentes, necessariamente apresentarão covariância nula. Mas, se duas variáveis apresentarem covariância nula, não necessariamente serão variáveis independentes. Isso porque a covariância mede o relacionamento linear.

Figura 30. Covariância nula: sem relacionamento

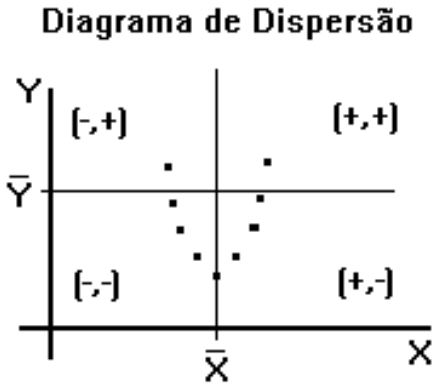


A situação representada na **Erro! Fonte de referência não encontrada.** é sem relacionamento nenhum, pois uma das variáveis (*Y*) apresenta valor constante.

Deve estar bem evidente que alterações na variável *X* não provocam alterações na variável *Y*.

A **Erro! Fonte de referência não encontrada.** apresenta uma situação especial. É possível ver um diagrama de dispersão onde as variáveis apresentam claramente um relacionamento. Uma parábola é um relacionamento quadrático. Entretanto, a covariância nesse exemplo também é nula, o que ressalta a característica de que a covariância mede apenas o relacionamento linear.

Figura 24. Covariância nula: sem relacionamento linear, mas com relacionamento não linear



Exemplo: A partir da amostra é possível calcular os indicadores:

Fertilizante (ton./acre)	Lucro (mil R$/acre)
100	40
200	50
300	50
400	70
500	65
600	65
700	80

$$\sum X = 2.800 \text{ e } \sum Y = 420$$

$$\bar{X} = \frac{\sum X}{n} = 400 \quad \bar{Y} = \frac{\sum Y}{n} = 60$$

e

E ainda $\sum XY = 184.500$

Então:

$$SQXY = \sum XY - n \times \bar{X} \times \bar{Y} = 184.500 - 7 \times 400 \times 60 = 16.500$$

Temos, então, $s_{XY} = \frac{SQXY}{n-1} = \frac{16.500}{6} = 2.750$

A covariância é não nula, indicando que há um relacionamento linear. Além disso, seu sinal positivo indica a direção do relacionamento: o crescimento de uma variável deve ser acompanhado do crescimento da outra variável. Ou a redução do valor de uma variável deve ser acompanhada da redução do valor da outra variável. Isso está de acordo com o diagrama de dispersão dessa amostra, apresentado na **Erro! Fonte de referência não encontrada.**.

8.3. Covariância de variáveis aleatórias e combinação de variáveis

As variáveis aleatórias são definidas através da distribuição de probabilidades, portanto o cálculo da covariância precisa ser feito através dessas distribuições de probabilidade. A covariância, nesse caso, é populacional e pode ser calculada para variáveis discretas da seguinte forma:

$$\sigma_{XY} = \sum_{i=1}^{n} X_i Y_i P_i - E(X) \times E(Y)$$

Considere que se deseja obter uma nova variável aleatória a partir de uma combinação de outras duas. Seja $Z = aX + bY$, onde Z, X e Y são variáveis aleatórias e *a* e *b* são tais que a,b > 0 e a + b = 1.

É possível definir os parâmetros dessa variável combinada:

$$E(Z) = aE(X) + bE(Y)$$

$$Var(Z) = \sigma_Z^2 = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\sigma_{XY}$$

Exemplo: Os retornos dos fundos de investimento dependem da condição econômica. As condições econômicas futuras são avaliadas por analistas que fazem previsões com base em probabilidades de ocorrência.

Considere dois fundos de investimento, cujos retornos possíveis estão descritos a seguir em função dos cenários econômicos futuros:

		Investimento	
P(xy)	**Condição econômica**	**Fundo Dow Jones**	**Fundo p/ condições econômicas ruins**
0,2	Recessão	-R$300,00	+R$200,00
0,5	Economia Estável	+R$100,00	+R$50,00
0,3	Economia em expansão	+R$250,00	-R$100,00

Com base na covariância dos retornos desses fundos, qual é o retorno esperado para um investimento que combine 50% do capital em cada um dos fundos?

Solução: A partir da amostra é possível calcular:

$$E(X) = 65 \text{ e } E(Y) = 35$$

$$\sigma_X^2 = 37.525 \text{ e } \sigma_Y^2 = 11{,}025$$

E então:

$$\sigma_{XY} = \sum_{i=1}^{n} X_i Y_i P_i - E(X)E(Y)$$

=(-300 × 200 × 0,2 + 100 × 50 × 0,5 + 250 × -100 × 0,3) – 65 × 35

A combinação proposta é Z = 0,5X + 0,5Y. Os parâmetros de Z serão dados por:

$$E(Z) = 0{,}5 \times 65 + 0{,}5 \times 35 = 50$$

$$\sigma_Z^2 = 0{,}25 \times 37525 + 0{,}25 \times 11025 + 0{,}5 \times -19275 = 2.500$$

$$\sigma_Z = 50$$

8.4. Descrição – correlação

A correlação é um indicador cujo cálculo não depende de o conjunto sob análise ser uma amostra ou uma população. Se os dados representarem uma amostra, a correlação será indicada por *r*. Se os dados representarem uma população, a correlação será indicada por *ρ*.

A correlação é calculada assim:

$$r \text{ ou } \rho = \frac{SQXY}{\sqrt{SQX \times SQY}}$$

Onde:

$$SQXY = \sum XY - n \times \bar{X} \times \bar{Y}$$

$$SQX = \sum X^2 - n \times \bar{X}^2$$

$$SQY = \sum Y^2 - n \times \bar{Y}^2$$

sendo n o tamanho da amostra

A correlação e a covariância guardam uma importante relação uma com a outra:

$$\rho = \frac{\sigma_{XY}}{\sigma_X \times \sigma_Y}$$

Ou seja, a covariância dividida pelo produto dos desvios-padrão é igual à correlação. Isso vale também no âmbito amostral:

$$s = \frac{s_{XY}}{s_X \times s_Y}$$

A análise do sinal do coeficiente de correlação é feita de forma idêntica ao sinal da covariância. Mas o coeficiente de correlação amplia a capacidade analítica da covariância. Isso porque a análise da Covariância está limitada ao seu sinal. Os limites de valor da covariância (máximo e mínimo) não são óbvios. Por exemplo, uma covariância igual a 100 pode ser grande para determinado conjunto de dados e pequena para outro conjunto. Isso porque a covariância tem como limite o produto dos desvios-padrão das variáveis.

Além disso, a covariância é medida em uma unidade difícil de ser compreendida, que é o produto das variáveis originais. Ou seja, se X e Y estão medidos em R$, então a medida da covariância de X e Y é R$ ao quadrado. Por outro lado, o coeficiente de correlação não possui unidades.

A característica mais relevante do coeficiente de correlação é que ele é limitado:

$$-1 \leq \rho \leq 1$$

Essa característica permite quantificar o grau de dependência entre as variáveis.

Exemplo: A partir da amostra foi possível calcular os indicadores:

Fertilizante (ton/acre)	Lucro (mil R$/acre)
100	40
200	50
300	50
400	70
500	65
600	65
700	80

$$\sum X = 2.800 \text{ e } \sum Y = 420$$

$$\bar{X} = \frac{\sum X}{n} = 400 \text{ e } \bar{Y} = \frac{\sum Y}{n} = 60$$

$$\sum XY = 184.500 \text{ e } SQXY = 16.500$$

$$\text{E } s_{XY} = \frac{SQXY}{n-1} = \frac{16.500}{6} = 2.750$$

E agora, $\sum X^2 = 1.400.000$ e $\sum Y^2 = 26.350$.

Com isso, $SQX = \sum X^2 - n \times \bar{X} = 280.000$ e $SQY = \sum Y^2 - n \times \bar{Y}^2 = 1.150$

Então:

$$r = \frac{SQXY}{\sqrt{SQX \times SQY}} = \frac{16.500}{\sqrt{280.000 \times 1.150}} = 0{,}9195$$

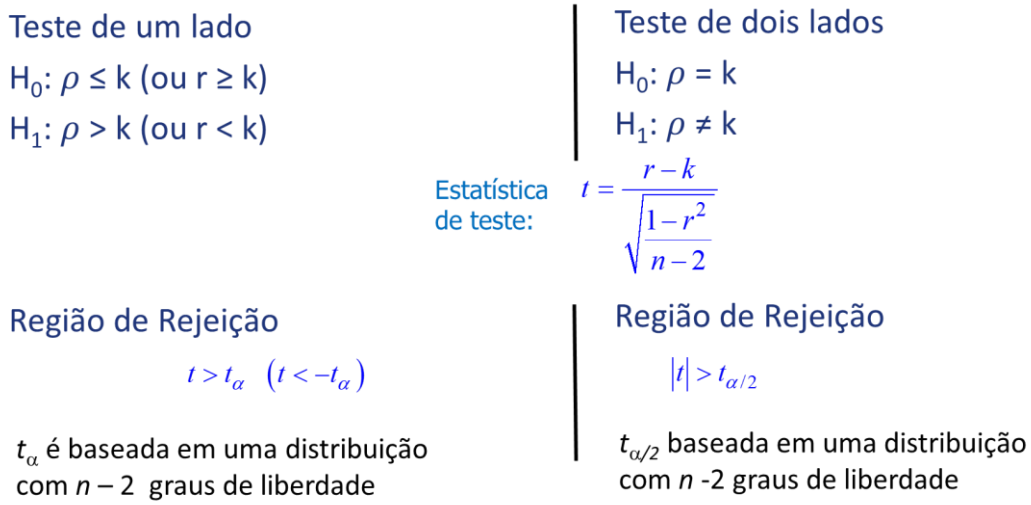
A análise deste indicador também permite concluir que a direção do relacionamento entre X e Y é positivo. Mas permite concluir, também, que a relação é forte, uma vez que o indicador está próximo de 1.

8.5. Inferência para a correlação

Em algumas situações, pode ser necessário testar alguma hipótese sobre o valor populacional da correlação, mesmo tendo apenas informações amostrais. Uma hipótese importante que precisa ser rejeitada é a de que a correlação não é zero, o que significa a existência de um relacionamento linear entre as variáveis sob análise.

As técnicas de teste de hipóteses já foram apresentadas, mas para o caso da correlação os elementos importantes estão descritos na **Erro! Fonte de referência não encontrada.**. Esse teste usa a distribuição t de Student.

Figura 32. Regras para teste de hipóteses da correlação



Exemplo: A partir dos dados do caso do fazendeiro, tínhamos n = 7 e r = 0,9195. É possível, usando significância igual a $\alpha = 0{,}05$, sustentar a hipótese de que a correlação não é nula?

Solução:

1. $\begin{cases} H_0: \rho = 0 \\ H_1: \rho \neq 0 \end{cases}$.
2. $\alpha = 0{,}05$.
3. $t_{teste} = \dfrac{r-\rho}{\sqrt{\dfrac{1-r^2}{n-2}}}$.
4. n = 7, r = 0,9195 .
5. Com seis graus de liberdade $t_{0{,}025} = 2{,}57$. Assim, rejeita H_0 se $|t_{teste}| > 2{,}57$.

6. $$t_{teste} = \frac{0{,}9195}{\sqrt{\frac{1 - 0{,}9195^2}{7 - 2}}} = 5{,}23$$.

7. Decisão: não rejeita H_0.

Ou seja, a correlação é significativa.

8.6. Regressão linear simples

Regressões são modelos matemáticos em forma de equações que procuram expressar as relações de causa (uma ou mais variáveis independentes) e efeito (uma única variável dependente). As regressões pode ser:

- Lineares ou não lineares.
- Múltiplas ou simples.

Vamos realizar o estudo das regressões lineares simples. No início do processo é importante identificar:

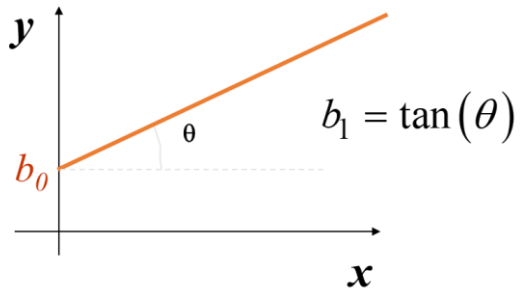
- Variável dependente, ou variável explicada (y)
- Variável independente, ou variável explicadora (x)

O modelo de regressão linear é uma reta, que é descrita pela equação de primeiro grau:

$$\hat{Y} = b_0 + b_1 X$$

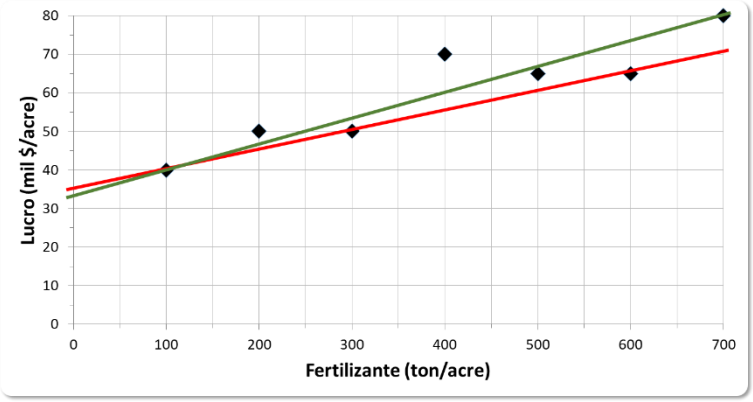
Os coeficientes dessa equação têm interpretações importantes. São chamados de coeficiente linear (b_0) e coeficiente angular (b_1). Veja na **Erro! Fonte de referência não encontrada.** a interpretação dos coeficientes: o coeficiente linear está associado ao valor de Y quando X é zero, que é o ponto de interseção da reta com o eixo Y. Já o coeficiente angular está associado à inclinação da reta e pode ser medido como a tangente do ângulo que a reta forma com o eixo X.

Figura 33. Interpretação gráfica da regressão linear simples



A partir de uma amostra, é possível projetar diferentes retas sobre os pontos. Por exemplo, na **Erro! Fonte de referência não encontrada.** estão projetadas duas retas sobre os pontos que são a amostra do caso do fazendeiro. O critério de escolha da melhor reta é chamado de Mínimos Quadrados dos Resíduos. Alguns conceitos importantes precisam ser definidos.

Figura 34. Possíveis retas para modelar os dados do fazendeiro



$\hat{Y}_i$ é o valor estimado para Y_i. $\hat{Y}_i$ é o valor que está sob a reta. Como $\hat{Y}_i$ não é igual a Y_i, define-se que a diferença entre eles é o resíduo: $\varepsilon_i = Y_i - \hat{Y}_i$. Por conta disso, a equação de regressão pode ser escrita de duas formas:

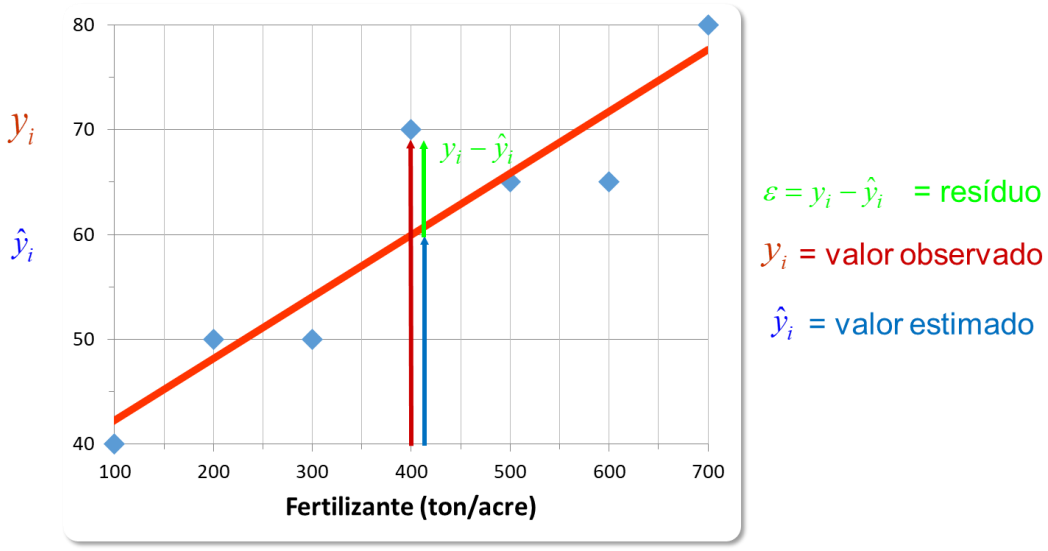
$t_{0,025} = 2,57$

$$\hat{Y}_i = b_0 + b_1 X_i$$

$$Y_i = b_0 + b_1 X_i + \varepsilon_i$$

Esses elementos estão demonstrados na Figura 35. É possível ver que, para o ponto selecionado, com $X_i = 400$, têm-se $Y_i = 70$ e $\hat{Y}_i = 60$. Logo, $\varepsilon_i = 10.$

Figura 25. Y real, Y estimado e resíduo



Para determinar a melhor reta, o procedimento dos mínimos quadrados busca os valores para os coeficientes que minimizam a expressão conhecida como Soma dos Quadrados dos Resíduos (SQR):

$$SQR = \sum \varepsilon_i^2 = \sum (Y_i - \hat{Y}_i)^2 = \sum (Y_i - b_0 - b_1 X_i)^2$$

Através de procedimentos de cálculo, é possível determinar que os valores de b_0 e de b_1 que minimizam SQR são dados por:

$$b_1 = \frac{SQXY}{SQX}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

Exemplo: A partir dos dados do caso do fazendeiro, tínhamos $SQXY = 16.500$, $SQX = 280.000$, $\bar{X} = 400$ e $\bar{Y} = 60$.

1) Como fica a equação de regressão?
2) Qual interpretação dos valores estimados para os parâmetros?
3) Quais são os valores previstos para o lucro se forem usadas 400 ton./acre de fertilizante? Como isso se compara com o observado?
4) Quais são os valores previstos para o lucro se forem usadas 1.200 ton./acre de fertilizante? Como isso se compara com o observado?

Solução: A equação tem a forma $\hat{Y} = b_0 + b_1 X$, sendo:

$$b_1 = \frac{SQXY}{SQX} = \frac{16.500}{280.000} = 0{,}0589$$

$$b_0 = \bar{Y} - b_1 \times \bar{X} = 60 - 0{,}0589 \times 400 = 36{,}4286$$

Então, a equação de regressão fica:

$$\hat{Y} = 36{,}4286 + 0{,}0589X$$

1) O coeficiente linear $b_0 = 36{,}4286$ é interpretado como o valor previsto para o Y quando X = 0. Portanto, se houver uma safra onde não seja aplicado fertilizante no solo, o lucro esperado será de $\hat{Y} = 36{,}4286$.

   Aqui cabe uma ressalva importante sobre a extrapolação: não há, na amostra, nenhum valor de X próximo de 0. Por isso, há pouca certeza sobre esse valor. Esse assunto voltará a abordado a partir da solução da questão 4.

   O coeficiente angular $b_1 = 0{,}0589$ é

interpretado como a inclinação da reta e está relacionado com o aumento no $\hat{Y}$ em função do aumento do X: sempre que X aumentar uma unidade, $\hat{Y}$ vai aumentar $0{,}0589$ unidade. Portanto, cada tonelada a mais de fertilizante usada em cada acre vai levar a um aumento no lucro na ordem de R$0,0589.

Se $X = 400$, então $\hat{Y} = \hat{Y} = 36{,}4286 + 0{,}0589 \times 400 = 36{,}4286 + 23{,}56 = 59{,}9886$. Ou seja, a previsão é de que o lucro seja de R$59,9886.

Comparando com a amostra, vemos que há uma observação onde $X = 400$ e $Y = 70$. Assim, é possível encontrar como resíduo $\varepsilon = Y - \hat{Y} = 70 - 59{,}9886 = 10{,}0114$.

A divergência entre o valor estimado e o valor observado precisa ser interpretada com cautela. Apesar de ter havido um lucro de R$70,00 quando foram usadas 400 ton. de fertilizante, a previsão era de que o lucro seria de apenas R$60,00. A observação colhida foi extraordinariamente boa. Se outras safras fossem realizadas com a mesma quantidade de fertilizante, os lucros não seriam todos iguais – alguns seriam maiores e outros seriam menores. O modelo de regressão prevê que a média (o valor esperado) é R$59,9886.

2) Se $X = 1.200$, então $\hat{Y} = \hat{Y} = 36{,}4286 + 0{,}0589 \times 1.200 = 36{,}4286 + 70{,}68 = 107{,}1086$. Ou seja, a previsão é de que o lucro seja de R$107,1086.

Na tentativa de comparar com o observado, descobrimos que nenhuma observação foi feita com X = 1.200. Então, essa comparação não pode ser feita. Registra-se que essa previsão é uma extrapolação ao domínio da variável explicativa, e isso é um perigo adicional para a precisão da previsão.

As observações amostrais consideram sete valores de X. O menor deles é 100 e o maior é 700. Qualquer previsão feita considerando X entre 100

e 700 é chamada de interpolação. Qualquer previsão considerando X menor do que 100 ou maior do que 700 é chamada de extrapolação.

A extrapolação é sempre mais arriscada, porque não se sabe exatamente o comportamento dos dados fora do domínio de estudo. Os tamanhos do resíduo servem de apoio para analisar as previsões de interpolação. Não são muito úteis para analisar as previsões de extrapolação, onde os resíduos podem ficar muito grandes.

8.6.1. Decomposição da variação da variável dependente

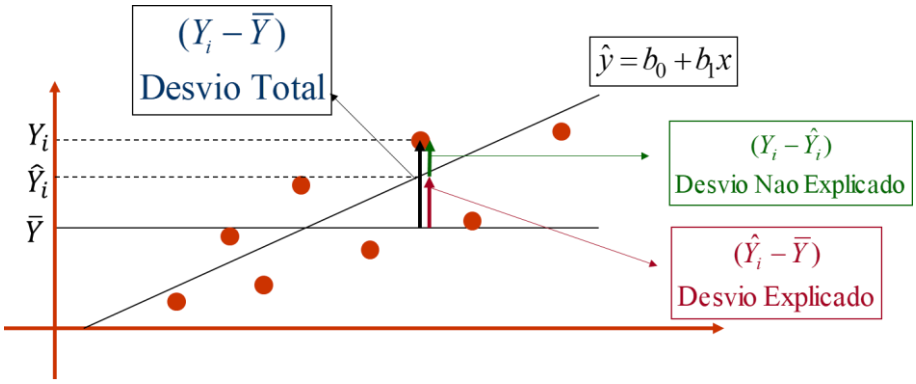
Se queremos prever o valor da variável dependente Y sem conhecer o exato valor da variável independente, nossa melhor estimativa seria o valor da média amostral de Y.

Caso conheçamos o valor de X, podemos calcular a melhor regressão dada pela amostra e, portanto, calcular o valor de Y através da regressão obtida. Isso significa dizer que conseguimos explicar parte do nosso erro de previsão.

A expressão $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + (Y_i - \hat{Y}_i)$ é uma identidade matemática: uma rápida olhada no segundo membro mostra que $\hat{Y}_i$ aparece duas vezes, uma com sinal positivo e outra com sinal negativo, de forma que se cancelam, e o segundo membro é idêntico ao primeiro.

A Figura 36 dá uma interpretação geométrica para a equação. A partir de um ponto selecionado, são identificados o valor observado Y_i e o valor estimado pela regressão $\hat{Y}_i$. Além disso, está identificada também a média dos valores amostrais $\bar{Y}$. O valor $Y_i - \bar{Y}$ é chamado de desvio total e não depende da regressão: é uma característica da variável dependente. O desvio total é decomposto em duas parcelas, sendo que $Y_i - \hat{Y}_i$ – que é o que inicialmente chamamos de resíduo – representa o desvio que a regressão não consegue explicar. Ao passo que $\hat{Y}_i - \bar{Y}$ representa o ganho da regressão: a parcela que pode ser explicada.

Figura 26. Desvio total, explicado e não explicado



A análise feita individualmente vale para cada ponto, mas em algumas situações essas parcelas podem ficar negativas. Ao considerar todos os pontos simultaneamente, é possível provar que essa relação continua ao considerar o quadrado dos valores. Ou seja:

$$\sum(Y_i - \bar{Y})^2 = \sum\left(\hat{Y}_i - \bar{Y}\right)^2 + \sum\left(Y_i - \hat{Y}_i\right)^2$$

A soma dos desvios quadrados é chamada de variação. Então, a identidade acima é lida como: Variação Total é igual a Variação Explicada mais Variação não Explicada. A Variação Total será indicada por SQT; a Variação Explicada será indicada por $SQReg$; e a Variação não Explicada será indicada por SQR. Assim, a expressão acima é reescrita como:

STQ = SQReg + SQR

Onde:

- $STQ = SQY = \sum(Y_i - \bar{Y})^2 = \sum Y_i^2 - n \times \bar{Y}^2$
- $SQReg = \sum\left(\hat{Y}_i - \bar{Y}\right)^2 = b_1 \times SQXY$

- $SQR = \sum(Y_i - \hat{Y}_i)^2 = SQY - b_1 \times SQXY$

A partir da decomposição da variação total da variável dependente, é possível definir uma estatística que mede a proporção que é explicada pela regressão:

$$R^2 = \frac{\text{Variação Explicada}}{\text{Variação Total}} = 1 - \frac{\text{Variação não Explicada}}{\text{Variação Total}}$$

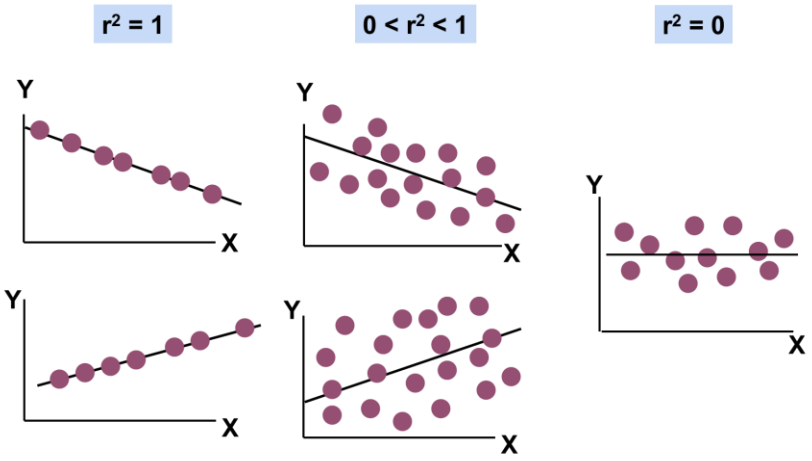
Essa estatística é chamada de coeficiente de determinação. Em termos numéricos, a fórmula computacional para ela é:

$$R^2 = \frac{SQReg}{STQ} = 1 - \frac{SQR}{STQ}$$

O coeficiente de determinação é uma proporção, então:

- $0 \leq R^2 \leq 1$.
- Se R^2 for próximo de 1 a regressão tem um bom ajustamento.
- Se R^2 for próximo de 0 a regressão tem um fraco ajustamento.

Figura 37. Exemplos de valores de R^2



Exemplo: Considerando os dados do fazendeiro:

5) Qual a variação total da variável dependente?
6) Como a variação é decomposta pela regressão?
7) Qual o valor do coeficiente de determinação e como ele é analisado?

Solução:

1) A variação total da variável dependente é $STQ = SQY = \sum Y_i^2 - n \times \bar{Y}^2$.

Esse valor já foi calculado anteriormente e é $STQ = 1.150$.

2) A decomposição da variação total é $STQ = SQReg + SQR$.

- $SQReg = \sum(\hat{Y}_i - \bar{Y})^2 = b_1 \times SQXY = 0{,}0589 \times 16.500 = 972{,}32$.
- $SQR = \sum(Y_i - \hat{Y}_i)^2 = SQY - b_1 \times SQXY = 1.150 - 972{,}32 = 177{,}68$.

3) A partir da decomposição da variação é possível calcular:

$$R^2 = 1 - \frac{SQR}{STQ} = 1 - \frac{177{,}68}{1.150} = 0{,}8455$$

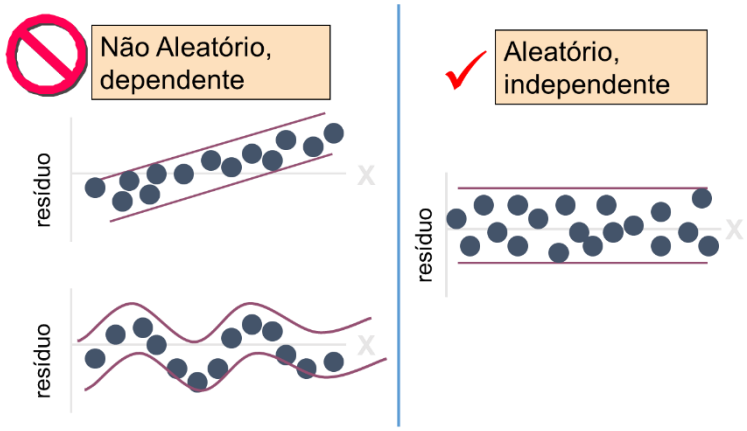
A análise é que o valor é alto, próximo de 1. Indica que 84,55% das variações do lucro do fazendeiro podem ser explicadas pela quantidade de fertilizante que ele colocou no solo.

8.6.2. Análise dos resíduos

Os resíduos oferecem importante fonte de informação para validar pressupostos teóricos do Modelo de Regressão. Dessa forma, os resíduos são analisados em um gráfico onde seus valores são lançados no eixo das ordenadas (vertical), e a variável independente, no eixo das abcissas (horizontal). Neste gráfico espera-se ver:

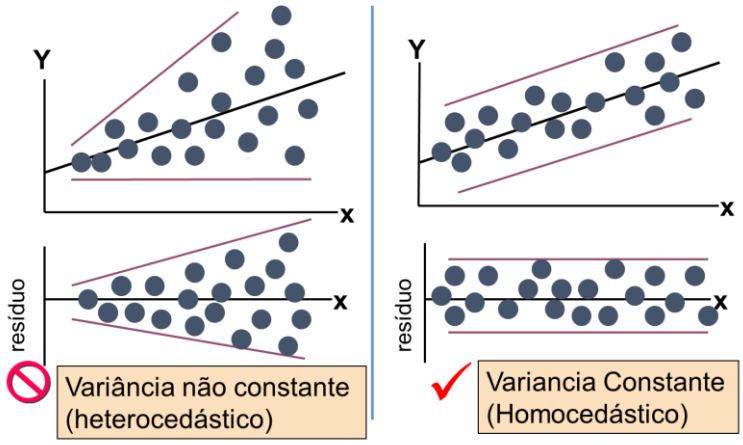
1) Aleatoriedade e independência dos resíduos (veja **Erro! Fonte de referência não encontrada.**)
2) Homocedasticidade, ou dispersão constante (veja **Erro! Fonte de referência não encontrada.**)

Figura 27. Aleatoriedade e independência dos resíduos



Além disso, os resíduos devem seguir uma distribuição normal, com média igual a zero. Algumas vezes, é necessário realizar um procedimento de verificação. Mas, se a amostra for grande o suficiente, isso não é necessário.

Figura 28. Heterocedasticidade e homocedasticidade



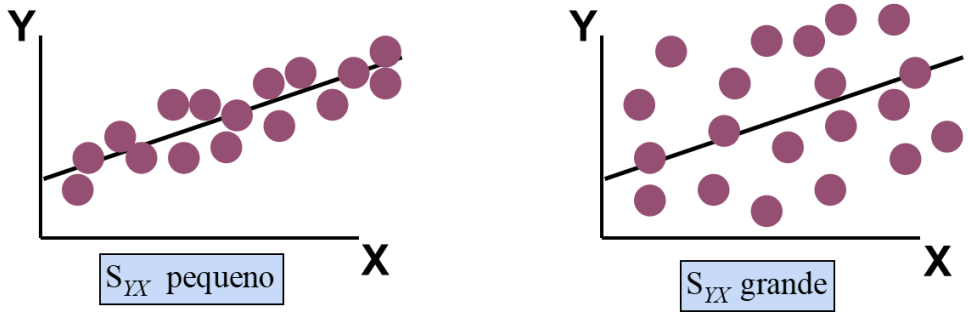
8.6.3. Inferências no modelo de regressão

Os resíduos da regressão têm média zero. Isso é observado já na amostra, quando a estimativa é feita pelo método dos mínimos quadrados ordinários. Então, não há maiores dúvidas sobre como a população se comporta. Entretanto, os resíduos podem ser grandes ou pequenos, quando analisados em módulo. Um indicador importante para mensurar o tamanho dos resíduos é o erro-padrão, que é dado por:

$$s_{XY} = \sqrt{\frac{SQR}{n-2}}$$

A interpretação do valor do erro-padrão dos resíduos está associada à qualidade do ajustamento. Veja, na **Erro! Fonte de referência não encontrada.**0, uma interpretação gráfica para o erro-padrão:

Figura 40. Interpretação do valor do erro-padrão



O erro-padrão da estimativa é usado também para estimar o erro-padrão da inclinação:

$$s_{b_1} = \frac{s_{XY}}{\sqrt{XQX}}$$

Assim, é possível estimar um intervalo de confiança para a inclinação verdadeira, ou seja, o coeficiente angular populacional, β_1:

$$\beta_1 = b_1 \pm t_{\alpha/2} \times s_{b_1}$$

Ou seja:

$$\beta_1 \in \left(b_1 - t_{\alpha/2} \times s_{b_1} \; ; \; b_1 + t_{\alpha/2} \times s_{b_1}\right)$$

A distribuição t de Student sempre será usada para essa estimativa. O grau de liberdade é $n - 2$.

Exemplo: O erro-padrão da estimativa para o caso do fazendeiro é definido por:

$$s_{XY} = \sqrt{\frac{SQR}{n-2}} = \sqrt{\frac{177{,}68}{5}} = \sqrt{35{,}5{,}4} = 5{,}96$$

E o erro-padrão para o parâmetro de inclinação (coeficiente angular) é:

$$s_{b_1} = \frac{s}{\sqrt{SQX}} = \frac{5{,}96}{\sqrt{280.000}} = 0{,}0112$$

Assim, considerando 95% de confiança ($\alpha = 0{,}05$) e $n - 2 = 5$ graus de liberdade, encontramos $t_{0{,}025} = 2{,}5706$. Então:

$$\beta_1 = b_1 \pm t_{\alpha/2} \times s_{b_1} = 0{,}0589 \pm 2{,}5706 \times 0{,}0112$$

Ou seja:

$$\beta_1 \in (0{,}0301\ ;0{,}0877)$$

Também é possível conduzir um teste de hipóteses sobre o verdadeiro valor da inclinação (coeficiente angular populacional).

Figura 41. Teste de hipóteses para a inclinação verdadeira

Teste de um lado		**Teste de dois lados**
H_0: $\beta_1 \leq k$ (ou $\beta_1 \geq k$)		H_0: $\beta_1 = k$
H_1: $\beta_1 > k$ (ou $\beta_1 < k$)		H_1: $\beta_1 \neq k$
	Estatística de teste: $t = \frac{b_1 - k}{s_{b_1}}$	
Região de Rejeição $t > t_\alpha$ $(t < -t_\alpha)$ t_α é baseada em uma distribuição com $n - 2$ graus de liberdade		Região de Rejeição $\lvert t \rvert > t_{\alpha/2}$ $t_{\alpha/2}$ baseada em uma distribuição com n -2 graus de liberdade

Dentre as diversas hipóteses que podem ser lançadas sobre o coeficiente de inclinação, há uma que é mais importante: a hipótese de que $\beta_1 = 0$ precisa ser rejeitada, ou a regressão não tem utilidade: uma reta com inclinação zero é uma reta horizontal, e isso quer dizer que a variável explicativa não influencia a variável explicada (do mesmo jeito que foi feito na seção 8.5).

Teste de significância da inclinação

1. $\begin{cases} H_0: \beta_1 = 0 \\ H_1: \beta_1 \neq 0 \end{cases}$.
2. α = 0,05.
3. $t_{teste} = \frac{b_1 - 0}{s_{b_1}}$.
4. $n = 7$, $b_1 = 0{,}0589$ e $s_{b_1} = 0{,}0112$.
5. Rejeita H_0 se $|t_{teste}| > 2{,}5706$..
6. $t_{teste} = \frac{0{,}0589 - 0}{0{,}0112} = 5{,}26$.
7. Decisão: rejeita H_0.

Ou seja, a inclinação no caso do fazendeiro é significante, o que quer dizer que a relação entre fertilizante e lucro existe na população. Outra inferência importante a ser feita refere-se a estimar intervalos de confiança para os valores previstos. Os valores previstos podem ter significados diferentes:

1. $\hat{Y}_i = b_0 + b_1 X_i$: a previsão é de um valor pontual de Y_i. Por exemplo, qual é o lucro **da safra** plantada em um solo preparado com 500 ton. de fertilizante por acre?
2. $E(Y_i) = b_0 + b_1 X_i$: a previsão é do valor esperado de Y_i. Por exemplo, qual é o **lucro médio de todas as safras** que foram e serão plantadas em um solo preparado com 500 ton. de fertilizante por acre?

Os intervalos podem ser estimados fazendo-se:

$$E(Y|X_i) = \hat{Y}_i \pm t_{\alpha/2} \times s_{XY}\sqrt{h_i}$$

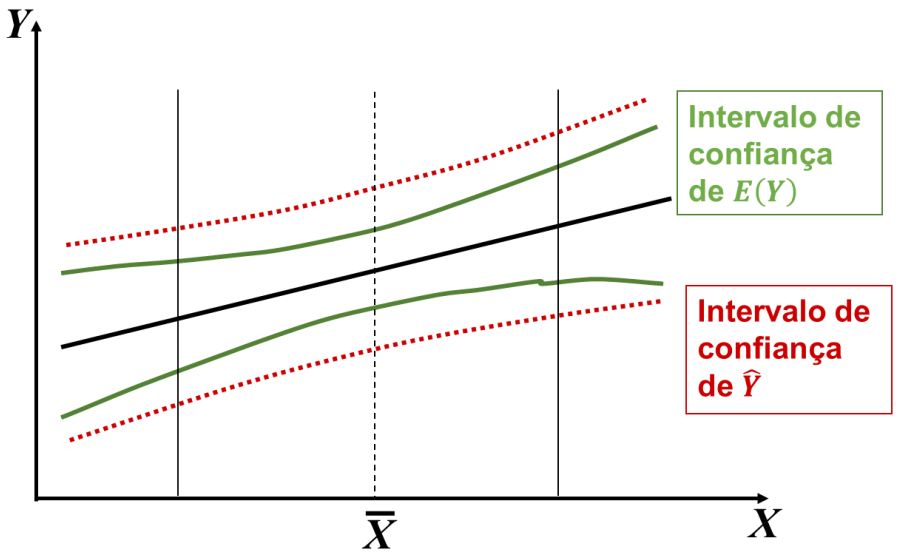
ou

$$Y_i = \hat{Y}_i \pm t_{\alpha/2} \times s_{XY}\sqrt{1 + h_i}$$

Onde: $h_i = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{SQX}$

Como se vê na **Erro! Fonte de referência não encontrada.**, os intervalos de confiança para a previsão pontual são sempre mais amplos do que os intervalos de confiança para os valores esperados. Isso ocorre em consequência do teorema do limite central: o valor esperado tem um comportamento menos errático do que uma ocorrência pontual. Ou seja, é possível que, por conta de outros fatores (clima, cenário econômico etc.), determinada safra seja extraordinariamente boa ou extraordinariamente ruim, levando a lucros muito altos ou muito baixos. Então, a previsão pontual precisa considerar esses fenômenos raros. Mas como o valor esperado é a média dos valores possíveis, e para cada valor muito alto haverá um valor bem baixo, a variabilidade da média será bem menor.

Figura 29. Intervalos de confiança para a previsão



Exemplo: Considerando-se o caso do fazendeiro, deseja-se prever as estimativas intervalares para o caso em que 500 ton. de fertilizante sejam utilizadas em cada acre de terra.

Solução: Para $X_i = 500$, temos $Y_i = 36{,}4286 + 0{,}0589 \times 500 = 65{,}87$.

Para estimar os intervalos de confiança, calculamos $h_i = \frac{1}{7} + \frac{(500-400)^2}{280.000} = 0{,}1786$

.

Assim, a previsão para o valor esperado é:

$$E(Y|X_i = 500) = 65{,}87 \pm 2{,}5706 \times 5{,}96 \times \sqrt{0{,}1786}$$

$$E(Y|X = 500) \in (59{,}40\ ;72{,}34)$$

E a previsão para uma ocorrência individual é:

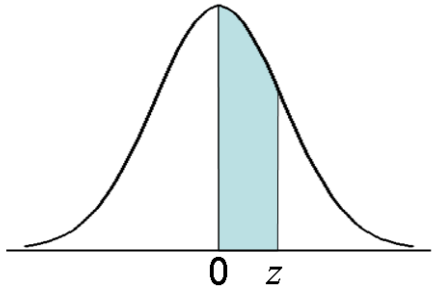
$$Y_i = 65{,}87 \pm 2{,}5706 \times 5{,}96 \times \sqrt{1{,}1786}$$

$$Y_i \in (49{,}23\ ;82{,}50)$$

Capítulo 9. Anexos

9.1. Tabela de distribuição normal

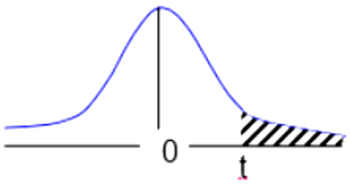
Áreas da curva normal-padrão



z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2517	0,2549
0,7	0,2580	0,2611	0,2642	0,2673	0,2704	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621
1,1	0,3643	0,3665	0,3686	0,3708	0,3729	0,3749	0,3770	0,3790	0,3810	0,3830
1,2	0,3849	0,3869	0,3888	0,3907	0,3925	0,3944	0,3962	0,3980	0,3997	0,4015
1,3	0,4032	0,4049	0,4066	0,4082	0,4099	0,4115	0,4131	0,4147	0,4162	0,4177
1,4	0,4192	0,4207	0,4222	0,4236	0,4251	0,4265	0,4279	0,4292	0,4306	0,4319
1,5	0,4332	0,4345	0,4357	0,4370	0,4382	0,4394	0,4406	0,4418	0,4429	0,4441
1,6	0,4452	0,4463	0,4474	0,4484	0,4495	0,4505	0,4515	0,4525	0,4535	0,4545
1,7	0,4554	0,4564	0,4573	0,4582	0,4591	0,4599	0,4608	0,4616	0,4625	0,4633
1,8	0,4641	0,4649	0,4656	0,4664	0,4671	0,4678	0,4686	0,4693	0,4699	0,4706
1,9	0,4713	0,4719	0,4726	0,4732	0,4738	0,4744	0,4750	0,4756	0,4761	0,4767
2,0	0,4772	0,4778	0,4783	0,4788	0,4793	0,4798	0,4803	0,4808	0,4812	0,4817
2,1	0,4821	0,4826	0,4830	0,4834	0,4838	0,4842	0,4846	0,4850	0,4854	0,4857
2,2	0,4861	0,4864	0,4868	0,4871	0,4875	0,4878	0,4881	0,4884	0,4887	0,4890
2,3	0,4893	0,4896	0,4898	0,4901	0,4904	0,4906	0,4909	0,4911	0,4913	0,4916
2,4	0,4918	0,4920	0,4922	0,4925	0,4927	0,4929	0,4931	0,4932	0,4934	0,4936
2,5	0,4938	0,4940	0,4941	0,4943	0,4945	0,4946	0,4948	0,4949	0,4951	0,4952
2,6	0,4953	0,4955	0,4956	0,4957	0,4959	0,4960	0,4961	0,4962	0,4963	0,4964
2,7	0,4965	0,4966	0,4967	0,4968	0,4969	0,4970	0,4971	0,4972	0,4973	0,4974
2,8	0,4974	0,4975	0,4976	0,4977	0,4977	0,4978	0,4979	0,4979	0,4980	0,4981
2,9	0,4981	0,4982	0,4982	0,4983	0,4984	0,4984	0,4985	0,4985	0,4986	0,4986
3,0	0,4987	0,4987	0,4987	0,4988	0,4988	0,4989	0,4989	0,4989	0,4990	0,4990

9.2. Tabela de distribuição de Student

Valores críticos para a distribuição t de Student



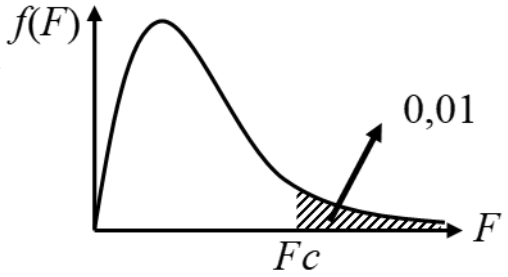
23	1,3195	1,7139	2,0687	2,4999	2,8073
24	1,3178	1,7109	2,0639	2,4922	2,7969
25	1,3163	1,7081	2,0595	2,4851	2,7874
26	1,3150	1,7056	2,0555	2,4786	2,7787
27	1,3137	1,7033	2,0518	2,4727	2,7707
28	1,3125	1,7011	2,0484	2,4671	2,7633
29	1,3114	1,6991	2,0452	2,4620	2,7564
30	1,3104	1,6973	2,0423	2,4573	2,7500
31	1,3095	1,6955	2,0395	2,4528	2,7440
32	1,3086	1,6939	2,0369	2,4487	2,7385
33	1,3077	1,6924	2,0345	2,4448	2,7333
34	1,3070	1,6909	2,0322	2,4411	2,7284
35	1,3062	1,6896	2,0301	2,4377	2,7238
36	1,3055	1,6883	2,0281	2,4345	2,7195
37	1,3049	1,6871	2,0262	2,4314	2,7154
38	1,3042	1,6860	2,0244	2,4286	2,7116
39	1,3036	1,6849	2,0227	2,4258	2,7079
40	1,3031	1,6839	2,0211	2,4233	2,7045
41	1,3025	1,6829	2,0195	2,4208	2,7012
42	1,3020	1,6820	2,0181	2,4185	2,6981
43	1,3016	1,6811	2,0167	2,4163	2,6951
44	1,3011	1,6802	2,0154	2,4141	2,6923
45	1,3006	1,6794	2,0141	2,4121	2,6896
50	1,2987	1,6759	2,0086	2,4033	2,6778
165	1,2867	1,6541	1,9744	2,3492	2,6060
170	1,2866	1,6539	1,9740	2,3485	2,6051
175	1,2864	1,6536	1,9736	2,3478	2,6042
180	1,2863	1,6534	1,9732	2,3472	2,6034
185	1,2861	1,6531	1,9729	2,3467	2,6027
190	1,2860	1,6529	1,9725	2,3461	2,6020
195	1,2859	1,6527	1,9722	2,3456	2,6013
200	1,2858	1,6525	1,9719	2,3451	2,6006
210	1,2856	1,6521	1,9713	2,3442	2,5994
220	1,2854	1,6518	1,9708	2,3434	2,5984
230	1,2852	1,6515	1,9703	2,3427	2,5974
240	1,2851	1,6512	1,9699	2,3420	2,5965
250	1,2849	1,6510	1,9695	2,3414	2,5956
260	1,2848	1,6507	1,9691	2,3408	2,5949
270	1,2847	1,6505	1,9688	2,3402	2,5942
280	1,2846	1,6503	1,9685	2,3397	2,5935
290	1,2845	1,6501	1,9682	2,3393	2,5929
300	1,2844	1,6499	1,9679	2,3388	2,5923
310	1,2843	1,6498	1,9676	2,3384	2,5918
320	1,2842	1,6496	1,9674	2,3381	2,5913
330	1,2841	1,6495	1,9672	2,3377	2,5908
340	1,2840	1,6493	1,9670	2,3374	2,5904
350	1,2840	1,6492	1,9668	2,3370	2,5899
400	1,2837	1,6487	1,9659	2,3357	2,5882

23	1,3195	1,7139	2,0687	2,4999	2,8073
24	1,3178	1,7109	2,0639	2,4922	2,7969
25	1,3163	1,7081	2,0595	2,4851	2,7874
26	1,3150	1,7056	2,0555	2,4786	2,7787
27	1,3137	1,7033	2,0518	2,4727	2,7707
28	1,3125	1,7011	2,0484	2,4671	2,7633
29	1,3114	1,6991	2,0452	2,4620	2,7564
30	1,3104	1,6973	2,0423	2,4573	2,7500
31	1,3095	1,6955	2,0395	2,4528	2,7440
32	1,3086	1,6939	2,0369	2,4487	2,7385
33	1,3077	1,6924	2,0345	2,4448	2,7333
34	1,3070	1,6909	2,0322	2,4411	2,7284
35	1,3062	1,6896	2,0301	2,4377	2,7238
36	1,3055	1,6883	2,0281	2,4345	2,7195
37	1,3049	1,6871	2,0262	2,4314	2,7154
38	1,3042	1,6860	2,0244	2,4286	2,7116
39	1,3036	1,6849	2,0227	2,4258	2,7079
40	1,3031	1,6839	2,0211	2,4233	2,7045
41	1,3025	1,6829	2,0195	2,4208	2,7012
42	1,3020	1,6820	2,0181	2,4185	2,6981
43	1,3016	1,6811	2,0167	2,4163	2,6951
44	1,3011	1,6802	2,0154	2,4141	2,6923
45	1,3006	1,6794	2,0141	2,4121	2,6896
50	1,2987	1,6759	2,0086	2,4033	2,6778
165	1,2867	1,6541	1,9744	2,3492	2,6060
170	1,2866	1,6539	1,9740	2,3485	2,6051
175	1,2864	1,6536	1,9736	2,3478	2,6042
180	1,2863	1,6534	1,9732	2,3472	2,6034
185	1,2861	1,6531	1,9729	2,3467	2,6027
190	1,2860	1,6529	1,9725	2,3461	2,6020
195	1,2859	1,6527	1,9722	2,3456	2,6013
200	1,2858	1,6525	1,9719	2,3451	2,6006
210	1,2856	1,6521	1,9713	2,3442	2,5994
220	1,2854	1,6518	1,9708	2,3434	2,5984
230	1,2852	1,6515	1,9703	2,3427	2,5974
240	1,2851	1,6512	1,9699	2,3420	2,5965
250	1,2849	1,6510	1,9695	2,3414	2,5956
260	1,2848	1,6507	1,9691	2,3408	2,5949
270	1,2847	1,6505	1,9688	2,3402	2,5942
280	1,2846	1,6503	1,9685	2,3397	2,5935
290	1,2845	1,6501	1,9682	2,3393	2,5929
300	1,2844	1,6499	1,9679	2,3388	2,5923
310	1,2843	1,6498	1,9676	2,3384	2,5918
320	1,2842	1,6496	1,9674	2,3381	2,5913
330	1,2841	1,6495	1,9672	2,3377	2,5908
340	1,2840	1,6493	1,9670	2,3374	2,5904
350	1,2840	1,6492	1,9668	2,3370	2,5899
400	1,2837	1,6487	1,9659	2,3357	2,5882

9.3. Tabela de distribuição F com $\alpha = 0,01$

Valores Críticos para a distribuição F

Nível de significância: 0,05



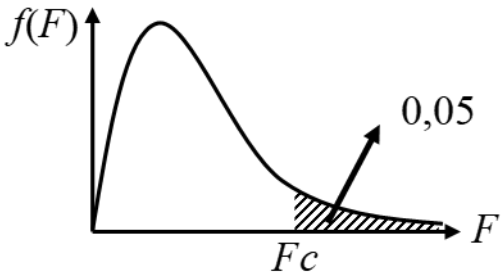
grau de liberdade do numerador

grau de liberdade do denominador	0,01	1	2	3	4	5	8	10	15	20	30	50
	2	98,50	99,00	99,17	99,25	99,30	99,37	99,40	99,43	99,45	99,47	99,48
	3	34,12	30,82	29,46	28,71	28,24	27,49	27,23	26,87	26,69	26,50	26,35
	4	21,20	18,00	16,69	15,98	15,52	14,80	14,55	14,20	14,02	13,84	13,69
	5	16,26	13,27	12,06	11,39	10,97	10,29	10,05	9,72	9,55	9,38	9,24
	6	13,75	10,92	9,78	9,15	8,75	8,10	7,87	7,56	7,40	7,23	7,09
	7	12,25	9,55	8,45	7,85	7,46	6,84	6,62	6,31	6,16	5,99	5,86
	8	11,26	8,65	7,59	7,01	6,63	6,03	5,81	5,52	5,36	5,20	5,07
	9	10,56	8,02	6,99	6,42	6,06	5,47	5,26	4,96	4,81	4,65	4,52
	10	10,04	7,56	6,55	5,99	5,64	5,06	4,85	4,56	4,41	4,25	4,12
	11	9,65	7,21	6,22	5,67	5,32	4,74	4,54	4,25	4,10	3,94	3,81
	12	9,33	6,93	5,95	5,41	5,06	4,50	4,30	4,01	3,86	3,70	3,57
	13	9,07	6,70	5,74	5,21	4,86	4,30	4,10	3,82	3,66	3,51	3,38
	14	8,86	6,51	5,56	5,04	4,69	4,14	3,94	3,66	3,51	3,35	3,22
	15	8,68	6,36	5,42	4,89	4,56	4,00	3,80	3,52	3,37	3,21	3,08
	16	8,53	6,23	5,29	4,77	4,44	3,89	3,69	3,41	3,26	3,10	2,97
	17	8,40	6,11	5,18	4,67	4,34	3,79	3,59	3,31	3,16	3,00	2,87
	18	8,29	6,01	5,09	4,58	4,25	3,71	3,51	3,23	3,08	2,92	2,78
	19	8,18	5,93	5,01	4,50	4,17	3,63	3,43	3,15	3,00	2,84	2,71
	20	8,10	5,85	4,94	4,43	4,10	3,56	3,37	3,09	2,94	2,78	2,64
	25	7,77	5,57	4,68	4,18	3,85	3,32	3,13	2,85	2,70	2,54	2,40
	30	7,56	5,39	4,51	4,02	3,70	3,17	2,98	2,70	2,55	2,39	2,25
	40	7,31	5,18	4,31	3,83	3,51	2,99	2,80	2,52	2,37	2,20	2,06
	50	7,17	5,06	4,20	3,72	3,41	2,89	2,70	2,42	2,27	2,10	1,95
	60	7,08	4,98	4,13	3,65	3,34	2,82	2,63	2,35	2,20	2,03	1,88
	70	7,01	4,92	4,07	3,60	3,29	2,78	2,59	2,31	2,15	1,98	1,83
	80	6,96	4,88	4,04	3,56	3,26	2,74	2,55	2,27	2,12	1,94	1,79
	100	6,90	4,82	3,98	3,51	3,21	2,69	2,50	2,22	2,07	1,89	1,74
	120	6,85	4,79	3,95	3,48	3,17	2,66	2,47	2,19	2,03	1,86	1,70
	140	6,82	4,76	3,92	3,46	3,15	2,64	2,45	2,17	2,01	1,84	1,67
	160	6,80	4,74	3,91	3,44	3,13	2,62	2,43	2,15	1,99	1,82	1,66
	200	6,76	4,71	3,88	3,41	3,11	2,60	2,41	2,13	1,97	1,79	1,63
	250	6,74	4,69	3,86	3,40	3,09	2,58	2,39	2,11	1,95	1,77	1,61
	300	6,72	4,68	3,85	3,38	3,08	2,57	2,38	2,10	1,94	1,76	1,59
	350	6,71	4,67	3,84	3,37	3,07	2,56	2,37	2,09	1,93	1,75	1,58
	400	6,70	4,66	3,83	3,37	3,06	2,56	2,37	2,08	1,92	1,75	1,58
	450	6,69	4,65	3,83	3,36	3,06	2,55	2,36	2,08	1,92	1,74	1,57
	500	6,69	4,65	3,82	3,36	3,05	2,55	2,36	2,07	1,92	1,74	1,57

9.4. Tabela de distribuição F com $\alpha = 0,05$

Valores Críticos para a distribuição F

Nível de significância: 0,05

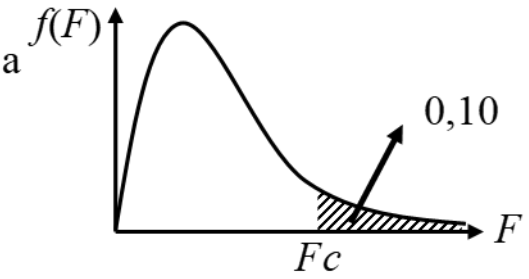


grau de liberdade do denominador	grau de liberdade do numerador										
0,05	1	2	3	4	5	8	10	15	20	30	50
2	18,51	19,00	19,16	19,25	19,30	19,37	19,40	19,43	19,45	19,46	19,48
3	10,13	9,55	9,28	9,12	9,01	8,85	8,79	8,70	8,66	8,62	8,58
4	7,71	6,94	6,59	6,39	6,26	6,04	5,96	5,86	5,80	5,75	5,70
5	6,61	5,79	5,41	5,19	5,05	4,82	4,74	4,62	4,56	4,50	4,44
6	5,99	5,14	4,76	4,53	4,39	4,15	4,06	3,94	3,87	3,81	3,75
7	5,59	4,74	4,35	4,12	3,97	3,73	3,64	3,51	3,44	3,38	3,32
8	5,32	4,46	4,07	3,84	3,69	3,44	3,35	3,22	3,15	3,08	3,02
9	5,12	4,26	3,86	3,63	3,48	3,23	3,14	3,01	2,94	2,86	2,80
10	4,96	4,10	3,71	3,48	3,33	3,07	2,98	2,85	2,77	2,70	2,64
11	4,84	3,98	3,59	3,36	3,20	2,95	2,85	2,72	2,65	2,57	2,51
12	4,75	3,89	3,49	3,26	3,11	2,85	2,75	2,62	2,54	2,47	2,40
13	4,67	3,81	3,41	3,18	3,03	2,77	2,67	2,53	2,46	2,38	2,31
14	4,60	3,74	3,34	3,11	2,96	2,70	2,60	2,46	2,39	2,31	2,24
15	4,54	3,68	3,29	3,06	2,90	2,64	2,54	2,40	2,33	2,25	2,18
16	4,49	3,63	3,24	3,01	2,85	2,59	2,49	2,35	2,28	2,19	2,12
17	4,45	3,59	3,20	2,96	2,81	2,55	2,45	2,31	2,23	2,15	2,08
18	4,41	3,55	3,16	2,93	2,77	2,51	2,41	2,27	2,19	2,11	2,04
19	4,38	3,52	3,13	2,90	2,74	2,48	2,38	2,23	2,16	2,07	2,00
20	4,35	3,49	3,10	2,87	2,71	2,45	2,35	2,20	2,12	2,04	1,97
25	4,24	3,39	2,99	2,76	2,60	2,34	2,24	2,09	2,01	1,92	1,84
30	4,17	3,32	2,92	2,69	2,53	2,27	2,16	2,01	1,93	1,84	1,76
40	4,08	3,23	2,84	2,61	2,45	2,18	2,08	1,92	1,84	1,74	1,66
50	4,03	3,18	2,79	2,56	2,40	2,13	2,03	1,87	1,78	1,69	1,60
60	4,00	3,15	2,76	2,53	2,37	2,10	1,99	1,84	1,75	1,65	1,56
70	3,98	3,13	2,74	2,50	2,35	2,07	1,97	1,81	1,72	1,62	1,53
80	3,96	3,11	2,72	2,49	2,33	2,06	1,95	1,79	1,70	1,60	1,51
100	3,94	3,09	2,70	2,46	2,31	2,03	1,93	1,77	1,68	1,57	1,48
120	3,92	3,07	2,68	2,45	2,29	2,02	1,91	1,75	1,66	1,55	1,46
140	3,91	3,06	2,67	2,44	2,28	2,01	1,90	1,74	1,65	1,54	1,44
160	3,90	3,05	2,66	2,43	2,27	2,00	1,89	1,73	1,64	1,53	1,43
200	3,89	3,04	2,65	2,42	2,26	1,98	1,88	1,72	1,62	1,52	1,41
250	3,88	3,03	2,64	2,41	2,25	1,98	1,87	1,71	1,61	1,50	1,40
300	3,87	3,03	2,63	2,40	2,24	1,97	1,86	1,70	1,61	1,50	1,39
350	3,87	3,02	2,63	2,40	2,24	1,96	1,86	1,70	1,60	1,49	1,39
400	3,86	3,02	2,63	2,39	2,24	1,96	1,85	1,69	1,60	1,49	1,38
450	3,86	3,02	2,62	2,39	2,23	1,96	1,85	1,69	1,59	1,48	1,38
500	3,86	3,01	2,62	2,39	2,23	1,96	1,85	1,69	1,59	1,48	1,38

9.5. Tabela de distribuição F com α = 0,10

Valores Críticos para a distribuição F

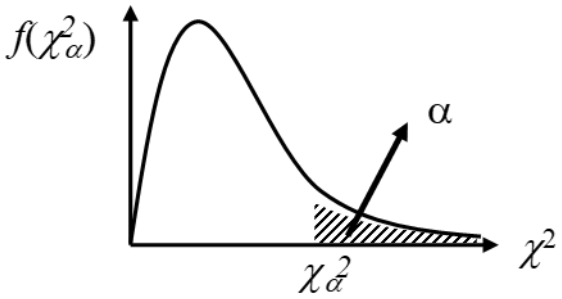
Nível de significância: 0,05



grau de liberdade do denominador	Grau de Liberdade do Numerador										
0,1	1	2	3	4	5	8	10	15	20	30	50
2	8,53	9,00	9,16	9,24	9,29	9,37	9,39	9,42	9,44	9,46	9,47
3	5,54	5,46	5,39	5,34	5,31	5,25	5,23	5,20	5,18	5,17	5,15
4	4,54	4,32	4,19	4,11	4,05	3,95	3,92	3,87	3,84	3,82	3,80
5	4,06	3,78	3,62	3,52	3,45	3,34	3,30	3,24	3,21	3,17	3,15
6	3,78	3,46	3,29	3,18	3,11	2,98	2,94	2,87	2,84	2,80	2,77
7	3,59	3,26	3,07	2,96	2,88	2,75	2,70	2,63	2,59	2,56	2,52
8	3,46	3,11	2,92	2,81	2,73	2,59	2,54	2,46	2,42	2,38	2,35
9	3,36	3,01	2,81	2,69	2,61	2,47	2,42	2,34	2,30	2,25	2,22
10	3,29	2,92	2,73	2,61	2,52	2,38	2,32	2,24	2,20	2,16	2,12
11	3,23	2,86	2,66	2,54	2,45	2,30	2,25	2,17	2,12	2,08	2,04
12	3,18	2,81	2,61	2,48	2,39	2,24	2,19	2,10	2,06	2,01	1,97
13	3,14	2,76	2,56	2,43	2,35	2,20	2,14	2,05	2,01	1,96	1,92
14	3,10	2,73	2,52	2,39	2,31	2,15	2,10	2,01	1,96	1,91	1,87
15	3,07	2,70	2,49	2,36	2,27	2,12	2,06	1,97	1,92	1,87	1,83
16	3,05	2,67	2,46	2,33	2,24	2,09	2,03	1,94	1,89	1,84	1,79
17	3,03	2,64	2,44	2,31	2,22	2,06	2,00	1,91	1,86	1,81	1,76
18	3,01	2,62	2,42	2,29	2,20	2,04	1,98	1,89	1,84	1,78	1,74
19	2,99	2,61	2,40	2,27	2,18	2,02	1,96	1,86	1,81	1,76	1,71
20	2,97	2,59	2,38	2,25	2,16	2,00	1,94	1,84	1,79	1,74	1,69
25	2,92	2,53	2,32	2,18	2,09	1,93	1,87	1,77	1,72	1,66	1,61
30	2,88	2,49	2,28	2,14	2,05	1,88	1,82	1,72	1,67	1,61	1,55
40	2,84	2,44	2,23	2,09	2,00	1,83	1,76	1,66	1,61	1,54	1,48
50	2,81	2,41	2,20	2,06	1,97	1,80	1,73	1,63	1,57	1,50	1,44
60	2,79	2,39	2,18	2,04	1,95	1,77	1,71	1,60	1,54	1,48	1,41
70	2,78	2,38	2,16	2,03	1,93	1,76	1,69	1,59	1,53	1,46	1,39
80	2,77	2,37	2,15	2,02	1,92	1,75	1,68	1,57	1,51	1,44	1,38
100	2,76	2,36	2,14	2,00	1,91	1,73	1,66	1,56	1,49	1,42	1,35
120	2,75	2,35	2,13	1,99	1,90	1,72	1,65	1,55	1,48	1,41	1,34
140	2,74	2,34	2,12	1,99	1,89	1,71	1,64	1,54	1,47	1,40	1,33
160	2,74	2,34	2,12	1,98	1,88	1,71	1,64	1,53	1,47	1,39	1,32
200	2,73	2,33	2,11	1,97	1,88	1,70	1,63	1,52	1,46	1,38	1,31
250	2,73	2,32	2,11	1,97	1,87	1,69	1,62	1,51	1,45	1,37	1,30
300	2,72	2,32	2,10	1,96	1,87	1,69	1,62	1,51	1,45	1,37	1,29
350	2,72	2,32	2,10	1,96	1,86	1,69	1,62	1,51	1,44	1,37	1,29
400	2,72	2,32	2,10	1,96	1,86	1,69	1,61	1,50	1,44	1,36	1,29
450	2,72	2,31	2,10	1,96	1,86	1,68	1,61	1,50	1,44	1,36	1,28
500	2,72	2,31	2,09	1,96	1,86	1,68	1,61	1,50	1,44	1,36	1,28

9.6. Tabela de distribuição de qui-quadrado

Valores Críticos para a distribuição χ^2 (Qui-quadrado)



grau de liberdade	nível de significância - α											
	0,995	0,990	0,975	0,950	0,900	0,750	0,250	0,100	0,050	0,025	0,010	0,005
1	0,00	0,00	0,00	0,00	0,02	0,10	1,32	2,71	3,84	5,02	6,63	7,88
2	0,01	0,02	0,05	0,10	0,21	0,58	2,77	4,61	5,99	7,38	9,21	10,60
3	0,07	0,11	0,22	0,35	0,58	1,21	4,11	6,25	7,81	9,35	11,34	12,84
4	0,21	0,30	0,48	0,71	1,06	1,92	5,39	7,78	9,49	11,14	13,28	14,86
5	0,41	0,55	0,83	1,15	1,61	2,67	6,63	9,24	11,07	12,83	15,09	16,75
6	0,68	0,87	1,24	1,64	2,20	3,45	7,84	10,64	12,59	14,45	16,81	18,55
7	0,99	1,24	1,69	2,17	2,83	4,25	9,04	12,02	14,07	16,01	18,48	20,28
8	1,34	1,65	2,18	2,73	3,49	5,07	10,22	13,36	15,51	17,53	20,09	21,95
9	1,73	2,09	2,70	3,33	4,17	5,90	11,39	14,68	16,92	19,02	21,67	23,59
10	2,16	2,56	3,25	3,94	4,87	6,74	12,55	15,99	18,31	20,48	23,21	25,19
11	2,60	3,05	3,82	4,57	5,58	7,58	13,70	17,28	19,68	21,92	24,72	26,76
12	3,07	3,57	4,40	5,23	6,30	8,44	14,85	18,55	21,03	23,34	26,22	28,30
13	3,57	4,11	5,01	5,89	7,04	9,30	15,98	19,81	22,36	24,74	27,69	29,82
14	4,07	4,66	5,63	6,57	7,79	10,17	17,12	21,06	23,68	26,12	29,14	31,32
15	4,60	5,23	6,26	7,26	8,55	11,04	18,25	22,31	25,00	27,49	30,58	32,80
16	5,14	5,81	6,91	7,96	9,31	11,91	19,37	23,54	26,30	28,85	32,00	34,27
17	5,70	6,41	7,56	8,67	10,09	12,79	20,49	24,77	27,59	30,19	33,41	35,72
18	6,26	7,01	8,23	9,39	10,86	13,68	21,60	25,99	28,87	31,53	34,81	37,16
19	6,84	7,63	8,91	10,12	11,65	14,56	22,72	27,20	30,14	32,85	36,19	38,58
20	7,43	8,26	9,59	10,85	12,44	15,45	23,83	28,41	31,41	34,17	37,57	40,00
21	8,03	8,90	10,28	11,59	13,24	16,34	24,93	29,62	32,67	35,48	38,93	41,40
22	8,64	9,54	10,98	12,34	14,04	17,24	26,04	30,81	33,92	36,78	40,29	42,80
23	9,26	10,20	11,69	13,09	14,85	18,14	27,14	32,01	35,17	38,08	41,64	44,18
24	9,89	10,86	12,40	13,85	15,66	19,04	28,24	33,20	36,42	39,36	42,98	45,56
25	10,52	11,52	13,12	14,61	16,47	19,94	29,34	34,38	37,65	40,65	44,31	46,93
26	11,16	12,20	13,84	15,38	17,29	20,84	30,43	35,56	38,89	41,92	45,64	48,29
27	11,81	12,88	14,57	16,15	18,11	21,75	31,53	36,74	40,11	43,19	46,96	49,64
28	12,46	13,56	15,31	16,93	18,94	22,66	32,62	37,92	41,34	44,46	48,28	50,99
29	13,12	14,26	16,05	17,71	19,77	23,57	33,71	39,09	42,56	45,72	49,59	52,34
30	13,79	14,95	16,79	18,49	20,60	24,48	34,80	40,26	43,77	46,98	50,89	53,67
40	20,71	22,16	24,43	26,51	29,05	33,66	45,62	51,81	55,76	59,34	63,69	66,77
50	27,99	29,71	32,36	34,76	37,69	42,94	56,33	63,17	67,50	71,42	76,15	79,49
60	35,53	37,48	40,48	43,19	46,46	52,29	66,98	74,40	79,08	83,30	88,38	91,95
70	43,28	45,44	48,76	51,74	55,33	61,70	77,58	85,53	90,53	95,02	100,43	104,21
80	51,17	53,54	57,15	60,39	64,28	71,14	88,13	96,58	101,88	106,63	112,33	116,32
90	59,20	61,75	65,65	69,13	73,29	80,62	98,65	107,57	113,15	118,14	124,12	128,30
100	67,33	70,06	74,22	77,93	82,36	90,13	109,14	118,50	124,34	129,56	135,81	140,17
150	109,14	112,67	117,98	122,69	128,28	137,98	161,29	172,58	179,58	185,80	193,21	198,36
200	152,24	156,43	162,73	168,28	174,84	186,17	213,10	226,02	233,99	241,06	249,45	255,26
300	240,66	245,97	253,91	260,88	269,07	283,14	316,14	331,79	341,40	349,87	359,91	366,84

Capítulo 10. Bibliografia

- **Bibliografia básica da disciplina:**

[1] LEVINE, David M., STEPHAN, David F. e SZABAT, Kathryn A. **Estatística: teoria e aplicações usando o Microsoft® Excel em português**. 7. ed. Rio de Janeiro: LTC, 2016. xxvii, 760 p.
[2] BUSSAB, Wilton de Oliveira e MORETTIN, Pedro Alberto. **Estatística básica**. 9. ed. São Paulo: Saraiva, 2017. xxii, 554 p.
[3] MCCLAVE, James T.; BENSON, P. George. e SINCICH, Terry. **Estatística para administração e economia**, 10. ed. São Paulo. Pearson, 2015.

- **Bibliografia Complementar da Disciplina:**

– SEBER, J.A.F.; WILD, C.J. **Encontros com o acaso: um primeiro curso de análise de dados e inferência.** Rio de Janeiro: LTC, 2004.
– AGRESTI, Alan.; FINLAY, Barbara et al. **Métodos estatísticos para as ciências sociais**. Porto Alegre: Penso, 2012.
– FIELD, Andry e VIALI, Lorí. **Descobrindo a estatística usando o SPSS**. Porto Alegre: Artmed, 2009.