MBA EM

DATA SCIENCE

Introdução à Programação com Python

Prof. Dr. Wilson Tarantin Junior

Natan Manoel Mendonça 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonça 394.876.988-50

MBA USP ESALQ

Introdução ao Machine Learning

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Machine learning

- Contextualização

  - Em termos gerais, é o processamento e a análise de dados por meio de algoritmos, com o objetivo de gerar informações úteis para fundamentar a tomada de decisão

    - *Data-driven decision making*: redução de incertezas, aumento da eficácia
    - As aplicações do machine learning são multidisciplinares!

  - Aplica-se o machine learning com o objetivo de **encontrar padrões nos dados**, seja gerando modelos preditivos ou análises exploratórias para identificar relações latentes

  - Envolve conhecimentos de estatística, softwares ou linguagem de programação e sobre a área de interesse para a interpretação dos resultados

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Banco de dados

- Definição e composição
  - O banco de dados é o **objeto** onde estão armazenadas as informações de interesse para a análise em questão
  - Frequentemente, o banco de dados contém uma amostra, que nada mais é do que um subconjunto extraído da população
  - O banco de dados é composto por variáveis e por observações
    - **Observações**: unidades que têm suas características e atributos analisados
    - **Variáveis**: características/atributos observados, medidos ou categorizados

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Banco de dados

- Estrutura para uso

  - Para aplicação em machine learning, comumente o banco de dados é estruturado com as observações em linhas e as variáveis em colunas em uma **estrutura tabular**

	Idade	Altura	Cidade	Profissão	Renda	...
Pessoa 1						
Pessoa 2						
Pessoa 3						
Pessoa 4						
Pessoa 5						
Pessoa 6						
Pessoa 7						
Pessoa 8						
Pessoa 9						
Pessoa 10						
...						

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tipos de variáveis

- As variáveis podem ser divididas em

  - **Métricas**: são as variáveis quantitativas, isto é, apresentam características que podem ser mensuradas ou contadas

  - **Não métricas**: são as variáveis qualitativas, indicam características que não podem ser medidas. Tais variáveis contêm categorias, por isto, muitas vezes, são chamadas de variáveis categóricas

  - **A identificação do tipo de variável é fundamental para a escolha da ferramenta estatística que será utilizada na análise dos dados**

Natan Manoel Menezes 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis qualitativas

- Características principais
  - As variáveis qualitativas têm sua representação feita por meio de tabelas de distribuição de frequências ou gráficos
  - Não é possível calcular medidas de resumo como média ou desvio padrão para elas
  - Exemplos: nacionalidade, nível de escolaridade, profissão, estado civil, turno do expediente, escalas likert...

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis quantitativas

- Características principais

  - As variáveis quantitativas podem ser representadas por diversas ferramentas, como gráficos, medidas de posição ou localização, dispersão e de forma. A seguir, alguns exemplos:

    - Medidas de posição ou localização: média, mediana e quartis
    - Medidas de dispersão: variância e desvio padrão
    - Medidas de forma: assimetria e curtose

  - Exemplos: idade em anos, renda mensal em Reais, número de habitantes no município, nota na prova (0 a 10), margem de lucro mensal percentual de uma empresa, número de filhos, quantidade de usuários do sistema...

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Detalhando as variáveis

- Outras características relevantes
  - Variáveis qualitativas: dicotômica ou policotômica; nominal ou ordinal
    - Dicotômica: duas categorias (binária); Policotômica: mais de duas categorias
    - Nominal: não estabelece relação de grandeza/ordem; Ordinal: estabelece ordem
  - Variáveis quantitativas: discretas ou contínuas
    - Discretas: possuem conjunto finito e numerável de valores, em geral, são obtidas a partir de dados de contagem (0, 1, 2, 3, 4, 5...)
    - Contínuas: assumem valores pertencentes ao intervalo de números reais

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis e técnicas

- Como identificar a técnica adequada
  - Modelos **não supervisionados** de machine learning
    - Também conhecidos como modelos exploratórios ou técnicas de interdependência
    - Estuda relação entre variáveis, mas sem a intenção de criar modelos confirmatórios
    - Não há inferência dos resultados encontrados para observações de fora da amostra
    - Objetivos: redução dos dados, classificação ou agrupamento de observações e variáveis, correlação ou associação entre variáveis

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

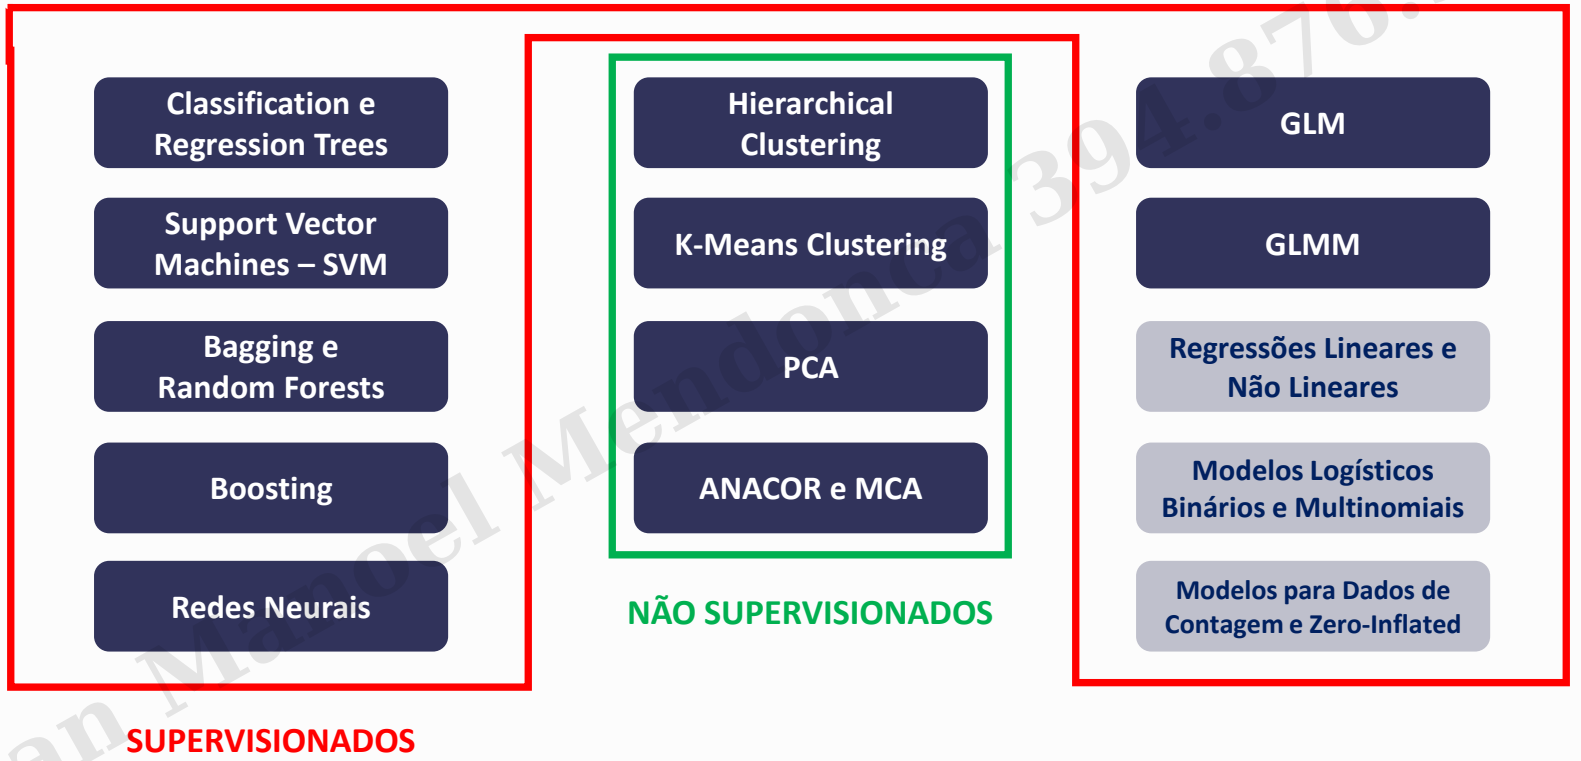
Variáveis e técnicas

- Como identificar a técnica adequada
  - Modelos **supervisionados** de machine learning
    - Conhecidos como modelos confirmatórios ou técnicas de dependência
    - O objetivo é estimar modelos, equações, com o intuito de elaborar previsões
    - Portanto, há inferência dos resultados para outras observações de fora da amostra

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

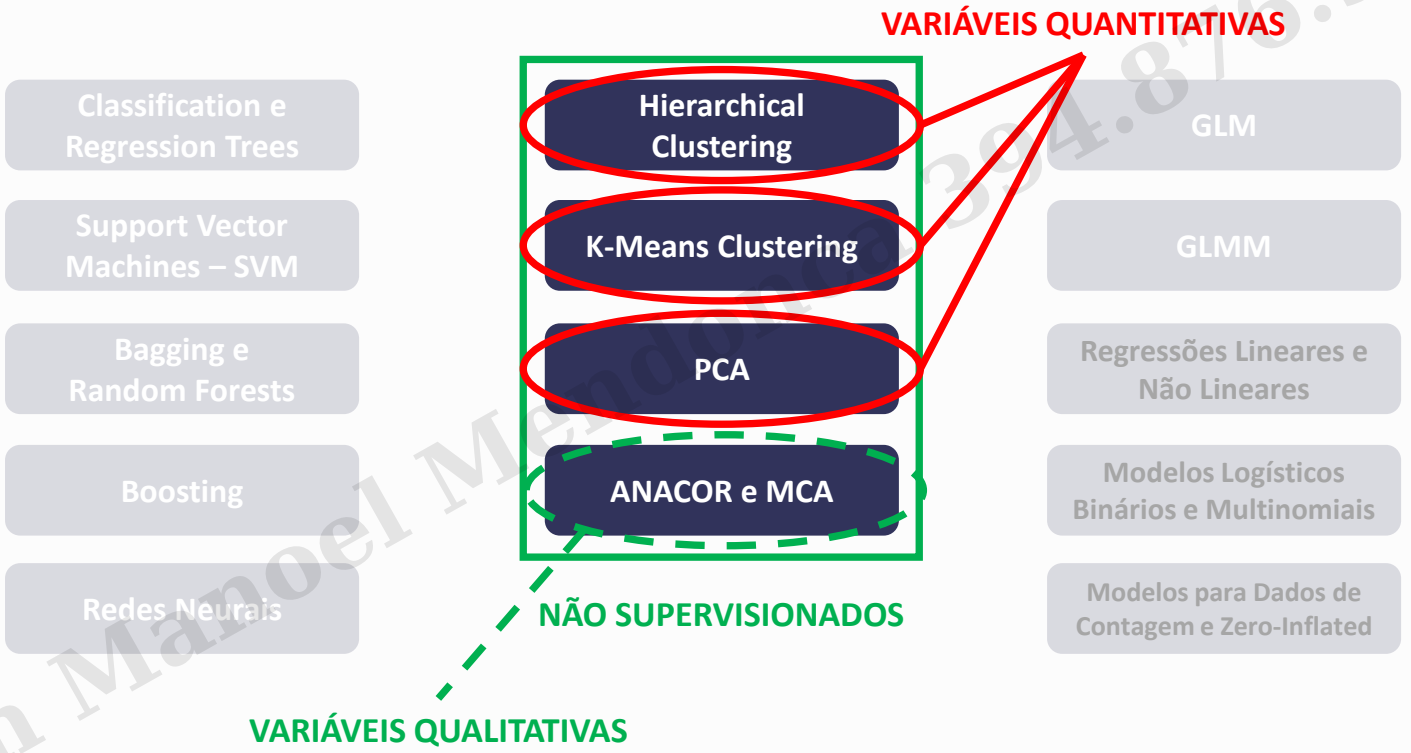
Classificação de algoritmos



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

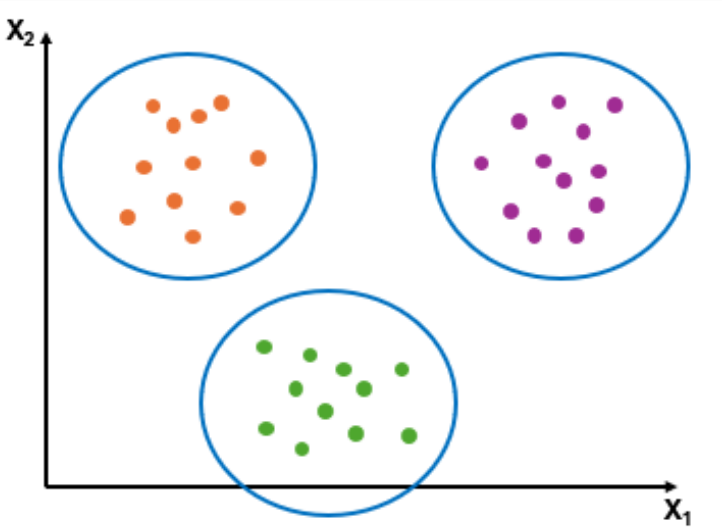
Modelos não supervisionados



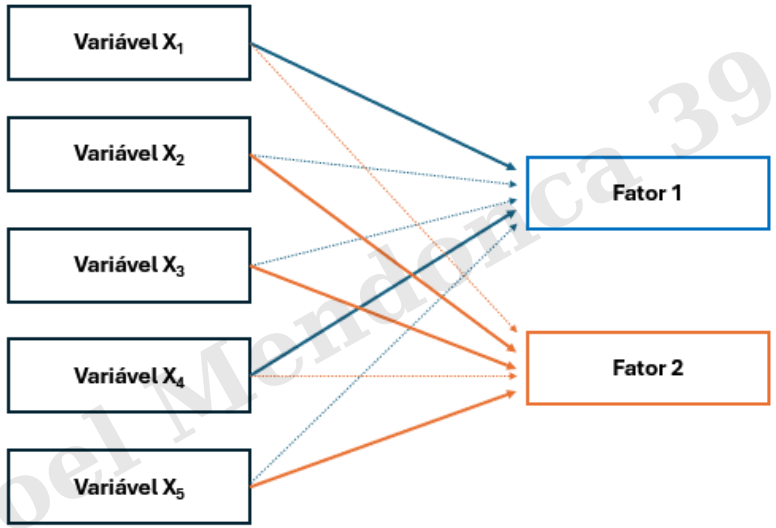
Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

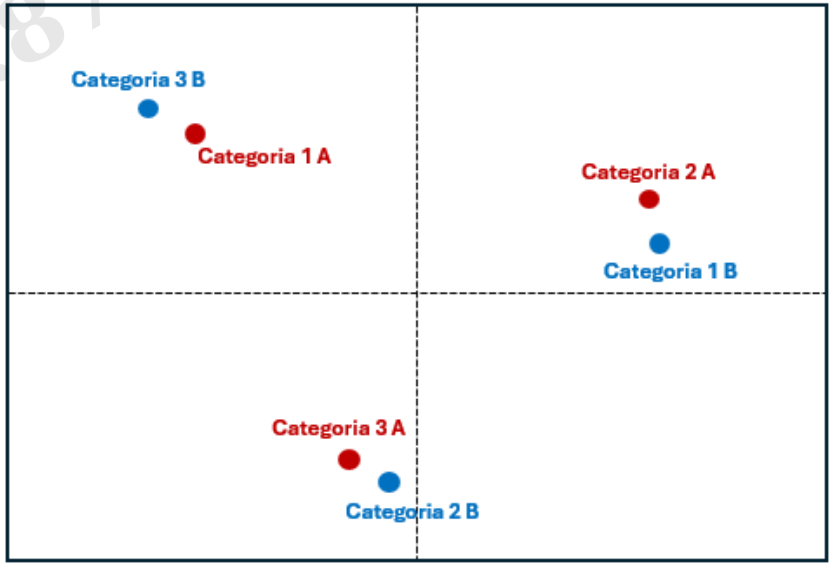
Modelos não supervisionados



Clustering



PCA

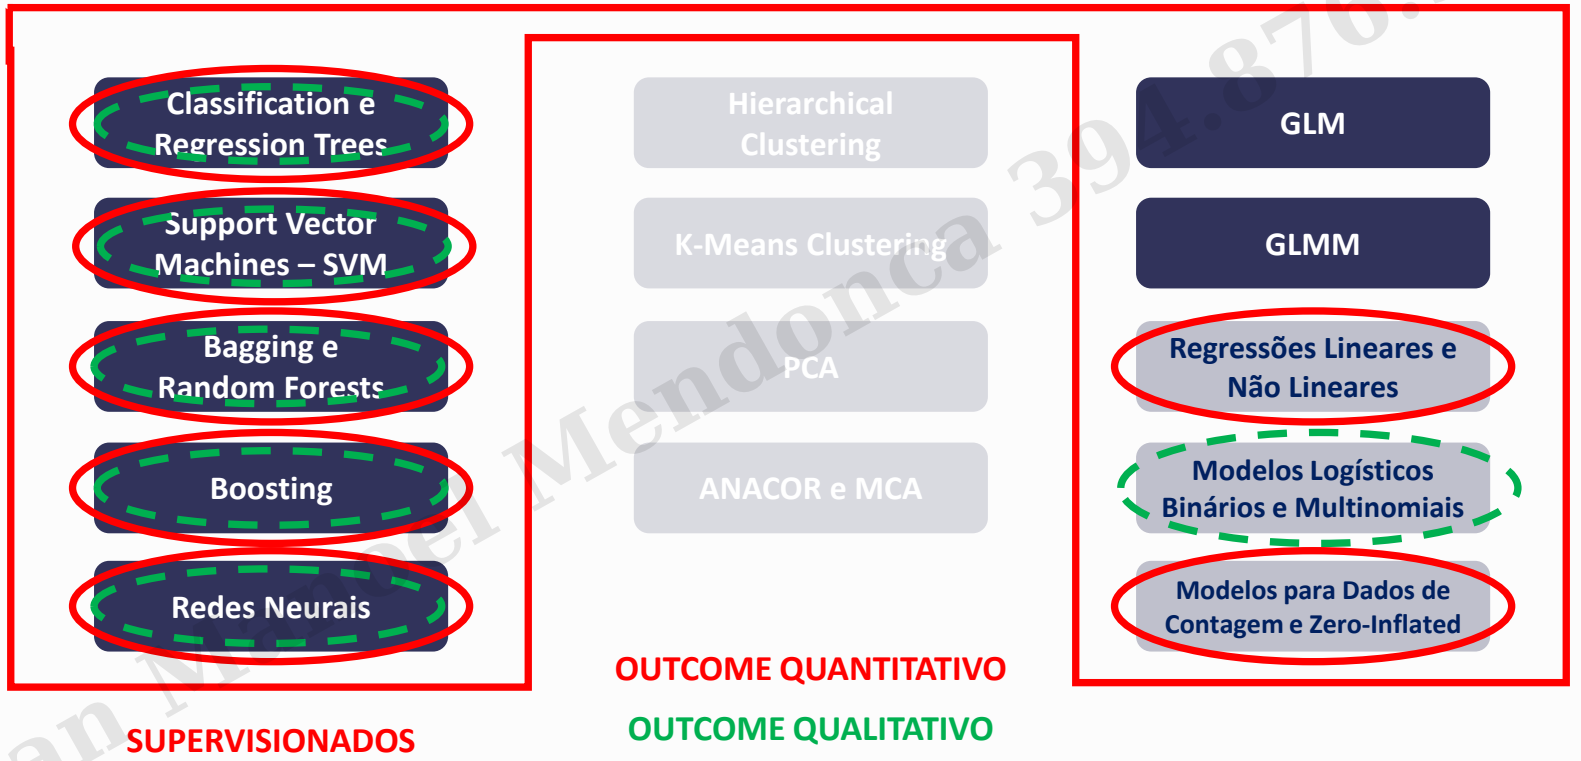


ANACOR

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Supervisionados

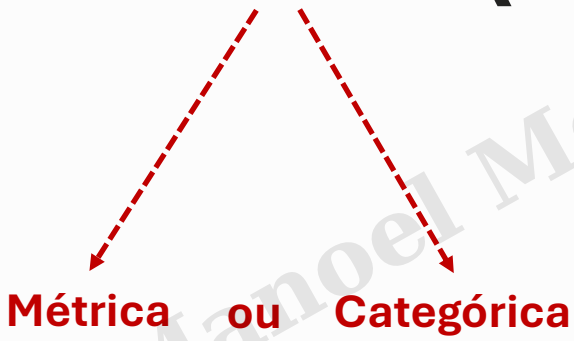


Natan Machado Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Modelos supervisionados

$$Y = f(X_1, X_2, \cdots, X_k)$$



Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Referência

- FÁVERO, L. P.; BELFIORE, P. Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. LTC, 2024.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Introdução ao Python

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Apresentação

- **Python**: é a linguagem de programação que vamos utilizar

- Neste curso, vamos implementá-lo por meio do **Spyder (IDE)**

  - Software que torna o uso do Python mais simples para o usuário

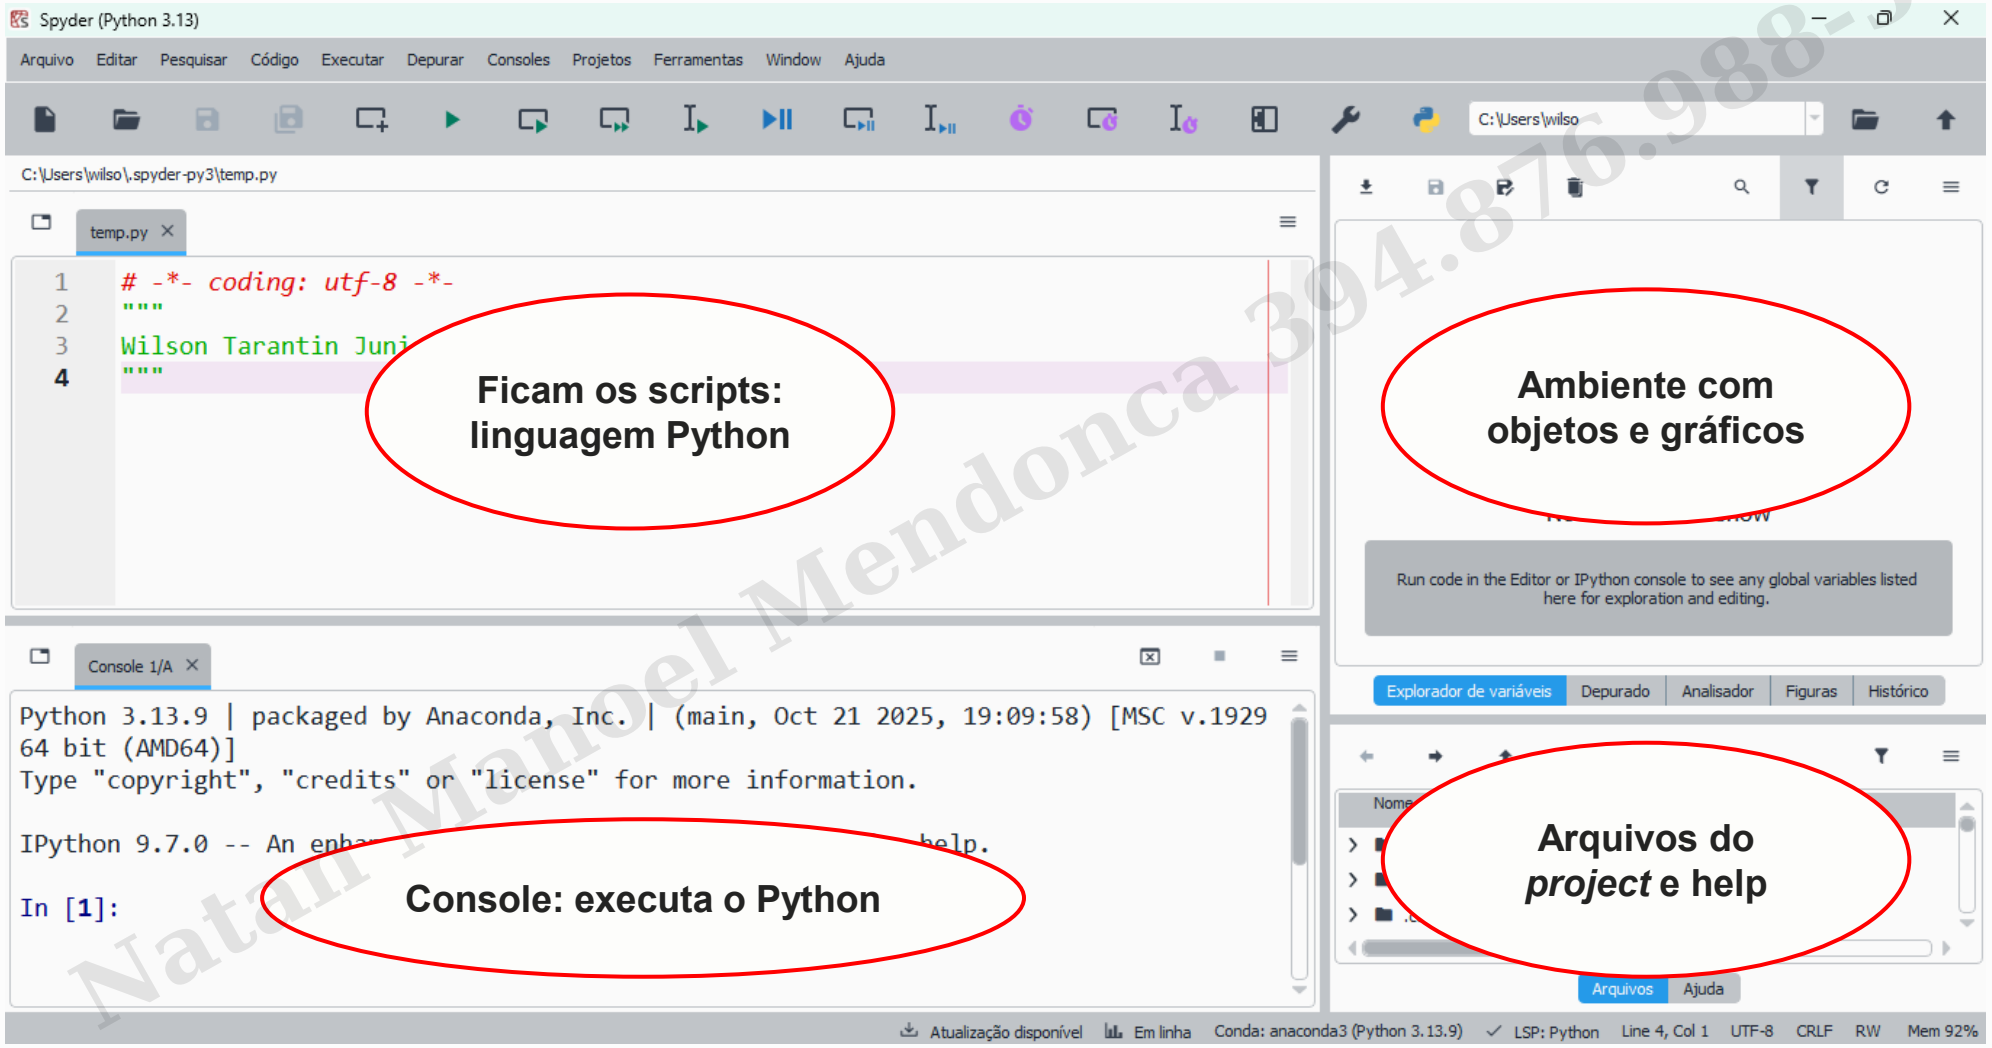
- Para instalar o Spyder, vamos baixá-lo por meio da plataforma Anaconda

  - **Acessar o tutorial de instalação do Anaconda disponibilizado em conjunto com os materiais de aula!**

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ajuste: Window > Layouts da janela > Rstudio



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Acessando um *project*

- Sempre que acessar um projeto em execução, acesse o *project*:
  - Retire a pasta do arquivo compactado (caso esteja)
  - No Spyder acesse: Projetos > Abrir Projeto > Selecione a pasta
  - Os arquivos contidos no *project* aparecerão no ambiente

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pacotes

- Alguns pacotes que utilizaremos:
  - Pandas: manipulação e análise de dados
  - Numpy: funções matemáticas e dados
  - Matplotlib: visualização de dados em gráficos
  - Seaborn: também é um pacote gráfico
  - Plotly: gráficos interativos

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Documentação

- Leituras e documentação para consulta
  - https://pandas.pydata.org/docs/index.html
  - https://numpy.org/doc/stable/
  - https://matplotlib.org/
  - https://seaborn.pydata.org/
  - https://plotly.com/python/

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Sugestões de Leituras/Referências

- BRUCE, P.; BRUCE, A.; GEDECK, P. Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python. 2 ed. O'Reilly Media, 2020.

- FÁVERO, L. P.; BELFIORE, P. Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. LTC, 2024.

- GRUS, J. Data Science do zero: noções fundamentais com Python. 2 ed. Alta Books, 2021.

- McKINNEY, W. Python Para Análise de Dados: Tratamento de Dados com Pandas, NumPy e IPython. Novatec Editora, 2018.

- VANDERPLAS, J. Python Data Science Handbook: Essential Tools for Working with Data. 2 ed. O'Reilly Media, 2023.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Wilson Tarantin Jr. | linkedin.com/in/wilson-tarantin-junior-359476190

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ