MBA EM

DATA SCIENCE

Text Mining, Sentiment Analysis e NLP III

Prof. Guilherme Bezerra de Lima

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonça 394.876.988-50

MBA USP ESALQ



DESAFIO

- POSITIVAS
- NEGATIVAS

Natan Manoel Mendonca 394.876.838-50

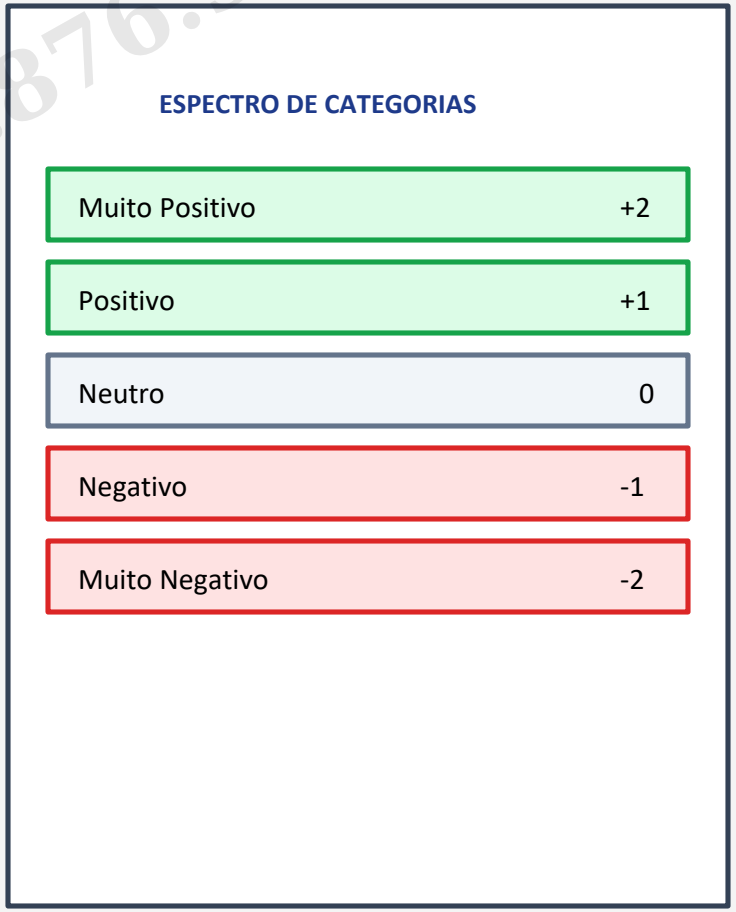
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Processamento de Linguagem Natural (PLN) e Aprendizado de Máquina (AM)

Extrair emoções, atitudes e opiniões em texto.

Qualidade do dado > ***Qualquer algoritmo de ponta***.

AS **não é uma técnica única**, mas um processo.



Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

AS COMO PIPELINE DE DECISÕES TÉCNICAS



GRANULARIDADE

Definição do nível de análise: documento, frase ou aspecto.



ALGORITMO

Escolha entre léxico, ML clássico ou Deep Learning.



MÉTRICA

Validação técnica dos dados.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

GRANULARIDADE: DOCUMENTO, FRASE E ASPECTO



NÍVEL DE DOCUMENTO

Classifica o texto inteiro como uma única opinião.
Útil para reviews globais, mas pouco detalhado para análises complexas.



NÍVEL DE FRASE

Classifica cada sentença individualmente.
Primeiro identifica se é subjetiva ou objetiva, depois define a polaridade.



NÍVEL DE ASPECTO

O nível mais refinado.
Foca em características específicas e essenciais para um feedback detalhado.

ESTRATÉGIA: A escolha da granularidade deve ser feita ANTES de definir a arquitetura do modelo.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Aspect-Based Sentiment Analysis (ABSA)

Em vez de atribuir um único rótulo geral a um texto inteiro, identifica os diferentes aspectos (características, entidades ou tópicos específicos)

Natan Manoel Mendonca 394.876.908-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Exemplo 1 - Aspect-Based Sentiment Analysis (ABSA)

Em vez de atribuir um único rótulo geral a um texto inteiro, ***identifica os diferentes aspectos*** (características, entidades ou tópicos específicos)

O atendimento foi excelente, mas a comida demorou muito para chegar.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Exemplo 2 - Aspect-Based Sentiment Analysis (ABSA)

É uma abordagem de análise de sentimentos que, em vez de atribuir um único rótulo geral a um texto inteiro, ***identifica os diferentes aspectos*** (características, entidades ou tópicos específicos)

O quarto do hotel estava limpo e confortável, mas o Wi-Fi era extremamente lento.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Exemplo 2 - Aspect-Based Sentiment Analysis (ABSA)

EXEMPLO COLAB

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

DO DADO BRUTO À CLASSIFICAÇÃO

COLETA **01**

Obtenção de dados brutos via APIs (Twitter/X, reviews, logs) ou web scraping.

PRÉ-PROC **02**

Limpeza: tokenização, lematização, stemming e remoção de stopwords.

EXTRAÇÃO **03**

Transformação de texto em vetores numéricos (TF-IDF, Word Embeddings).

CLASSIF **04**

Aplicação do modelo (ML ou DL) para rotular a polaridade do sentimento.

Natan Manoel Mendonça 394.876.988-50

CRÍTICO: O pré-processamento impacta diretamente na acurácia final

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

O QUE AINDA PRECISA SER RESOLVIDO

DESAFIOS ATUAIS

1. Sarcasmo, ironia e emojis complexos.
2. Dependência de dados do Twitter/X.
3. Polaridade intermediária e ambiguidade.
4. Viés linguístico.



ESSAS LACUNAS SÃO ONDE O DATA SCIENTIST AGREGA MAIOR VALOR DIFERENCIAL HOJE.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Previsões da Análise de Sentimento no Futuro

Desafios além do texto, integrando imagens, áudio.

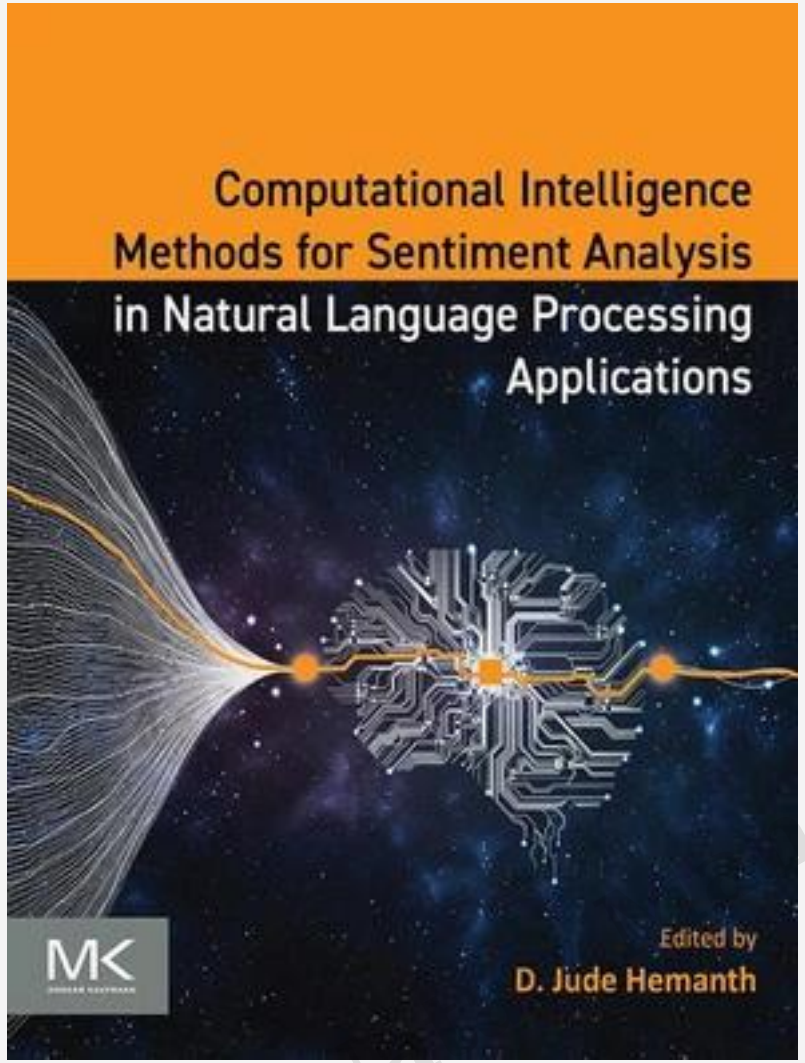
Interpretar emoções humanas de forma precisa exigirá modelos cada vez mais inteligentes, capazes de compreender *múltiplas fontes de informação* e lidar com ambiguidades e diversidade cultural.





Natan Marinho Mendonca 504.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



1.8 Future direction

SA is not a simple process to do manually. The ability to recognize the feelings of the text or find the hidden emotions behind the text is very important. DL is the current generation of technology, and this can be used for various tasks of SA. There has been very little work done in this technique with respect to SA; in the future, more work needs to be done on word embeddings, i.e., how sentiment information can be incorporated into its embeddings. The majority of SA research has relied solely on textual modalities. Multimodal information fusion is a core component of multimodal SA. The selection of reliable fusion remains a significant future work. Fine-grained annotation can also open the door to novel multimodal fusion approaches because fine-grained annotations should better guide multimodal fusion methods. Thus, apart from incorporating star rating and user rating in the form of text, one can opt for an exhaustive rating of products with the help of multimodal data, where the reviews of a product can be incorporated using various modalities such as voice, image, or emoticon.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Prof. Guilherme Bezerra de Lima | https://www.linkedin.com/in/guilherme-lima-developer/

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ