MBA EM

DATA SCIENCE

Text Mining, Sentiment Analysis e NLP I

Guilherme Bezerra de Lima

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ

A responsabilidade pela idoneidade, originalidade
e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ

Text Mining

Natan Manoel Medonca 394.876.988-50

Professor Guilherme Lima

Minhas redes

guilhermelimadev

guilherme-lima-developer

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

01

Comunicação e uma linguagem

Natan Manoel Mendonca 394.876.988-50

Fundamental para o text mining

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Uma língua não é apenas um conjunto de palavras. Ela representa a **cultura**, as **tradições** e a **união de um povo**.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Carrega a **história** e a **identidade** de uma comunidade, tornando-se parte essencial do que ela é.

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Contextualizar

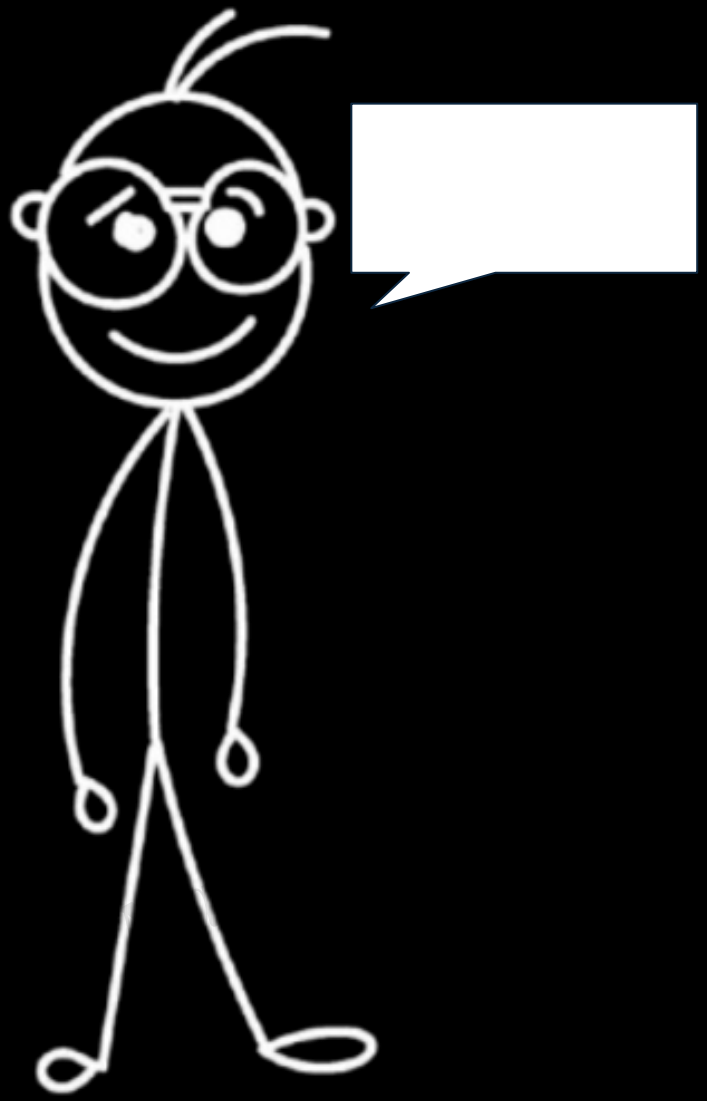
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Valério

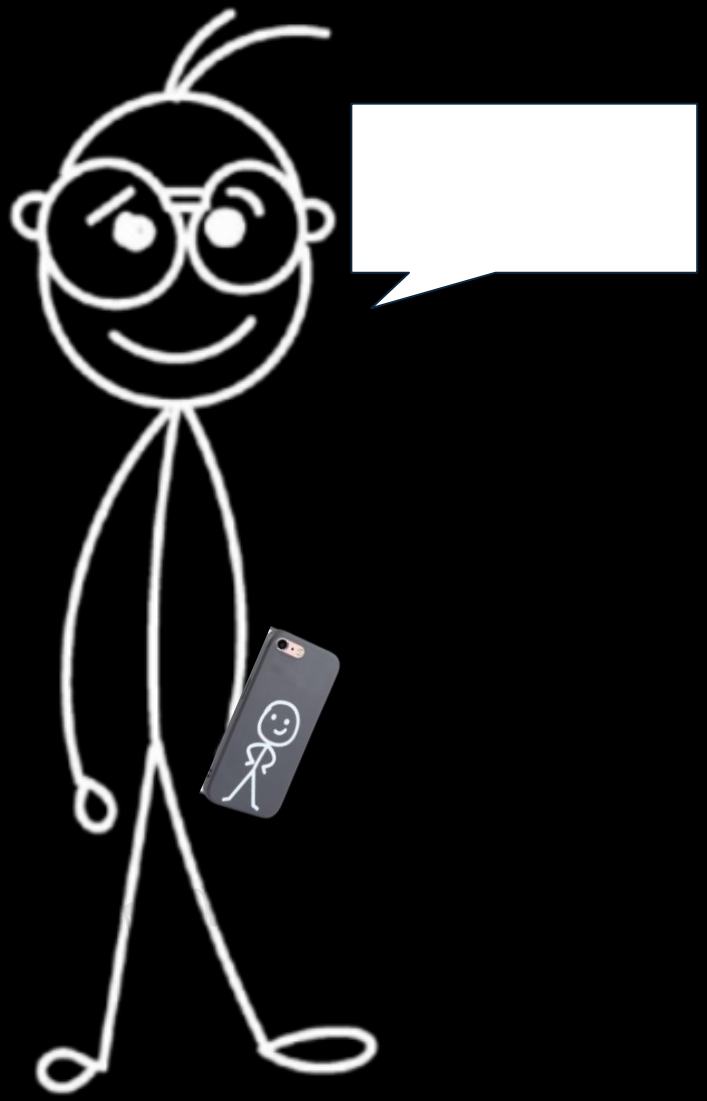
Um cientista de dados em uma empresa

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



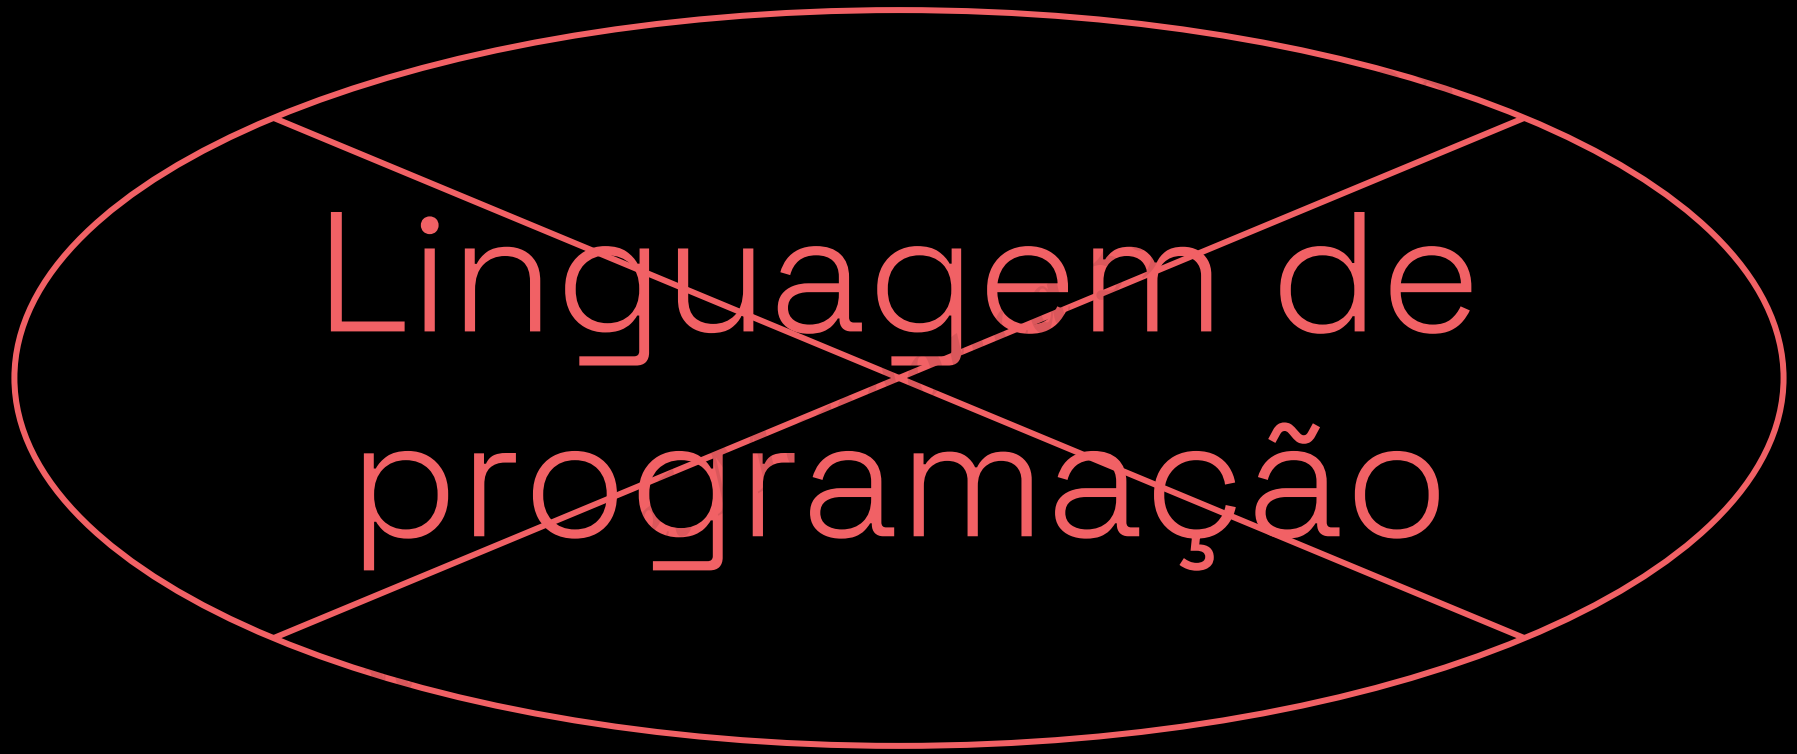


A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98





A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Linguagem natural

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Binário



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Algumas áreas da ciência da computação…

NPL	Análise de Sentimento	LLMs	Text Mining
Processamento de Linguagem Natural	Identificação de emoções textuais	Redes neurais para texto	Extração de informações textuais

Natan Mantovani Mendo… 088-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Algumas áreas da ciência da computação...

NLP – Processa e entende a linguagem humana por meio de algoritmos computacionais.

Análise de Sentimento – Detecta emoções e opiniões em textos, classificando como positivas, negativas ou neutras.

LLMs – Modelos de IA treinados em grandes volumes de texto para gerar e compreender linguagem natural.

Text Mining – Extrai padrões, insights e informações úteis a partir de grandes quantidades de texto.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Text Mining

Extrair informações valiosas de textos

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Sobrecarga de informações

Vivemos em uma era de sobrecarga de informações.



Natan Manoel Mendonca 594.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

A **maior parte dos dados** gerados está em formato **textual**, seja em redes sociais, documentos empresariais ou artigos científicos.



Natan Manfel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Mas como extrair conhecimento desse volume gigantesco de textos?



Text Mining surge como a solução para extrair *valor* e *conhecimento* desses dados.

Processo de descobrir padrões, informações úteis e conhecimento a partir de grandes volumes de dados textuais.



Natan Manoel Menezes 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Garimpar ouro em meio a um **rio de texto**.

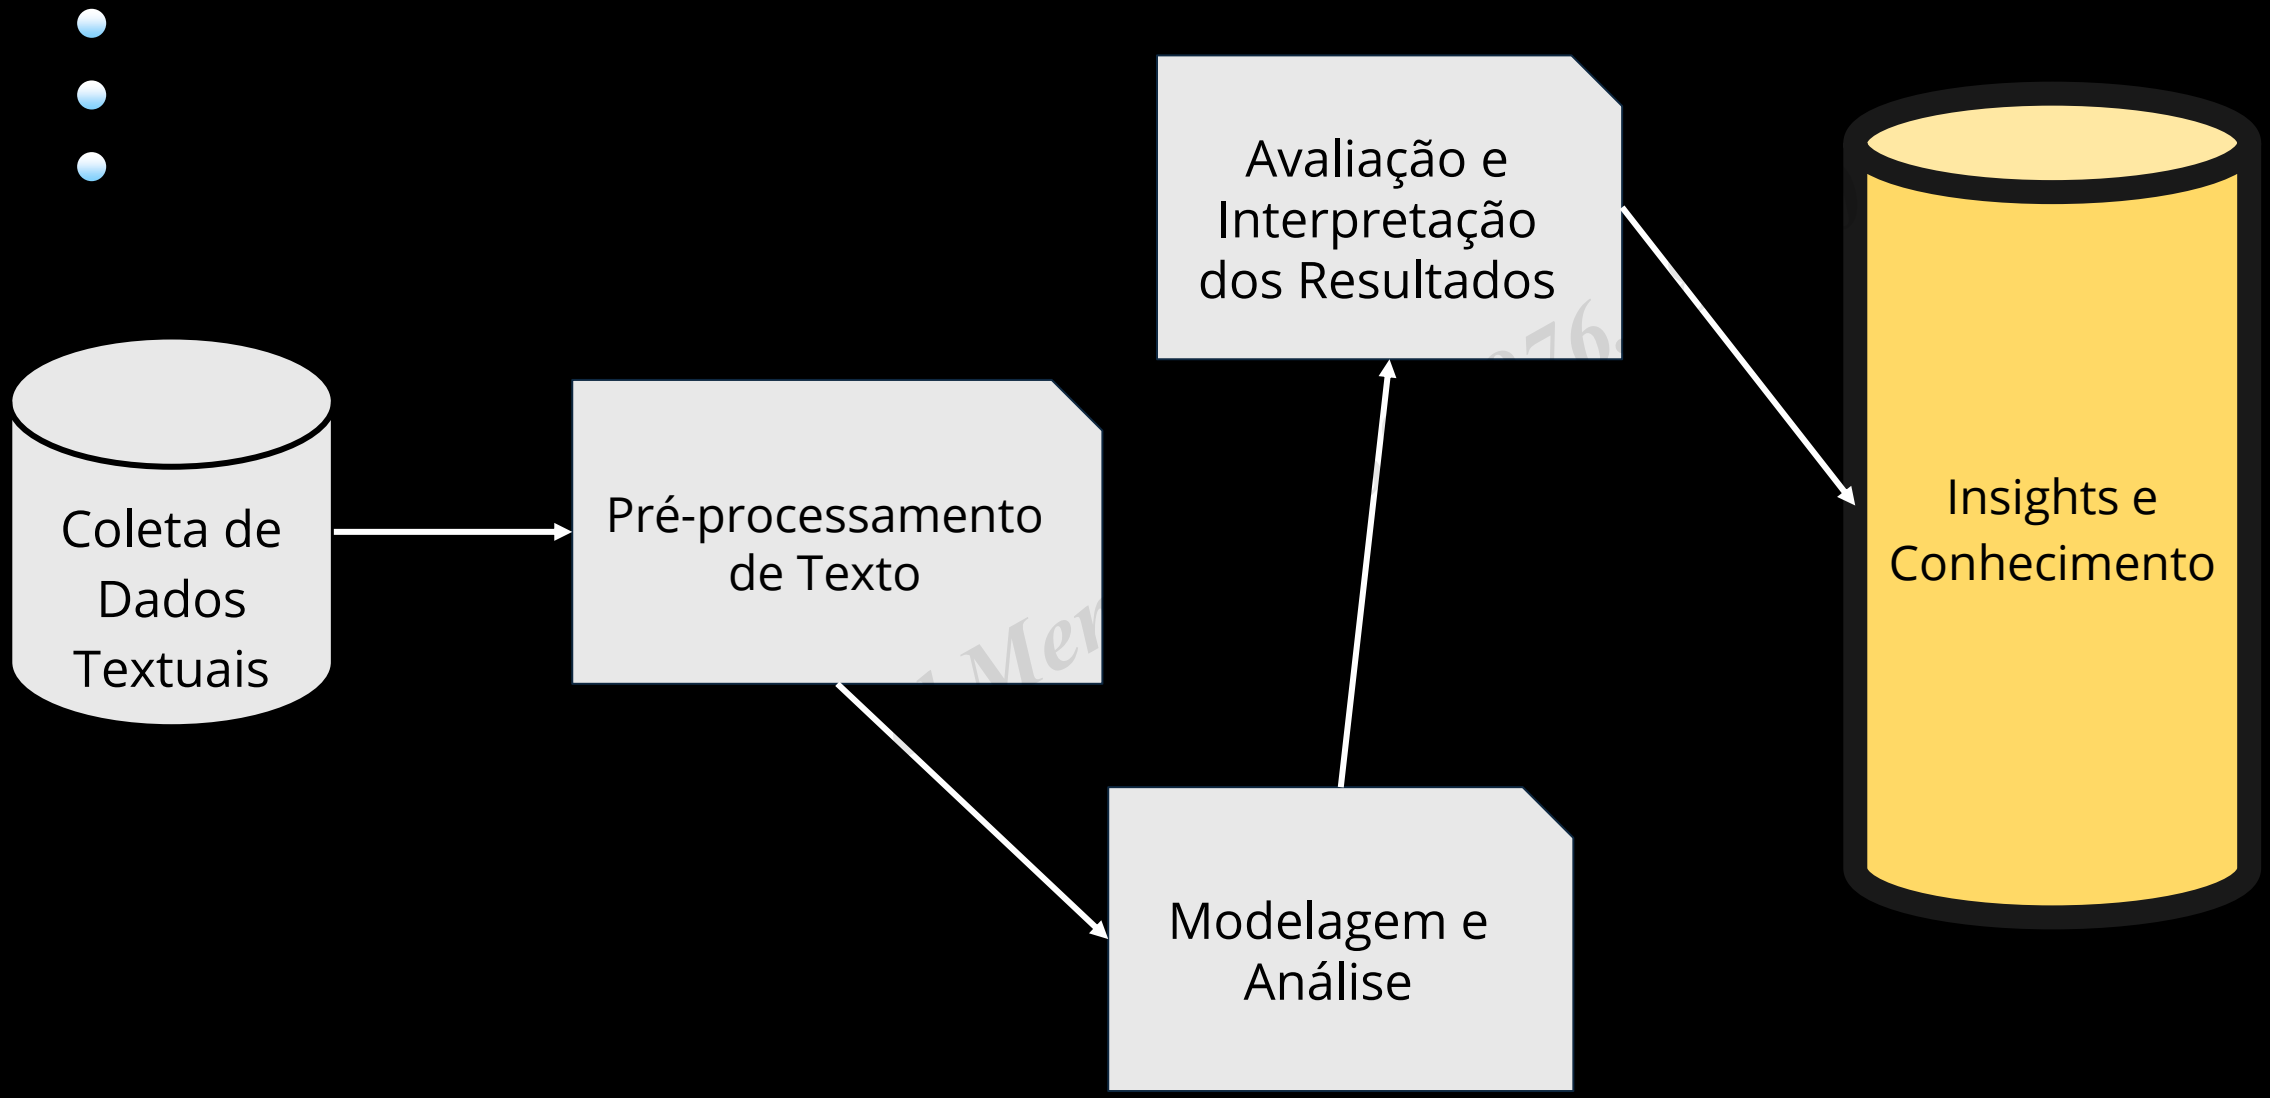
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

→ Onde o Text Mining Brilha?

1 Análise de Sentimentos	4 Classificação de Textos
2 Extração de Informação	5 Modelagem de Tópicos
3 Sumarização de Textos	6 Detecção de Fraudes e Spam

Natan Manoel Mendonça 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Lowercasing

Padronizar o texto.

Texto original: "Eu amo DS!"
Após lowercasing: ["eu", "amo", "ds", "!"]

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Lowercasing

Padronizar o texto.

Texto original: "Eu amo DS!"
Após lowercasing: ["eu", "amo", "ds", "!"]

Remoção de Pontuação

Eliminar sinais de pontuação.

Texto original: "Eu amo DS!"
Após remoção: ["eu", "amo", "ds"]

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Tokenização

Dividir um texto em unidades menores

Texto original: "Eu amo MBA!"
Após tokenização: ["Eu", "amo", "MBA", "!"]

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Tokenização

Dividir um texto em unidades menores

Texto original: "Eu amo DS!"
Após tokenização: ["Eu", "amo", "DS", "!"]

Stopwords

palavras comuns que não agregam muito significado ao conteúdo

Exemplo: "a", "o", "e", "de", "que", "em"

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Stemming

Reduzir palavras à sua raiz

Texto original: "Eu amo DS!"
Após lowercasing: Eu am DS

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pré-processamento de Texto

Stemming

Reduzir palavras à sua raiz

Texto original: "Eu amo DS!"
Após lowercasing: ["eu", "amo", "ds", "!"]

Lemmatization

Reduz a palavra à sua forma canônica

"Amasse" → Stemming: "am"
Lemmatization: "amar"

Natan Manoel Mendonca 394.876.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Cada etapa ajuda a preparar o texto para análise!

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Texto Bruto (Original)

”Eu estou aprendendo processamento de linguagem natural!”
”Os algoritmos de machine learning são incríveis.”
”O cachorro correu rapidamente pelo parque.”
”Hoje eu comprei um livro sobre NLP.”
”As árvores estão balançando com o vento forte.”

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Lowercasing

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Lowercasing

”eu estou aprendendo processamento de linguagem natural!”
”os algoritmos de machine learning são incríveis.”
”o cachorro correu rapidamente pelo parque.”
”hoje eu comprei um livro sobre nlp.”
”as árvores estão balançando com o vento forte.”

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Remoção de Pontuação

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Remoção de Pontuação

”eu estou aprendendo processamento de linguagem natural”
”os algoritmos de machine learning sao incriveis”
”o cachorro correu rapidamente pelo parque”
”hoje eu comprei um livro sobre nlp”
”as arvores estao balancando com o vento forte”

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tokenization

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tokenization

[eu, estou, aprendendo, processamento, de, linguagem, natural]

[os, algoritmos, de, machine, learning, sao, incriveis]

[o, cachorro, correu, rapidamente, pelo, parque]

[hoje, eu, comprei, um, livro, sobre, nlp]

[as, arvores, estao, balancando, com, o, vento, forte]

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Stopwords

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Stopwords

aprendendo processamento linguagem natural

algoritmos machine learning incriveis

cachorro correu rapidamente parque

comprei livro nlp

arvores balancando vento forte

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Stemming

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Stemming

aprend, process, linguag, natur

algoritm, machin, learn, incriv

cachorr, corr, rapid, parqu

compr, livr, nlp

arvor, balanc, vent, fort

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Lemmatization

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Lemmatization

aprender, processamento, linguagem, natural

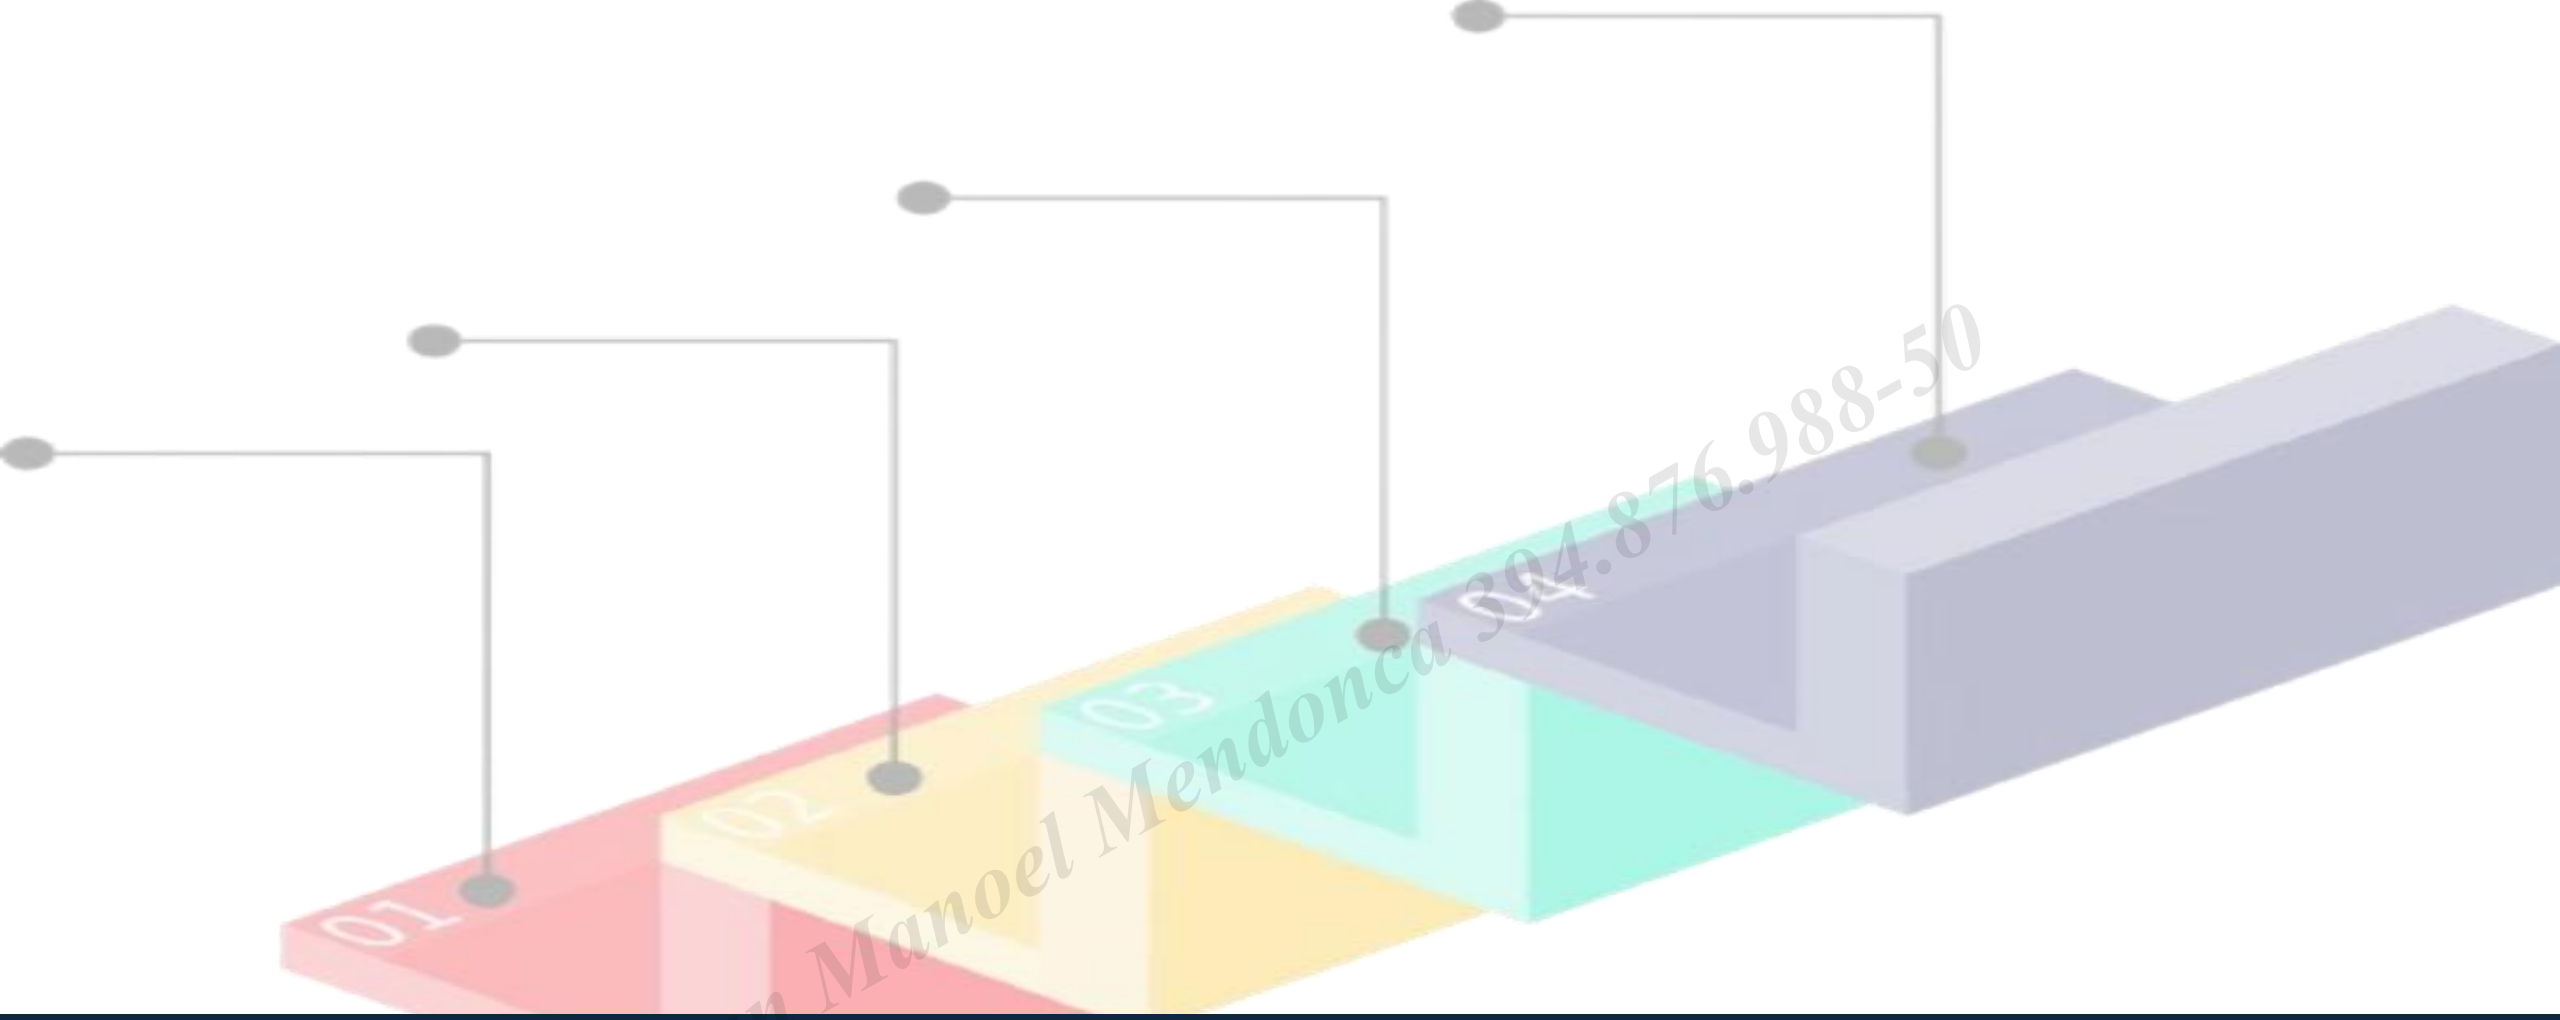
algoritmo, machine, learning, incrível

cachorro, correr, rápido, parque

comprar, livro, nlp

árvore, balançar, vento, forte

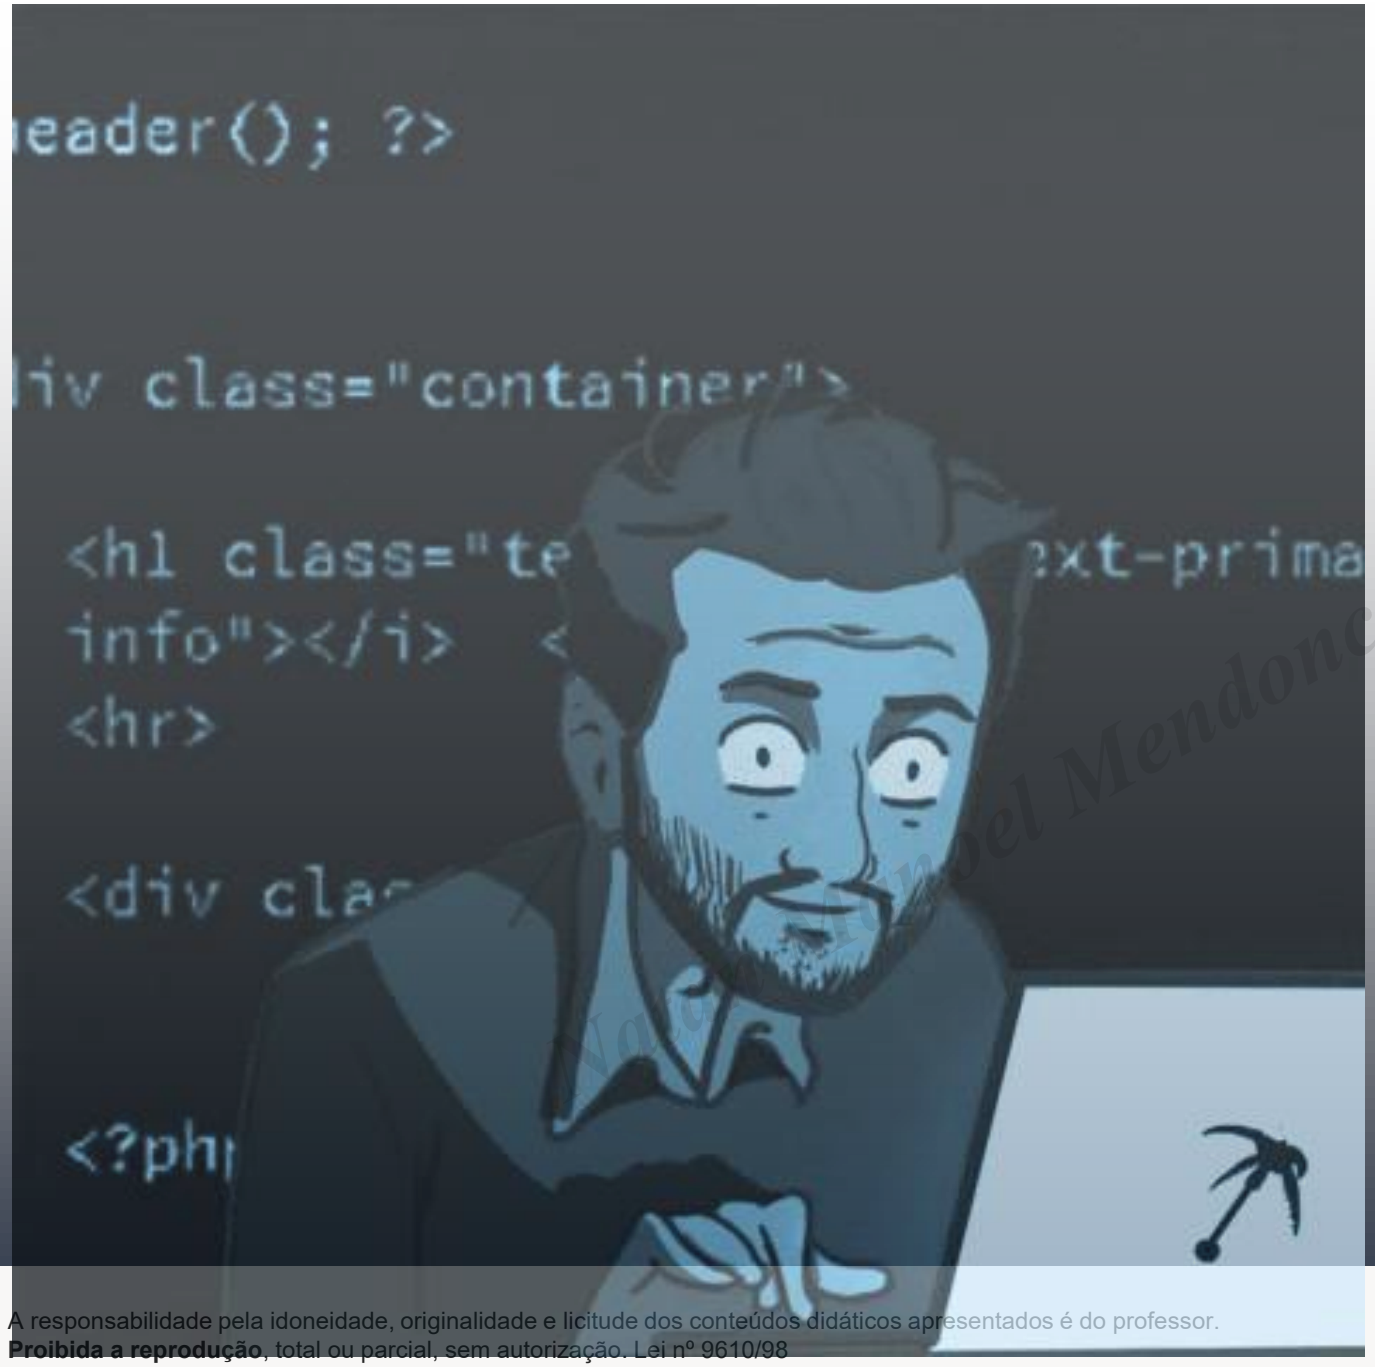
A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Natan Manoel Mendonca 304.876.988-50

Cada etapa melhora a preparação dos dados para análise.

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



Vamos **processar** um **texto**

Nadia Emmel Mendonca 394.871.988-50

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Obrigado!

Guilherme Bezerra de Lima| linkedin.com/in/guilherme-lima-developer

Natan Manoel Mendonca 394.876.988-50

MBA USP ESALQ